

人工智能:数学与
工程视角

2026年3月

第一章

学习作为一种功能近似

1.1 学习问题和数据

现代人工智能主要关注的是如何从数据中学习。从宏观层面来说,我们被赋予对世界的观察数据,并被要求构建一个能够进行预测、决策或生成新数据的系统。

我们将其形式化如下。令

$$X \subseteq \mathbb{R}^d$$

表示输入空间和

是

输出空间。数据集是样本的集合。

$$D = \{(x_i, y_i)\}_{i=1}^n, x_i \in X, y_i \in Y。$$

学习的目标是构建一个函数

$$f: X \rightarrow Y$$

它反映了投入和产出之间的关系。

例如。

- 在回归分析中, $Y \subseteq \mathbb{R}$ 。
- 在分类中, $Y = \{1, \dots, K\}$ 。
- 在生成建模中, $Y = X$ 符号。 , 目标是对数据分布进行建模

虽然这个公式看起来很简单,但它掩盖了机器学习的核心挑战:我们只能观察到有限数量的样本,但我们却在寻找一个在未见过的数据上表现良好的函数。

1.2 函数、模型和表示

学习算法并非搜索所有可能的函数,而是从模型类 (或假设空间)中选择一个函数。

$$H = \{f_\theta : \theta \in \Theta\}.$$

这里:

- θ 表示参数,
- Θ 是参数空间,
- f_θ 是由 θ 决定的函数。

示例 (线性模型)。

$$f_\theta(x) = w \cdot x + b, \theta = (w, b).$$

示例 (神经网络)。

$$f_\theta(x) = W_L \sigma(W_{L-1} \sigma(\cdots \sigma(W_1 x))),$$

其中 σ 为非线性激活函数。

H 的选择体现了对问题结构的假设。
这被称为归纳偏置,我们将在后面的章节中再次讨论这个概念。

表示方式很重要。两个模型可能都表示同一类函数,但由于以下原因,它们在实践中的表现却截然不同:

- 优化特性,
- 数值稳定性,
- 泛化行为。

因此,模型不仅仅是一个函数类,它也是一个计算和统计对象。

1.3 近似法作为核心范式

机器学习本质上是一个近似问题。

我们假设存在一个未知函数

$$f : X \rightarrow Y$$

管理数据的规则:

$$y = f(x) + \text{噪声}.$$

1.4. 回归和分类示例

5

由于 f 未知, 我们寻求一个近似值 f_θ , 使得

$$f_\theta \approx f.$$

为了量化这种近似, 我们引入了一个损失函数。

$$\ell: Y \times Y \rightarrow \mathbb{R}.$$

f 的质量是通过风险来衡量的。

$$R(f) = \mathbb{E}_{(x,y)} \ell(f(x), y).$$

由于数据分布未知, 我们转而尽量降低经验风险。

$$R_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i).$$

学习问题。

$$\min_{\theta \in \Theta} R_n(f_\theta).$$

这个简单的优化问题是几乎所有现代机器学习算法的基础。

1.4 回归和分类示例

tion

1.4.1 回归

在回归分析中, 输出空间为 $Y = \mathbb{R}$ 。

常用的损失函数是平方误差:

$$\ell(f(x), y) = (f(x) - y)^2.$$

经验风险变为

$$R_n(f) = \frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2.$$

解释。

- 对较大偏差给予严厉惩罚
- 可得到线性模型的解析可解

1.4.2 分类

在分类中, $Y = \{1, \dots, K\}$ 。

模型通常不会直接预测标签,而是输出分数或概率:

$$f(x) \in \mathbb{R}^K。$$

常见的损失是交叉熵损失:

$$\ell(f(x), y) = -\log p_\theta(y | x)。$$

解释。

- 鼓励正确分类概率
- 与最大似然估计密切相关

1.5 从近似到概括

由此产生了一个核心问题:最小化经验风险并不能保证在新数据上取得良好的性能。

关键问题:为什么一个能够很好地拟合训练数据的函数,在未见过的数据上也应该表现良好?

这个问题引出了以下方面的研究:

- 概括,
- 模型复杂度,
- 正则化,
- 感应偏置。

这些思想构成了机器学习的理论基础,并将……
本书中逐步展开。

1.6 统一的视角

我们总结一下学习过程:

1. 选择 H 型模型。
2. 定义损失函数 ℓ
3. 解决优化问题
4. 根据未见过的数据进行评估

1.7 展望

7

三个相互作用的组成部分：

- 近似（模型表达能力）
- 优化（找到合适参数的能力）
- 泛化能力（在新数据上的表现）

现代人工智能,尤其是深度学习,之所以成功,是因为它……
大规模地平衡这三个方面。

1.7 Outlook

本章介绍了本书的核心观点:在不确定性下,学习是函数逼近的过程。

下一章,我们将构建学习的概率框架。
将经验风险最小化与统计推断联系起来。

指导原则。在本文中,我们将重点强调:

- 基于数学的直觉,
- 将模型视为结构化的近似值,
- 以及作为这些思想的计算实现的算法。

第二章

概率视角

学习

2.1 随机性和数据生成

在第一章中,我们将学习定义为利用数据逼近未知函数的问题。现在,我们将通过引入不确定性来完善这一观点。

数据并非确定性的。即使存在真实关系,观测结果也会受到噪声、变异性和信息不完整等因素的影响。一种自然的建模方法是使用概率。

我们假设数据是根据未知的概率分布生成的。

P 在 $X \times Y$ 上。

数据集

$$D = \{(x_i, y_i)\}_{i=1}^n$$

被建模为从 P 中抽取的独立样本:

$$(x_i, y_i) \sim P.$$

解释。

- 分布 P 捕捉了数据生成过程的所有属性。
- 该数据集只是对该过程的有限、有噪声的观察。

这种观点改变了学习的目标:我们不再是拟合数据集,而是学习底层分布的属性。

2.2 条件结构与预测

P 的一种有用分解方式是

$$P(x, y) = P(y | x)P(x)。$$

关键对象:条件分布 $P(y | x)$ 。

预测可以理解为对这种条件关系的估计。

示例 (回归)。

$$y = f(x) + \varepsilon, E[\varepsilon | x] = 0。$$

然后

$$f(x) = E[y | x]。$$

示例 (分类)。

$$P(y = k | x), k = 1, \dots, K。$$

预测相当于选择最有可能的类别:

$$= \arg \max_k P(y = k | x)。$$

因此,许多学习问题可以简化为估计条件期望或概率。

2.3 贝叶斯定理与推断

贝叶斯定理揭示了条件概率之间的基本关系:

$$P(y | x) = \frac{P(x | y)P(y)}{P(x)}。$$

解释。

- $P(y)$ 是关于 y 的先验信念,
- $P(x | y)$ 表示在给定 y 的情况下观察到 x 的可能性, · $P(y | x)$ 表示在观察到 x 之后的后验信念。

在实践中,贝叶斯定理提出了两种互补的方法:

- 判别式建模:直接对 $P(y | x)$ 进行建模
- 生成式建模:模型 $P(x | y)$ 和 $P(y)$

工程视角。

- 判别式模型通常能产生更好的预测性能。
- 生成模型提供更丰富的结构,并且可以生成数据。

2.4 损失函数作为统计目标

在第一章中,我们介绍了损失函数作为误差的度量。从概率论的角度来看,损失函数自然而然地源于统计学原理。

考虑一个模型 f_θ ,它定义了一个条件分布 $p_\theta(y | x)$ 。

负对数似然值。

$$\ell(f_\theta(x), y) = -\log p_\theta(y | x)。$$

最大限度降低经验风险

$$\frac{1}{n} \sum_{i=1}^n -\log p_\theta(y_i | x_i)$$

等价于最大化似然函数:

$$\max_{\theta} \sum_{i=1}^n \log p_\theta(y_i | x_i)。$$

例如。

- 高斯噪声 $\Rightarrow$ 平方损失
- 分类分布 $\Rightarrow$ 交叉熵损失

因此,许多常用的损失函数并非任意的 它们与实际应用相关。
对数据的概率假设做出响应。

2.5 风险与预期损失

学习的真正目标是最大限度地减少预期损失 (或风险)。

$$R(f) = E_{(x,y) \sim P} \ell(f(x), y)。$$

理想的问题。

$$\min_{f \in H} R(f)$$

然而, P 是未知的,因此无法精确计算 $R(f)$ 。

相反,我们使用经验风险来近似计算:

$$R_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i)。$$

经验风险最小化 (ERM)。

$$\min_{f \in H} R_n(f)。$$

ERM是大多数机器学习算法的核心原理。

2.6 近似、估计和优化 tion

概率模型揭示了三种不同的误差来源：

1. 近似误差 模型类 H 可能不包含真实函数。
2. 估计误差 我们仅观察到来自 P 的有限样本。
3. 优化误差 我们可能无法找到经验风险的精确最小值。

洞察。现代机器学习系统之所以有效,是因为它们能够平衡这三种错误。

2.7 条件期望作为最优预处理 预测器

一项关键的理论成果为理解最优预测器的结构提供了重要线索。

命题。对于平方损失,使风险最小化的函数是

$$f^*(x) = E[y | x].$$

解释。

- 最优预测是条件均值。
- 学习的目标是逼近这种条件期望。

这一结果解释了为什么回归模型即使数据存在噪声,也仍然专注于估计平均值。

2.8 从概率到算法

虽然概率框架提供了清晰的思路,但实际算法必须在约束条件下运行：

- 数据有限，
- 高维输入，
- 计算能力限制。

因此,模型的设计不仅要保证统计学上的可靠性,还要保证：

- 计算效率高，

2.9. 统一的视角

13

- 数值稳定，
- 可扩展至大型数据集。

概率与计算之间的这种相互作用是现代机器学习的一个决定性特征。

2.9 统一的视角

现在我们可以完善学习流程了：

1. 假设数据来自未知分布 P 。
2. 选择模型 $p_{\theta}(y | x)$ 或函数 f_{θ}
3. 定义一种基于概率原理的损失
4. 最大限度降低经验风险

关键点 :学习是指从有限样本中近似条件分布的过程。

2.10 Outlook

本章介绍了学习的概率基础：

- 数据作为来自某个分布的样本，
- 预测即估计条件结构，
- 损失函数作为统计目标。

下一章,我们将研究假设空间和归纳偏置,它们决定了可以学习哪些类型的函数以及如何实现泛化。

指导原则 :概率提供了不确定性的语言,但成功的学习需要将其与结构、计算和近似相结合。

第三章

假设空间和归纳偏置

3.1 功能类和模型族

在前几章中,我们将学习问题表述为选择一个能够最小化经验风险的函数的问题。然而,我们尚未解决一个关键问题:

我们可以选择哪些功能?

这个问题可以通过指定假设空间 (或模型类) 来回答。

$$H = \{f_\theta : \theta \in \Theta\}.$$

假设空间定义了学习过程中候选函数的集合
算法可以表示。

函数类示例。

· 线性模型:

$$f(x) = w \cdot x + b.$$

· 多项式模型:

$$f(x) = \sum_{|\alpha| \leq d} c_\alpha x^\alpha.$$

· 神经网络:

$$f_\theta(x) = W_L \sigma(W_{L-1} \sigma(\dots \sigma(W_1 x))).$$

H 的每一个选择都对投入和产出之间的关系提出了结构性假设。

表达能力。如果一个假设空间能够逼近多种函数,则称该假设空间具有表达能力。

例如,具有足够宽度的神经网络可以逼近紧域上的任何连续函数(通用逼近性质)。

然而,表达能力本身并不能决定模型的性能。一个表达能力很强的模型可能完美拟合训练数据,但却无法泛化。

因此, H 的选择不仅仅是近似的问题,而是要在表达性、稳定性和可学习性之间取得平衡的问题。

3.2 归纳偏见和先验结构

假设空间引入了一种对某些函数相对于其他函数的隐性偏好。这种偏好被称为归纳偏差。

定义(非正式):归纳偏差是指允许学习算法超越观测数据进行泛化的一组假设。

如果没有归纳偏差,学习是不可能的:无数个函数可以对训练数据进行插值,但只有一些函数能够很好地泛化。

归纳偏见的来源。

- 模型类别:线性模型倾向于线性关系。
- 架构:卷积网络倾向于局部性和横向平移。
方差。
- 正则化:惩罚较大的参数有利于更简单的函数。
- 优化:基于梯度的方法可能更倾向于某些解。
众多例子之一。

与先验知识的联系。归纳偏差可以被视为对问题相关先验知识的编码:

- 平滑度,
- 稀疏性,
- 组成结构,
- 不变性。

工程视角。成功的模型并非中立的 它们是经过精心设计,旨在反映数据中的结构。

例如:

- 卷积神经网络利用图像中的空间局部性,

3.3. 偏差-方差权衡（直觉）

17

- Transformer 利用序列中元素之间的关系。

因此,归纳偏见不是一种限制,而是学习的必要组成部分。

3.3 偏差-方差权衡（直觉）

现在我们来研究假设空间的选择如何影响泛化。

考虑点 x 处的预期预测误差：

$$E (f(x) - y)^2。$$

从概念上讲,这种错误可以分解为三个组成部分：

- 偏差 :由于系统近似而产生的误差
- 方差 :由于对数据的敏感性而产生的误差
- 噪声 :数据固有的随机性

高偏差模型。

- 简单假设空间（例如,线性模型）
- 可能对数据拟合不足
- 方差低但系统误差大

高方差模型。

- 高表达力模型（例如,深度网络）
- 可以紧密拟合训练数据
- 对噪声和波动敏感

权衡取舍。增加模型复杂度通常会导致：

- 减少偏见，
- 增加方差。

洞察力。良好的概括需要平衡这两种影响。

备注 :在现代深度学习中,这种经典观点得到了改进 :由于隐式正则化和优化效应,高度过参数化的模型仍然可以具有良好的泛化能力。

3.4 选择表示法

学习系统的性能不仅取决于函数类,还取决于输入的表达方式。

定义:表示是一种变换。

$$\phi: X \rightarrow Z$$

将原始输入映射到特征空间。

然后,模型对 $\phi(x)$ 而不是 x 进行运算:

$$f(x) = g(\phi(x))。$$

例子。

- 多项式特征: $\phi(x) = (x, x^2, \dots)$
- 神经网络中的学习特征

核心思想:应用于丰富表示的简单模型可能比应用于原始输入的复杂模型更有效。

特征工程与表征学习。

- 传统方法依赖于手动设计的特征
- 深度学习自动学习表征

组合式表示。深度网络以分层方式构建表示:

- 下层捕捉局部模式,
- 较高级捕捉抽象结构。

几何视角。表示法会转换数据的几何形状,使得:

- 类变得可分离,
- 结构变得更简单,
- 学习变得更容易。

因此,选择一种表示方法等价于选择一个坐标系。
这样,学习问题就变得容易解决了。

3.5 统一的视角

现在我们可以细化学习问题了：

1. 选择一个表示
2. 选择假设空间 H
3. 通过结构和正则化施加归纳偏置
4. 优化经验风险

学习的关键要素：

- 表示形式（数据编码方式）
- 函数类（可以表达什么）
- 感应偏置（哪种方式更可取）

现代深度学习系统将这些要素统一起来：它们学习表征-行为和功能同时发生，受到隐性和显性偏见的引导。

3.6 展望

本章强调，学习不仅是拟合数据，而且是选择正确的函数和表示空间。

下一章，我们将学习视为一个优化问题进行研究，重点关注关于模型在实践中如何训练。

指导原则：概括并非仅仅源于数据，而是源于数据、模型结构和归纳偏差之间的相互作用。

第四章

学习即优化

4.1 学习的优化公式

在前几章中,我们将学习问题表述为最小化经验风险的问题。现在,我们将从优化的角度来审视这个问题。

回想一下,模型由 $\theta \in \Theta$ 参数化,而学习过程就是求解该参数。

$$\min_{\theta \in \Theta} R_n(\theta) \text{ 其中 } R_n(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\theta}(x_i), y_i)。$$

关键观察:学习过程简化为在高维参数空间上最小化一个函数。

这种公式统一了多种模型:

- 线性回归 $\rightarrow$ 凸二次优化
- 逻辑回归 $\rightarrow$ 凸优化
- 神经网络 $\rightarrow$ 高度非凸优化

目标结构。

- 各数据点的损失总和
- 通常平滑 (可微分)
- 高维且可能非凸

工程限制。精确最小化几乎不可能实现。因此,我们的目标是在有限的计算时间内找到足够好的参数。

因此,优化不仅仅是一种数学工具 它决定了哪些模型在实践中是可用的。

4.2 基于梯度的方法

大多数现代学习算法都依赖于基于梯度的优化。

梯度下降法。给定一个可微的目标函数 $L(\theta)$, 其更新规则为:

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t),$$

其中 $\eta > 0$ 为学习率。

解释。

- 梯度 $\nabla L(\theta)$ 指向增长最快方向
- 沿负梯度方向移动会降低损失。

几何视图。梯度下降法遵循损失函数曲面的局部几何形状, 向值较低的区域移动。

选择学习率。

- 太小 $\rightarrow$ 收敛速度慢
- 过大 $\rightarrow$ 不稳定或发散

例如 (二次损失函数)。对于凸二次函数, 在适当条件下, 梯度下降法会收敛到全局最小值。

局限性: 计算完整梯度需要对所有数据点求和:

$$\nabla L(\theta) = \frac{1}{n} \sum_{i=1}^n \nabla \ell(f_{\theta}(x_i), y_i)。$$

对于大型数据集, 这将导致计算成本很高。

4.3 随机优化

为了解决完整梯度计算成本过高的问题, 我们采用随机近似法。

随机梯度下降法 (SGD)。在每一步中, 采样一个数据点 (或小批量数据), 并计算近似梯度:

$$\theta_{t+1} = \theta_t - \eta \nabla \ell(f_{\theta}(x_{it}), y_{it})。$$

小批量新加坡元。

$$\theta_{t+1} = \theta_t - \eta \frac{1}{|B_t|} \sum_{i \in B_t} \nabla \ell(f_{\theta}(x_i), y_i)。$$

主要特性。

4.4. 损失景观的几何形状

23

- 每次迭代的计算成本更低
- 给优化过程引入噪声

洞察。随机梯度下降法中的噪声并非完全有害 它可以帮助摆脱局部最小值,提高泛化能力。

权衡。

- 小批量更新 → 更新噪音大但成本低
- 大批量更新 → 稳定但成本高昂

实用方法。

- 动量 :通过平滑更新来加速收敛
- 自适应方法 (例如 Adam) :根据参数调整学习率

随机优化是现代深度学习的基石。

4.4 损失景观的几何学

为了理解优化行为,考虑损失函数的几何形状是有用的。

损失景观。功能

$$L(\theta)$$

在参数空间上定义一个曲面。

关键点。

- 局部最小值: $\nabla L(\theta) = 0$, L 为局部最小值
- 鞍点: $\nabla L(\theta) = 0$, 但不为最小值

凸函数与非凸函数。

- 凸优化问题 :所有局部最小值都是全局最小值
- 非凸问题 :多个局部最小值和鞍点

神经网络会产生高度非凸的损失函数,但基于梯度的方法在实践中往往能够取得成功。

平坦的最小值与尖锐的最小值。

- 平坦最小值 :损失在解附近变化缓慢
- 急剧下降 :损失变化迅速

观察。随机梯度下降法 (SGD) 找到的解往往位于较为平坦的区域,这些区域是通常与更好的泛化能力相关。

高维效应。在高维空间中:

鞍点比局部最小值更常见

- 许多方向的曲率可能接近于零

几何直觉。优化可以被视为驾驭一个复杂的系统。

塑造景观的因素:

- 模型架构,
- 数据分发,
- 参数化。

4.5 优化和泛化

优化不仅仅是最小化训练损失 它还会影响泛化能力。

核心思想:即使训练误差相似,不同的优化算法也可能收敛到不同的解。

隐性偏差。基于梯度的方法在众多可能的最小化解中表现出对某些特定解的偏好。

例子。

- 在参数过多的线性模型中,梯度下降法通常能找到最小值。
规范解决方案

含义:优化是建模过程的一部分 它隐式地对学习到的函数进行正则化。

4.6 统一的视角

现在我们可以改进学习过程:

1. 基于数据和模型定义损失函数
2. 构建优化问题
3. 应用基于梯度的方法 (通常是随机方法)
4. 获得一个由目标函数和优化参数共同决定的解决方案。
纳米

4.7 展望

25

三个相互关联的方面：

- 目标（要最小化的因素）
- 算法（如何最小化）
- 几何形状（损失景观的结构）

现代机器学习之所以成功,不仅是因为定义了良好的目标,还因为高效的优化方法可以利用其结构。

4.7 展望

本章介绍了优化作为学习的核心组成部分：

- 将学习视为最大限度降低经验风险，
- 以基于梯度的方法作为主要工具，
- 随机性既是必要条件也是优势。

在下一章中,我们将更仔细地研究泛化,探讨一个根本问题:为什么拟合数据良好的模型在未见过的例子上仍然能够表现良好。

指导原则:学习不仅在于我们优化什么,还在于我们如何优化。

第五章

概括和 过拟合

5.1 训练和测试表现

在前几章中,我们将学习定义为最小化经验风险,并研究了优化算法如何找到解决方案。然而,一个核心问题仍然存在:

为什么一个能够很好地拟合训练数据的模型,在未见过的数据上也能表现良好?

为了解决这个问题,我们将绩效分为两种类型。

训练误差。

$$R_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i)。$$

测试误差 (泛化误差)。

$$R(f) = E_{(x,y)} \ell(f(x), y)。$$

关键区别。

- 训练误差度量与观测数据相符
- 测试误差衡量新数据的性能

如果模型的训练误差接近其测试误差,则该模型具有良好的泛化能力。

概括性差距。

$$R(f) - R_n(f)。$$

洞察 :仅仅最小化训练误差是不够的。学习的目标是 minimized 测试误差,而测试误差是无法直接观察的。

实用方法。我们使用与训练数据分离的验证集来近似评估测试性能。

5.2 过拟合和欠拟合

训练误差和测试误差之间的关系会导致两种基本失效模式。

尺码不合适。

模型过于简单,无法捕捉数据的结构。

- 训练误差高
- 测试误差高

过拟合。

模型与训练数据 (包括噪声)拟合得过于紧密。

- 训练误差极低
- 测试误差高

举例来说,一个高度灵活的模型可以对所有训练点进行插值,但在训练点之间表现却可能不稳定。

权衡取舍。随着模型复杂性的增加:

- 训练误差通常会减少,
- 测试误差可能先减小,然后增大。

经典模型。存在一个最佳的复杂度水平,可以平衡欠拟合和过拟合。

备注 (现代视角) :在深度学习中,模型通常远远超越了这种经典模式,在保证较低训练误差的同时,也未必会牺牲泛化能力。我们将在后文中再次探讨这一现象。

5.3 模型容量和复杂性

要理解过拟合,我们必须量化模型的表达能力。

模型容量。假设空间 H 拟合各种函数的能力。

例如。

5.4. 非正式概括原则

29

- 线性模型:容量低
- 高次多项式:高容量
- 深度神经网络:容量非常大

容量的定性影响。

- 低容量 → 高偏差,低方差
- 高容量 → 低偏差,高方差

复杂性度量（非正式）。

- 参数数量
- 网络的深度和宽度
- 参数规范

重要发现:模型容量并非仅由参数数量决定,模型结构和学习算法也起着至关重要的作用。

例如,参数数量相同的两个神经网络,其行为可能截然不同,这取决于:

- 建筑学,
- 初始化,
- 优化动态。

因此,容量应该被视为表征、参数化和训练过程的结合。

5.4 非正式概括原则

尽管现代机器学习中关于泛化的完整理论仍在发展中,但一些指导原则在实践中得到了广泛的遵守。

1. 更简单的模型往往具有更好的泛化能力。

这一原则通常被称为奥卡姆剃刀原理:在符合数据的模型中,更简单的模型更受欢迎。

简洁可以有多种形式:

- 参数更少,
- 较小的规范,

- 更流畅的功能。

2. 正则化可以提高泛化能力。

正则化引入了额外的约束或惩罚,从而有利于更简单的解决方案。

例如:

- 体重下降,
- 辍学,
- 提前停止。

3. 更多的数据可以提高概括性。

随着样本量的增加:

- 经验风险能更好地近似真实风险,
- 估计误差减小。

4. 感应偏置至关重要。

概括性取决于模型中内置的假设:

- 平滑度,
- 不变性,
- 组成结构。

5. 优化影响泛化能力。

即使多个解的训练误差都很低,优化算法的选择也会影响最终找到的解。

这种现象被称为隐式正则化。

6. 噪音可能是有益的。

训练中的随机性 (例如,SGD)可以通过防止收敛到过于复杂的解来帮助避免过拟合。

总结性见解:概括并非由单一因素决定,而是由以下因素相互作用决定:

- 型号容量,
- 数据,
- 感应偏置,
- 优化。

5.5 统一的视角

现在我们可以将学习重新解释为平衡两个目标的问题：

- 拟合训练数据，
- 保持概括能力。

核心肌群张力。

拟合数据而非避免过拟合。

实用策略。

1. 选择合适的模型类
2. 通过规范化控制产能
3. 利用验证结果指导模型选择
4. 监控训练和测试表现

现代观点。深度学习系统运行的环境中,经典直觉只能部分适用,但归纳偏置和结构的基本原理仍然至关重要。

5.6 展望

本章介绍了概括能力作为学习中的核心挑战：

- 区分训练和测试表现，
- 理解过拟合和欠拟合，
- 将模型容量与泛化能力联系起来。

下一章,我们将更详细地研究正则化方法,重点关注如何在实践中控制模型复杂性。

指导原则:好的模型并非完美契合数据,而是能够捕捉到超越观测案例的潜在结构。

第六章

正则化和 结构

6.1 基于范数的正则化

在前几章中,我们看到,高表达能力的模型虽然能够很好地拟合训练数据,但也存在过拟合的风险。正则化提供了一种系统性的方法来控制模型的复杂度并提高泛化能力。

基本思路:在经验风险的基础上,对参数施加惩罚:

$$\min_{\theta \in \Theta} R_n(\theta) + \lambda \Omega(\theta),$$

在哪里:

- $\Omega(\theta)$ 衡量模型的复杂度,
- $\lambda > 0$ 控制正则化的强度。

常见的处罚方式。

- ℓ_2 正则化 (权重衰减):

$$\Omega(\theta) = \|\theta\|_2^2.$$

- ℓ_1 正则化:

$$\Omega(\theta) = \|\theta\|_1.$$

解释。

- ℓ_2 正则化有利于较小的、分布的参数
- ℓ_1 正则化促进稀疏性

从几何角度来看,正则化将解限制在参数空间中具有受控范数的区域内。

统计学观点。范数惩罚可以解释为对参数施加先验分布:

- $\ell_2 \rightarrow$ 高斯先验
- $\ell_1 \rightarrow$ 拉普拉斯先验

实际效果。正则化可以降低方差并提高稳定性,但通常会略微增加偏差。

6.2 约束和惩罚

正则化可以用两种等价的方式来表述:

- 处罚形式:

$$\min_{\theta} R_n(\theta) + \lambda \Omega(\theta),$$

- 受限形式:

$$\min_{\theta} R_n(\theta) \text{ 满足 } \Omega(\theta) \leq C.$$

洞察。这些公式密切相关:对于合适的 λ 和 C 值,它们会得出相似的解。

例如。

- 岭回归: ℓ_2 惩罚
- 套索: ℓ_1 罚球

解释:该约束条件限制了有效搜索空间,防止出现过于复杂的解决方案。

双重视角。惩罚项在数据拟合度和模型简洁性之间进行权衡,而约束条件则对模型复杂度施加了严格的限制。

从工程角度来看,惩罚模型通常更容易优化,而约束模型则能提供更清晰的几何直观理解。

6.3 隐式正则化

并非所有正则化都是显式的。在许多现代学习系统中,优化算法本身就会倾向于某些特定的解。

定义 (非正式): 隐式正则化是指算法即使在没有显式惩罚的情况下也倾向于选择特定解的现象。

例如 (线性模型)。在过参数线性回归中,梯度下降法收敛于所有插值解中的最小范数解。

示例 (深度学习)。

- 随机梯度下降法倾向于找到具有特定结构的解

不同的优化器会导致不同的泛化行为

隐式正则化的来源。

- 初始化
- 优化动态
- 随机性 (例如,小批量处理)

关键洞见:即使模型拥有足够的容量来完美拟合数据,训练过程也决定了最终找到的解。

启示:理解泛化能力不仅需要分析模型和损失函数,还需要分析优化过程。

6.4 提前停止和实用方法

规范化也可以通过实际的培训策略来实现。

提前停止训练。我们不会完全最小化训练损失,而是在验证性能开始下降时停止训练。

解释。

- 早期迭代捕捉到了大规模结构
- 后续迭代可能拟合噪声

与正则化的关系。在许多情况下,提前停止的行为类似于 ℓ_2 正则化。

其他实用方法。

- 掉线:训练期间随机停用单元

- 数据增强 :通过转换扩展数据集
- 噪声注入 :向输入或参数添加噪声

解释。

- Dropout 鼓励冗余和增强鲁棒性
- 数据增强编码不变性

噪声会使学习到的函数变得平滑。

从工程角度来看,这些方法通常易于实现且非常有效,尤其是在深度学习系统中。

6.5 结构即正则化

除了显式的惩罚和训练技巧之外,模型结构本身也起到了一种强大的正则化作用。

例如。

- 卷积层增强局部性
- 残余连接稳定深度网络
- 注意力机制捕捉关系结构

核心思想 :结构限制了可以表示的函数类型,从而引导学习朝着有意义的解决方案发展。

洞察。在现代机器学习中,架构设计通常比显式正则化更重要。

6.6 统一的视角

正则化可以理解为控制学习函数的有效复杂度。

正则化的形式。

- 明确的 (惩罚、约束)
- 隐式 (优化动态)
- 结构 (模型架构)

6.7 展望

37

统一目标。

适应数据和控制的复杂性。

关键组成部分。

- 模型类
- 正则化机制
- 优化算法

这些因素相互作用,共同决定训练效果和泛化能力。

6.7 展望

本章介绍了正则化作为控制模型复杂性的核心工具:

- 基于规范的惩罚,
- 约束和惩罚,
- 优化的隐含影响,
- 诸如提前停止和辍学等实用技巧。

本书的下一部分将探讨具体的监督学习模型,
从线性回归和最小二乘法开始。

指导原则:成功的学习不仅需要拟合数据,还需要塑造解决方案空间,从而使有意义的模式涌现。

第七章

线性回归和 最小二乘法

7.1 线性模型和投影

线性回归是机器学习中最简单、最基本的模型之一。尽管它很简单,但它阐明了许多关键概念,这些概念也适用于更复杂的模型。

模型。我们考虑如下形式的函数。

$$f(x) = w \cdot x + b,$$

其中 $w \in \mathbb{R}^d$ 且 $b \in \mathbb{R}$ 。

给定数据集 $\{(x_i, y_i)\}_{i=1}^n$ 数据。我们的目标是找到最合适的参数 (w, b)

矩阵形式。令

$$X = \begin{pmatrix} -x_1 & - \\ -x_2 & - \\ \vdots & \vdots \\ -x_n & - \end{pmatrix} \in \mathbb{R}^{n \times d}, \quad y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

为简单起见,我们通过 aug- 将偏差纳入参数向量中。

将 x 表示为一个常数分量。那么该模型就变成了

$$f(x) = w \cdot x,$$

预测向量为

$$\hat{y} = Xw.$$

几何解释。 X 的列向量张成 $\mathbb{R}^n$ 的一个子空间。线性回归在这个子空间中寻找与 y 最接近的向量 $\hat{y}$ 。

因此,线性回归可以看作是一个正交投影问题。

7.2 最小二乘法作为优化方法

损失函数的自然选择是平方误差：

$$\ell(f(x_i), y_i) = (f(x_i) - y_i)^2.$$

客观的。

$$\min_w \frac{1}{n} \|Xw - y\|^2.$$

这是一个凸二次优化问题。

最优性条件。令梯度为零,即可得到正规方程：

$$X^T X w = X^T y.$$

解（当 $X^T X$ 可逆时）。

$$w = (X^T X)^{-1} X^T y.$$

投影解释。拟合值 $\hat{y} = Xw$ 满足

$$y - \hat{y} \perp \text{span}(X),$$

这意味着残差与 X 的列空间正交。

洞察。最小二乘解是在模型类别中,以欧氏距离衡量的 y 的最佳近似值。

参数过多的情况。如果 $X^T X$ 不可逆（例如, $d > n$ ）,则存在无穷多个解。在这种情况下,通常选择最小范数解：

$$w = X (X^T X)^{-1} X^T y.$$

该解决方案与前几章讨论过的隐式正则化密切相关。

7.3 条件和数值稳定性

虽然闭式解提供了见解,但实际计算取决于矩阵 $X^T X$ 的数值性质。

条件数。 $X^T X$ 的条件数衡量其对抗扰动的敏感度：

$$\kappa(X^T X) = \frac{\lambda_{\max}}{\lambda_{\min}},$$

其中 $\lambda_{\max}$ 和 $\lambda_{\min}$ 分别是最大和最小特征值。

身体状况不佳。

7.4. 岭回归

41

- 当 $\lambda_{\min}$ 非常小时发生
- 导致不稳定的解决方案
- 数据的微小变化会导致 w 的巨大变化

原因。

- 高度相关的特征
- 冗余或近乎冗余的输入

实际后果。

- 反演中的数值不稳定性
- 概括性差

补救措施。

- 特征缩放和归一化
- 删除冗余功能
- 正则化（接下来讨论）

算法说明:在实践中,通常会避免直接求逆,而倾向于使用更稳定的方法,例如 QR 分解或奇异值分解 (SVD)。

7.4 岭回归

岭回归将 ℓ_2 正则化引入到最小二乘问题中。

客观的。

$$\min_w \|Xw - y\|_2^2 + \lambda \|w\|_2^2, \quad \lambda > 0。$$

解决方案。

$$w = (X^T X + \lambda I)^{-1} X^T y。$$

解释。

- 通过移动 $X^T X$ 的特征值来增加稳定性
- 降低对噪音的敏感度
- 控制参数的大小

42 第七章 线性回归和最小二乘法

几何视角。岭回归通过向原点收缩来调整解,从而平衡数据拟合度和参数范数。

偏差-方差权衡。

- 略微增加偏差
- 显著降低方差

与条件数的关系。对于 $\lambda > 0$, 矩阵 $X^T X + \lambda I$ 始终可逆,从而提高了数值稳定性。

贝叶斯解释。岭回归相当于假设 w 服从高斯先验分布。

7.5 统一的视角

线性回归体现了机器学习的几个核心主题:

- 将学习视为向函数空间的投影
- 优化作为解决结构化问题的一种手段
- 正则化作为控制复杂性和稳定性的方法

三种视角。

- 几何:投影到子空间
- 代数:求解正规方程
- 统计学:估计条件期望

这些观点自然而然地扩展到了更复杂的模型,包括神经网络。

7.6 展望

本章介绍了线性回归作为基础模型:

- 最小二乘法公式,
- 几何解释,
- 数值方面的考虑,
- 通过岭回归进行正则化。

在下一章中,我们将这些思想扩展到逻辑回归分类,其中概率建模起着核心作用。

指导原则:简单的模型往往揭示深层结构。理解这些模型有助于深入了解更复杂的学习系统。

第八章

逻辑回归和分类

8.1 概率解释

与输出为实值的回归问题不同,分类问题涉及预测离散标签。一种自然的方法是建立给定输入下每个类别的概率模型。

二元分类。令 $Y = \{0, 1\}$ 。我们不直接预测标签,而是建模。

$$P(y = 1 | x)。$$

逻辑模型。我们假设

$$P(y = 1 | x) = \sigma(w \cdot x),$$

其中 σ 为 sigmoid 函数

$$\sigma(z) = \frac{1}{1 + e^{-z}}。$$

S形函数的性质。

- 将 $\mathbb{R}$ 映射到 $(0, 1)$
- 平滑且单调
- 可解释为概率

对数比值解释。该模型表明

$$= \frac{P(y = 1 | x) \log \frac{P(y = 1 | x)}{P(y = 0 | x)}}{w \cdot x}$$

因此,逻辑回归将对数几率建模为输入的线性函数。

多分类扩展。对于 K 个类别,我们使用 softmax 函数:

$$P(y = k | x) = \frac{\exp(w_k \cdot x)}{\sum_{j=1}^K \exp(w_j \cdot x)}.$$

这种公式确保概率均为正数且总和为 1。

8.2 交叉熵损失

为了训练模型,我们需要一个能够反映概率准确率的损失函数。

二元交叉熵损失。

$$\ell(f(x), y) = -y \log p(x) + (1 - y) \log(1 - p(x)),$$

其中 $p(x) = P(y = 1 | x)$ 。

多类交叉熵。

$$\ell(f(x), y) = -\log P(y | x).$$

解释。

- 对自信但错误的预测处以重罚。
- 鼓励使用校准概率

几何洞察力。交叉熵衡量预测分布与真实标签分布之间的差异。

实际优势。与平方损失不同,交叉熵损失函数能够为分类任务产生行为良好的梯度。

8.3 最大似然视角

逻辑回归可以从最大似然原理推导而来。

似然函数。

$$L(w) = \prod_{i=1}^n P(y_i | x_i; w).$$

对数似然值。

$$\ell(w) = \sum_{i=1}^n \log P(y_i | x_i; w).$$

最大化对数似然函数等价于最小化经验交叉熵损失：

$$\text{最小化} \quad - \sum_{i=1}^n \log P(y_i | x_i; w)。$$

二元情况。代入 sigmoid 模型后,得到一个凸优化问题。

梯度。对于二元分类，

$$\nabla_w \ell(w) = \sum_{i=1}^n (\sigma(w \cdot x_i) - y_i)x_i。$$

洞察力。

- 梯度反映了由输入特征加权的预测误差
- 训练过程会调整参数,以减少预测概率与标签之间的差异

正则化。与线性回归类似,通常会添加一个 ℓ_2 惩罚项：

$$\text{最小化} \quad - \sum_{i=1}^n \log P(y_i | x_i; w) + \lambda \|w\|_2^2。$$

解释:这对应于高斯先验下的最大后验概率 (MAP)估计。

8.4 决策边界

虽然逻辑回归模型处理的是概率,但它最终会产生决策。

二元决策规则。

$$y = \begin{cases} 1 & \text{如果 } P(y=1 | x) \geq 0.5 \\ 0 & \text{否则} \end{cases}$$

等效条件。

$$w \cdot x \geq 0。$$

决策边界。满足以下条件的点集：

$$w \cdot x = 0$$

在 $\mathbb{R}^d$ 中定义一个超平面。

几何解释。

46 第八章 逻辑回归与分类

输入空间被分为两个半空间

法向量 w 决定方向

多分类问题。决策边界通过比较线性关系确定。

得分：

$$w_k, x = w_j, x。$$

局限性：逻辑回归生成的是线性决策边界，不进行特征变换则无法捕捉非线性结构。

扩展。非线性决策边界可以通过以下方式获得：

- 特征映射，
- 内核方法，
- 神经网络。

8.5 统一的视角

逻辑回归将几个关键概念联系起来：

- 概率建模：预测条件概率
- 优化：最小化交叉熵损失
- 几何形状：线性决策边界

与线性回归的比较。

- 线性回归预测值
- 逻辑回归预测概率

关键见解：分类可以被视为对离散结果的不确定性进行建模。

8.6 展望

本章介绍了逻辑回归作为一种基本的分类模型：

- 概率解释，
- 交叉熵损失，
- 最大似然估计，
- 决策边界的几何结构。

下一章,我们将使用特征映射和核函数扩展线性模型。
使它们能够捕捉非线性关系。

指导原则:有效的分类既需要表达力强的模型,也需要适当的概率公式。

第九章

特征地图和 非线性模型

9.1 基数扩展

线性模型简单且计算效率高,但其表达能力有限:它们只能表示输入空间中的线性关系。克服这一局限性的一个自然方法是在应用线性模型之前对输入进行变换。

特征图。特征图是一种函数

$$\phi: X \rightarrow \mathbb{R}^m,$$

它将原始输入映射到新的特征空间。

然后,我们定义一个如下形式的模型

$$f(x) = w \cdot \phi(x)。$$

示例(多项式特征)。对于 $x \in \mathbb{R}, x^d$ 。

$$\phi(x) = (1, x, x^2, \dots, x^d)$$

示例(交互特征)。对于 $x \in \mathbb{R}$, 捕获交互。 $x_i x_j$, 包括诸如 $x_i x_j$ 之类的术语。

核心思想:特征空间中的线性模型对应于原始输入空间中的非线性模型。

解释:基展开允许我们通过组合更简单的构建模块来近似复杂的函数。

与逼近论的联系。多项式、傅里叶基和其他函数系统通过线性组合可以逼近各种各样的函数。

9.2 特征空间中的线性模型

特征图定义完成后,学习过程与之前相同:

$$\min_{\mathbf{w}} \frac{1}{n} \sum_{i=1}^n \ell(\mathbf{w}, (\mathbf{x}_i), y_i)。$$

矩阵形式。设 $\Phi \in \mathbb{R}^{n \times m}$ 设特征矩阵为:

$$\Phi = \begin{bmatrix} - & - \\ - & - \\ - & - \\ - & - \\ - & - \end{bmatrix} \begin{matrix} (\mathbf{x}_1) \\ (\mathbf{x}_2) \\ \vdots \\ (\mathbf{x}_n) \end{matrix} \begin{matrix} - \\ - \\ - \\ - \\ - \end{matrix}。$$

然后,预测结果由以下方式给出:

$$\mathbf{y} = \Phi \mathbf{w}。$$

洞察。所有线性回归和分类方法只需将 $\mathbf{X}$ 替换为 Φ 即可直接扩展到特征空间。

表现力与复杂性。

- 增加特征维度 m 可以提高表达能力
- 但同时也增加了过拟合的风险和计算成本

从几何角度来看,数据被嵌入到更高维的空间中,在该空间中它可能线性可分。

例如,将 $\mathbb{R}^2$ 映射到 $\mathbb{R}^3$ 后, $\mathbb{R}^2$ 中无法被直线分离的点,可以通过超平面分离。
2 可能变得可分离
3。

9.3 核心思想（直觉）

当特征空间维度非常高甚至无限大时,就会出现挑战。

观察。许多算法都依赖于特征向量之间的内积:

$$(\mathbf{x}), (\mathbf{x}')。$$

核函数。核函数是一种函数。

$$k(\mathbf{x}, \mathbf{x}') = (\mathbf{x}), (\mathbf{x}')，$$

它计算这个内积,而无需显式地计算 $(\mathbf{x})$ 。

关键思想（核技巧）。我们可以通过直接使用 $k(\mathbf{x}, \mathbf{x}')$ 在高维特征空间中进行隐式运算。

内核示例。

9.4. 通过特征表达情感

51

- 多项式核：

$$k(x, x') = (\|x - x'\| + c)^d$$

- 高斯 (RBF)核：

$$k(x, x') = \exp - 2\sigma^2 \frac{\|x - x'\|^2}{2}$$

解释。

- 核函数衡量输入之间的相似性

它们定义了一个隐式特征空间

实际优势。

- 避免显式进行高维计算
- 支持灵活的非线性模型

局限性。

- 计算成本随数据点数量的增加而增加
- 可扩展性不如现代深度学习方法

9.4 通过功能实现表达能力

特征图决定了模型可以表示哪些功能。

关键问题： 的选择如何影响模型的表达能力？

洞察 :在特征空间足够丰富的条件下,线性模型可以逼近高度复杂的函数。

权衡。

- 丰富的特征 → 高表现力
- 但过拟合的风险增加

功能设计原则。

- 对领域知识 (例如,不变性)进行编码
- 捕捉相关结构
- 保持计算可处理性

从特征工程到表征学习。

- 传统方法依赖于手动设计的特征

深度学习能够自动从数据中学习特征

组合性。复杂的特征可以通过组合更简单的变换来构建：

$$\Phi(x) = \Phi_L(\Phi_{L-1}(\cdots \Phi_1(x)))。$$

这一思想构成了神经网络的基础。

几何视角。特征图重塑了数据的几何形状：

- 聚类变得可分离，
- 非线性结构变为线性结构，
- 距离和相似性被重新定义。

9.5 统一的视角

特征图为线性模型和非线性行为之间架起了一座桥梁。

关键组成部分。

- 特征图
- 特征空间中的线性模型
- 参数优化

两种范式。

- 固定功能:手动设计 (例如,内核)
- 学习到的特征:与模型 (深度学习)联合优化

核心见解:机器学习中的非线性通常并非源于模型本身,而是源于数据的表示方式。

9.6 展望

本章介绍了特征映射作为扩展线性模型的一种方法：

- 非线性建模的基展开，
- 在变换空间中进行线性学习，
- 用于隐式高维特征的核方法，

- 表征在表达中的作用。

下一章,我们将学习支持向量机,它结合了地理信息系统 (Geo-Symbol)和支持向量机。利用核方法进行指标分析,生成强大的分类器。

指导原则:表现形式的选择往往决定了成败。

学习系统与模型的选择同样重要。

第十章

支持向量机

10.1 利润最大化

在前几章中,我们学习了线性分类器及其通过特征映射的扩展。支持向量机 (SVM)通过引入一个几何原理——间隔最大化——来完善这些思想。

二元分类设置。令 $y_i \in \{-1, +1\}$, 并考虑一个线性分类器。

$$f(x) = \mathbf{w} \cdot \mathbf{x} + b.$$

如果满足以下条件,则该点被正确分类:

$$y_i(\mathbf{w} \cdot \mathbf{x}_i + b) > 0.$$

边际。数据点的 (功能性) 边际定义为:

$$y_i(\mathbf{w} \cdot \mathbf{x}_i + b).$$

几何裕度。点到决策边界的距离是

$$\frac{y_i(\mathbf{w} \cdot \mathbf{x}_i + b)}{\|\mathbf{w}\|}.$$

目标: 找到一个分类器, 使得所有训练点上的最小间隔最大化。

优化问题。

$$\underset{\mathbf{w}, b}{\text{最大限度}} \quad \underset{\mathbf{w}, b}{\text{最小}} \quad \frac{y_i(\mathbf{w} \cdot \mathbf{x}_i + b)}{\|\mathbf{w}\|}.$$

等价公式。通过固定尺度,我们得到

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{满足 } y_i(w \cdot x_i + b) \geq 1 \quad \forall i。$$

解释。

- 最大化利润 $\leftrightarrow$ 最小化 $\|w\|$
- 鼓励各班级之间严格隔离

支持向量。只有最接近决策边界的点 (即满足约束条件的点) 才会影响解。

洞察力。支持向量机关注的是最具信息量的数据点,而不是所有训练数据。

10.2 硬边距和软边距

上述公式假设数据是线性可分的。但在实践中,这种情况很少发生。

硬间隔支持向量机。· 假设完全

可分性

- 强制执行约束:

$$y_i(w \cdot x_i + b) \geq 1$$

局限性:对噪声和异常值敏感;可能没有可行的解决方案。

软间隔支持向量机。引入松弛变量 $\xi_i \geq 0$:

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i。$$

客观的。

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i,$$

其中 $C > 0$ 控制间隔大小和分类误差之间的权衡。

解释。

- ξ_i 衡量违反边际约束的程度
- 较大的 C 值 $\rightarrow$ 对错误的惩罚力度更大
- 较小的 C 值 $\rightarrow$ 允许更大的灵活性

与损失函数的联系。软边际公式对应于最小化铰链损失:

$$\ell(x_i, y_i) = \max(0, 1 - y_i f(x_i))。$$

洞察。支持向量机将间隔最大化与对不可分离数据的鲁棒性相结合。

10.3 双重形式（概念性）

SVM优化问题可以采用一种称为对偶形式的替代表示方法。

核心思想。我们不优化 w , 而是引入与每个数据点相关的变量 α_i 。

双重问题（非正式）。

$$\underset{\alpha}{\text{最大限度}} \quad \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle, \quad$$

受 α_i 的约束。

重要观察结果。

- 该解仅取决于内积 $\langle x_i, x_j \rangle$
- 只有支持向量的 α_i 值不为零

w 的重建

$$w = \sum_{i=1}^n \alpha_i y_i x_i。$$

洞察。分类器表示为训练点的加权组合。

实际意义。

- 支持使用内核方法
- 揭示了解决方案的稀疏性

10.4 核方法再探

对偶形式使我们能够将 SVM 扩展到非线性分类。

核函数替换。用核函数替换内积：

$$\langle x_i, x_j \rangle \rightarrow k(x_i, x_j)。$$

生成的分类器。

$$f(x) = \sum_{i=1}^n \alpha_i y_i k(x_i, x) + b。$$

解释。

- 将数据隐式映射到特征空间

- 在原始空间中构建非线性决策边界

例如。

- 多项式核
- 高斯 (RBF)核

几何视图。数据被转换到一个线性可分的空间,并在该空间中找到最大间隔分隔符。

优势。

- 灵活的非线性建模
- 强大的理论保证

局限性。

- 计算成本随数据集大小增加而增加
- 可扩展性不如现代深度学习方法

10.5 统一的视角

支持向量机融合了以下几个核心思想:

- 几何: 边际最大化
- 优化: 凸二次规划
- 表示方法: 特征图和特征核

关键见解。

好的分类器能够最大限度地分离类别。

- 仅需一部分数据点即可确定解决方案
- 可以通过核函数引入非线性

支持向量机展示了如何将几何学和优化相结合,从而产生强大的学习算法。

10.6 Outlook

本章介绍了支持向量机作为一种分类的原理性方法：

- 基于边际的学习，
- 针对真实世界数据的软约束
- 双重公式和稀疏性，
- 非线性模型的核方法。

下一章,我们将回到模型评估和选择,重点关注
关于如何在实践中比较模型和选择超参数。

指导原则:有效的学习需要在表达性和稳健性之间取得平衡,这通常是通过几何和优化原理实现的。

第十一章

模型评估和 选拔

11.1 培训、验证和测试

在前几章中,我们开发了用于从数据中学习的模型和优化方法。然而,一个关键的实际问题仍然存在:我们如何以可靠的方式评估和比较模型?

一个核心挑战是,真正的风险是什么。

由于数据生成分布 P 不可访问,因此

$R(f) = E_{(x,y) \sim P} [\ell(f(x), y)]$ 是未知的。

数据分割。为了评估泛化性能,我们将可用数据集分为三个部分:

- 训练集:用于拟合模型参数
- 验证集:用于调整超参数
- 测试集:用于评估最终性能

工作流程。

1. 在训练集上训练模型
2. 使用验证集选择超参数
3. 在测试集上评估最终模型

关键原则:模型选择过程中不得使用测试集,否则会导致过于乐观的估计结果。

对验证数据的过拟合。重复调优可能会间接导致模型对验证集过拟合。这促使人们采用更稳健的评估策略,例如交叉验证。

11.2 交叉验证

交叉验证提供了一种利用有限数据来评估模型性能的系统方法。

k折交叉验证。

- 将数据集划分为 k 个子集（折叠）
- 对于每一次折叠：
 - 在 k - 1 折交叉验证集上进行训练
 - 对剩余的折叠部分进行评估
- 对各折叠的结果取平均值

交叉验证估计。

$$R_{CV} = \frac{1}{k} \sum_{j=1}^k R_j,$$

其中 R_j 是第 j 折的验证误差。

优势。

- 高效利用数据
- 更稳定的性能估算

k 的选择。

- 较小的 k 值（例如 5）：速度更快，偏差更高
- 较大的 k 值（例如，留一法）：偏差较小，但方差和成本较高。

实际应用。交叉验证广泛用于超参数调优，尤其适用于数据集较小或中等规模的情况。

11.3 性能指标

评价指标的选择取决于学习任务。

11.3. 绩效指标

63

11.3.1 回归指标

- 均方误差 (MSE):

$$\frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2$$

- 平均绝对误差 (MAE):

$$\frac{1}{n} \sum_{i=1}^n |f(x_i) - y_i|$$

解释。

- MSE 对较大误差的惩罚力度更大
- MAE 对异常值更具鲁棒性

11.3.2 分类指标

准确性。

$$\frac{\text{正确预测次数}}{\text{预测总数}}$$

精确率和召回率。

- 精确率: 预测为阳性结果正确的比例
- 召回率: 实际检测到的阳性病例所占的比例

F1 分数。

$$F1 = 2 \cdot \frac{\text{精确率} \cdot \text{召回率}}{\text{精确率} + \text{召回率}}$$

ROC 和 AUC。

- ROC 曲线绘制真阳性率与假阳性率的关系图
- AUC 概括了整体分类性能

数据不平衡。当类别不平衡时, 准确率可能会产生误导; 精确率、召回率和 AUC 可以提供更具参考价值的评估结果。

概率指标。对于输出概率的模型, 交叉熵损失通常用作评估指标。

11.4 型号比较

选择模型需要根据验证性能对多个候选模型进行比较。

超参数。

- 正则化强度
- 模型架构
- 优化参数

甄选程序。

1. 定义一组候选模型
2. 使用验证或交叉验证评估每个模型
3. 选择性能最佳的型号

模型选择与评估。

模型选择使用验证数据

- 最终评估使用测试数据

模型选择中的过拟合问题。测试过多的模型会增加偶然选择表现良好的模型的风险。

实用策略。

- 使用交叉验证
- 限制超参数的搜索空间
- 当性能相近时,优先选择更简单的模型。

权衡取舍。

- 准确性与复杂性
- 性能与计算成本

可重复性。可靠的模型比较需要一致的数据划分和受控的实验环境。

11.5 统一的视角

模型评估和选择是学习过程中不可或缺的组成部分。

管道。

- 在数据上训练模型
- 评估泛化性能
- 选择最佳型号
- 评估最终表现

主要挑战。

- 数据有限
- 估计值的差异
- 选择过程中存在过度拟合的风险

核心见解:可靠的评估需要将训练、验证和测试这三个环节的角色分开。

11.6 展望

本章介绍了模型评估和选择的原则:

- 分离数据以进行无偏评估,
- 使用交叉验证进行稳健估计,
- 选择合适的绩效指标,
- 系统地比较模型。

下一章,我们将更深入地研究优化方法,重点是探讨大规模机器学习中使用的实用技术。

指导原则:模型的好坏取决于其评估方式。可靠的评估对于有效的学习至关重要。

第十二章

实践中的优化

12.1 随机梯度下降

在第四章中,我们介绍了基于梯度的优化方法,并将其作为训练机器学习模型的主要方法。然而,在实践中,计算大型数据集上的完整梯度通常在计算上是不可行的。

随机梯度下降法 (SGD)。它不计算完整的梯度,

$$\nabla L(\theta) = \frac{1}{n} \sum_{i=1}^n \nabla \ell(f_{\theta}(x_i), y_i),$$

我们用一个随机选择的数据点来近似表示它:

$$\theta_{t+1} = \theta_t - \eta \nabla \ell(f_{\theta}(x_{it}), y_{it}).$$

解释。

每次更新都是对真实梯度的噪声估计。

- 噪声来源于采样

主要特性。

- 每次迭代的计算成本低
- 支持在大数据集上进行训练
- 将随机性引入优化过程

趋同行为 (非正式)。

- SGD 不会精确收敛到最小值

相反,它会在低损耗区域附近波动。

洞察。SGD 的随机性有助于跳出尖锐的最小值,更有效地探索损失空间。

12.2 小批量生产和效率

在实践中,SGD 很少使用单个数据点来实现。相反,我们使用小批量数据。

小批量新加坡元。

$$\theta_{t+1} = \theta_t - \eta \frac{1}{|B_t|} \sum_{i \in B_t} \nabla \ell(f(\theta(x_i), y_i),$$

其中 B_t 是数据点的子集（批次）。

优势。

- 降低梯度估计的方差
- 利用并行计算（例如,GPU）
- 比纯SGD更新更稳定

批量大小权衡。

- 小批量：
 - 嘈杂的更新
 - 在某些情况下,概括性更强
- 大批量：
 - 更精确的梯度
 - 每步计算成本较高

效率方面的考虑。

- 内存限制限制了批处理大小
- 更大的批次处理可受益于硬件加速

周期和迭代次数。

- 一个周期:遍历数据集一次
- 迭代:一次参数更新

12.3 动量和自适应方法

基本随机梯度下降法可能速度慢或不稳定,尤其是在高维问题中。
多项改进提升了其性能。

12.3. 动量和自适应方法

69

12.3.1 动量

更新规则。

$$\mathbf{v}_{t+1} = \beta \mathbf{v}_t + \nabla L(\theta_t), \quad \theta_{t+1} = \theta_t - \eta \mathbf{v}_{t+1}.$$

解释。

- 累积过去的梯度
- 平滑更新并加速收敛

几何直觉。动量有助于快速穿越平坦区域,并减少在曲率较大的方向上的振荡。

12.3.2 自适应方法

自适应方法会根据各个参数调整学习率。

例如。

- AdaGrad
- RMSProp
- 亚当

核心思想。

- 基于过去梯度幅值的尺度更新
- 对于不常出现的特征,使用更大的步长。
- 对于频繁更新的参数,应使用较小的步长。

亚当(概念形式)。

- 维护梯度和梯度平方的移动平均值
- 结合了动量和自适应缩放

实际观察。

- 自适应方法通常收敛速度更快
- 在某些情况下,带动量的随机梯度下降法可能具有更好的泛化能力

12.4 实际收敛行为

在现实世界中,优化很少遵循理想化的理论行为。

学习率调度。

- 随着时间的推移降低学习率
- 常用策略:
 - 阶跃衰减, - 指数衰减, - 余弦退火

热身。

- 从较小的学习率开始
- 逐步增加以稳定早期训练

高原和陡坡。

- 训练损失可能会缓慢减少,然后突然改善
- 反映了损失格局的转变

噪声和泛化。

- 来自随机梯度下降的噪声可以起到隐式正则化的作用
- 有助于避免急剧的最低点

终止条件。

- 固定轮数
- 训练损失的收敛
- 基于验证的提前终止

实际挑战。

- 选择学习率
- 调整超参数
- 平衡速度和稳定性

洞察力。实践中的优化既是一门科学,也是一门艺术,它既受理论原则的指导,也受经验教训的指导。

12.5 统一的视角

现代机器学习中的优化涉及多个相互作用的组成部分：

- 算法:SGD 及其变体
- 超参数:学习率、批大小
- 动态特性:噪声、曲率、景观结构

核心权衡取舍。

- 速度与稳定性
- 准确性与计算成本
- 优化与泛化

关键洞见:优化算法的行为不仅影响模型的学习速度,也影响它们找到的解决方案。

12.6 展望

本章从实践角度探讨了优化问题：

- 随机梯度法，
- 小批量生产和效率，
- 动量算法和自适应算法，
- 现实世界的趋同行为。

下一章,我们将研究数值和统计稳定性,重点关注数据预处理和条件化如何影响学习。

指导原则:有效的优化需要同时理解算法及其所应用问题的结构。

第十三章

数值和统计

稳定

13.1 不良状态

在前几章中,我们研究了优化方法及其在实际应用中的表现。然而,这些方法的有效性很大程度上取决于问题的数值特性。

定义（非正式）:如果输入的微小变化导致输出的巨大变化,则称该问题是病态的。

示例（线性回归）。解决方案

$$w = (X^T X)^{-1} X^T y$$

当 $X^T X$ 接近奇异时,对扰动很敏感。

条件数。对于正定矩阵 A ,条件数是

$$\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}.$$

解释。

- $\kappa(A)$ 值较大 $\rightarrow$ 病态问题
- $\kappa(A)$ 较小 $\rightarrow$ 良条件问题

几何直觉。病态条件对应于损失函数的水平集拉长,使得优化变得困难。

结果。

梯度法收敛速度慢

矩阵求逆中的数值不稳定性

- 对噪声的敏感性

导致身体状况不佳的原因。

- 高度相关的特征
- 冗余输入
- 变量尺度不佳

13.2 缩放和归一化

提高条件数的一个简单而有效的方法是对数据进行预处理。

特征缩放。将每个特征变换为具有可比的量级。

标准化。

$$\leftarrow \frac{x_j - \mu_j}{\sigma_j},$$

其中 μ_j 和 σ_j 分别是特征 j 的均值和标准差。

归一化。将输入数据缩放至有界范数,例如:

$$x \leftarrow \frac{x}{\|x\|}.$$

对优化的影响。

- 使渐变在各个维度上更加平衡
- 提高收敛速度
- 降低数值不稳定性

与条件数有关。适当的缩放可以减少问题的条件数。

深度学习中的归一化。

- 批量归一化
- 层归一化

洞察 :归一化可以看作是动态调整优化问题的几何形状。

13.3 对噪声的敏感性

现实世界的的数据通常存在噪声。一个稳定的学习算法不应该对微小的扰动过于敏感。

噪声源。

- 测量误差
- 观测数据不完整
- 内在随机性

对学习的影响。

- 可能导致过拟合
- 可能导致参数估计不稳定

例如（最小二乘法）。在病态问题中, y 中的微小噪声会导致 w 发生巨大变化。

偏差-方差视角。

- 高方差模型对噪声更敏感
- 正则化降低了敏感性

稳定性即鲁棒性。稳定的算法在输入受到轻微扰动时,仍能产生相似的输出。

算法稳定性（非正式定义）。如果移除或修改单个数据点不会显著改变学习到的模型,则认为该算法是稳定的。

洞察。稳定性与泛化能力密切相关:稳定的算法往往具有更好的泛化能力。

13.4 稳健性考虑

除了数值稳定性之外,我们还关注对更广泛形式的扰动的鲁棒性。

鲁棒性的类型。

- 对数据噪声的鲁棒性
- 对分布变化的稳健性
- 对对抗性扰动的鲁棒性

鲁棒的损失函数。

- 均方误差 :对异常值敏感
- 绝对误差 :更稳健

正则化和鲁棒性。限制模型复杂度通常可以提高鲁棒性。

数据增强。在训练数据中引入变化可以提高模型对数据变换的鲁棒性。

对抗性视角（非正式）。精心选择的微小扰动可以显著影响模型预测,尤其是在高维情况下。

洞察力。稳健性既需要稳定的模型,也需要对数据做出适当的假设。

13.5 统一的视角

数值稳定性和统计稳定性密切相关：

- 数值稳定性 :对计算误差的敏感性
- 统计稳定性 :对数据变化的敏感性

关键因素。

- 问题的条件化
- 数据预处理
- 模型复杂性
- 正则化

核心见解 :稳定的学习系统是指在数值和统计上的微小扰动下仍能表现得可预测的系统。

13.6 展望

本章从数值和统计两个角度探讨了稳定性：

- 不良体能状况及其后果
- 缩放和归一化的作用，

13.6 展望

77

- 对噪声敏感,
- 稳健性方面的考虑。

下一章,我们将从经典模型过渡到神经网络。
将深度学习视为这些理念的自然延伸。

指导原则。稳定性对于可靠的学习至关重要。模型应该
不仅要拟合数据,而且要以一种能够应对扰动和不确定性的方式进行拟合。

第十四章

从经典模型到神经网络

14.1 浅层模型的局限性

在前几章中,我们研究了一系列经典模型,包括线性回归、逻辑回归和核方法。这些模型功能强大且易于理解,但它们也存在一些根本性的局限性。

浅层模型。我们指的是这种形式的模型。

$$f(x) = w \cdot \phi(x),$$

其中要么是固定的,要么只涉及一层变换。

主要局限:表征。这些模型的成功在很大程度上取决于特征 $\phi(x)$ 的选择。

挑战。

- 设计有效的功能需要领域专业知识
- 固定特征图可能无法捕捉复杂结构
- 高维特征空间计算成本可能很高。

表达能力有限。

- 线性模型产生线性决策边界
- 核方法虽然灵活,但随着数据量的增加,其扩展性较差。

维度灾难。显式特征扩展通常需要指数级数量的特征才能捕捉复杂的模式。

洞察。传统模型将表征和学习分开:先设计特征,然后拟合模型。这种分离可能会限制它们的有效性。

第十四章 从经典模型到神经网络

14.2 函数的组合结构

许多现实世界的功能都具有组合结构。

定义（非正式）：如果一个函数可以写成若干个更简单函数的组合,则称该函数是组合函数：

$$f(x) = f_L(f_{L-1}(\cdots f_1(x)))。$$

例如。

- 图像:边缘 → 形状 → 物体
- 语言:字符 → 单词 → 句子

层级结构。每一层都以不同的抽象层次捕捉模式。

组合的效率。组合表示法可以用相对较少的参数描述复杂的函数。

与浅层模型形成对比。浅层模型可能需要指数级数量的单元来表示一个可以用多层模型简洁表达的函数。

洞察力。深度允许重用中间计算,从而实现更高效的表示。

14.3 深度学习的动机

深度学习源于通过组合来学习表征和功能的思想。

神经网络。一个具有 L 层的神经网络具有以下形式：

$$f(x) = f_L(f_{L-1}(\cdots f_1(x))),$$

其中每一层通常都是一个仿射变换,然后是一个非线性变换。

主要优势。

- 自动特征学习:特征是从数据中学习得到的,而不是手动设计的。
- 表达能力:深度网络可以表示高度复杂的功能。
- 可扩展性:利用大型数据集和现代硬件进行高效训练。

通用逼近（非正式）。只要容量足够,神经网络可以逼近一大类函数。

实际应用效果显著。深度学习在以下方面取得了强劲表现：

- 计算机视觉，
- 自然语言处理，
- 语音识别，
- 生成式建模。

关键转变。我们不再设计功能，而是设计能够自动学习功能架构。

14.4 向已习得表征的过渡

从经典模型到深度学习的过渡涉及表征构建方式的改变。

传统方法。

- 特征图是固定的
- 模型学习参数 w

深度学习方法。

- 特征图 θ 是参数化的
- 表征和模型是联合学习的

模型结构。

$$f(x) = g(\theta(x)),$$

其中 θ 和 g 都取决于参数。

层级表示。

- 早期图层 : 局部或低级特征
- 中间层 : 图案和结构
- 最后几层 : 特定任务的表征

几何视角。深度网络通过连续的非线性映射转换数据,重塑其几何结构,从而简化学习过程。

从优化角度来看,学习过程涉及同时优化所有层上的高度非凸目标函数。

通过结构进行正则化。架构选择会施加归纳偏差,从而引导学习:

- 卷积层编码局部性,

第十四章 从经典模型到神经网络

- 注意力机制编码关系，
- 残差连接稳定训练。

洞察。深度学习将表征、建模和优化统一到一个框架中。

14.5 统一的视角

现在我们可以重新解读模型的演变：

- 经典模型 :固定表征 + 简单模型
- 核方法 :隐式高维表示
- 深度学习 :学习分层表征

核心思想 :现代机器学习的强大之处在于学习能够简化问题的表征方式。

关键组成部分。

- 表示 (特征)
- 函数 (映射)
- 优化 (学习)

深度学习以统一且可扩展的方式整合了这些组件。

14.6 展望

本章阐述了从经典模型向神经网络的过渡：

- 浅层模型的局限性，
- 成分结构的重要性，
- 深度架构的优势，
- 转向学习表征。

下一章 ,我们将通过研究神经网络来开始深度学习的研究。
网络作为组合函数逼近器。

指导原则 :复杂问题通常需要结构化的表示 ,而深度分析为构建这些表示提供了一种自然的方法。

第十五章

神经网络作为 成分模型

15.1 分层架构

神经网络的结构是由组织成层的简单变换组合而成。这种分层架构是其关键特征,使其能够对复杂的关系进行建模。

基本结构。一个具有 L 层的神经网络定义了一个函数。

$$f(x) = f_L \circ f_{L-1} \circ \dots \circ f_1(x),$$

其中每一层都具有以下形式

$$f_\ell(z) = \sigma(W_\ell z + b_\ell).$$

成分。

- W_ℓ : 权重矩阵
- b_ℓ : 偏置向量
- σ : 非线性激活函数

前向传播。给定输入 x , 网络计算中间表示:

$$z^{(1)} = f_1(x), z^{(2)} = f_2(z^{(1)}), \dots, z^{(L)} = f_L(x).$$

解释。

- 每一层都会改变数据的表示方式。

第15章 神经网络作为组合模型

最终输出取决于连续的改进。

常用激活函数。

- ReLU: $\sigma(z) = \max(0, z)$
- Sigmoid 函数: $\sigma(z) = \frac{1}{1+e^{-z}}$
- tanh: $\sigma(z) = \tanh(z)$

非线性作用。如果没有非线性激活函数,线性层的组合就会简化为单一的线性变换。

洞察:非线性使神经网络能够表示复杂的非线性关系。

15.2 表现力和深度

一个核心问题是神经网络的架构如何影响其表达能力。

宽度与深度。

- 宽度:每层单元数
- 深度:层数

浅层网络与深层网络。

- 浅层网络:层数少,但可能非常宽
- 深度网络:层数很多,通常更窄

关键观察:深度使得函数能够更有效地表示。

例如(复合函数)。具有层级结构的函数可以用深度网络简洁地表示,但在浅层网络中可能需要指数级数量的参数。

几何直觉。每一层都会重塑输入空间,逐步将复杂的结构转化为更简单的结构。

分段线性。采用 ReLU 激活函数的网络代表具有多个区域的分段线性函数。

洞察力。深度使线性区域的数量呈指数级增长,从而增强表现力。

权衡。

- 更深的深度 → 更高的表现力
- 但优化也更具挑战性

15.3 通用逼近（洞察）

一个基本的理论结果解释了为什么神经网络是强大的逼近器。

通用逼近（非正式）。具有单个隐藏层和合适激活函数的前馈神经网络,在给定的足够宽的紧致域上,可以逼近任何连续函数。

解释。

- 神经网络具有高度表达能力
- 即使是浅层网络也能近似复杂函数

局限性。

- 该定理并未具体说明需要多少个单位。
- 实践学习可能比较困难

深度的作用。虽然理论上浅层网络已经足够,但深层网络通常能提供更高效率的表示。

洞察力。普遍近似保证了存在性,但不能保证效率或可学习性。

与实践相结合。深度架构之所以受欢迎,是因为它们:

- 需要的参数更少,
- 在很多情况下更容易训练,
- 与数据中的组成结构保持一致。

15.4 表征学习

神经网络的一个显著特点是能够自动学习表征。

学习到的特征。每一层都会生成一个表示。

$$z^{(\ell)} = f_{\ell}(z^{(\ell-1)}),$$

它对输入信息进行编码。

表征层级。

- 早期图层:局部或低级特征
- 中间层:图案和结构

第15章 神经网络作为组合模型

- 最后几层:特定任务特征

与传统方法形成对比。

- 传统模型使用固定特征图
- 神经网络从数据中学习特征

几何视角。每一层都会改变数据的几何形状,使其更容易分离或建模。

组合式学习。特征是通过跨层组合更简单的特征而构建的。

诠释。学习包含两方面的发现:

- 如何表示数据,
- 如何将表示形式映射到输出。

洞察。表征学习是深度学习在各个领域取得成功的关键原因。

15.5 统一的视角

可以从三个互补的角度来理解神经网络:

- 函数:非线性函数的复合
- 几何变换:数据表示的变换
- 计算:分层处理架构

核心组件。

- 参数 ($W\ell$, $b\ell$)
- 非线性激活
- 组成结构

关键洞见:神经网络的强大之处不仅在于其表达能力,还在于其通过组合学习结构化表征的能力。

15.6 展望

本章介绍了神经网络作为组合模型：

- 分层架构，
- 深度在表现力中的作用，
- 以普适逼近作为理论基础，
- 表征学习是核心原则。

下一章,我们将研究如何高效地训练神经网络。
采用反向传播和自动微分。

指导原则 :复杂函数通常可以理解为简单函数的组合,而神经网络提供了一个从数据中学习此类组合的框架。

第15章 神经网络作为组合模型

第十六章

反向传播和 自动微分

16.1 计算图

神经网络是由多个函数组成的。为了高效地计算梯度,将这些计算过程显式地表示出来是很有用的。

计算图。计算图是一种有向无环图(DAG),它表示如何通过更简单的操作构建函数。

节点和边。

- 节点表示变量或中间值
- 边表示函数依赖关系

例如,考虑一个简单的函数

$$z = (x_1 + x_2) \cdot x_3。$$

我们可以将其表示为一个图:

- $a = x_1 + x_2$
- $z = a \cdot x_3$

前向传递。我们从输入到输出评估图,计算所有中间值。

洞察。神经网络是一个大型计算图,其中每一层都对应一组操作。

第十六章 反向传播和自动微分

16.2 链式法则和逆模微分
汇报

要训练神经网络,我们必须计算损失函数对所有参数的梯度。

链式法则。对于函数复合,

$$f(x) = f_L(f_{L-1}(\dots f_1(x))),$$

导数是通过重复应用链式法则得到的。

局部导数。计算图中的每个节点都贡献一个局部导数。

反向模式微分。通过将灵敏度从输出端反向传播到图中来计算梯度。

基本原理。如果变量 z 通过中间变量依赖于 x ,那么

$$\frac{\partial L}{\partial x} = \sum_{\text{路径}} \frac{\partial L}{\partial z} \cdot \frac{\partial z}{\partial x}.$$

反向传播。将梯度在网络中反向传播的过程称为反向传播。

例如,对于 $z = a \cdot x^3$ 和 $a = x_1 + x_2$,

$$\frac{\partial z}{\partial x_1} = \frac{\partial z}{\partial a} \cdot \frac{\partial a}{\partial x_1}.$$

洞察。反向传播系统地将链式法则应用于整个计算图。

16.3 高效梯度计算

简单地计算梯度会消耗大量的计算资源,特别是对于深度网络而言。

核心思想:重用前向传递过程中的中间计算结果。

向前传球。

- 计算所有中间值
- 储存起来以备重复使用

向后传球。

- 按相反顺序计算梯度

- 重用已存储的中间值

复杂度。反向传播计算梯度的成本与计算函数本身的成本相当。

梯度流。梯度逐层传播：

$$\frac{\partial L}{\partial W\ell} \quad \text{取决于} \quad \frac{\partial L}{\partial z(\ell)}。$$

共享子计算。计算图确保重复操作只计算一次。

洞察：反向传播之所以高效，是因为它避免了冗余计算并利用了网络结构。

16.4 实施视角

现代机器学习框架使用自动微分来实现反向传播。

自动微分（AD）。

- 计算精确导数（达到数值精度）
- 适用于可微运算的任意组合

AD的两种模式。

- 前向模式
- 反向模式（用于深度学习）

为什么使用反向模式？当函数有很多参数但只有一个输出时（这在学习问题中很常见），反向模式效率很高。

实际工作流程。

1. 将模型定义为计算图
2. 执行前向传播以计算损失
3. 使用自动微分计算梯度
4. 使用优化算法更新参数

内存方面的考虑。

- 必须存储中间值以进行反向传递

大型模型需要谨慎的内存管理。

第十六章 反向传播和自动微分

数值问题。

- 梯度消失和梯度爆炸
- 有限精度算术

洞察。自动微分抽象化了梯度计算的复杂性,使从业者能够专注于模型设计。

16.5 统一的视角

反向传播将几个核心概念联系起来:

- 数学:导数的链式法则
- 计算:中间值的有效重用
- 算法:深度网络的可扩展训练

关键组成部分。

- 计算图
- 前传
- 后传

核心见解:反向传播算法通过系统地应用链式法则,能够高效地训练复杂模型。

16.6 展望

本章介绍了反向传播和自动微分:

- 计算图作为模型的表示,
- 反向模式微分以实现高效梯度,
- 通过自动微分实现实际应用。

下一章,我们将研究训练深度网络所面临的挑战。
包括初始化和梯度相关问题。

指导原则:高效的梯度计算是现代深度学习成为可能的关键。

第十七章

训练深度网络

17.1 初始化策略

训练深度神经网络涉及在高维参数空间中优化高度非凸的目标函数。初始化的选择对优化是否成功起着至关重要的作用。

随机初始化。参数通常是随机初始化的：

$w_{\ell}^{(0)}$ 分布， $b(0)$ 等于 0 或较小的值。

为什么不初始化为零呢？

- 对称性:所有单元的行为都完全相同
- 不会发生任何有意义的学习。

方差保持。一个关键原则是选择合适的初始化方法,使得激活值在层间传播时既不会消失也不会爆炸。

示例 (Xavier/Glorot 初始化)。

$$\text{Var}(W_{ij}) \approx \frac{2}{n_{in} + n_{out}}。$$

示例 (He 初始化)。

$$\text{Var}(W_{ij}) \approx \frac{2}{n_{in}}。$$

洞察:正确的初始化能够维持信号在各层之间的稳定传播。

对训练的影响。

- 良好的初始化 → 更快的收敛速度
- 初始化不良 → 训练缓慢或失败

17.2 消失梯度和爆炸梯度

训练深度网络的一个主要困难源于梯度的行为。

梯度传播。反向传播涉及重复乘以权重矩阵及其导数：

$$\frac{\partial L}{\partial z(\ell)} = \frac{\partial L}{\partial z(\ell+1)} W_{(\ell+1)}' \cdot \sigma'_{\ell+1}(z(\ell+1))$$

梯度消失。

- 梯度随深度呈指数级缩小
- 早期层学习速度非常慢

梯度爆炸。

- 梯度呈指数增长
- 导致不稳定和数值问题

原因。

- 重复乘以较小或较大的值
- 饱和激活函数（例如, sigmoid 函数）

缓解策略。

- 谨慎初始化
- 使用非饱和激活函数（例如, ReLU）
- 归一化方法
- 渐变裁剪

洞察 : 稳定的梯度流对于深度网络的有效学习至关重要。

17.3 优化挑战

深度网络引入了比经典模型所面临的优化挑战更大的挑战。

非凸性。损失函数存在许多局部最小值和鞍点。

高维性。参数空间可以包含数百万甚至数十亿个变量。

鞍点。

- 比局部最小值不良的情况更常见
- 可能会减慢优化速度

平坦区域与尖锐区域。

- 平坦地区 :进展缓慢
- 尖锐区域 :不稳定

病态条件。不同方向的曲率可能差异很大,这使得优化变得困难。

实用策略。

- 使用随机优化算法 (SGD)
- 应用动量或自适应方法
- 对输入和激活值进行归一化

洞察。尽管理论上很复杂,但由于现实世界问题的结构性,简单的优化方法在实践中往往效果很好。

17.4 实证训练行为

训练深度网络时经常会表现出一些理论无法完全解释的特征模式。

训练动态。

- 损失初期迅速下降
- 后期收敛速度较慢

泛化行为。

- 训练损失可能接近于零
- 测试性能可能仍然良好

双下降法 (非正式说法)。增加模型规模可能会先增加后减少检验误差。

过度参数化的作用。

- 大型模型更容易优化

许多解决方案都能实现较低的训练误差。

隐式正则化。优化动力学倾向于某些解,这些解通常具有良好的泛化性能。

学习曲线。

- 绘制训练误差和验证误差随时间变化的曲线
- 用于诊断欠拟合和过拟合

实际观察。

- 更大的数据集可以提高性能
- 更深层的模型可以捕捉到更多结构
- 通常需要仔细调校

洞察力。当理论不完善时,经验行为可以提供重要的指导。

17.5 统一的视角

深度网络的训练涉及多个相互作用的组件:

- 初始化:设置起始点
- 梯度流:决定信号传播
- 优化:应对损失局面
- 数据和模型规模:影响泛化能力

核心挑战:确保在高维非凸环境下进行稳定高效的训练。

关键见解:成功的训练取决于架构、初始化和优化的协调一致。

17.6 展望

本章探讨了训练深度网络的实际挑战:

- 初始化策略,
- 消失的梯度和爆炸的梯度,
- 优化困难,
- 经验训练行为。

下一章,我们将研究激活函数和架构设计
这些选择会进一步影响深度网络的行为。

指导原则:训练深度网络需要平衡数学原理和经验洞察。

第十八章

激活函数和架构

18.1 非线性激活

非线性激活函数是神经网络的基本组成部分。它们使网络能够表示仅靠线性变换无法捕捉的复杂非线性关系。

激活函数的作用。神经网络中的每一层都应用如下形式的变换：

$$z \rightarrow \sigma(Wz + b),$$

其中 σ 是逐元素应用的。

为什么非线性是必要的？如果 σ 是线性的，那么多层组合就简化为单一的线性变换：

$$W_L W_{L-1} \cdots W_1 x,$$

消除了深度带来的优势。

常用激活函数。

- 乙状结肠：

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

- Tanh：

$$\sigma(z) = \tanh(z)$$

- ReLU（修正线性单元）：

$$\sigma(z) = \max(0, z)$$

第18章 激活函数和架构

特性。

- S形函数和tanh函数都很平滑,但可能会饱和
- ReLU 函数简单易用,避免了正值区域的饱和现象

变体。

- 泄漏 ReLU
- ELU
- GELU

梯度行为。

- 饱和激活 → 梯度消失
- 分段线性激活函数 → 稳定梯度

洞察 :激活函数的选择对表达能力和优化动力学都有着显著的影响。

18.2 建筑设计模式

除了各个层之外,神经网络的整体结构对其性能也起着至关重要的作用。

全连接网络。每一层都与前一层的所有单元相连。

卷积架构。

- 利用空间局部性
- 在不同地点共享参数

残余连接。

- 添加层之间的身份映射：

$$z^{(\ell+1)} = z^{(\ell)} + F(z^{(\ell)})$$

- 改善梯度流量和稳定性

归一化层。

- 批量归一化
- 层归一化

模块化设计。现代架构通常由重复的模块组成（例如,卷积模块、Transformer模块）。

洞察力。建筑设计蕴含着引导学习的归纳偏见。

18.3 深度与宽度

神经网络的结构以其深度和宽度为特征。

宽度。每层单元数。

深度。层数。

浅层宽带网络。

- 可以近似许多函数
- 可能需要大量参数

深度网络。

- 捕捉层级结构
- 通常参数效率更高

表达能力比较。某些功能可以用深度网络高效表示,但却需要指数级规模的浅层网络。

优化考量。

- 更深的网络更难训练
- 诸如残余连接之类的技术可以缓解这种情况。

洞察力。深度提供了一种编码组成结构的自然方式。

18.4 表达能力方面的考虑

神经网络的表达能力取决于其架构和激活函数。

表达能力。模型近似各种函数的能力。

影响表达能力的因素。

- 深度和宽度
- 激活函数的选择
- 连接结构

分段线性网络。ReLU 网络表示由多个线性区域组成的函数。

从几何角度来看,每一层都会对输入空间进行划分,从而增加表示的复杂性。

权衡取舍。

第18章 激活函数和架构

- 高表达力 → 更好的近似效果
- 但会增加过拟合的风险和优化难度。

隐式约束。架构限制了可以表示的函数类别,从而提供了归纳偏置。

洞察力。仅仅具备表达能力是不够的;有效的学习需要在表征能力和可训练性之间取得平衡。

18.5 统一的视角

激活函数和架构共同决定:

- 信息如何在网络中流动,
- 如何表示复杂函数,
- 模型训练的难易程度。

核心组件。

- 非线性激活
- 层连接
- 建筑模式

关键见解。神经网络架构的设计是现代机器学习的核心方面,它将数学结构与经验性能相结合。

曼斯。

18.6 展望

本章探讨了激活函数和架构的作用:

- 非线性激活函数能够实现表达模型,
- 塑造学习的架构模式,
- 深度和宽度之间的权衡,
- 影响表达能力的因素。

下一章,我们将学习归一化方法,它们起着关键作用。
在稳定和加速训练中。

指导原则:深度学习系统的有效性不仅取决于其规模,还取决于其结构。

第十九章

归一化方法

19.1 批次归一化

训练深度神经网络对激活值的规模 and 分布非常敏感。归一化方法通过标准化中间表示来解决这个问题。

批量归一化 (BatchNorm)。给定一层中的激活值 z , 批量归一化按如下方式对其进行变换:

$$z_i = \frac{z_i - \mu_B}{\sqrt{\hat{\sigma}_B^2 + \epsilon}},$$

其中 μ_B 和 $\hat{\sigma}_B^2$ 是小批量计算的均值和方差。

仿射变换。归一化之后, 应用可学习变换:

$$y_i = \gamma z_i + \beta,$$

其中 γ 和 β 是参数。

目的。

- 稳定激活分布
- 改善梯度流量
- 加快培训

解释: 批量归一化降低了对参数和输入尺度的敏感性。

训练与推理。

- 训练期间: 从小批量数据计算统计数据
- 在推断过程中: 使用运行平均值。

实际效果。

- 允许更大的学习速率
- 降低对初始化的依赖

19.2 层和实例归一化

虽然 BatchNorm 依赖于批次统计信息,但其他归一化方法独立于批次运行。

19.2.1 层归一化

定义:层归一化是指对单个数据点内的所有特征进行归一化处理。

$$z = \frac{z - \mu_{\text{层}}}{\sqrt{2\sigma_{\text{层}}^2 + \epsilon}}$$

特性。

- 与批次大小无关
- 适用于序列模型 (例如,Transformer)

19.2.2 实例归一化

定义。实例归一化是指对每个样本进行独立归一化,通常在视觉任务中跨空间维度进行归一化。

应用程序。

- 图像生成
- 风格转移

方法比较。

- 批量归一化:使用批量统计信息
- LayerNorm:使用每个样本的特征统计信息
- 实例归一化:使用每个样本的空间统计数据

洞察:不同的归一化方法反映了对数据结构的不同假设。

19.3 训练的稳定性

归一化方法可以提高训练的稳定性和效率。

对优化的影响。

- 平滑损失曲线
- 降低对参数缩放的敏感性
- 改善体能

梯度流。

- 防止梯度消失和爆炸
- 保持信号稳定传播

内部协变量偏移（非正式）。随着训练过程中参数的变化,激活分布也会发生变化。归一化可以减少这种影响。

正则化效应。

- BatchNorm 通过批次统计引入噪声
- 可以提高泛化能力

学习率交互作用。

- 支持使用更大的学习率
- 有助于加快收敛速度

洞察:归一化重塑了优化问题,使其更容易解决。

19.4 理论与实践见解

尽管归一化方法被广泛应用,但对其理论的理解仍在不断发展。

尺度不变性。归一化使网络对参数尺度变化的敏感性降低。

重新参数化。归一化可以看作是改变模型参数化的方式,这会影响优化动态过程。

优化的几何结构。归一化有效地改变了损失函数的几何结构,通常使其条件数更高。

经验观察。

- 提高训练速度
- 增强跨架构的稳定性
- 在许多现代深度网络中至关重要

局限性。

- BatchNorm 取决于批次大小
- 处理极小批量产品时可能表现不佳

设计考量。

- 归一化方法的选择取决于架构和数据
- 通常与其他技术结合使用（例如，残余连接）

洞察。归一化既是一种实用工具，也是一种提高优化效果的概念机制。

19.5 统一的视角

归一化方法可以理解为以下变换：

- 标准化表示方法，
- 改善体能状况，
- 稳定梯度流，
- 引入隐式正则化。

核心组件。

- 归一化步骤
- 可学习的扩展和调整
- 与优化动力学的交互

关键见解：归一化在使深度网络能够大规模训练方面起着核心作用。

19.6 展望

本章探讨了深度学习中的归一化方法：

- 批次归一化及其变体，
- 其他标准化策略，
- 他们在稳定训练中的作用，
- 理论和实践视角。

下一章,我们将研究深度学习特有的正则化技术,包括 dropout 和数据增强。

指导原则:精心设计的中间表示变换可以显著提高优化和泛化能力。

第二十章

深度正则化学习

20.1 丢包和噪声注入

深度神经网络具有很强的表达能力,容易出现过拟合训练数据的情况。因此,正则化技术对于提高泛化能力至关重要。

Dropout。Dropout 是一种随机正则化方法,在训练过程中随机停用某些单元。

机制。对于每个单元,都会对一个二进制掩码进行采样:

$$m_i \sim \text{Bernoulli}(p),$$

激活过程会进行相应修改。

$$z_i = m_i z_i。$$

解释。

- 每次迭代训练一个不同的子网络
- 防止特征的共同适应

推断。在测试时,激活值会进行缩放以弥补 dropout:

$$z_i \leftarrow p z_i。$$

影响。

- 提高稳健性
- 减少过拟合

噪声注入。更广义地说,可以将噪声添加到输入、激活值或参数中:

$$\mathbf{z} \leftarrow \mathbf{z} + \boldsymbol{\varepsilon},$$

其中 $\boldsymbol{\varepsilon}$ 为随机噪声。

洞察。噪声促使模型学习对微小扰动不敏感的稳定特征。

20.2 重量衰减

权重衰减是深度学习中最广泛使用的正则化技术之一。

客观的。

$$\min_{\boldsymbol{\theta}} \mathcal{R}(\boldsymbol{\theta}) + \lambda \|\boldsymbol{\theta}\|_2^2.$$

解释。

- 对较大的参数值进行惩罚
- 鼓励采用更简单的模型

对优化的影响。更新规则变为

$$\boldsymbol{\theta}_{t+1} = (1 - \eta\lambda)\boldsymbol{\theta}_t - \eta \nabla \mathcal{R}(\boldsymbol{\theta}_t).$$

洞察。训练过程中,参数逐渐缩小至零。

与稳定性相关。较小的权重通常能带来更平滑的函数和更好的泛化能力。

贝叶斯解释。权重衰减对应于参数的高斯先验分布。

20.3 数据增强

数据增强通过人为地增加训练数据的多样性来提高泛化能力。

基本思路:通过应用变换生成新的训练样本:

$$(x, y) \rightarrow (T(x), y),$$

其中 T 保留标签。

示例(视觉)。

- 旋转、平移、缩放

- 翻转、裁剪
- 颜色扰动

示例（其他领域）。

- 输入噪声注入
- 文本中的同义词替换

解释。

- 编码不变性（例如,旋转不变性）
- 扩大有效数据集大小

几何视图。数据增强扩大了与每个标签关联的输入空间区域。

洞察。数据增强通过约束函数在变换下保持一致的行为,起到了一种正则化的作用。

20.4 优化的隐性偏差

深度学习中的正则化并不局限于显式方法。优化本身也会引入某种形式的隐式偏差。

过度参数化。深度网络通常拥有比数据点更多的参数,导致许多解的训练误差为零。

关键问题:优化算法会选择哪个方案?

隐性偏见。基于梯度的方法往往倾向于具有特定属性的解,例如:

- 小规范,
- 功能流畅,
- 某些结构模式。

例如（线性模型）。梯度下降法收敛于所有插值解中的最小范数解。

深度学习视角。

- SGD噪声会影响优化轨迹

不同的优化器会得到不同的解决方案。

洞察。训练过程本身就起到了一种规范化的作用。

与显式正则化的交互。隐式正则化和显式正则化通常共同作用,塑造学习到的模型。

20.5 统一的视角

深度学习中的正则化有多种形式：

- 显式 :权重衰减、dropout
- 数据驱动 :增强
- 隐式 :优化动态

核心目标。

拟合数据并促进推广应用。

关键见解 :泛化能力不仅取决于模型本身 ,还取决于模型的训练方式及其所接触的数据。

20.6 展望

本章探讨了深度学习特有的正则化技术：

- 丢包和噪声注入，
- 体重下降，
- 数据增强，
- 优化过程中存在的隐性偏见。

下一章 ,我们将研究残差网络和跳跃连接，
在实现超深架构方面发挥关键作用。

指导原则 :有效的正则化源于模型结构、数据转换和优化动态的结合。

第21章

残差网络和 跳过连接

21.1 退化问题

随着神经网络深度的增加,人们可能会预期其性能会因表达能力的增强而提升。然而,在实践中,更深的网络训练起来可能更加困难。

观察发现,即使更深的模型可以表示与较浅模型相同的功能,增加模型深度也可能导致更高的训练误差。

性能下降问题。

- 更深的网络性能不如更浅的网络。
- 并非由于过拟合,而是由于优化难度。

直觉告诉我,理论上,增加层数可以学习恒等映射关系并保持性能。然而,标准的训练流程很难找到这样的解决方案。

与梯度连接。

- 深邃的构图放大了消失和爆发的渐变效果
- 信息可能在各层之间劣化

洞察力。深度增强了表现力,但也带来了优化方面的挑战,这些挑战必须通过架构设计来解决。

第21章 残差网络和跳跃连接

21.2 残差学习

残差网络 (ResNets)通过引入跳跃连接来解决退化问题。

残余块。

$$z^{(\ell+1)} = z^{(\ell)} + F(z^{(\ell)}),$$

其中 F 是一个可学习的变换。

解释。

- 网络学习的不是映射 $H(z)$,而是残差：

$$F(z) = H(z) - z$$

- 完整的映射关系变为 $H(z) = z + F(z)$

优势。

- 更容易学习身份的微小扰动
- 改善层间梯度流动
- 减少降解

梯度传播。梯度可以直接通过恒等连接传播：

$$\frac{\partial z^{(\ell+1)}}{\partial z^{(\ell)}} = I + \frac{\partial F}{\partial z^{(\ell)}}.$$

洞察力。跳跃连接为信息和梯度提供了替代路径,从而稳定了训练。

21.3 动力系统视角

残差网络可以解释为离散动力系统。

离散动力学。

$$z^{(\ell+1)} = z^{(\ell)} + F(z^{(\ell)}).$$

连续时间类比。这类似于常微分方程的离散化：

$$\frac{dz(t)}{dt} = F(z(t)).$$

欧拉离散化。步长 $\Delta t = 1$,

$$z(t + \Delta t) \approx z(t) + \Delta t F(z(t)).$$

解释。

- 各层对应于时间步长

网络深度对应于随时间推移的演变

稳定性。残余连接有助于在表征空间中维持稳定的轨迹。

洞见:将神经网络视为动态系统,可以为理解其深度、稳定性和训练动态提供一个框架。

21.4 非常深的架构

残差连接使得训练极深的网络成为可能。

经验观察。

- 可以成功训练拥有数百层或数千层的网络。
- 使用残余连接时,性能会随着深度的增加而提高

建筑模式。

- 堆叠剩余块
- 与归一化层结合
- 利用瓶颈结构提高效率

扩展行为。

- 更深层的模型可以捕捉到更复杂的模式
- 由于跳跃连接,训练保持稳定

泛化能力。残差网络尽管容量很大,但通常也具有好的泛化能力。

局限性。

- 计算成本增加
- 架构复杂性

洞察力。精心的建筑设计使深度感在实际应用中变得切实可行。

第21章 残差网络和跳跃连接

21.5 统一的视角

残差网络展示了架构创新如何解决深度学习中的根本挑战。

关键组成部分。

- 跳过连接
- 残差映射
- 稳定梯度流

核心理念。

- 学习扰动而不是完整的变换
- 通过身份映射促进优化
- 将网络解释为动态系统

关键洞见 :架构设计可以从根本上改变学习算法的行为。

21.6 展望

本章介绍了残差网络和跳跃连接：

- 深度网络中的退化问题，
- 残差学习作为一种解决方案，
- 与动力系统的联系，
- 支持非常深层的架构。

下一章,我们将研究卷积神经网络,它利用数据中的空间结构。

指导原则 :有效的架构将数学结构与实际考量相结合,使深度学习能够大规模应用。

第22章

卷积神经网络

22.1 卷积作为结构化线性运算

托尔

卷积神经网络 (CNN)旨在利用数据中的结构,特别是图像和信号中的结构。其核心操作是卷积,可以理解为一种结构化的线性变换。

离散卷积。对于一维输入 $x \in \mathbb{R}^n$ 和核 $w \in \mathbb{R}^k$, 卷积定义为

$$(y \otimes w)_i = \sum_{j=1}^k w_j x_{i-j}。$$

二维卷积。对于图像,卷积应用于空间维度:

$$y(i, j) = \sum_{u, v} w(u, v) x(i - u, j - v)。$$

紫外线

线性算子视角。卷积可以写成矩阵向量乘法:

$$y = Kx,$$

其中 K 是一个结构化 (托普利兹或块托普利兹) 矩阵。

关键特性: 参数共享。

- 所有位置均采用相同的内核
- 减少参数数量

本地连接。

每个输出仅取决于输入的局部区域。

- 反映数据中的空间局部性

洞察:卷积为线性变换赋予结构,使其高效且适用于结构化数据。

22.2 平移不变性

卷积架构的一个关键动机是平移不变性。

平移等变性。卷积层满足:

$$x(\cdot - \tau) \rightarrow y(\cdot - \tau),$$

这意味着输入发生偏移,输出也会相应偏移。

解释。

- 在一个位置检测到的特征也可以在其他位置检测到。
- 该模型不依赖于绝对位置

从等变性到不变性。

- 等变性保留了空间结构
- 不变性消除了对位置的敏感性

实现不变性。

- 联合运营
- 全局平均

洞察力。平移不变性反映了视觉感知的一个关键特性:无论物体位于何处,都可以被识别。

22.3 池化和层级结构

卷积神经网络通常包含池化操作,可以在降低空间分辨率的同时保留重要特征。

汇集。

- 最大池化:选择区域内的最大值
- 平均池化:计算平均值

22.4. 视觉应用

117

影响。

- 降低维度
- 引入了对小变换的不变性

层级结构。

- 前几层检测简单特征（边缘、纹理）
- 中间层检测模式（形状、部件）· 深层检测复杂结构（物体）

感受野。影响特定单元的输入区域随深度增加而增大。

洞察。卷积神经网络以分层的方式构建表征,将局部特征组合成全局模式。

22.4 视觉应用

卷积神经网络在视觉任务中取得了显著的成功。

图像分类。

- 给图像分配标签
- 例如:物体识别

目标检测。

- 识别并定位图像中的物体

分割。

- 为每个像素分配标签
- 能够详细了解场景

生成式建模。

- 图像合成
- 超分辨率

建筑实例。

- 卷积层 + 池化
- 残余连接
- 编码器-解码器结构

洞察。卷积神经网络之所以有效,是因为它们将特定领域的结构融入到模型中。

22.5 统一的视角

卷积神经网络融合了几个关键思想：

- 结构化线性算子:卷积
- 归纳偏置:局部性和平移不变性
- 层级结构:多尺度表征学习

核心组件。

- 卷积层
- 非线性激活
- 联合运营

关键见解:通过在架构中融入结构,卷积神经网络 (CNN)能够同时实现高效性和强大的泛化能力。

22.6 展望

本章介绍了卷积神经网络：

- 卷积作为一种结构化的线性算子，
- 平移等变性和不变性，
- 分层特征学习，
- 在视觉领域的应用。

下一章,我们将研究序列模型,它是神经网络的扩展。
适用于序列数据和时间序列数据。

指导原则:有效的模型会充分利用其所要处理的数据结构。

第23章

序列模型

23.1 循环神经网络

许多现实世界的数据类型都是顺序的,包括时间序列、文本和语音。序列模型旨在捕捉随时间推移的依赖关系。

循环神经网络 (RNN)。RNN通过维护一个随时间演变的隐藏状态 h_t 来处理序列 $(x_1, x_2, \dots, x_T)$:

$$\begin{aligned} h_t &= (W_h h_{t-1} + W_x x_t + b), \\ y_t &= \psi(W_y h_t + c), \end{aligned}$$

其中 ψ 是非线性函数。

解释。

- h_t 总结了过去的信息
- 相同的参数在各个时间步中重复使用。

参数共享。与前馈网络不同,循环神经网络 (RNN)可以跨时间共享权重,这使得它们适用于可变长度序列。

随着时间的推移,循环神经网络 (RNN)可以被视为具有共享参数的深度网络:

$$h_1 \rightarrow h_2 \rightarrow \dots \rightarrow h_T。$$

洞察。循环神经网络通过递归更新隐藏状态来建模时间依赖性。

23.2 门控架构 (LSTM、GRU)

标准循环神经网络难以捕捉长期依赖关系。门控架构可以解决这一局限性。

23.2.1 长短期记忆网络 (LSTM)

核心思想:引入一种能够长期保存信息的记忆细胞。

盖茨。

- 输入门:控制新信息
- 遗忘门:控制要丢弃的内容
- 输出门:控制要输出的内容

结构 (概念)。

- 细胞状态通过受控更新而演变

闸门控制信息流

影响。

- 有助于了解长期依赖关系
- 缓解梯度消失问题

23.2.2 门控循环单元 (GRU)

简化架构。

- 结合了输入和遗忘机制
- 参数比 LSTM 少

更新机制。

- 更新门控存储器保持
- 重置门控制过去状态的影响

洞察。门控机制使网络能够动态控制信息流。

23.3 长期依赖关系

序列建模的核心挑战在于如何捕捉长时间跨度内的依赖关系。

问题。

- 早期时间步骤的信息可能会丢失
- 梯度可能会在反向传播过程中消失

时间反向传播 (BPTT)。训练循环神经网络 (RNN) 涉及在多个时间步长内传播梯度：

$$\frac{\partial L}{\partial h_t} = \frac{\partial L}{\partial h_T} \prod_{k=t}^{T-1} \frac{\partial h_{k+1}}{\partial h_k}.$$

梯度行为。

- 重复乘法会导致梯度消失或梯度爆炸

门控机制的作用。

- 为渐变流动提供更顺畅的路径
- 允许选择性记忆保留

实用技巧。

- 渐变裁剪
- 截断反向传播

洞察。对长期依赖关系进行建模需要同时考虑架构和优化两方面因素。

23.4 复发的局限性

尽管循环架构具有诸多优势,但它们也存在一些重要的局限性。

顺序计算。

- 处理过程必须分步骤进行
- 限制并行化

难以处理长期依赖关系。

即使是门控架构也有其局限性。

- 信息可能会在长序列中降解

优化挑战。

训练可能不稳定

- 对超参数敏感

内存瓶颈。固定大小的隐藏状态必须概括整个历史过程。

洞察。循环为序列提供了一个自然的框架,但可能无法有效地扩展到复杂的长程依赖关系。

23.5 统一的视角

序列模型将神经网络扩展到时间序列数据:

- 状态:隐藏表征随时间演变
- 动态特性:递归更新定义了时间行为
- 记忆:信息存储在隐藏状态中

建筑演变。

- $RNN \rightarrow LSTM/GRU \rightarrow$ 基于注意力机制的模型

关键见解:序列模型的设计围绕着管理信息随时间推移的流动展开。

23.6 展望

本章介绍了序列模型:

- 循环神经网络,
- 门控架构,
- 长期依赖关系带来的挑战,
- 复发限制。

下一章,我们将研究注意力机制,它解决了许多问题。
循环模型的局限性。

指导原则:有效的序列建模需要建立机制,以便随着时间的推移保存和访问相关信息。

第24章

注意力与变形金刚

24.1 注意力机制

基于循环的序列模型将过去的信息压缩到一个固定大小的隐藏状态中。这在对长序列进行建模时会造成瓶颈。

注意力机制的核心思想是：它不依赖于单一的隐藏状态，而是允许模型直接访问输入的所有相关部分。

查询键值框架。注意力由三个组成部分构成：

- 查询 (q)
- 键(ki)
- 价值观（六）

注意力权重。

$$\alpha_i = \frac{\exp(q, k_i)}{\sum_j \exp(q, k_j)}$$

输出。

$$\text{Attn}(q, K, V) = \sum_i \alpha_i v_i$$

解释。

- 该查询确定哪些输入是相关的
- 权重 α_i 代表重要性

洞察力。注意力以灵活的、数据依赖的机制取代了固定的记忆。

24.2 自我关注

自我注意是指在单个序列内应用注意力机制。
定义:序列中的每个元素都关注所有其他元素。

构造。给定输入 $x_1, \dots, x_T$ ，定义：

$$q_i = W_Q x_i, \quad k_i = W_K x_i, \quad v_i = W_V x_i。$$

注意力输出。

$$y_i = \sum_{j=1}^T a_{ij} v_j, \quad a_{ij} = \frac{\exp(-q_i, k_j)}{\sum_l \exp(-q_i, k_l)}。$$

特性。

- 捕获所有位置之间的依赖关系
- 完全可跨序列元素并行化

位置编码。由于自注意力机制具有排列不变性,因此必须显式地添加位置信息。

洞察力。自我关注为建模序列中的关系提供了一种灵活的机制。

24.3 Transformer架构

Transformer架构完全由注意力机制构建而成。

基本组成部分。

- 多头自我关注
- 前馈层
- 残余连接
- 归一化层

多头注意力机制。多个注意力机制并行应用：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(H_1, \dots, H_h)W_O,$$

其中每个头部 H_i 使用不同的投影来计算注意力。

前馈网络。

$$\text{FFN}(x) = \sigma(W_1x + b_1)W_2 + b_2。$$

残余结构。

$$\mathbf{x} \leftarrow \mathbf{x} + \text{Layer}(\mathbf{x}),$$

然后进行归一化处理。

建筑布局。

- 一叠相同的积木
- 每个模块 : 注意力 + 前馈

编码器-解码器结构。

- 编码器处理输入序列
- 解码器生成输出序列时会关注编码器的输出

洞察。Transformer 模型用注意力机制取代了循环,从而能够高效地对长程依赖关系进行建模。

24.4 扩展和应用

Transformer 模型在各个领域都展现出了卓越的可扩展性和性能。

扩展行为。

- 性能随模型规模、数据量和计算能力的增加而提高
- 支持训练非常大的模型

并行化。

- 与循环神经网络 (RNN) 不同,Transformer 并行处理序列。
- 高效利用现代硬件

应用程序。

- 自然语言处理 (翻译、文本生成)
- 视觉 (视觉转换器)
- 语音处理
- 多模态学习

预训练和微调。

- 基于海量数据集训练的大型模型

- 通过微调适应特定任务

局限性。

- 序列长度的二次复杂度
- 计算成本高

洞察。规模和数据可用性是现代深度学习性能的关键驱动因素。

24.5 统一的视角

注意力和转换器融合了几个概念：

- 表示 :输入的动态加权
- 计算 :序列的并行处理
- 架构 :模块化和可扩展的设计

核心组件。

- 查询键值关注
- 多头机构
- 残差层和归一化层

关键见解 :注意力机制提供了一种灵活的交互建模机制 ,取代了固定的顺序结构。

24.6 展望

本章介绍了注意力机制和转换器：

- 注意力作为一种灵活的记忆机制，
- 用于序列建模的自注意力机制，
- Transformer架构，
- 扩展行为和应用。

下一章 ,我们将研究生成模型 ,从概率建模和潜在变量方法开始。

指导原则 :现代架构的成功在于实现数据元素之间灵活、可扩展的交互。

第25章

生成式编程的基础 造型

25.1 密度估计和抽样

生成式建模旨在学习数据的潜在分布并从中生成新的样本。

目标:给定数据 $x = \text{pdata}$, 学习一个近似真实分布的模型 $p_\theta(x)$ 。

密度估算。

- 显式模型定义了概率密度 $p_\theta(x)$
- 学习通常基于最大似然法:

$$\theta_{\text{最大}} = \underset{\theta}{\text{argmax}} \mathbb{E}_{x \sim \text{pdata}} [\log p_\theta(x)].$$

采样。模型训练完成后,我们会生成新的样本:

$$x \sim p_\theta(x)。$$

两种视角。

- 基于似然性的方法:直接对 $p_\theta(x)$ 进行建模
- 隐式:定义采样过程而不显式地定义密度

挑战。

- 高维数据
- 复杂分布

- 高效采样

洞察。生成式建模既包括表示分布,也包括从中生成样本。

25.2 潜在变量模型

许多生成模型引入潜在变量来捕捉潜在结构。

潜在变量构建。

$$p_{\theta}(x) = \int p_{\theta}(x | z) p(z) dz,$$

其中 z 为潜在变量。

解释。

- z 代表隐藏的变异因素
- $p(z)$ 是一个简单的先验分布 (例如,高斯分布)

生成过程。

1. 样本 $z \sim p(z)$
2. 生成 $x \sim p_{\theta}(x | z)$

学习上的挑战。边际似然函数涉及一个难以处理的积分。

推断。我们引入近似后验 $q(z | x)$ 。

洞察。潜在变量提供了一种结构化的方法来模拟复杂的数据分布。

25.3 基于能源的视角

另一种观点通过能量函数来模拟概率分布。

基于能量的模型 (EBM)。

$$p_{\theta}(x) = \frac{\exp(-E_{\theta}(x))}{Z(\theta)},$$

其中 $E_{\theta}(x)$ 为能量函数, $Z(\theta)$ 为配分函数:

$$Z(\theta) = \int \exp(-E_{\theta}(x)) dx.$$

解释。

- 低能量 → 高概率

高能量 → 低概率

学习。

- 需要估计涉及 $Z(\theta)$ 的梯度
- 通常采用基于抽样的方法

与物理学的联系。基于能量的模型类似于统计力学中的分布。

洞察。基于能量的公式提供了一种灵活的方法来定义分布,而无需以闭合形式表示归一化密度。

25.4 生成模型的评估

由于高维分布的复杂性,评估生成模型具有挑战性。

基于可能性的评估。

- 对数似然
- 困惑度 (针对序列)

样品质量。

- 目视检查 (例如,图像)
- 人工评价 (例如,文本评价)

差异度量。

- Kullback-Leibler 散度
- 詹森-香农散度

分布指标。

- 初始评分
- 弗雷切起始距离 (FID)

挑战。

- 样本质量和多样性之间的权衡
- 高维空间中概率估计的难度

模式崩溃。某些模型产生的多样性有限,仅关注可能输出结果的子集。

洞察力。没有任何单一指标能够完全衡量生成模型的质量。

25.5 统一的视角

可以通过多个互补的框架来理解生成式建模：

- 概率:直接对 $p(x)$ 进行建模
- 潜在变量:引入隐藏结构
- 基于能量:通过能量定义分布

核心挑战。

- 高维建模
- 高效采样
- 可靠的评估

关键见解:生成模型旨在以一种既能理解又能综合数据的方式捕捉数据分布的结构。

25.6 展望

本章介绍了生成式建模的基础知识：

- 密度估计和抽样，
- 潜在变量模型，
- 基于能量的视角，
- 生成模型的评估。

在接下来的章节中,我们将研究特定类别的生成模型,包括变分自编码器、生成对抗网络和扩散模型。

指导原则:生成式建模不仅旨在预测数据,而且旨在理解和重现其潜在结构。

第二十六章

基于似然的潜在变量学习

26.1 最大似然估计

生成模型的核心原则之一是最大似然估计 (MLE)。其目标是选择能够最大化观测数据概率的模型参数。

目标。给定数据 $\{x_i\}_{i=1}^n$

我们最大化： $\prod_{i=1}^n p_{\theta}(x_i)$ ，

$$\text{最大} \theta \quad \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(x_i)。$$

解释。

- 鼓励模型为观测数据赋予高概率。
- 等价于最小化负对数似然

与散度的联系。最大似然估计法最小化 Kullback-Leibler 散度：

$$KL(p_{\text{data}} \parallel p_{\theta})。$$

坡度。

$$\nabla_{\theta} \log p_{\theta}(x)$$

对于显式模型,通常可以高效地计算。

洞察。最大似然估计提供了一种从数据中学习概率模型的原则性方法。

第26章 基于似然的潜在变量学习

26.2 隐变量和边缘化

潜在变量模型引入隐藏变量 z 来捕捉潜在结构。

边际似然。

$$p_{\theta}(x) = \int p_{\theta}(x, z) dz = \int p_{\theta}(x | z) p(z) dz。$$

对数似然值。

$$\log p_{\theta}(x) = \int \log p_{\theta}(x, z) dz。$$

解释。

- z 解释了 x 的变异性。
- 该模型整合了所有可能的潜在解释

挑战。对 z 的积分通常难以处理,尤其是在高维情况下。

后验分布。

$$p_{\theta}(z | x) = \frac{p_{\theta}(x, z)}{p_{\theta}(x)}。$$

洞察力。学习既需要评估边际可能性,也需要对潜在变量进行推理。

26.3 难解性和近似

精确计算边际似然通常是不可行的。

棘手问题的根源。

- 高维潜在空间
- 复杂似然函数

近似策略。

- 基于抽样的方法 (例如,蒙特卡罗方法)
- 确定性近似
- 变分法

蒙特卡罗近似法。

$$p_{\theta}(x) \approx \frac{1}{N} \sum_{i=1}^N p_{\theta}(x | z_i), \quad z_i \sim p(z)。$$

局限性。

- 高方差估计
- 计算成本高昂

另一种观点。我们不直接近似积分,而是近似后验概率 $p_{\theta}(z | x)$ 。

洞察。在潜在变量模型中,近似是不可避免的,它影响着理论和实践。

26.4 变分原理

变分法为近似求解难以处理的量提供了一个强大的框架。

变分分布。引入一个易于处理的分布 $q(z | x)$ 来近似真实的后验分布。

关键身份。

$$\log p_{\theta}(x) = \mathbb{E}_{q(z|x)} \log \frac{p_{\theta}(x, z)}{q(z|x)} + \text{KL}(q_{\psi}(z|x) \parallel p_{\theta}(z|x))。$$

证据下限 (ELBO) 。

$$\mathcal{L}(\theta, \Phi) = \mathbb{E}_{q_{\Phi}(z|x)} [\log p_{\theta}(x, z) - \log q_{\Phi}(z|x)]。$$

下界属性。

$$\mathcal{L}(\theta, \Phi) \leq \log p_{\theta}(x)。$$

分解。

$$\mathcal{L}(\theta, \Phi) = \mathbb{E}_{q_{\Phi}(z|x)} [\log p_{\theta}(x | z)] - \text{KL}(q_{\Phi}(z|x) \parallel p(z))。$$

解释。

- 第一项:重建质量
- 第二项:向先验正则化

第26章 基于似然的潜在变量学习

优化。

- 最大化关于 θ 和的ELBO
- 联合学习生成模型和推理模型

洞察力。变分方法将棘手的推理问题转化为优化问题。

26.5 统一的视角

基于似然的潜在变量学习涉及几个相互关联的概念：

- 最大似然估计:从观测数据中学习
- 潜在变量:对隐藏结构进行建模
- 近似法:处理难解积分
- 变分推断:基于优化的近似

核心权衡。

近似精度与计算可行性之间的权衡。

关键见解:引入潜在变量可以提高建模能力,但需要使用近似推断技术。

26.6 展望

本章介绍了基于似然的隐变量学习：

- 最大似然估计，
- 对隐性变量的边缘化，
- 棘手问题的挑战，
- 变分原理和ELBO。

下一章,我们将这些思想应用于变分自编码器，实用且应用广泛的生成模型。

指导原则:复杂的概率模型需要近似推断,而变分方法提供了一种有原则且可扩展的解决方案。

第27章

变分自编码器

27.1 潜在表征

变分自编码器 (VAE)是一种将潜在变量建模与神经网络相结合的生成模型。

核心思想:学习一个低维潜在表示 z ,以捕捉数据 x 的底层结构。

生成模型。

$$z \sim p(z), x \sim p_{\theta}(x | z),$$

其中 $p(z)$ 通常选择为标准高斯分布。

潜在空间。

- 连续的低维表示
- 对数据的语义结构进行编码

解释。

- 潜在空间中相邻的点对应于相似的数据
- 潜在空间中的插值会产生有意义的变化

目标:两者都要掌握。

- 生成模型 $p_{\theta}(x | z)$,
- 推理模型 $q(z | x)$ 。

洞察。潜在表示提供了一种结构化的方法来建模复杂的数据分布。

27.2 证据下限 (ELBO)

VAE 的训练方法是最大化上一章中引入的证据下限。

ELBO 目标。

$$L(\theta, \Phi) = \mathbb{E}_{q\Phi(z|x)} [\log p\theta(x | z)] - \text{KL}(q\Phi(z | x) \parallel p(z))。$$

解释。

- 第一项 :重建精度
- 第二项 :向先验正则化

权衡。

- 良好的重建与结构化潜在空间

重参数化技巧。为了优化期望值,我们将 z 表示为:

$$z = \mu\Phi(x) + \sigma\Phi(x) \odot \epsilon, \epsilon \sim N(0, I)。$$

益处。

- 支持基于梯度的优化
- 降低梯度估计的方差

洞察。ELBO 平衡了数据重构和潜在结构,构成了 VAE 训练的核心。

27.3 编码器-解码器架构

VAE 是在编码器-解码器框架中使用神经网络实现的。

编码器。

$$q(z |$$

$x)$ 将输入数据映射到潜在参数 $(\mu(x), \sigma(x))$ 。

解码器。

$$p\theta(x | z)$$

将潜在变量映射回数据空间。

建筑学。

- 编码器网络 :将数据压缩成潜在表示
- 解码器网络 :从潜在编码中重构数据

训练流程。

1. 将 x 编码为 (μ, σ)
2. 使用重参数化对 z 进行采样
3. 对 z 进行解码以重构 x
4. 计算 ELBO 并更新参数

采样。新数据通过以下方式生成：· 对 $z \sim p(z)$ 进

行采样 · 计算 $x \sim p_\theta(x |$

$z)$

洞察力。编码器-解码器结构将推理和生成整合到一个统一的框架中。

27.4 实际考虑因素

实现 VAE 涉及几个重要的设计选择。

选择可能性。

- 连续数据的高斯似然
- 二元数据的伯努利似然

KL 散度项。当 $q(z | x)$ 和 $p(z)$ 均为高斯分布时, 通常具有闭合形式。

后部塌陷。

- 该模型忽略了潜在变量
- $q(z | x)$ 接近 $p(z)$

缓解策略。

- KL 退火
- 更具表现力的解码器

潜在空间结构。

- 平滑性使得插值成为可能
- 正则化鼓励有意义的表示

评估。

- ELBO 作为培训目标
- 样品质量和多样性

洞察。实际性能取决于重构、正则化和模型容量之间的平衡。

27.5 统一的视角

变分自编码器结合了几个关键思想：

- 潜在变量建模
- 变分推断
- 神经网络参数化

核心组件。

- 编码器 $q(z|x)$
- 解码器 $p_\theta(x|z)$
- ELBO 目标

关键见解:VAE 为学习具有潜在结构的概率生成模型提供了一种可扩展的方法。

27.6 展望

本章介绍了变分自编码器：

- 潜在表征，
- ELBO 优化，
- 编码器-解码器架构，
- 实际考虑因素。

下一章,我们将研究生成对抗网络,它从不同的角度研究生成建模。

指导原则:将概率建模与神经网络相结合,可以实现灵活且可扩展的生成模型。

第28章

生成对抗网络

28.1 对抗性建模

生成对抗网络 (GAN) 提供了一种基于两个模型之间博弈的生成建模替代方法。

核心思想: 同时训练两个网络:

- 生成器 G_θ : 将噪声 $z \sim p(z)$ 映射到数据空间
- 判别器 D : 区分真实数据和生成数据

极小极大目标。

$$\min_{\theta} \max_D \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z \sim p(z)} [\log(1 - D(G_\theta(z)))].$$

解释。

生成器试图欺骗鉴别器。

- 鉴别器试图区分真假样本

均衡状态。在最优状态下, 生成器生成的样本与真实数据无法区分。

隐式建模。GAN 定义了一种采样过程, 而无需显式地对 $p_\theta(x)$ 进行建模。

洞察力。学习被描绘成两个相互竞争的目标之间的博弈。

28.2 散度最小化

GAN 可以理解为最小化分布之间的差异。

最优判别器。对于给定的生成器,最优判别器为:

$$D^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_{\theta}(x)}.$$

最终目标。代入D得到:

$$JS(p_{data} // p_{\theta}), \text{最小}$$

其中 JS 表示 Jensen-Shannon 散度。

解释。

- GAN训练隐式地最小化了分布之间的差异
- 随着分布越来越接近,生成器的性能也会提高。

局限性。

- 当支持集不重叠时,发散性可能表现不佳。

洞察:生成对抗网络 (GAN)将博弈论学习与统计散度最小化相结合。

28.3 训练不稳定性

由于目标的对抗性,训练 GAN 通常具有挑战性。

非凸非凹优化问题。极小极大问题通常无法稳定收敛。

模式崩溃。

- 发电机产生的输出种类有限
- 未能捕获完整的数据分布

振荡动力学。

- 生成器和鉴别器可能无法收敛
- 参数可能循环或发散

梯度问题。

28.4. 变体和改进

141

- 当判别器过强时,梯度会消失
- 由于对抗性反馈导致的不稳定更新

实用技巧。

- 仔细平衡生成器和鉴别器更新
- 标签平滑
- 梯度惩罚

洞察。对抗训练引入的动态特性与标准优化有着本质区别。

28.4 变体和改进

为了解决训练难题并提高性能,人们提出了许多 GAN 的变体。

Wasserstein GAN (WGAN)。

- 将JS散度替换为Wasserstein距离
- 改善稳定性和梯度行为

带有梯度惩罚的WGAN。

- 通过梯度惩罚强制执行 Lipschitz 约束

条件生成对抗网络 (GAN) 。

- 根据标签或输入生成样本

CycleGAN 和图像转换。

- 无需配对数据即可学习域之间的映射关系

基于风格的生成对抗网络 (GAN) 。

- 引入结构化潜在空间
- 实现对生成图像的精细控制

洞察:改进 GAN 通常涉及修改目标函数、网络架构或训练流程。

28.5 统一的视角

生成对抗网络 (GAN) 为生成建模提供了一种独特的方法：

- 隐式模型 : 定义采样时不显式地定义密度

对抗训练 : 两个网络竞争

- 发散度最小化 : 分布对齐

核心组件。

- 生成器 G_θ
- 鉴别器 D
- 极小极大目标

关键见解 : 对抗学习为生成建模提供了一个强大但极具挑战性的框架。

28.6 展望

本章介绍了生成对抗网络：

- 对抗性公式，
- 基于差异的解释，
- 训练挑战，
- 主要变化和改进。

下一章,我们将研究扩散模型,它为基于随机过程的生成建模提供了一种截然不同的方法。

指导原则。不同的生成框架在可处理性、稳定性和样本质量之间提供了不同的权衡。

第29章

流量标准化

29.1 变量替换公式

归一化流提供了一类基于概率分布可逆变换的生成模型。

核心思想。从简单的基本分布 $z \sim p(z)$ 开始,并将其转换为复杂的分布 $x = f_\theta(z)$ 。

变量替换公式。如果 f 可逆且可微,则

$$p_\theta(x) = p(z) \det \frac{\partial z}{\partial x}, \quad \text{其中 } z = f^{-1}(x)。$$

等价形式。

$$\log p_\theta(x) = \log p(z) + \log \det \frac{\partial z}{\partial x}。$$

解释。

- 密度随局部体积畸变而变化
- 该决定因素衡量扩张或收缩

洞察。归一化流可以将简单的分布转化为复杂的分布,同时跟踪密度变化。

29.2 可逆变换

规范化流的设计依赖于构建既具有表现力又计算高效的可逆变换。

要求。

- f 必须是可逆的
- 雅可比行列式必须是可处理的

转化的组成。

$$x = f_L \circ f_{L-1} \circ \dots \circ f_1(z)。$$

雅可比矩阵分解。

$$\log \det \frac{\partial z}{\partial x} = \sum_{\ell=1}^L \log \det \frac{\partial h_{\ell-1}}{\partial h_{\ell}}。$$

变换的类型。

- 仿射耦合层
- 自回归变换
- 体积守恒流

权衡。

- 表达能力与计算效率

洞察力。精心设计的可逆映射能够实现易于处理且富有表现力的生成模型。

29.3 精确似然计算

归一化流量的一个关键优势是能够计算精确的似然性。

可能性。

$$\log p_{\theta}(x) = \log p(f^{-1}(x)) + \log \det \frac{\partial f^{-1}}{\partial x}。$$

与其他型号的比较。

- VAE :近似似然
- 生成对抗网络 (GAN) :隐式似然
- 流 :精确似然

采样。

- 样本 $z \sim p(z)$

- 计算 $x = f_{\theta}(z)$

推理。

- 计算 $z = f_{\theta}^{-1}(x)$
- 利用变量变换法评估密度

效率方面的考虑。

- 雅可比行列式必须能够高效计算。
- 通常通过三角矩阵或结构化矩阵实现

洞察。归一化流能够实现精确似然性和高效采样的难得结合。

29.4 模型设计

设计有效的规范化流程需要在表达性和可操作性之间取得平衡。

耦合层。

- 将变量分成两部分
- 将一部分转化为另一部分所决定的形式

自回归流。

- 按顺序建立依赖关系
- 三角雅可比矩阵简化了行列式的计算

堆叠变换。

- 多层结构增强了表现力
- 每一层都会增加转换的复杂性

可逆神经网络。

- 旨在确保可逆性的架构

局限性。

- 可逆性的架构约束
- 高维数据的计算成本

洞察。流程模型设计需要在灵活性和计算限制之间取得平衡。

29.5 统一的视角

规范化流程融合了几个关键理念：

- 变换 :将简单分布映射到复杂分布
- 可逆性 :实现精确的密度计算
- 构图 :通过层次构建富有表现力的模型

核心组件。

- 基本分布 $p(z)$
- 可逆映射 f_0
- 雅可比行列式

关键见解 :通过精心设计可逆变换,我们可以构建具有精确似然性的富有表现力的生成模型。

29.6 展望

本章介绍了流的规范化：

- 密度变换的变量替换，
- 可逆变换，
- 精确似然计算，
- 实用模型设计。

下一章,我们将研究扩散模型,该模型接近生成式。

通过随机过程和迭代改进进行建模。

指导原则 :概率分布的结构化变换为生成式建模提供了一个强大的框架。

第三十章

扩散模型:直觉

30.1 噪声注入过程

扩散模型是一种生成模型,它通过逐步将数据转换为噪声,然后再逆转这一过程来实现。

前向过程。我们定义一个随机变量序列 $(x_0, x_1, \dots, x_T)$,其中:

- $x_0 \sim p_{\text{data}}$
- x_T 趋近于一个简单的分布 (例如,高斯噪声)

噪声注入。在每个步骤中,我们都添加少量高斯噪声:

$$x_t = \sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \epsilon_t, \epsilon_t \sim N(0, I).$$

马尔可夫结构。

- 每一步都仅取决于前一步的状态
- 该过程是一个马尔可夫链

影响。

- 逐渐破坏数据结构
- 将数据分布转换为噪声

洞察。前向过程定义了一种受控方法,可以将复杂的数据分布映射到简单的分布。

30.2 去噪视角

生成过程学会逆转噪声注入。

逆向过程。我们的目标是建立以下模型：

$$p_{\theta}(x_{t-1} | x_t),$$

它逐步消除噪音。

去噪解释。

· 每一步都会预测出噪声较小的数据版本。

· 该模型学习从噪声中恢复结构

学习目标:该模型经过训练,能够预测每一步中添加的噪声:

$$\epsilon_{\theta}(x_t, t) \approx \epsilon_t.$$

简化损失。

$$\mathbb{E}_{t, x_0, \epsilon} \|\epsilon - \epsilon_{\theta}(x_t, t)\|^2.$$

采样。

· 从噪声 $x_T \sim N(0, I)$ 开始

· 迭代去噪以获得 x_0

洞察力的产生是通过反复对随机噪声进行去噪,最终得到结构化数据。

30.3 基于评分的视图

扩散模型也可以通过评分函数来解释。

评分函数。

$$s(x) = \nabla_x \log p(x).$$

核心思想:与其直接对 $p(x)$ 进行建模,不如学习它的得分。

与扩散有关。

· 去噪函数近似于噪声分布的得分

· 每一步都对应于估计 $\nabla_x \log p_t(x)$

朗之万动力学。

$$\mathbf{x}_{t+1} = \mathbf{x}_t + \eta \nabla \log p(\mathbf{x}_t) + \sqrt{2\eta} \boldsymbol{\xi}_t,$$

其中 $\boldsymbol{\xi}_t$ 为高斯噪声。

解释。

- 样本是通过沿着对数密度梯度生成的
- 噪声确保了对分布的探索

洞察:扩散模型将去噪与基于梯度的概率分布采样联系起来。

30.4 概念联系

扩散模型统一了概率论、优化理论和物理学中的几个概念。

与其他模型的连接。

- 潜在变量模型:引入中间噪声状态
- 基于能量的模型:与得分函数相关
- 马尔可夫过程:序列变换

连续时间限制。

- 离散步骤近似随机微分方程
- 导致持续扩散过程

数据的几何形状。

噪声会使数据分布更加平滑。

- 去噪恢复结构

与其他生成模型的比较。

- VAE:概率潜在模型
- GAN:对抗训练
- 流:可逆变换
- 扩散:迭代细化

洞察。扩散模型结合了概率建模、迭代去噪和基于梯度的采样。

30.5 统一的视角

扩散模型可以从多个角度理解：

- 概率论 :通过噪声过程对分布进行建模
- 算法 :迭代去噪过程
- 几何 :遵循数据空间中的梯度

核心组件。

- 前向噪声过程
- 反向去噪过程
- 学习得分或噪声预测器

关键见解 :可以通过逆转简单的随机过程来生成复杂的数据分布。

30.6 展望

本章从直观的角度介绍了扩散模型：

- 噪声注入过程，
- 去噪作为生成过程，
- 基于分数的解读，
- 与其他模型的概念联系。

下一章,我们将更严格地研究扩散模型,包括其概率公式和训练目标。

指导原则 :可以通过学习变换,逐步细化简单的噪声,从而学习复杂的结构。

第31章

扩散模型： 数学基础

31.1 正向和逆向过程

扩散模型建立在一对随机过程之上：一个正向（加噪）过程和一个反向（去噪）过程。

前向过程。我们定义一个马尔可夫链 $(x_0, x_1, \dots, x_T)$ ，使得：

$$q(x_t | x_{t-1}) = N(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I),$$

其中 $\{\beta_t\}_{t=1}^T$ 这是一个偏差表。

闭合形式的表达式。通过组合高斯跃迁，我们得到：

$$q(x_t | x_0) = N(x_t; \sqrt{\alpha_t} x_0, (1 - \alpha_t) I),$$

其中 $\alpha_t = 1 - \prod_{s=1}^t \beta_s$ 且 β_t 解释。

- 随着 t 的增加， x_t 的噪声越来越大
- 对于较大的 T ， $x_T \approx N(0, I)$

逆向过程。我们试图建立以下模型：

$$p_\theta(x_{t-1} | x_t),$$

在适当的假设下，它也是高斯分布：

$$p_\theta(x_{t-1} | x_t) = N(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)).$$

学习目标：训练参数 θ 以近似真实的逆向转换。

洞察力。正向过程是固定且简单的，而反向过程是需要学习的。

第31章 扩散模型:数学基础

31.2 分数匹配

扩散模型的另一种形式是基于得分匹配的。

评分函数。

$$s_t(x) = \nabla_x \log p_t(x),$$

其中 $p_t(x)$ 是 x_t 的分布。

目标。我们不直接对 $p_t(x)$ 进行建模,而是学习 $s_t(x)$ 。

去噪分数匹配。对于高斯扰动,分数满足:

$$s_t(x_t) = -\frac{1}{\alpha^{-t}} (x_t - \sqrt{\alpha^{-t}} x_0).$$

学习公式。我们训练一个神经网络 $s_\theta(x_t, t)$ 来近似得分:

$$\mathbb{E}_{t, x_0, \epsilon} \|s_\theta(x_t, t) - \nabla_x \log q(x_t | x_0)\|^2.$$

等效性。该目标等价于预测噪声 ϵ 。

洞察力。分数匹配提供了一种学习对数密度梯度的原则性方法。

31.3 朗之万动力学

利用朗之万动力学可以实现从分布中采样。

朗格文号事件最新进展。

$$x_{k+1} = x_k + \eta \nabla_x \log p(x_k) + 2\eta \bar{\xi}_k, \quad \xi_k \sim N(0, I).$$

解释。

· 梯度项驱动样本向高密度区域移动。

· 噪声项确保探索

与扩散模型的联系。

· 学习到的分数近似于 $\nabla_x \log p(x)$

· 抽样采用基于分数的更新

连续时间极限。朗之万动力学对应于一个随机微分方程:

$$dx_t = \nabla_x \log p(x_t) dt + \sqrt{2} dW_t,$$

其中 W_t 为布朗运动。

洞察:扩散采样可以看作是学习得分的近似朗之万动力学。

31.4 抽样算法

扩散模型的数学公式推导出了几种抽样方法。

祖先样本采集。

- 从 $x_T \sim N(0, I)$ 开始
- 迭代采样：
$$x_{t-1} \sim p_{\theta}(x_{t-1} | x_t)$$

确定性变体。

- 使用确定性更新而非采样
- 降低波动性并加快生成速度

基于分数的抽样。

- 使用离散朗之万动力学
- 使用学习到的评分函数进行更新

权衡取舍。

- 更多步骤 $\rightarrow$ 更高质量的样品
- 步骤更少 $\rightarrow$ 生成速度更快

数值方面的考虑。

- 选择步长
- 更新的稳定性

洞察。采样是一个由学习到的梯度指导的迭代改进过程。

31.5 统一的视角

扩散模型可以通过多种数学框架来理解：

- 马尔可夫过程 :正向链和反向链
- 分数匹配 :学习对数密度梯度
- 随机动力学 :朗之万方程

核心组件。

第31章 扩散模型:数学基础

- 前向噪声过程 $q(x_t | x_{t-1})$
- 逆过程 $p_\theta(x_{t-1} | x_t)$
- 得分函数 $s_\theta(x_t, t)$

关键见解:扩散模型统一了概率建模、随机过程和基于梯度的采样。

31.6 展望

本章阐述了扩散模型的数学基础:

- 正向和反向随机过程,
- 评分匹配公式,
- 朗之万动力学,
- 采样算法。

下一章,我们将研究现代改进和实际应用。
扩散模型比较。

指导原则:可以通过在随机动力系统中追踪学习到的梯度来对复杂分布进行采样。

第32章

大规模生成模型

32.1 实践中的扩散（例如,稳定扩散）

扩散模型已成为大规模生成建模的主要方法之一,尤其是在图像合成领域。

从理论到实践。实际的扩散系统的基本框架的基础上,通过架构和算法的改进进行了扩展:

- 用于去噪的 U-Net 架构
- 条件化机制 (例如,文本嵌入)
- 高效的抽样策略

潜在扩散。模型并非直接在像素空间中运行,而是在低维潜在空间中运行:

- 将图像编码成潜在表征
- 在潜在空间中进行扩散
- 解码回像素空间

优势。

- 降低计算成本
- 提高了可扩展性

条件反射。生成模型可以通过额外的输入进行引导:

- 文字提示
- 类标签
- 其他方式

洞察。现代扩散系统将概率建模与强大的神经网络架构和条件反射机制相结合。

32.2 大型语言模型

大型语言模型 (LLM)是序列的生成模型,通常基于Transformer架构。

自回归建模。LLM 模型对序列的联合分布进行建模：

$$p(x_1, \dots, x_T) = \prod_{t=1}^T p(x_t \mid x_1, \dots, x_{t-1})。$$

培训目标。

$$\max_{\theta} \mathbb{E} \sum_{t=1}^T \log p_{\theta}(x_t \mid x_{<t})。$$

Transformer主干网。

- 自我注意力层
- 前馈网络
- 残差连接和归一化

能力。

- 文本生成
- 问答
- 代码生成
- 推理任务

预训练和微调。

- 基于大型语料库进行预训练
- 适应下游任务

洞察。LLM 利用规模和架构来建模复杂的序列依赖关系。

32.3 尺度定律

实证研究揭示了模型性能与规模之间的系统性关系。

缩放因子。

- 模型规模（参数数量）
- 数据集大小
- 计算资源

经验法则。

$$\text{误差} \propto N^{-\alpha},$$

其中 N 代表尺度, $\alpha > 0$ 。

影响。

- 较大的模型往往性能更好
- 规模越大,收益越少

计算最优权衡方案。

- 平衡模型大小和数据集大小
- 高效分配计算资源

涌现行为。

- 新技术大规模出现
- 难以通过小型模型进行预测

洞察。规模化是现代机器学习系统性能的根本驱动因素。

32.4 工程方面的考虑

大规模生成模型需要精心设计才能进行训练和部署。

分布式培训。

- 数据并行
- 模型并行性
- 流水线并行

硬件加速。

- GPU 和专用加速器
- 内存和带宽限制

优化挑战。

- 大批量生产
- 学习率调度
- 规模稳定性

推理方面的考虑。

- 延迟与吞吐量
- 模型压缩和量化

数据方面的考虑。

- 数据质量和多样性
- 预处理和过滤

安全与对齐。

- 控制模型输出
- 减轻有害或带有偏见的行为

洞察力。工程学在将理论模型转化为实际系统中发挥着至关重要的作用。

32.5 统一的视角

大规模生成模型整合了多个维度：

- 建模 :概率和神经架构
- 计算 :大规模优化
- 数据 :海量且多样化的数据集
- 系统 :分布式和高效的实现

核心思想 :性能源于模型、数据和计算之间的相互作用。

关键见解 :现代生成模型不仅由其数学公式定义 ,还由其规模和系统级设计定义。

32.6 展望

本章探讨了大规模生成模型：

- 扩散模型在实践中的应用，
- 大型语言模型，
- 尺度定律，
- 工程方面的考虑。

至此,我们对现代生成建模技术的研究就结束了。

指导原则 :机器学习的进步源于理论、架构、数据和大规模计算的结合。

第33章

深度泛化学习

33.1 过度参数化

经典学习理论认为,参数过多的模型容易过拟合。然而,现代深度学习常常处于高度过参数化的状态,即参数数量超过训练样本数量。

观察。

- 深度网络可以精确地拟合训练数据
- 然而,它们通常也能很好地推广到未见过的数据。

插值机制。在参数过多的模型中,通常可以实现零训练误差:

$$R_n(\theta) = 0。$$

多种解决方案。有许多参数配置可用于插值数据。

关键问题:为什么有些解决方案具有良好的普适性,而另一些则不具备?

有效复杂性。

- 仅凭参数数量无法确定泛化能力
- 结构和训练动态都发挥着作用

洞察。过度参数化改变了学习的本质:我们不再是在模型中进行选择,而是在解决方案中进行选择。

33.2 梯度法的隐含偏差

优化算法并非平等地探索所有可能的解决方案,而是隐含地偏向某些特定的解决方案。

隐性偏差。优化方法倾向于在众多训练误差较低的解决方案中偏向某些特定方案。

例如(线性回归)。在欠定系统中,梯度下降法收敛于最小范数解:

最小化 $\|w\|_2^2$, 约束条件为 $Xw = y$ 。

深度网络。

- 内隐偏见更为复杂
- 取决于架构、初始化和优化器

SGD的作用。

随机梯度中的噪声会影响轨迹

- 可能更倾向于平坦的最低点

平坦的最小值与尖锐的最小值。

- 平坦的最小值: 对抗扰动更稳健
- 尖锐的最小值: 更敏感, 但可能泛化能力更差

洞察力。泛化能力不仅取决于模型本身, 还取决于模型的优化方式。

33.3 双世代现象

经典的偏差-方差权衡理论预测, 模型复杂度的增加会导致过拟合。然而, 现代的观察结果揭示了一种更为微妙的现象。

双下降。

- 随着模型规模的增大, 测试误差先减小, 然后增大, 最后再次减小。

阶段。

- 欠参数化状态: 经典行为
- 插值阈值: 峰值测试误差

33.4. 未决问题

163

- 过参数化机制:提高泛化能力

解释。

- 更大的模型可以找到更好的插值解

优化发挥着关键作用

实证证据。

- 在神经网络、核方法和其他模型中均有观察到

洞见:模型复杂性和泛化能力之间的关系比经典理论所描述的更为丰富。

33.4 未决问题

尽管取得了显著进展,但深度学习中的泛化理论仍然不完善。

主要挑战。

- 理解为什么过度参数化的模型能够泛化
- 表征深度网络中的隐性偏见
- 解释优化动力学的作用

理论方向。

- 参数数量以外的复杂性度量
- 基于稳定性的泛化界限
- 信息论方法

与其他领域的联系。

- 统计物理学 (能量景观)
- 动力系统 (训练动力学)
- 信息论 (压缩和表示)

实际意义。

- 建筑设计
- 优化算法的选择
- 正则化策略

洞察。理解深度学习中的泛化能力是一个活跃的研究领域,它连接了理论与实践。

33.5 统一的视角

深度学习中的泛化能力源于多种因素的相互作用：

- 模型容量:神经网络的表达能力
- 优化:训练算法的隐含偏差
- 数据:输入数据的结构和分布

核心思想:泛化能力并非由单一因素决定,而是由整个学习过程的动态变化决定。

关键见解:现代深度学习挑战了传统的直觉,需要新的理论框架。

33.6 展望

本章探讨了深度学习中的泛化问题：

- 过度参数化和插值，
- 优化方法的隐含偏见，
- 双世代现象，
- 未解决的理论问题。

至此,我们对现代机器学习和深度学习的理论和实践基础的探索就结束了。

指导原则:理解泛化需要整合优化、概率和表征学习中的思想。

第34章

几何与动力学学习

34.1 损失景观

训练神经网络可以看作是在高维损失空间中导航。

损失函数。给定参数 $\theta \in \mathbb{R}^d$, 损失定义了一个函数:

$$L(\theta) : \mathbb{R}^d \rightarrow \mathbb{R}.$$

景观诠释。

- 各点对应于参数配置
- 高度对应于损失值

关键点。

- 局部最小值: $\nabla L(\theta) = 0$, 曲率为正
- 鞍点: 混合曲率方向

高维几何。

- 鞍点比局部最小值更常见

许多方向几乎是平坦的。

平坦的最小值与尖锐的最小值。

- 平坦最小值: 对抗扰动具有鲁棒性

- 尖锐的极小值 :对参数变化敏感

可视化（概念图）。低维投影揭示了山谷、山脊和高原。

洞察 :损失函数的几何形状对优化和泛化能力有显著影响。

34.2 神经切线核（直觉）

神经切线核（NTK）提供了一种神经网络训练的线性化视角。

线性化。在初始化 θ_0 附近,该网络可以近似为：

$$f_{\theta}(x) \approx f_{\theta_0}(x) + \nabla_{\theta} f_{\theta_0}(x) \cdot (\theta - \theta_0)。$$

神经切线核。

$$K(x, x') = \nabla_{\theta} f_{\theta_0}(x) \cdot \nabla_{\theta} f_{\theta_0}(x')。$$

解释。

- 定义初始化时由网络诱导的核
- 训练过程类似于核函数为 K 的核回归。

无限宽度限制。

- NTK 变得确定性
- 训练动态趋于线性

洞察。NTK 将深度学习与经典的核方法联系起来。

34.3 训练的连续时间视角

基于梯度的优化可以看作是一个连续时间动态系统。

梯度下降更新。

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t)。$$

连续时间极限。当 $\eta \rightarrow 0$ 时,我们得到一个微分方程：

$$\frac{d\theta(t)}{dt} = - \nabla L(\theta(t)).$$

梯度流。

- 参数沿最陡下降方向演变
- 轨迹在参数空间中遵循曲线

能量解释。沿轨迹方向,损失逐渐减小:

$$\frac{d}{dt}L(\theta(t)) = -\|\nabla L(\theta(t))\|^2 \leq 0。$$

扩展到随机动力学。随机梯度下降引入了噪声:

$$d\theta(t) = -\nabla L(\theta(t))dt + \Sigma^{1/2} dW_t, \text{其中} W_t$$

为布朗运动。

洞察。训练可以理解为一个由梯度和噪声共同塑造的连续过程。

34.4 动力系统视角

神经网络训练和表征学习可以从动力系统的角度来看待。

参数动态。

- $\theta(t)$ 在优化下的演变

表征动力学。

- 训练过程中特征 $f_{\theta(t)}(x)$ 的演变

稳定。

- 稳定不动点对应于最小值
- 稳定性取决于曲率和噪声

吸引子。

- 优化过程可能会收敛到参数空间的特定区域。

与残差网络的连接。深度网络类似于离散化的动态系统。

特征演化。

- 早期训练:快速特征变化
- 后期阶段:微调

洞察力。学习是一个动态过程,其参数和表征都会随着时间的推移而不断演变。

34.5 统一的视角

学习的几何学和动力学提供了一个统一的框架：

- 几何学 :损失景观的结构
- 动力学 :优化轨迹
- 线性化 :NTK 近似
- 随机性 :噪声在训练中的作用

核心思想 :理解学习需要分析目标的结构和优化的动态过程。

关键见解 :现代深度学习处于几何学、概率论和动力系统的交叉领域。

34.6 展望

本章探讨了学习的几何结构和动力学：

- 损失景观及其结构，
- 神经切线核视角，
- 优化的连续时间视角，
- 动力系统解释。

这些视角提供了对学习方式更深入的理论理解。

ing 现象发生在现代机器学习系统中。

指导原则 :学习既是一个几何问题,也是一个动态过程,它受到模型结构和优化之间相互作用的影响。

第35章

实用系统设计

35.1 数据管道

在现代机器学习系统中,数据与模型同等重要。高效的系统设计始于可靠且可扩展的数据管道。

数据管道。数据管道将原始数据转换为适合训练和评估的形式。

阶段。

- 数据收集
- 清洗和预处理
- 特征提取或编码
- 存储和访问

预处理。

- 归一化和缩放
- 处理缺失值
- 数据增强

流式处理与批处理。

- 批量处理流程以大块数据进行处理

流式管道持续处理数据

数据质量。

- 一致性和正确性

- 噪声和偏差方面的考虑

洞察。机器学习系统的质量从根本上来说受限于其数据的质量。

35.2 培训工作流程

训练现代模型需要协调的工作流程来管理数据、计算和实验。

训练循环。

1. 加载一批数据
2. 计算预测值
3. 评估损失
4. 计算梯度
5. 更新参数

实验管理。

- 跟踪超参数
- 记录指标和日志
- 比较不同的模型配置

超参数调优。

- 网格搜索、随机搜索
- 自适应方法（例如，贝叶斯优化）

分布式培训。

- 跨多个设备的数据并行处理
- 大型模型的并行化

检查点。

- 保存中间模型状态
- 支持恢复和实验

洞察力。精心设计的流程能够实现高效的实验和可靠的模型开发。

35.3 调试和诊断

训练机器学习模型通常涉及诊断优化过程中出现的问题。

常见问题。

- 训练结果不收敛
- 过拟合或拟合不足
- 数值不稳定性

诊断工具。

- 训练曲线和验证曲线
- 梯度范数
- 激活统计数据

理智检验。

- 验证在小数据集上损失是否减少
- 检查梯度正确性
- 确保标签和数据一致

可视化。

- 持续监测各项指标
- 检查中间输出

系统性调试。

- 隔离组件
- 简化模型
- 逐步增加复杂性

洞察力。调试是机器学习中的一项基本技能,需要理论理解和实践经验。

35.4 可重复性

可重复性对于科学和工程的可靠性至关重要。

定义:如果一个结果在相同条件下能够始终如一地获得,则称该结果是可重复的。

变异来源。

- 随机初始化
- 数据重组
- 硬件和数值差异

最佳实践。

- 修复随机种子
- 记录配置和超参数
- 版本数据集和代码

实验跟踪。

- 系统地存储结果
- 维护实验日志

决定论与绩效。

- 完全确定性执行可能会降低性能
- 可重复性和效率之间的权衡

洞察力。可重复性确保结果可靠,并可在此基础上进行拓展。

35.5 统一的视角

实用系统设计集成了多个组件:

- 数据:管道和预处理
- 计算:训练工作流程
- 诊断:调试工具
- 可靠性:可重复性实践

核心思想:成功的机器学习系统需要对数据、模型和基础设施进行精心协调。

关键见解:实际效果不仅取决于算法,还取决于支撑算法的系统。

35.6 展望

本章探讨了机器学习系统的实际应用方面：

- 数据管道，
- 培训工作流程，
- 调试和诊断，
- 可重复性。

本书到此结束。

最后一条指导原则。机器学习既是一门数学学科,也是一门工程实践,它需要对理论、数据和系统有深刻的理解。

第三十六章

极限与未来 方向

36.1 稳健性和不确定性

现代机器学习系统取得了令人印象深刻的性能,但它们仍然对扰动和不确定性很敏感。

稳健性。如果模型的预测结果在输入发生微小变化时仍保持稳定,则该模型是稳健的:

$$\|x - x'\| \text{ 小} \Rightarrow f(x) \approx f(x')。$$

对抗样本。

精心设计的扰动可以显著改变预测结果。

- 通常难以被人类察觉

分布格局发生变化。

- 训练集和测试集的分布可能有所不同
- 在新条件下性能可能会下降

不确定性估计。

- 随机不确定性:数据中固有的噪声
- 认知不确定性:由于知识有限而产生的不确定性

方法。

- 贝叶斯方法

- 集成模型
- 校准技术

洞察力。可靠的人工智能系统除了做出准确预测外,还必须能够量化和管理不确定性。

36.2 现代人工智能的失效模式

尽管现代模型在实证上表现出色,但它们也存在系统性的失效模式。

常见问题。

- 对错误预测的过度自信
- 对虚假相关性的敏感性
- 对罕见或分布外输入缺乏稳健性

数据依赖性。

模型会继承训练数据中存在的偏差

- 绩效反映的是数据分布情况,而非对数据的真实理解

概括性限制。

- 难以将结果推广到训练计划之外
- 组合推理方面的挑战

扩展性限制。

- 增大尺寸并不能解决所有问题
- 即使在大规模情况下,某些故障仍然存在

洞察力。了解失效模式对于提高可靠性和指导未来研究至关重要。

36.3 可解释性

可解释性旨在理解模型如何以及为什么做出预测。

动机。

- 信任和透明度
- 调试和模型改进

- 科学理解

可解释性的类型。

- 特征归因 :输入的重要性
- 表征分析 :学习特征的结构
- 模型简化 :用更简单的模型近似复杂模型

挑战。

- 高维表示
- 非线性相互作用
- 缺乏独特的解释

权衡取舍。

- 准确性与可解释性
- 简洁性与忠实性

洞察力。可解释性并非单一属性,而是理解复杂模型的一系列方法的集合。

36.4 未来研究方向

机器学习的未来在于理论、数据和系统的交汇点。

理论方向。

- 理解深度学习中的泛化
- 表征优化动力学
- 连接离散模型和连续模型

建模方向。

- 结合视觉、语言和动作的多模态模型
- 更高效、可扩展的架构
- 具有更强推理能力的模型

数据与学习范式。

- 自主学习和无监督学习

- 从有限或嘈杂的数据中学习
- 持续终身学习

系统与效率。

- 降低计算和能源成本
- 高效的训练和推理

安全与对齐。

- 确保行为可靠且可控
- 减轻意外后果

跨学科联系。

- 神经科学和认知科学
- 物理学和动力系统
- 数学和统计学

洞见。未来的进步需要整合跨学科的洞见,并在理论与实证进展之间取得平衡。

36.5 最终视角

本书从数学和实践两个角度探讨了机器学习和深度学习。

核心主题。

- 将学习视为函数逼近和优化
- 通过深度架构进行表征学习
- 概率建模和生成过程
- 规模和系统层面的考量

核心思想:学习系统是由数据、模型和算法的相互作用塑造而成的。

最后一点感悟。人工智能是一个不断发展的领域,理论与实践在这个领域中不断相互启发、相互挑战。

36.6 闭幕致辞

机器学习处于学科交叉的独特位置,它将严谨的数学与实用的工程学相结合。

前景。

- 新的理论框架将加深我们对……的理解
- 新的架构和系统将扩展功能
- 负责任的开发将产生实际影响

最后一条指导原则:人工智能的未来不仅取决于性能的提升,更取决于理解、可靠性和负责任的使用。