

人工知能 :数学的および 工学的視点

2026年3月

第1章

学習を機能として捉える 近似

1.1 学習問題とデータ

現代の人工知能は、主にデータからの学習という問題に取り組んでいます。大まかに言えば、私たちは世界の観察結果を与えられ、予測、意思決定、あるいは新たなデータ生成を行うことができるシステムを構築することを求められます。

これを以下のように形式化する。

$$X \subseteq \mathbb{R}^d$$

入力空間を表し、

$$Y$$

出力空間。データセットはサンプルの集合です。

$$D = \{(x_i, y_i)\}_{i=1}^n, x_i \in X, y_i \in Y.$$

学習の目標は関数を構築することです

$$f: X \rightarrow Y$$

それは入力と出力の関係性を捉えている。

例。

- 回帰分析では、 $Y \subseteq \mathbb{R}$ です。
- 分類においては、 $Y = \{1, \dots, K\}$ となります。
- 生成モデリングでは、 $Y = X$ となります。そして目標は、データ分布をモデル化することです。

この定式化は一見単純に見えるが、機械学習における中心的な課題を覆い隠している。つまり、我々は限られた数のサンプルしか観測できないにもかかわらず、未知のデータに対して優れた性能を発揮する関数を求めなければならないのだ。

1.2 関数、モデル、および表現

学習アルゴリズムは、考えられるすべての関数を探索するのではなく、モデルクラス（または仮説空間）から関数を選択します。

$$H = \{f_\theta : \theta \in \Theta\}.$$

ここ：

- θ はパラメータを表します。
- Θ はパラメータ空間であり、
- f_θ は θ によって決定される関数です。

例（線形モデル）。

$$f_\theta(x) = w \cdot x + b, \theta = (w, b).$$

例（ニューラルネットワーク）。

$$f_\theta(x) = W_L \sigma(W_{L-1} \sigma(\cdots \sigma(W_1 x))),$$

ここで σ は非線形活性化関数である。

H の選択は、問題の構造に関する仮定を暗示している。

これは帰納的バイアスとして知られており、後の章で改めて取り上げる概念です。

表現方法は重要です。2つのモデルが同じクラスの関数を表現していても、実際には以下のような理由で大きく異なる動作をすることがあります。

- 最適化特性、
- 数値安定性、
- 一般化行動。

したがって、モデルは単なる関数クラスではなく、計算および統計的な対象でもある。

1.3 近似を中核パラダイムとする

機械学習の本質は、近似問題である。

未知の関数が存在すると仮定する

$$f : X \rightarrow Y$$

データを管理するもの：

$$y = f(x) + \text{ノイズ}.$$

1.4. 回帰分析と分類の例

5

f なので y は未知であるため、以下の近似値 $f\theta$ を求めます。

$$f\theta \approx f$$

この近似を定量化するために、損失関数を導入する。

$$\ell: Y \times Y \rightarrow \mathbb{R}.$$

f の品質はリスクによって測定されます

$$R(f) = E_{(x,y)} \ell(f(x), y)。$$

データ分布が不明であるため、代わりに経験的リスクを最小化します。

$$R_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i)。$$

学習上の問題。

$$\min_{\theta \in \Theta} R_n(f\theta)。$$

この単純な最適化問題は、現代のほぼすべての機械学習アルゴリズムの基礎となっている。

1.4 回帰分析と分類分析の例

シヨン

1.4.1 回帰分析

回帰分析では、出力空間は $Y = \mathbb{R}$ です。

損失関数としてよく用いられるのは二乗誤差である。

$$\ell(f(x), y) = (f(x) - y)^2。$$

経験的リスクは

$$R_n(f) = \frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2。$$

解釈。

- 大きな偏差に対しては強いペナルティを課す
- 線形モデルに対して解析的に扱いやすい解が得られる

6 第1章 関数近似としての学習

1.4.2 分類

分類においては、 $Y = \{1, \dots, K\}$ となる。

モデルはラベルを直接予測する代わりに、スコアや確率を出力することが多い。

$$f(x) \in \mathbb{R}^K.$$

一般的な損失関数として、交差エントロピー損失がある。

$$\ell(f(x), y) = -\log p_\theta(y | x).$$

解釈。

- 正しいクラス確率を促す
- 最尤推定法との強い関連性

1.5 近似から一般化へ

ここで重要な問題が生じる。経験的リスクを最小限に抑えることが、新しいデータに対する良好なパフォーマンスを保証するものではないということだ。

重要な疑問。 訓練データによく適合する関数が、未知のデータに対しても優れた性能を発揮するのはなぜか？

この疑問は、以下の研究につながる。

- 一般化、
- モデルの複雑さ、
- 正則化、
- 帰納的バイアス。

これらのアイデアは機械学習の理論的基盤を形成し、本書全体を通して展開されている。

1.6 統一的な視点

学習プロセスを要約すると以下のようになります。

1. モデルクラス H を選択します
2. 損失関数 ℓ を定義する
3. 最適化問題を解く
4. 未知のデータに基づいて評価する

1.7. 展望

7

相互作用する3つの構成要素：

- 近似（モデルの表現力）
- 最適化（適切なパラメータを見つける能力）
- 汎化性能（新しいデータに対する性能）

現代の人工知能、特にディープラーニングが成功しているのは、これら3つの側面を大規模にバランスよく両立させる。

1.7 展望

本章では、本書の中心視点である「不確実性下における関数近似としての学習」を紹介した。

次の章では、学習の根底にある確率的フレームワークを展開します。経験的リスク最小化と統計的推論を結びつけること。

指導原則。本書全体を通して、以下の点を強調します。

- 数学に基づいた直感、
- 構造化された近似としてのモデル、
- そして、これらのアイデアを計算によって実現したアルゴリズム。

第2章

確率論的視点

学ぶ

2.1 ランダム性とデータ生成

第1章では、学習をデータから未知の関数を近似する問題として紹介しました。今回は、不確実性を組み込むことで、この視点をさらに発展させます。

データは決定論的ではない。たとえ真の関係性が存在する場合でも、観測結果にはノイズ、変動性、不完全な情報が伴う。これをモデル化する自然な方法は、確率を用いることである。

データは未知の確率分布に従って生成されると仮定します。

P は $X \times Y$ 上にあります。

データセット

$$D = \{(x_i, y_i)\}_{i=1}^n$$

P から抽出された独立したサンプルとしてモデル化されます。

$$(x_i, y_i) \sim P.$$

解釈。

- 分布 P は、データ生成プロセスのすべての特性を捉えている。
- このデータセットは、このプロセスに関する有限かつノイズの多い観測データに過ぎません。

この視点は学習の目標を変える。データセットに適合させるのではなく、基となる分布の特性を学習することを目指す。

2.2 条件構造と予測

Pの有用な分解は次のように与えられる。

$$P(x, y) = P(y | x)P(x)。$$

主要な対象 : 条件付き分布 $P(y | x)$ 。

予測とは、この条件付き関係を推定することと理解できる。

例 (回帰分析)。

$$y = f(x) + \varepsilon, E[\varepsilon | x] = 0。$$

それから

$$f(x) = E[y | x]。$$

例 (分類)。

$$P(y = k | x), k = 1, \dots, K。$$

予測とは、最も可能性の高いクラスを選択することに相当します。

$$y = \arg \max_k P(y = k | x)。$$

したがって、多くの学習問題は、条件付き期待値または確率の推定に帰着する。

2.3 ベイズの定理と推論

ベイズの定理は、条件付き確率間の基本的な関係を示している。

$$P(y | x) = \frac{P(x | y)P(y)}{P(x)}。$$

解釈。

- $P(y)$ は y に関する事前信念であり、
- $P(x | y)$ は、 y が与えられた場合に x を観測する尤度であり、
- $P(y | x)$ は、 x を観測した後の事後信念です。

実際には、ベイズの定理は2つの相補的なアプローチを示唆している。

- 判別モデリング: $P(y | x)$ を直接モデル化する
- 生成モデリング: $P(x | y)$ と $P(y)$ をモデル化する

工学的視点。

- 識別モデルは、多くの場合、より優れた予測性能を発揮する。
- 生成モデルはより豊かな構造を提供し、データを生成できる。

2.4 統計的目的としての損失関数

第1章では、誤差の尺度として損失関数を紹介しました。確率論的な観点から見ると、損失関数は統計的原理から自然に導き出されるものです。

条件付き分布 $p_{\theta}(y | x)$ を定義するモデル f_{θ} を考えます。

負の対数尤度。

$$\ell(f_{\theta}(x), y) = -\log p_{\theta}(y | x).$$

経験的リスクを最小限に抑える

$$\frac{1}{n} \sum_{i=1}^n -\log p_{\theta}(y_i | x_i)$$

これは、可能性を最大化することと同等です。

$$\max_{\theta} \prod_{i=1}^n p_{\theta}(y_i | x_i).$$

例。

- ガウスノイズ $\Rightarrow$ 二乗損失
- カテゴリ分布 $\Rightarrow$ 交差エントロピー損失

したがって、一般的に使用される損失関数の多くは任意ではなく、相関関係があります。データに関する確率的な仮定に基づいて対応する。

2.5 リスクと予想損失

学習の真の目的は、予想される損失（またはリスク）を最小限に抑えることである。

$$R(f) = E_{(x,y) \sim P} \ell(f(x), y).$$

理想的な問題だ。

$$\min_{f \in H} R(f).$$

しかし、 P は未知数であるため、 $R(f)$ を正確に計算することはできません。

代わりに、経験的リスクを用いて近似値を算出する。

$$R_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i).$$

経験的リスク最小化（ERM）。

$$\min_{f \in H} R_n(f).$$

ERMは、ほとんどの機械学習アルゴリズムの根底にある中心的な原理である。

2.6 近似、推定、最適化 シヨン

確率論的定式化により、3つの異なる誤差要因が明らかになった。

1. 近似誤差 モデルクラス H には真の関数が含まれていない可能性があります。
2. 推定誤差 P から有限サンプルしか観測できません。
3. 最適化誤差 経験的リスクの正確な最小値を見つけることができない場合があります。

洞察。現代の機械学習システムが効果的なのは、これら3つのエラーのバランスを取っているからです。

2.7 最適な事前条件としての条件付き期待 ディクター

重要な理論的成果は、最適な予測因子の構造に関する洞察を提供する。

命題。二乗損失の場合、リスクを最小化する関数は次のとおりである。

$$f^*(x) = E[y | x]。$$

解釈。

- 最適な予測値は条件付き平均です。
- 学習の目的は、この条件付き期待値を近似することである。

この結果は、データにノイズが含まれている場合でも、回帰モデルが平均値の推定に重点を置く理由を説明している。

2.8 確率からアルゴリズムへ

確率論的枠組みは明確さをもたらすが、実用的なアルゴリズムは制約の下で動作しなければならない。

- 限られたデータ、
- 高次元入力、
- 計算上の制約。

したがって、モデルは統計的に妥当であるだけでなく、以下の点も満たすように設計されています。

- 計算効率が良く、

2.9. 統一的な視点

13

- 数値的に安定しており、
- 大規模データセットにも対応可能。

確率と計算の相互作用は、現代の機械学習を特徴づける重要な要素である。

2.9 統一的な視点

これで学習パイプラインを改良できます。

1. データは未知の分布 P から生成されると仮定する
2. モデル $p_{\theta}(y | x)$ または関数 f_{θ} を選択します。
3. 確率論的原理から導き出される損失を定義する
4. 実証的リスクを最小限に抑える

重要なポイント。学習とは、有限個のサンプルから条件付き分布を近似するプロセスである。

2.10 展望

本章では、学習の確率論的基礎について紹介した。

- 分布からのサンプルとしてのデータ、
- 条件付き構造の推定としての予測、
- 損失関数を統計的目的関数として用いる。

次の章では、仮説空間と帰納的バイアスについて考察します。これらは、どのような種類の関数を学習できるか、そしてどのように一般化が可能になるかを決定します。

指導原則。確率は不確実性を表現する言語を提供するが、効果的な学習には、それを構造、計算、近似と組み合わせることが必要である。

第3章

仮説空間と 誘導バイアス

3.1 関数クラスとモデルファミリー

これまでの章では、学習を経験的リスクを最小化する関数を選択する問題として定式化しました。しかし、重要な問題にはまだ取り組んでいません。

どの機能を選択できるのですか？

この質問には、仮説空間（またはモデルクラス）を指定することで答えることができます。

$$H = \{f_\theta : \theta \in \Theta\}.$$

仮説空間は、学習が候補とする関数の集合を定義します。
アルゴリズムは表現できる。

関数クラスの例。

- 線形モデル:

$$f(x) = w \cdot x + b.$$

- 多項式モデル:

$$f(x) = \sum_{|a| \leq d} \alpha \text{ キャックス }^a$$

- ニューラルネットワーク:

$$f_\theta(x) = W_L \sigma(W_{L-1} \sigma(\dots \sigma(W_1 x))).$$

Hの選択はそれぞれ、入力と出力の関係に関する構造的な仮定を課す。

表現力。仮説空間は、幅広い関数を近似できる場合に表現力に優れていると言われる。

例：十分な幅を持つニューラルネットワークは、コンパクトな領域上の任意の連続関数を近似することができる（普遍近似特性）。

しかし、表現力だけでは性能は決まりません。表現力の高いモデルは訓練データには完璧に適合するかもしれませんが、汎化性能に欠ける可能性があります。

したがって、Hの選択は単なる近似の問題ではなく、表現力、安定性、学習しやすさのバランスを取ることに関わる問題である。

3.2 誘導バイアスと事前構造

仮説空間は、特定の関数を他の関数よりも暗黙のうちに優先させる傾向を生み出す。この傾向は帰納的バイアスとして知られている。

定義（非公式）：帰納的バイアスとは、学習アルゴリズムが観測データを超えて一般化することを可能にする一連の仮定のことである。

帰納的バイアスがなければ、学習は不可能である。訓練データを補間できる関数は無限に存在するが、うまく汎化できるのはそのうちのごく一部に過ぎない。

帰納的バイアスの発生源。

- モデルクラス：線形モデルは線形関係を重視します。
- アーキテクチャ：畳み込みネットワークは局所性と翻訳を優先します。
分散。
- 正則化：大きなパラメータにペナルティを与えることで、より単純な関数が有利になる。
- 最適化：勾配ベースの手法は特定の解を好む場合がある
数あるうちの1つ。

事前知識との関連性。帰納的バイアスは、問題に関する事前知識を符号化するものと見なすことができる。

- 滑らかさ、
- スパース性、
- 構成構造、
- 不変性。

工学的観点から見ると、成功するモデルは中立的なものではなく、データ内の構造を反映するように綿密に設計されている。

例えば：

- CNNは画像内の空間的局所性を利用し、

3.3. バイアス・バリエーションのトレードオフ（直感）

17

- トランスフォーマーは、シーケンス内の要素間の関係性を利用します。

したがって、帰納的バイアスは制約ではなく、学習に必要な要素である。

3.3 バイアス・バリエーションのトレードオフ（直感）

次に、仮説空間の選択が一般化にどのように影響するかを検証する。

点 x における予測誤差の期待値を考えてみましょう。

$$E(f(x) - y)^2。$$

このエラーは概念的に3つの要素に分解できる。

- バイアス : 系統的な近似による誤差
- 分散 : データの感度による誤差
- ノイズ : データに内在するランダム性

バイアスの大きいモデル。

- 単純な仮説空間（例 : 線形モデル）
- データに適合しきれない可能性がある
- 分散は小さいが、系統誤差が大きい

高分散モデル。

- 表現力の高いモデル（例 : ディープネットワーク）
- トレーニングデータにうまく適合させることができる
- ノイズや変動に敏感

トレードオフ。モデルの複雑さが増すと、一般的に次のようになります。

- バイアスを減らし、
- 分散が増加する。

洞察。適切な一般化には、これら二つの効果のバランスを取ることが必要である。

注記 : 現代の深層学習では、この古典的な考え方は洗練されています。過剰にパラメータ化されたモデルでも、暗黙的な正則化と最適化効果により、高い汎化性能を発揮できるのです。

3.4 表現方法の選択

学習システムの性能は、関数クラスだけでなく、入力がどのように表現されるかにも依存する。

定義。表現とは変換である。

$$: X \rightarrow Z$$

生の入力データを特徴空間にマッピングする。

このモデルは、 x ではなく $\phi(x)$ に基づいて動作します。

$$f(x) = g(\phi(x)).$$

例。

- 多項式特性: $\phi(x) = (x, x^2, \dots)$
- ニューラルネットワークで学習された特徴

重要な考え方。豊富な表現にシンプルなモデルを適用する方が、生の入力に複雑なモデルを適用するよりも強力な効果を発揮する可能性がある。

特徴量エンジニアリングと表現学習の比較。

- 従来の手法は、手作業で設計された機能に依存している
- ディープラーニングは表現を自動的に学習する

構成的表現。ディープネットワークは階層的に表現を構築する。

- 下位層は局所的なパターンを捉え、
- 上位層は抽象的な構造を捉える。

幾何学的観点。表現はデータの幾何学的構造を変換し、以下ようになる。

- クラスが分離可能になり、
- 構造が簡素化され、
- 学習が容易になる。

したがって、表現方法を選択することは、座標系を選択することと同等である。学習問題が扱いやすくなる。

3.5 統一的な視点

これで学習問題をより詳細に検討できます。

1. 表現を選択する
2. 仮説空間 H を選択する
3. 構造と正則化を通じて帰納的バイアスを課す
4. 経験的リスクを最適化する

学習の主要構成要素：

- 表現方法（データの符号化方法）
- 関数クラス（表現できる内容）
- 帰納的バイアス（どちらが好ましいか）

現代の深層学習システムはこれらの要素を統合します。表現を学習します。
暗黙的および明示的なバイアスに導かれながら、同時に機能と行動を決定づける。

3.6 展望

本章では、学習とは単にデータに適合させることだけではなく、適切な関数空間と表現を選択することでもあると強調した。

次の章では、学習を最適化問題として研究し、
実際にモデルがどのように訓練されるかについて。

基本原則。一般化はデータのみから生じるのではなく、データ、モデル構造、および帰納的バイアスの相互作用から生じる。

第4章

最適化としての学習

4.1 学習の最適化定式化

前章では、学習を経験的リスクを最小化する問題として定式化した。今回は、この問題を最適化の観点から考察する。

モデルは $\theta \in \Theta$ によってパラメータ化され、学習は解くことから成ります。

$$\min_{\theta \in \Theta} R_n(\theta) \quad \text{ここで} \quad R_n(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\theta}(x_i), y_i).$$

重要な観察結果。学習とは、高次元のパラメータ空間における関数の最小化に帰着する。

この定式化は、幅広いモデルを統合するものである。

- 線形回帰 → 凸二次最適化
- ロジスティック回帰 → 凸最適化
- ニューラルネットワーク → 極めて非凸な最適化

目標の構造。

- データポイントごとの損失の合計
- 多くの場合、滑らか（微分可能）
- 高次元で、場合によっては非凸である

工学的な制約。厳密な最小化はめったに不可能である。そのため、限られた計算時間内で十分な精度が得られるパラメータを見つけることを目指す。

したがって、最適化は単なる数学的なツールではなく、どのモデルが実際に使用可能かを決定するものである。

4.2 勾配ベースの手法

現代の学習アルゴリズムのほとんどは、勾配ベースの最適化に依存している。

勾配降下法。微分可能な目的関数 $L(\theta)$ が与えられた場合、更新ルールは次のようになります。

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t),$$

ここで $\eta > 0$ は学習率である。

解釈。

- 勾配 $\nabla L(\theta)$ は、最も急な増加方向を示している。
- 負の勾配方向に移動すると損失が減少します

幾何学的視点。勾配降下法は損失曲面の局所的な形状に沿って、値の低い領域へと移動します。

学習率の選択。

- 小さすぎる $\rightarrow$ 収束が遅い
- 大きすぎると不安定性または乖離が生じる

例（二次損失関数）。凸二次関数の場合、勾配降下法は適切な条件下で大域的最小値に収束します。

制限事項。完全な勾配を計算するには、すべてのデータポイントについて合計する必要があります。

$$\nabla L(\theta) = \frac{1}{n} \sum_{i=1}^n \nabla \ell(f\theta(x_i), y_i)。$$

大規模なデータセットの場合、これは計算コストが高くなる。

4.3 確率的最適化

完全な勾配計算の計算コストに対処するため、確率的近似法を用いる。

確率的勾配降下法（SGD）。各ステップで、データポイント（またはミニバッチ）をサンプリングし、近似勾配を計算します。

$$\theta_{t+1} = \theta_t - \eta \nabla \ell(f\theta(x_{it}), y_{it})。$$

ミニバッチSGD。

$$\theta_{t+1} = \theta_t - \eta \frac{1}{|B_t|} \sum_{i \in B_t} \nabla \ell(f\theta(x_i), y_i)。$$

主な特性。

- 反復あたりの計算コストが低い
- 最適化プロセスにノイズを導入する

洞察。SGDにおけるノイズは必ずしも有害ではなく、局所最適解に陥るのを回避し、汎化性能を向上させるのに役立つ可能性がある。

トレードオフ。

- バッチサイズが小さい → 更新頻度は高いが、更新コストは安い
- バッチサイズが大きい → 安定しているが、更新コストが高い

実践的な方法。

- モメンタム : 更新を平滑化することで収束を加速する
- 適応型手法 (例 : Adam) : パラメータごとに学習率を調整する

確率的最適化は、現代の深層学習の根幹を成すものである。

4.4 損失ランドスケープの幾何学

最適化の挙動を理解するためには、損失関数の形状を考慮することが有効である。

損失ランドスケープ。関数

$$L(\theta)$$

パラメータ空間上の曲面を定義する。

重要なポイント。

- 局所的最小値 : $\nabla L(\theta) = 0$, L は局所的に最小値である
- サドル点: $\nabla L(\theta) = 0$ だが、極小値ではない

凸型と非凸型。

- 凸問題 : すべての局所最小値は大域的 minimum である
- 非凸問題 : 複数の局所最小値と鞍点

ニューラルネットワークは非常に非凸な損失関数を生み出すが、勾配ベースの手法は実際にはしばしば成功する。

平坦な極値と鋭い極値。

- 平坦な最小値 : 解の周囲で損失がゆっくりと変化する
- 急激な最小値 : 損失が急速に変化する

観察。SGDによって見つかった解は、より平坦な領域に位置する傾向があり、より優れた一般化能力と関連付けられることが多い。

高次元効果。高次元では：

- 鞍点は局所的最小値よりも一般的である
- 多くの方向では曲率がほぼゼロになる可能性がある

幾何学的直観。最適化は複雑な構造をナビゲートすることと見なすことができる。景観を形作るもの：

- モデルアーキテクチャ、
- データ配信、
- パラメータ化。

4.5 最適化と一般化

最適化は、訓練損失を最小限に抑えるだけでなく、汎化能力にも影響を与える。

重要な考え方。異なる最適化アルゴリズムは、たとえ同様の学習誤差を達成したとしても、異なる解に収束する可能性がある。

暗黙のバイアス。勾配ベースの手法は、多数の最小化解の中から特定の解を優先する傾向がある。

例。

- 過剰パラメータ化された線形モデルでは、勾配降下法はしばしば最小値を見つけます。
標準解

意味するところ。最適化はモデリングプロセスの一部であり、学習された関数を暗黙的に正則化する。

4.6 統一的な視点

これで学習プロセスをさらに洗練させることができます。

1. データとモデルに基づいて損失関数を定義する
2. 最適化問題を定式化する
3. 勾配ベースの手法（多くの場合、確率的手法）を適用する
4. 目的関数と最適化関数の両方によって形作られた解を得る。
ナミクス

相互に作用する3つの側面：

- 目的（最小化すべきもの）
- アルゴリズム（最小化の方法）
- 幾何学（損失ランドスケープの構造）

現代の機械学習が成功しているのは、適切な目的関数が定義されているからだけでなく、効率的な最適化手法によってその構造を活用できるからでもある。

4.7 展望

本章では、学習の中心的な要素として最適化を紹介した。

- 経験的リスクを最小限に抑える学習、
- 勾配ベースの手法を主要なツールとして、
- 確率性は、必要条件であると同時に利点でもある。

次の章では、汎化についてより詳しく考察し、データによく適合するモデルが、未知の事例に対しても優れた性能を発揮できるのはなぜかという根本的な問題を取り上げます。

基本原則。学習とは、何を最適化するだけでなく、どのように最適化するかについても学ぶことである。

第5章

一般化と 過学習

5.1 トレーニングとテストのパフォーマンス

これまでの章では、学習を経験的リスクの最小化として定式化し、最適化アルゴリズムがどのように解を見つけるかを研究しました。しかし、中心的な疑問が残っています。

訓練データによく適合するモデルは、なぜ未知のデータに対しても優れた性能を発揮するのでしょうか？

この問題を解決するために、私たちはパフォーマンスを2つのタイプに分類します。

トレーニングエラー。

$$R_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i)。$$

テストエラー（一般化エラー）。

$$R(f) = E_{(x,y)} \ell(f(x), y)。$$

重要な違い。

- 観測データに適合させたトレーニング誤差尺度
- テスト誤差は新しいデータに対するパフォーマンスを測定します

モデルの汎化性能が高いとは、訓練誤差がテスト誤差に近いほど優れているということである。

一般化のギャップ。

$$R(f) - R_n(f)。$$

洞察。訓練誤差を最小限に抑えるだけでは不十分である。学習の目標は、直接観測できないテスト誤差を最小限に抑えることである。

実践的なアプローチ。訓練データとは別の検証データセットを用いて、テスト性能を近似的に評価します。

5.2 過学習と過小学習

訓練誤差とテスト誤差の関係は、2つの根本的な失敗モードにつながる。

適合不足。

- モデルが単純すぎてデータの構造を捉えきれしていない
- 高いトレーニングエラー
- 高いテスト誤差

過学習。

- モデルがノイズを含むトレーニングデータに過度に適合している
- トレーニングエラーが非常に少ない
- 高いテスト誤差

図解。非常に柔軟性の高いモデルは、すべての訓練データを補間できるかもしれないが、訓練データ間の領域では不安定な挙動を示す可能性がある。

トレードオフ。モデルの複雑さが増すにつれて：

- トレーニングエラーは通常減少し、
- テスト誤差は最初は減少し、その後増加する可能性があります。

古典的な考え方。過学習と過小学習のバランスが取れる最適な複雑さのレベルが存在する。

注記（現代的な視点）。深層学習においては、モデルはしばしばこの古典的な枠組みをはるかに超えて動作し、汎化性能の低下を招くことなく、低い訓練誤差を達成する。この現象については後ほど改めて考察する。

5.3 モデルの容量と複雑さ

過学習を理解するためには、モデルの表現力を定量化する必要がある。

モデル適合能力。仮説空間 H が幅広い関数に適合できる能力。

例。

- 線形モデル :低容量
- 高次多項式 :高容量
- ディープニューラルネットワーク :非常に高い容量

キャパシティの質的影響。

- 低容量 → 高バイアス、低分散
- 高容量 → 低バイアス、高分散

複雑性尺度（非公式）。

- パラメータの数
- ネットワークの深さと幅
- パラメータのノルム

重要な洞察。容量はパラメータの数だけで決まるわけではない。モデルの構造と学習アルゴリズムも重要な役割を果たす。

例 :同じ数のパラメータを持つ2つのニューラルネットワークでも、以下の要因によって動作が大きく異なる場合があります。

- 建築、
- 初期化、
- 最適化のダイナミクス。

したがって、容量は表現、パラメータ化、およびトレーニング手順の組み合わせとして捉えるべきである。

5.4 非公式な一般化の原則

現代の機械学習における汎化の完全な理論はまだ発展途上にあるものの、実践においてはいくつかの指針となる原則が広く観察されている。

1. より単純なモデルの方が、一般化しやすい傾向がある。

この原則はしばしばオッカムの剃刀と呼ばれ、データに適合するモデルの中で、より単純なモデルが好まれるというものである。

シンプルさには様々な形がある。

- パラメータが少ない、
- より小さな規範、

- よりスムーズな動作。

2. 正則化は汎化性能を向上させる。

正則化は、より単純な解を有利にするような追加の制約やペナルティを導入する。

例としては以下のようなものがあります。

- 体重減少、
- ドロップアウト、
- 早期中止

3. データ量が増えると、一般化の精度が向上する。

サンプルサイズが増加するにつれて：

- 経験的リスクは真のリスクをよりよく近似する。
- 推定誤差が減少する。

4. 誘導バイアスは不可欠である。

一般化は、モデルに組み込まれた仮定に依存する。

- 滑らかさ、
- 不変性、
- 構成構造。

5. 最適化は汎化に影響を与える。

最適化アルゴリズムの選択は、複数の解が低い学習誤差を達成する場合でも、どの解が見つかるかに影響を与える可能性がある。

この現象は暗黙的正則化として知られています。

6. 騒音は有益な場合もある。

トレーニングにおける確率性（例えばSGD）は、過度に複雑な解への収束を防ぐことで、過学習を回避するのに役立つ。

要約すると、一般化は単一の要因によって決定されるのではなく、以下の要素間の相互作用によって決定される。

- モデル容量、
- データ、
- 誘導バイアス、
- 最適化。

5.5 統一的な視点

学習とは、二つの目標のバランスを取る問題として捉え直すことができる。

- トレーニングデータに適合させる、
- 一般化する能力を維持する。

体幹の緊張。

データに適合させることと、過学習を避けること。

実践的な戦略。

1. 適切なモデルクラスを選択する
2. 規制による容量制御
3. 検証結果を参考にモデルを選択する
4. トレーニングとテストのパフォーマンスを監視する

現代的な視点。深層学習システムは、古典的な直観が部分的にしか通用しない領域で動作するが、帰納的バイアスと構造という根底にある原理は依然として不可欠である。

5.6 展望

本章では、学習における中心的な課題として一般化について紹介した。

- 訓練とテストのパフォーマンスを区別する、
- 過学習と過小学習を理解する、
- モデルの能力と一般化能力の関係。

次の章では、正則化手法をより詳細に検討し、モデルの複雑さを実際にどのように制御するかに焦点を当てます。

基本原則。優れたモデルとは、データに完全に適合するモデルではなく、観測された事例を超えて、根本的な構造を捉えるモデルである。

第6章

正則化と構造

6.1 ノルムに基づく正則化

前章で述べたように、表現力の高いモデルは訓練データに非常によく適合するものの、過学習のリスクがあります。正則化は、モデルの複雑さを制御し、汎化性能を向上させるための体系的な方法を提供します。

基本的な考え方。経験的リスクに、パラメータに対するペナルティを追加する。

$$\min_{\theta \in \Theta} R_n(\theta) + \lambda \Omega(\theta),$$

どこ：

- $\Omega(\theta)$ はモデルの複雑さを測定します。
- $\lambda > 0$ は正則化の強度を制御します。

一般的な罰則の選択肢。

- ℓ_2 正則化（重み減衰）：

$$\Omega(\theta) = \|\theta\|_2^2.$$

- ℓ_1 正則化:

$$\Omega(\theta) = \|\theta\|_1.$$

解釈。

- ℓ_2 正則化は、小さく分布したパラメータを好む
- ℓ_1 正則化はスパース性を促進する

幾何学的観点。正則化は、解が制御されたノルムを持つパラメータ空間の領域内に収まるように制限する。

統計的観点。ノルムペナルティは、パラメータに事前分布を課すものと解釈できる。

- $\ell_2 \rightarrow$ ガウス事前分布

- $\ell_1 \rightarrow$ ラプラス事前分布

実用上の効果。正則化は分散を低減し、安定性を向上させるが、多くの場合、バイアスがわずかに増加するという代償を伴う。

6.2 制約とペナルティ

正則化は、以下の2つの同等な方法で定式化できる。

- 罰則対象形式：

$$\min_{\theta} R_n(\theta) + \lambda \Omega(\theta),$$

- 制約付き形式：

$$\min_{\theta} R_n(\theta) \text{ は } \Omega(\theta) \leq C \text{ を満たす。}$$

洞察。これらの定式化は密接に関連しており、 λ と C を適切に選択すれば、同様の解が得られる。

例。

- リッジ回帰： ℓ_2 ペナルティ

- ラッソ： ℓ_1 ペナルティ

解釈：この制約は有効な探索空間を制限し、過度に複雑な解が生じるのを防ぎます。

二つの視点。ペナルティはデータ適合性とモデルの単純さのトレードオフであり、制約は複雑さに厳格な制限を課す。

工学的観点から見ると、ペナルティ項を含む定式化は最適化が容易な場合が多い一方、制約条件を含む定式化はより明確な幾何学的直感を提供する。

6.3 暗黙的正則化

正則化は必ずしも明示的に行われるわけではない。多くの最新の学習システムでは、最適化アルゴリズム自体が特定の解を好むように仕向けている。

定義（非公式）：暗黙的正則化とは、明示的なペナルティがない場合でも、アルゴリズムが特定の解を優先する傾向を指します。

例（線形モデル）。過剰パラメータ化された線形回帰では、勾配降下法は、すべての補間解の中で最小ノルム解に収束します。

例（ディープラーニング）。

- SGDは特定の構造を持つ解決策を見出す傾向がある
- 異なる最適化手法は、異なる汎化挙動をもたらす可能性がある

暗黙的な正則化の源泉。

- 初期化
- 最適化ダイナミクス
- 確率性（例：ミニバッチ処理）

重要なポイント。モデルがデータに完全に適合するだけの能力を備えていたとしても、どの解が見つかるかは学習手順によって決まる。

示唆。汎化を理解するには、モデルと損失だけでなく、最適化プロセスも分析する必要がある。

6.4 早期中止と実践的な方法

正則化は、実践的な訓練戦略によっても達成できる。

早期停止。訓練損失を完全に最小限に抑えるのではなく、検証性能が低下し始めた時点で訓練を停止します。

解釈。

- 初期の反復では大規模な構造が捉えられる
- 後の反復処理ではノイズに適合する可能性がある

正則化との関連性。早期停止は、多くの場合で ℓ_2 正則化と同様の挙動を示す。

その他の実践的な方法。

- ドロップアウト：トレーニング中にユニットをランダムに非アクティブ化する

- データ拡張 :変換によってデータセットを拡張する
- ノイズ注入 :入力またはパラメータにノイズを追加する

解釈。

- ドロップアウトは冗長性と堅牢性を促進する
- データ拡張は不変性を符号化する
- ノイズは学習された関数を平滑化する

工学的観点から見ると、これらの手法は実装が容易でありながら非常に効果的であり、特に深層学習システムにおいて顕著である。

6.5 構造を正則化として用いる

明示的なペナルティやトレーニングのテクニック以外にも、モデル構造自体が強力な正則化の形態として機能する。

例。

- 畳み込み層は局所性を強化する
- 残存接続が深層ネットワークを安定化させる
- 注意機構は関係構造を捉える

重要な考え方。構造によって表現可能な関数の種類が制限され、それによって学習が有意義な解決策へと導かれる。

洞察。現代の機械学習においては、明示的な正則化よりもアーキテクチャ設計の方が重要な場合が多い。

6.6 統一的な視点

正則化とは、学習された関数の実効的な複雑さを制御することと理解できる。

正規化の形態。

- 明示的（罰則、制約）
- 暗黙的（最適化ダイナミクス）
- 構造（モデルアーキテクチャ）

統一された目標。

データと制御の複雑さを適合させる。

主要構成要素。

- モデルクラス
- 正則化メカニズム
- 最適化アルゴリズム

これらの要素は相互に作用し合い、訓練の成果と一般化の両方を決定する。

6.7 展望

本章では、モデルの複雑さを制御するための中心的なツールとして正則化を紹介した。

- 規範に基づく罰則、
- 制約と罰則、
- 最適化の暗黙の効果、
- 早期中止や脱落といった実践的な手法。

本書の次の部分では、具体的な教師あり学習モデルについて見ていきます。
線形回帰と最小二乗法から始めます。

指導原則。効果的な学習には、データに適合させるだけでなく、意味のあるパターンが浮かび上がるように解空間を形成することが必要である。

第7章

線形回帰と 最小二乗法

7.1 線形モデルと予測

線形回帰は、機械学習において最も単純で基本的なモデルの一つです。その単純さにもかかわらず、より複雑なモデルにも応用できる多くの重要な概念を示しています。

モデル。次の形式の関数を考えます。

$$f(x) = w \cdot x + b,$$

ここで $w \in \mathbb{R}^d$ として $b \in \mathbb{R}$ 。

データセット $\{(x_i, y_i)\}_{i=1}^n$ が与えられたデータ、我々は、最適なパラメータ (w, b) を見つけることを目指します。

行列形式。

$$X = \begin{pmatrix} -x_1 & - \\ -x_2 & - \\ \vdots & \vdots \\ -x_n & - \end{pmatrix} \in \mathbb{R}^{n \times d}, \quad y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

簡略化のため、バイアスを aug- によってパラメータベクトルに組み込みます。

x を定数成分で表すと、モデルは次のようになります。

$$f(x) = w \cdot x,$$

予測ベクトルは

$$y = Xw.$$

幾何学的解釈。行列 X の列ベクトルは $\mathbb{R}^n$ の部分空間を張る。線形回帰は、この部分空間において y に最も近いベクトル $\hat{y}$ を求める。

したがって、線形回帰は直交射影問題として捉えることができる。

7.2 最小二乗法による最適化

損失関数として自然な選択肢は二乗誤差である。

$$\ell(f(x_i), y_i) = (f(x_i) - y_i)^2.$$

客観的。

$$\min_w \frac{1}{n} \|Xw - y\|^2.$$

これは凸二次最適化問題です。

最適性条件。勾配をゼロに設定すると、通常の方程式が得られます。

$$X^T X w = X^T y.$$

解（ $X^T X$ が可逆である場合）。

$$w = (X^T X)^{-1} X^T y.$$

投影解釈。適合値 $y = Xw$ は以下を満たす。

$$y - y \perp \text{span}(X),$$

つまり、残差は X の列空間に対して直交するということです。

考察。最小二乗解は、ユークリッド距離の観点から、モデルクラス内で y を最もよく近似する解です。

過剰パラメータ化の場合、 $X^T X$ が可逆でない場合（例えば、 $d > n$ ）、解は無限に存在します。この場合、多くの場合、最小ノルム解が選択されます。

$$w = X (X^T X)^{-1} X^T y.$$

この解法は、前章で述べた暗黙的正則化と密接に関連している。

7.3 条件付けと数値安定性

閉形式解は洞察を与えてくれるが、実際の計算は行列 $X^T X$ の数値特性に依存する。

条件付け。 $X^T X$ の条件数は、摂動に対する感度を測定します。

$$\kappa(X^T X) = \frac{\lambda_{\max}}{\lambda_{\min}},$$

ここで、 $\lambda_{\max}$ と $\lambda_{\min}$ はそれぞれ最大固有値と最小固有値である。

体調不良。

- $\lambda_{\min}$ が非常に小さい場合に発生する
- 不安定な解につながる
- データの小さな変化が、大きな変化を引き起こす可能性があります

原因。

- 相関性の高い特徴
- 冗長またはほぼ冗長な入力

実的な影響。

- 逆解析における数値的不安定性
- 一般化能力が低い

治療法。

- 特徴量のスケールリングと正規化
- 不要な機能を削除する
- 正則化（次項で説明）

アルゴリズムに関する注記：実際には、直接逆行列を求めるよりも、QR分解や特異値分解（SVD）などのより安定した手法を用いることが多い。

7.4 リッジ回帰

リッジ回帰は、最小二乗問題に ℓ_2 正則化を導入する。

客観的。

$$\min_w \|Xw - y\|_2^2 + \lambda \|w\|_2^2, \quad \lambda > 0.$$

解決。

$$w = (X^T X + \lambda I)^{-1} X^T y.$$

解釈。

- $X^T X$ の固有値をシフトすることで安定性を向上させる
- 騒音に対する感度を低減する
- パラメータの大きさを制御する

42 第7章 線形回帰と最小二乗法

幾何学的視点。リッジ回帰は、データへの適合性とパラメータのノルムのバランスを取りながら、解を原点に向かって縮小します。

バイアス・バリエーションのトレードオフ。

- バイアスをわずかに増加させる
- 分散を大幅に削減します

条件付けとの関連。行列 $X + \lambda I$ は $\lambda > 0$ の場合常に可逆であり、数値安定性が向上します。

ベイズ解釈。リッジ回帰は、 w に対してガウス事前分布を仮定することに相当する。

7.5 統一的な視点

線形回帰は、機械学習におけるいくつかの中心的なテーマを例示している。

- 関数空間への射影としての学習
- 最適化とは、構造化された問題を解決することである。
- 複雑性と安定性を制御するための正則化

3つの視点。

- 幾何学的 : 部分空間への射影
- 代数的 : 正規方程式の解法
- 統計的手法 : 条件付き期待値の推定

これらの視点は、ニューラルネットワークを含む、より複雑なモデルにも自然に拡張される。

7.6 展望

本章では、基礎モデルとして線形回帰を紹介した。

- 最小二乗定式化、
- 幾何学的解釈、
- 数値的な考察、
- リッジ回帰による正則化。

次の章では、これらの考え方をロジスティック回帰による分類へと拡張し、そこで確率モデルが中心的な役割を果たすことを示します。

基本原則 : 単純なモデルはしばしば深層構造を明らかにする。それらを理解することで、より複雑な学習システムへの洞察が得られる。

第8章

ロジスティック回帰と分類

8.1 確率的解釈

回帰問題では出力が実数値であるのに対し、分類問題では離散的なラベルを予測します。自然なアプローチとしては、入力が与えられた場合の各クラスの確率をモデル化することが挙げられます。

二値分類。Y = {0, 1} とする。ラベルを直接予測する代わりに、モデル化する。

$$P(y = 1 | x)$$

ロジスティックモデル。

$$P(y = 1 | x) = \sigma(w \cdot x),$$

ここで σ はシグモイド関数である。

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

シグモイド曲線の性質。

- Rを(0, 1)にマッピングする
- 滑らかで単調
- 確率として解釈可能

対数オッズの解釈。モデルは、

$$\frac{P(y = 1 | x)}{P(y = 0 | x)} \log = w \cdot x$$

したがって、ロジスティック回帰は、対数オッズを入力値の線形関数としてモデル化する。
多クラス拡張。K個のクラスに対しては、ソフトマックス関数を使用します。

$$P(y = k | x) = \frac{\exp(w_k \cdot x)}{\sum_{j=1}^K \exp(w_j \cdot x)}$$

この定式化により、確率はすべて正の値となり、合計が1になることが保証される。

8.2 交差エントロピー損失

モデルを訓練するには、確率的な精度を反映する損失関数が必要です。

二値交差エントロピー損失。

$$\ell(f(x), y) = -y \log p(x) + (1 - y) \log(1 - p(x))、$$

ここで、 $p(x) = P(y = 1 | x)$ 。

多クラス交差エントロピー。

$$\ell(f(x), y) = -\log P(y | x)。$$

解釈。

- 自信過剰だが誤った予測には大きなペナルティを課す
- 較正された確率を推奨する

幾何学的考察。交差エントロピーは、予測された分布と真のラベル分布との間の差異を測定する。

実用的な利点。二乗損失とは異なり、交差エントロピーは分類タスクにおいて扱いやすい勾配をもたらします。

8.3 最尤推定の観点から

ロジスティック回帰は、最尤法の原理から導き出すことができる。

尤度関数。

$$L(w) = \prod_{i=1}^n P(y_i | x_i; w)$$

対数尤度。

$$\ell(w) = \sum_{i=1}^n \log P(y_i | x_i; w)$$

対数尤度を最大化することは、経験的交差エントロピー損失を最小化することと同等である。

$$\underset{w}{\text{maximize}} \quad - \sum_{i=1}^n \log P(y_i | x_i; w)$$

二値の場合。シグモイドモデルを代入すると、凸最適化問題が得られます。

勾配。二値分類の場合、

$$\nabla_w \ell(w) = \sum_{i=1}^n (\sigma(w \cdot x_i) - y_i) x_i。$$

洞察力。

- 勾配は、入力特徴量によって重み付けされた予測誤差を反映している。
- トレーニングでは、予測確率とラベル間の不一致を減らすためにパラメータを調整します。

正則化。線形回帰と同様に、多くの場合、 ℓ_2 ペナルティ項を追加します。

$$\underset{w}{\text{maximize}} \quad - \sum_{i=1}^n \log P(y_i | x_i; w) + \lambda \|w\|_2^2。$$

解釈。これは、ガウス事前分布の下での最大事後確率（MAP）推定に相当します。

8.4 決定境界

ロジスティック回帰モデルは確率をモデル化するが、最終的には意思決定を行う。

二値決定ルール。

$$y = \begin{cases} 1 & P(y = 1 | x) \geq 0.5 \\ 0 & \text{それ以外の場合} \end{cases}$$

同等の状態。

$$w \cdot x = 0。$$

決定境界。

$$w \cdot x = 0$$

$\mathbb{R}^d$ における超平面を定義する。

幾何学的解釈。

46 第8章 ロジスティック回帰と分類

- 入力空間は2つの半空間に分割される
- 法線ベクトル w が向きを決定する

多クラスケース。決定境界は線形比較によって決定されます。
スコア:

$$w_k \cdot x = w_j \cdot x。$$

制限事項。ロジスティック回帰は線形の決定境界を生成します。特徴量変換を行わない限り、非線形構造を捉えることはできません。

拡張。非線形決定境界は、以下の方法で取得できます。

- 特徴マッピング、
- カーネル法、
- ニューラルネットワーク。

8.5 統一的な視点

ロジスティック回帰は、いくつかの重要な概念を結びつけています。

- 確率モデル : 条件付き確率の予測
- 最適化 : 交差エントロピー損失の最小化
- 形状 : 線形決定境界

線形回帰との比較。

- 線形回帰は値を予測します
- ロジスティック回帰は確率を予測します

重要な洞察。分類は、離散的な結果に関する不確実性をモデル化するものと捉えることができる。

8.6 展望

本章では、基本的な分類モデルとしてロジスティック回帰を紹介した。

- 確率的解釈、
- 交差エントロピー損失、
- 最尤推定、
- 決定境界の幾何学的構造。

次の章では、特徴マップとカーネルを使用して線形モデルを拡張します。
これにより、非線形関係を捉えることが可能になる。

基本原則。効果的な分類には、表現力豊かなモデルと適切な確率的定式化の両方が必要である。

第9章

フィーチャーマップと 非線形モデル

9.1 基底展開

線形モデルはシンプルで計算効率が良いものの、表現力に限界がある。入力空間における線形関係しか表現できないからだ。この限界を克服する自然な方法は、線形モデルを適用する前に入力を変換することである。

特徴マップ。特徴マップは関数です。

$$\phi : X \rightarrow \mathbb{R}^m,$$

これは、元の入力を新しい特徴空間にマッピングするものです。

次に、次の形式のモデルを定義します。

$$f(x) = \sum w_j \phi_j(x).$$

例（多項式の特徴）。 $x \in \mathbb{R}$ の場合、 $\phi_d(x)$ 。

$$\phi_d(x) = (1, x, x^2, \dots, x^d).$$

例（相互作用の特徴）。 $x \in \mathbb{R}$ の場合、相互作用を捕捉します。 $x_i x_j$ などの用語を含めます。

重要な考え方。特徴空間における線形モデルは、元の入力空間における非線形モデルに対応する。

解釈。基底展開を用いることで、より単純な構成要素を組み合わせることにより、複雑な関数を近似することができます。

近似理論との関連。多項式、フーリエ基底、その他の関数系を線形に組み合わせることで、幅広い関数を近似することができる。

9.2 特徴空間における線形モデル

特徴マップが定義されたら、学習はこれまでと同様に進められます。

$$\hat{w} = \frac{1}{n} \sum_{i=1}^n \ell(w, (x_i), y_i).$$

行列形式。Φ ∈ R とする。 n × m 特徴行列を以下に示す。

$$\Phi = \begin{pmatrix} - (x_1) & - \\ - (x_2) & - \\ \vdots & \vdots \\ - (x_n) & - \end{pmatrix}.$$

予測は次のように与えられる

$$y = \Phi w.$$

洞察。すべての線形回帰および分類手法は、XをΦに置き換えることで、特徴空間に直接拡張されます。

表現力と複雑さ。

- 特徴次元mを増やすと表現力が向上する
- しかし、過学習のリスクと計算コストも増加させる。

幾何学的観点。データはより高次元の空間に埋め込まれ、そこで線形分離可能になる可能性がある。

例 : R において直線で分離できない点を、R にマッピングした後の超平面で分² 離可能になるかもしれない³ 離する。

9.3 核となる概念（直観）

特徴空間の次元が非常に高い場合、あるいは無限次元の場合、課題が生じる。

観察。多くのアルゴリズムは、特徴ベクトル間の内積に依存している。

$$(x), (x')$$

カーネル関数。カーネルとは関数のことです。

$$k(x, x') = (x), (x')$$

これは、 (x)を明示的に評価することなく、この内積を計算します。

重要なアイデア（カーネルトリック）。k(x, x')を直接使用することで、高次元の特徴空間で暗黙的に作業できます。

カーネルの例。

- 多項式カーネル:

$$k(x, x') = (\|x - x'\| + c)^d$$

- ガウス (RBF)カーネル:

$$k(x, x') = \exp \left(-\frac{\|x - x'\|^2}{2\sigma^2} \right)$$

解釈。

- カーネルは入力間の類似性を測定する
- それらは暗黙的な特徴空間を定義する

実用的な利点。

- 明示的な高次元計算を避ける
- 柔軟な非線形モデルを可能にする

制限。

- 計算コストはデータポイントの数に比例する
- 最新の深層学習手法に比べて拡張性が低い

9.4 機能による表現力

特徴マップは、モデルが表現できる機能を決定します。

重要な問い。の選択はモデルの表現力にどのような影響を与えるのか？

洞察。十分な特徴空間における線形モデルは、非常に複雑な関数を近似することができる。

トレード・オフ。

- 豊富な機能 → 高い表現力
- しかし、過学習のリスクが高まる

機能設計の原則。

- ドメイン知識 (例: 不変性) をエンコードする
- 関連する構造を捉える
- 計算上の扱いやすさを維持する

特徴量エンジニアリングから表現学習まで。

- 従来の手法は、手作業で設計された機能に依存している
- ディープラーニングはデータから特徴を自動的に学習する

構成性。より単純な変換を組み合わせることで、複雑な機能を構築できる。

$$f(x) = L(L^{-1}(\cdots L^{-1}(x)))。$$

この考え方が、深層ニューラルネットワークの基礎を形成している。

幾何学的視点。フィーチャマップはデータの形状を再構築します。

- クラスターが分離可能になり、
- 非線形構造が線形になる、
- 距離と類似性の定義が再定義される。

9.5 統一的な視点

特徴マップは、線形モデルと非線形挙動の間の橋渡しとなる。

主要構成要素。

- 特徴マップ
- 特徴空間における線形モデル
- パラメータの最適化

二つのパラダイム。

- 固定機能 : 手動で設計 (例 : カーネル)
- 学習された特徴量 : モデルと共同で最適化 (深層学習)

重要な洞察。機械学習における非線形性は、モデル自体から生じるのではなく、データの表現方法から生じることが多い。

9.6 展望

本章では、線形モデルを拡張する方法として特徴マップを紹介した。

- 非線形モデリングのための基底展開、
- 変換された空間における線形学習、
- 暗黙的な高次元特徴のためのカーネル法、

- 表現における表象の役割。

次の章では、地理情報と統計情報を組み合わせたサポートベクターマシンについて学びます。
カーネル法を用いたメトリック分析により、強力な分類器を生成する。

指導原則。表現方法の選択は、成功を左右することが多い。
学習システムにおいては、モデルの選択と同様に重要な要素となる。

第10章

サポートベクターマシン

10.1 マージン最大化

これまでの章では、線形分類器とその特徴マップによる拡張について学習しました。サポートベクターマシン (SVM) は、マージン最大化という幾何学的原理を導入することで、これらの概念をさらに洗練させたものです。

二値分類設定。 $y_i \in \{-1, +1\}$ とし、線形分類器を考える。

$$f(x) = w, x + b.$$

ポイントが正しく分類されるのは、以下の条件を満たす場合です。

$$y_i (w, x_i + b) > 0.$$

マージン。データポイントの (機能的な) マージンは次のように定義されます。

$$y_i (w, x_i + b)$$

幾何学的マージン。点から決定境界までの距離は

$$\frac{y_i (w, x_i + b)}{\|w\|}.$$

目標 : すべての訓練データ点において、最小マージンを最大化する分類器を見つける。

最適化問題。

$$\max_{w, b} \min_i \frac{y_i (w, x_i + b)}{\|w\|}.$$

同等の定式化。スケールを固定すると、次の式が得られます。

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{ただし } y_i(w \cdot x_i + b) \geq 1 \quad \forall i \text{ を満たすものとする。}$$

解釈。

- マージンの最大化 $\leftrightarrow \|w\|$ の最小化
- 階級間の明確な分離を促進する

サポートベクター。決定境界に最も近い点（つまり、制約条件が等しい点）のみが解に影響を与えます。

洞察。SVMは、すべての訓練データではなく、最も情報量の多いポイントに焦点を当てます。

10.2 ハードマージンとソフトマージン

上記の定式化は、データが線形分離可能であることを前提としている。しかし実際には、このようなケースは稀である。

ハードマージンSVM。完全な分

離可能性を仮定する。

- 制約を強制する：

$$y_i(w \cdot x_i + b) \geq 1$$

制限事項：ノイズや外れ値の影響を受けやすく、有効な解が得られない可能性がある。

ソフトマージンSVM。スラック変数 $\xi_i \geq 0$ を導入します。

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i。$$

客観的。

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i、$$

ここで、 $C > 0$ はマージンサイズと分類誤差の間のトレードオフを制御する。

解釈。

- ξ_i はマージン制約違反の度合いを示す。
- C の値が大きいほど、エラーに対するペナルティが強くなる
- C が小さいほど、より柔軟に対応できます

損失関数との関連。ソフトマージン定式化は、ヒンジ損失の最小化に対応する。

$$\ell(x_i, y_i) = \max(0, 1 - y_i f(x_i))。$$

考察：SVMは、マージン最大化と非分離データに対するロバスト性を兼ね備えています。

10.3 二重定式化（概念）

SVM最適化問題には、双対定式化と呼ばれる別の表現方法が存在する。

重要なアイデア。 w を最適化する代わりに、各データポイントに関連付けられた変数 α_i を導入します。

双対問題（非公式）。

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle,$$

α_i に対する制約条件付き。

重要な指摘だ。

- 解は内積 $\langle x_i, x_j \rangle$ のみに依存する
- サポートベクターのみが非ゼロの α_i を持つ

w の再構築。

$$w = \sum_{i=1}^n \alpha_i y_i x_i.$$

考察。分類器は、訓練データの重み付き組み合わせとして表現される。

実用上の意義。

- カーネルメソッドの使用を可能にする
- 解の疎性を明らかにする

10.4 カーネル法の再検討

双対定式化により、SVMを非線形分類に拡張することが可能になる。

カーネル置換。内積をカーネル関数に置き換える。

$$\langle x_i, x_j \rangle \rightarrow k(x_i, x_j).$$

結果として得られる分類器。

$$f(x) = \sum_{i=1}^n \alpha_i y_i k(x_i, x) + b.$$

解釈。

- データを暗黙的に特徴空間にマッピングする

- 元の空間に非線形決定境界を構築する

例。

- 多項式カーネル
- ガウス (RBF)カーネル

幾何学的視点。データは線形分離可能な空間に変換され、そこで最大マージン分離点が求められる。

利点。

- 柔軟な非線形モデリング
- 強力な理論的保証

制限事項。

- 計算コストはデータセットのサイズとともに増加する
- 最新の深層学習手法に比べて拡張性が低い

10.5 統一的な視点

サポートベクターマシンは、いくつかの中心的なアイデアを統合しています。

- 幾何学 :マージン最大化
- 最適化 :凸二次計画法
- 表現方法 :特徴マップとカーネル

重要な洞察。

- 優れた分類器はクラス間の分離を最大化する
- データポイントのサブセットのみが解を決定する
- カーネルを通して非線形性を導入することができる

SVMは、幾何学と最適化を組み合わせることで、いかに強力な学習アルゴリズムが実現できるかを示す好例である。

10.6 展望

本章では、分類に対する原理に基づいたアプローチとしてサポートベクターマシンを紹介した。

- マージンベース学習、
- 実世界のデータに対するソフト制約、
- 二重定式化と疎性、
- 非線形モデルのためのカーネル法。

次の章では、モデルの評価と選択に戻り、
モデルを比較し、ハイパーパラメータを実際を選択する方法について。

指導原則。効果的な学習は、表現力と堅牢性のバランスを取り、多くの場合、幾何学的原理や最適化原理を通して行われる。

第11章

モデル評価と 選択

11.1 トレーニング、検証、およびテスト

これまでの章では、データから学習するためのモデルと最適化手法を開発しました。しかし、重要な実践的な疑問が残っています。それは、モデルを信頼できる方法で評価し、比較するにはどうすればよ

いかということです。

中心的な課題は、真のリスクが

$$R(f) = E(x, y) \quad P [\ell(f(x), y)] \text{ は、データ}$$

生成分布 P にアクセスできないため、不明です。

データ分割。汎化性能を近似するために、利用可能なデータセットを3つの部分に分割します。

- トレーニングセット : モデルパラメータの適合に使用
- 検証セット : ハイパーパラメータの調整に使用
- テストセット : 最終的なパフォーマンスを推定するために使用されます。

ワークフロー。

1. トレーニングセットでモデルをトレーニングする
2. 検証セットを使用してハイパーパラメータを選択する
3. テストセットで最終モデルを評価する

重要な原則。テストセットはモデル選択時に使用してはならない。使用すると、過度に楽観的な推定値が得られるためである。

検証データへの過学習。繰り返しチューニングを行うと、間接的に検証セットに過学習してしまう可能性がある。そのため、交差検証などのより堅牢な評価戦略が必要となる。

11.2 クロスバリデーション

交差検証は、限られたデータを用いてモデルの性能を推定するための体系的な方法を提供する。

k分割交差検証。

- データセットをk個のサブセット（フォールド）に分割する

- 各折り目について：

– k – 1 回のフォールドでトレーニングする

– 残りの折り目で評価する

- フォールド間で結果を平均する

交差検証による推定値。

$$R_{CV} = \frac{1}{k} \sum_{j=1}^k R_j,$$

ここで、 R_j はフォールドjにおける検証誤差である。

利点。

- データの効率的な活用
- より安定したパフォーマンス予測

kの選択。

- kが小さい場合（例：5）：高速だがバイアスが大きい
- kが大きい場合（例：リーブワンアウト法）：バイアスは低いが、分散とコストは高くなる。

実用例。交差検証は、特にデータセットのサイズが小さい場合や中程度の場合に、ハイパーパラメータのチューニングに広く用いられています。

11.3 パフォーマンス指標

評価指標の選択は、学習課題によって異なります。

11.3. パフォーマンス指標

63

11.3.1 回帰分析指標

- 平均二乗誤差 (MSE):

$$\frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2$$

- 平均絶対誤差 (MAE) :

$$\frac{1}{n} \sum_{i=1}^n |f(x_i) - y_i|$$

解釈。

- MSEは大きな誤差に対してより強いペナルティを課す
- MAEは外れ値に対してより頑健である

11.3.2 分類指標

正確さ。

$$\frac{\text{正解数}}{\text{予測総数}}$$

精度と再現性。

- 精度 : 予測された陽性例のうち、実際に正しかったものの割合
- リコール : 実際に陽性であった症例のうち、検出された症例の割合

F1スコア。

$$F1 = 2 \times \frac{\text{精度} \times \text{再現率}}{\text{精度} + \text{再現率}}$$

ROC曲線とAUC曲線。

- ROC曲線は真陽性率と偽陽性率をプロットしたものです。
- AUCは分類性能の全体的な要約値です。

不均衡データ。クラスの不均衡がある場合、精度は誤解を招く可能性があります。適合率、再現率、AUCはより有益な評価指標となります。

確率的指標。確率を出力するモデルの場合、評価指標として交差エントロピー損失がよく用いられます。

11.4 モデル比較

モデルを選択する際には、検証結果に基づいて複数の候補を比較検討する必要があります。

ハイパーパラメータ。

- 正則化の強度
- モデルアーキテクチャ
- 最適化パラメータ

選考手順

1. 候補モデルのセットを定義する
2. 検証または交差検証を用いて各モデルを評価する
3. 最も性能の良いモデルを選択してください

モデル選択と評価。

- モデル選択には検証データを使用する
- 最終評価にはテストデータを使用する

モデル選択における過学習。多くのモデルをテストすると、偶然に優れた性能を発揮するモデルを選択してしまうリスクが高まる。

実践的な戦略。

- 交差検証を使用する
- ハイパーパラメータの探索空間を制限する
- 性能が同程度の場合は、よりシンプルなモデルを優先する。

トレードオフ。

- 正確性 vs. 複雑さ
- パフォーマンスと計算コストの比較

再現性。信頼性の高いモデル比較には、一貫したデータ分割と管理された実験環境が必要です。

11.5 統一的な視点

モデルの評価と選択は、学習プロセスにおいて不可欠な要素である。

パイプライン。

- データに基づいてモデルをトレーニングする
- 汎化性能を推定する
- 最適なモデルを選択してください
- 最終パフォーマンスを評価する

主な課題。

- データが限られている
- 推定値のばらつき
- 選抜過程における過学習のリスク

重要なポイント。信頼性の高い評価を行うには、トレーニング、検証、テストの役割を明確に区別する必要がある。

11.6 展望

本章では、モデルの評価と選択の原則について紹介した。

- 偏りのない評価のためにデータを分離する、
- 頑健な推定値を得るための交差検証の使用、
- 適切なパフォーマンス指標の選択、
- モデルを体系的に比較する。

次の章では、最適化手法についてさらに深く研究し、大規模機械学習で使用される実践的な技術について解説します。

基本原則。モデルの価値は、その評価方法によって決まる。有意義な学習には、信頼できる評価が不可欠である。

第12章

最適化の実践

12.1 確率的勾配降下法

第4章では、機械学習モデルの学習における主要な手法として勾配ベースの最適化を紹介しました。しかし実際には、大規模なデータセットに対して完全な勾配を計算することは、計算上困難な場合が多いのです。

確率的勾配降下法 (SGD)。完全な勾配を計算する代わりに、

$$\nabla L(\theta) = \frac{1}{n} \sum_{i=1}^n \nabla \ell(f_{\theta}(x_i), y_i),$$

我々は、ランダムに選択された単一のデータポイントを使用してそれを近似する。

$$\theta_{t+1} = \theta_t - \eta \nabla \ell(f_{\theta}(x_{it}), y_{it}).$$

解釈。

- 各更新は、真の勾配のノイズを含む推定値である。
- ノイズはサンプリングから生じる

主な特性。

- 反復あたりの計算コストが低い
- 大規模データセットでのトレーニングを可能にする
- 最適化に確率性を導入する

収束挙動（非公式）。

- SGDは厳密には最小値に収束しない
- その代わりに、損失の少ない領域を中心に変動する。

洞察。SGDの確率性は、急激な最小値から抜け出し、損失ランドスケープをより効果的に探索するのに役立ちます。

12.2 ミニバッチ処理と効率性

実際には、SGDは単一のデータポイントを使用して実装されることはほとんどありません。代わりに、ミニバッチを使用します。

ミニバッチSGD。

$$\theta_{t+1} = \theta_t - \eta \frac{1}{|B_t|} \sum_{i \in B_t} \nabla \ell(f(\theta(x_i), y_i),$$

ここで、 B_t はデータポイントのサブセット（バッチ）である。

利点。

- 勾配推定値の分散を低減する
- 並列計算（例：GPU）を活用する
- 純粋なSGDよりも安定したアップデート

バッチサイズのトレードオフ。

- 少量生産：
 - 騒々しいアップデート
 - 場合によってはより優れた一般化
- 大量生産：
 - より正確なグラデーション
 - ステップあたりの計算コストが高い

効率性に関する考慮事項。

- メモリの制約によりバッチサイズが制限される
- より大きなバッチではハードウェアアクセラレーションの恩恵を受ける

エポックとイテレーション。

- 1エポック：データセットを1回通過する
- 反復：1回のパラメータ更新

12.3 運動量法と適応法

基本的なSGDは、特に高次元の問題においては、処理速度が遅かったり不安定になったりする可能性がある。いくつかの改良により、その性能が向上しました。

12.3. 運動量法と適応法

69

12.3.1 モメンタム

ルールを更新する。

$$\mathbf{v}_{t+1} = \beta \mathbf{v}_t + \nabla L(\theta_t), \quad \theta_{t+1} = \theta_t - \eta \mathbf{v}_{t+1}.$$

解釈。

- 過去の勾配を蓄積する
- アップデートをスムーズにし、収束を加速します

幾何学的な直感。運動量は平坦な領域を素早く移動するのに役立ち、曲率の高い方向での振動を軽減する。

12.3.2 適応的手法

適応型手法は、個々のパラメータに応じて学習率を調整する。

例。

- アダグラッド
- RMSProp
- アダム

重要な考え方。

- 過去の勾配の大きさに基づくスケールの更新
- 出現頻度の低い特徴には、より大きなステップを使用する
- 頻繁に更新されるパラメータには、より小さなステップを使用する

アダム（概念形態）。

- 勾配と勾配の二乗の移動平均を維持する
- モメンタムと適応スケールリングを組み合わせる

実践的な観察。

- 適応型手法は収束が速いことが多い
- モメンタム付きSGDは、状況によってはより一般化しやすい可能性がある

12.4 実用的収束挙動

現実世界では、最適化は理想的な理論的挙動に沿うことはほとんどない。

学習率スケジューリング。

- 時間の経過とともに学習速度が低下する
- 一般的な戦略：
 - ステップ減衰
 - 指数減衰、– コサインアニーリング

準備し始める。

- 最初は学習速度を小さくすることから始める
- 初期トレーニングを安定させるために徐々に増やす

平坦な状態と急激な落ち込み。

- トレーニング効果の低下は徐々に減少し、その後急激に改善する可能性がある
- 損失状況の変化を反映している

ノイズと一般化。

- SGDからのノイズは暗黙の正則化として機能する可能性がある
- 急激な最低値を回避するのに役立ちます

停止基準。

- 固定数のエポック
- トレーニング損失の収束
- 検証に基づく早期停止

実務上の課題。

- 学習ペースの選択
- ハイパーパラメータの調整
- 速度と安定性のバランス

洞察。実践における最適化は、理論的な原理と経験的な知見の両方に導かれる、科学であると同時に芸術でもある。

12.5 統一的な視点

現代の機械学習における最適化は、複数の相互作用する構成要素から成り立っています。

- アルゴリズム : SGDとその派生アルゴリズム
- ハイパーパラメータ : 学習率、バッチサイズ
- ダイナミクス : ノイズ、曲率、景観構造

根本的なトレードオフ。

- 速度と安定性
- 精度と計算コスト
- 最適化と一般化

重要な洞察。最適化アルゴリズムの挙動は、モデルの学習速度だけでなく、モデルが見つける解の種類にも影響を与える。

12.6 展望

本章では、最適化を実践的な観点から考察した。

- 確率的勾配法、
- ミニバッチ処理と効率性、
- 運動量および適応アルゴリズム、
- 現実世界における収束挙動。

次の章では、数値的および統計的安定性について考察し、データの前処理と条件付けが学習にどのように影響するかに焦点を当てます。

基本原則。効果的な最適化には、アルゴリズムそのものと、それが適用される問題の構造の両方を理解することが不可欠である。

第13章

数値および統計

安定性

13.1 不調

これまでの章では、最適化手法とその実際の挙動について考察しました。しかし、これらの手法の有効性は、問題の数値的な特性に大きく依存します。

定義（非公式）：入力のわずかな変化が出力の大きな変化につながる場合、その問題は悪条件であると言われる。

例（線形回帰）。解

$$w = (X^T X)^{-1} X^T y$$

$X^T X$ がほぼ特異な場合、摂動に対して敏感である。

条件数。正定値行列Aの場合、条件数は

$$\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}.$$

解釈。

- $\kappa(A)$ が大きい場合 → 条件の悪い問題
- $\kappa(A)$ が小さい → 条件の良い問題

幾何学的な直観。条件が悪いということは、損失関数のレベルセットが長く伸びていることを意味し、最適化を困難にする。

結果。

- 勾配法の収束が遅い

- 行列逆行列計算における数値的不安定性
- 騒音に対する感度

悪影響の原因。

- 相関性の高い特徴
- 冗長な入力
- 変数のスケーリングが不十分

13.2 スケーリングと正規化

条件付けを改善するシンプルかつ効果的な方法は、データを前処理することです。

特徴量のスケーリング。各特徴量を同程度の大きさになるように変換します。

標準化。

$$\leftarrow \frac{x_j - \mu_j}{\sigma_j},$$

ここで、 μ_j と σ_j は特徴 j の平均値と標準偏差である。

正規化。入力をスケーリングして、ノルムが制限されるようにします。例:

$$x \leftarrow \frac{x}{\|x\|}.$$

最適化への影響。

- グラデーションを次元間でよりバランス良くします
- 収束速度が向上します
- 数値的不安定性を低減する

条件数との関連。適切なスケーリングを行うことで、問題の条件数を減らすことができる。

深層学習における正規化。

- バッチ正規化
- レイヤー正規化

考察。正規化は、最適化問題の形状を動的に調整するものと考えられる。

13.3 ノイズに対する感度

現実世界のデータにはノイズが含まれていることが多い。安定した学習アルゴリズムは、小さな摂動に対して過度に敏感であってはならない。

騒音源。

- 測定誤差
- 不完全な観測結果
- 本質的なランダム性

学習への影響。

- 過学習につながる可能性がある
- パラメータ推定値を不安定化させる可能性がある

例（最小二乗法）。条件の悪い問題では、 y の小さなノイズが w に大きな変化をもたらす可能性があります。

バイアス・バリエーションの観点から。

- 高分散モデルはノイズに対してより敏感である
- 正則化により感度が低下する

安定性とは堅牢性のことである。安定したアルゴリズムは、入力が変わっても、同様の出力を生成する。

アルゴリズムの安定性（非公式）。単一のデータポイントを削除または変更しても学習済みモデルが大きく変化しない場合、そのアルゴリズムは安定しているとみなされます。

洞察。安定性は汎化性能と密接に関連している。安定したアルゴリズムは汎化性能が高い傾向がある。

13.4 堅牢性に関する考慮事項

数値的な安定性に加えて、より広範な摂動に対するロバスト性も重要な関心事となることが多い。

堅牢性の種類。

- データのノイズに対する耐性
- 分布変動に対する堅牢性
- 敵対的摂動に対する堅牢性

堅牢な損失関数。

- 平均二乗誤差 : 外れ値に敏感
- 絶対誤差 : より堅牢

正則化とロバスト性。モデルの複雑さを制限することで、ロバスト性が向上することが多い。

データ拡張。訓練データにバリエーションを導入することで、変換に対する耐性を向上させることができます。

敵対的視点（非公式）。慎重に選択された小さな摂動は、特に高次元の設定において、モデルの予測に大きな影響を与える可能性がある。

洞察。堅牢性を確保するには、安定したモデルとデータに関する適切な仮定の両方が必要です。

13.5 統一的な視点

数値的安定性と統計的安定性は密接に関連している。

- 数値安定性 : 計算誤差に対する感度
- 統計的安定性 : データ変動に対する感度

重要な要素。

- 問題の条件付け
- データ前処理
- モデルの複雑さ
- 正則化

核心的な洞察。安定した学習システムとは、数値的および統計的な小さな摂動に対して予測可能な挙動を示すシステムのことである。

13.6 展望

本章では、安定性を数値的観点と統計的観点の両方から検討した。

- 不調とその結果、
- スケーリングと正規化の役割、

- 騒音に対する感度、
- 堅牢性に関する考慮事項。

次の章では、古典的なモデルからニューラルネットワークへと移行します。
これらの考え方の自然な延長として、深層学習を推進する。

指導原則。安定性は信頼性の高い学習に不可欠である。モデルは
データに適合するだけでなく、摂動や不確実性に対して頑健な方法で適合させる。

第14章

古典モデルから ニューラルネットワーク

14.1 浅層モデルの限界

これまでの章では、線形回帰、ロジスティック回帰、カーネル法など、さまざまな古典的なモデルについて学習しました。これらのモデルは強力ですが、根本的な限界も抱えています。

浅いモデル。ここでは、次の形式のモデルを指します。

$$f(x) = w \cdot \phi(x),$$

ここで、 w は固定されているか、または単一の変換層のみを含む。

主な制約: 表現。これらのモデルの成功は、特徴量 $\phi(x)$ の選択に大きく依存します。

課題。

- 効果的な機能を設計するには、専門知識が必要です。
- 固定フィーチャーマップは複雑な構造を捉えきれない可能性がある
- 高次元特徴空間は計算コストが高くなる可能性がある

表現力の限界。

- 線形モデルは線形決定境界を生成する
- カーネル法は柔軟性を提供するが、データサイズに対するスケーラビリティが低い。

次元の呪い。明示的な特徴量拡張では、複雑なパターンを捉えるために指数関数的に多くの特徴量が必要となることが多い。

考察。従来のモデルでは、表現と学習が分離されています。つまり、まず特徴量が設計され、次にモデルが適合されます。この分離は、モデルの有効性を制限する可能性があります。

第14章 古典モデルからニューラルネットワークへ

14.2 関数の構成構造

現実世界の多くの機能は、構成的な構造を示す。

定義（非公式）：関数が合成関数であるとは、より単純な関数の合成として記述できる場合をいう。

$$f(x) = f_L(f_{L-1}(\dots f_1(x)))。$$

例。

- 画像: エッジ → 形状 → オブジェクト
- 言語: 文字 → 単語 → 文

階層構造。各層は、異なる抽象度レベルでパターンを捉えている。

構成の効率性。構成表現は、比較的少ないパラメータで複雑な関数を記述できます。

浅いモデルとは対照的である。浅いモデルでは、複数の層を用いてコンパクトに表現できる関数を表現するために、指数関数的に多くのユニットが必要となる場合がある。

洞察。深さによって中間計算の再利用が可能になり、より効率的な表現につながる。

14.3 深層学習の動機

深層学習は、表現と機能の両方を合成によって学習するという考え方から生まれた。

ニューラルネットワーク。L層のニューラルネットワークは次の形式をとります。

$$f(x) = f_L(f_{L-1}(\dots f_1(x)))$$

ここで、各層は通常、アフィン変換とその後の非線形変換から構成される。

主な利点。

- 自動特徴学習：特徴は手動で設計するのではなく、データから学習されます。
- 表現力：ディープネットワークは非常に複雑な関数を表現できる。
- 拡張性：大規模データセットと最新のハードウェアを用いた効率的なトレーニング。

普遍近似（非公式）。ニューラルネットワークは、十分な容量があれば、幅広い種類の関数を近似することができる。

実用面での成功。ディープラーニングは、以下の分野で優れた実績を上げています。

- コンピュータビジョン、
- 自然言語処理、
- 音声認識、
- 生成モデリング。

重要な転換点。機能を設計するのではなく、機能を自動的に学習できるアーキテクチャを設計する。

14.4 学習された表現への移行

古典的なモデルから深層学習への移行は、表現の構築方法の変化を伴う。

古典的なアプローチ。

- 特徴マップは固定されている
- モデルはパラメータを学習します

深層学習アプローチ。

- 特徴マップ θ はパラメータ化されている
- 表現とモデルは同時に学習される

モデル構造。

$$f(x) = g\theta(\theta(x)),$$

ここで、 θ と $g\theta$ はどちらもパラメータに依存する。

階層的な表現。

- 初期層 : 局所的または低レベルの特徴
- 中間層 : パターンと構造
- 最終層 : タスク固有の表現

幾何学的観点。ディープネットワークは、連続的な非線形マッピングによってデータを変換し、その形状を再構築することで学習を容易にする。

最適化の観点から見ると、学習とは、すべての層にわたって同時に、非常に非凸な目的関数を最適化することである。

構造による規則化。アーキテクチャの選択は、学習を導く帰納的バイアスを課す。

- 畳み込み層は局所性を符号化し、

第14章 古典モデルからニューラルネットワークへ

- 注意メカニズムは関係性を符号化し、
- 残存する神経結合がトレーニングを安定させる。

洞察。ディープラーニングは、表現、モデリング、最適化を単一のフレームワークに統合します。

14.5 統一的な視点

私たちは今、モデルの進化を再解釈することができる。

- 古典的モデル : 固定表現 + 単純モデル
- カーネル法 : 暗黙的な高次元表現
- ディープラーニング : 階層的な表現を学習する

核心となる考え方。現代の機械学習の力は、問題をより簡単に解決できるような表現を学習することにある。

主要構成要素。

- 表現（特徴）
- 機能（マッピング）
- 最適化（学習）

ディープラーニングは、これらの要素を統一的かつ拡張可能な方法で統合します。

14.6 展望

この章は、古典的なモデルからニューラルネットワークへの移行を促すきっかけとなった。

- 浅いモデルの限界、
- 構成構造の重要性、
- ディープアーキテクチャの利点、
- 学習された表現への移行。

次の章では、ニューラルネットワークの分析からディープラーニングの研究を始めます。ネットワークを合成関数近似器として利用する。

基本原則。複雑な問題には構造化された表現がしばしば必要であり、深層思考はそうした表現を構築するための自然な方法を提供する。

第15章

ニューラルネットワークとして 構成モデル

15.1 階層型アーキテクチャ

ニューラルネットワークは、単純な変換を階層的に組み合わせた構造になっています。この階層構造こそが、複雑な関係性をモデル化することを可能にする決定的な特徴です。

基本構造。L 層のニューラルネットワークは関数を定義します。

$$f(x) = f_L \circ f_{L-1} \circ \dots \circ f_1(x),$$

各層は、

$$f_\ell(z) = \sigma(W_\ell z + b_\ell).$$

構成要素。

- W_ℓ : 重み行列
- b_ℓ : バイアスベクトル
- σ : 非線形活性化関数

順伝播。入力 x が与えられると、ネットワークは中間表現を計算します。

$$z^{(1)} = f_1(x), z^{(2)} = f_2(z^{(1)}), \dots, z^{(L)} = f_L(x).$$

解釈。

- 各レイヤーはデータの表現を変換します

第15章 ニューラルネットワークを構成モデルとして捉える

- 最終出力は、連続的な改良に依存する

一般的な起動関数。

- ReLU: $\sigma(z) = \max(0, z)$
- シグモイド関数: $\sigma(z) = \frac{1}{1+e^{-z}}$
- Tanh: $\sigma(z) = \tanh(z)$

非線形性の役割。非線形活性化関数がない場合、線形層の構成は単一の線形変換に還元されます。

洞察。非線形性により、ニューラルネットワークは複雑な非線形関係を表現できるようになる。

15.2 表現力と深み

中心的な問いは、ニューラルネットワークの構造がその表現力にどのように影響を与えるかということである。

幅と奥行き。

- 幅 : 層あたりのユニット数
- 深さ : 層の数

浅いネットワークと深いネットワーク。

- 浅いネットワーク : 層が少なく、非常に広い可能性がある
- ディープネットワーク : 多くの層があり、多くの場合、より狭い

重要な観察結果。奥行きがあることで、関数をより効率的に表現できる。

例（合成関数）。階層構造を持つ関数は、ディープネットワークではコンパクトに表現できますが、シャローネットワークでは指数関数的に多くのパラメータが必要になる場合があります。

幾何学的な直感。各レイヤーは入力空間を再構成し、複雑な構造を徐々に単純な構造へと変換していく。

区分的線形性。ReLU活性化関数を持つネットワークは、潜在的に多くの領域を持つ区分的線形関数を表します。

洞察。奥行きが深くなると、線形領域の数が指数関数的に増加し、表現力が向上します。

トレードオフ。

- より深い表現力
- しかし、より困難な最適化も必要となる

15.3 普遍近似（洞察）

ある基本的な理論的結果が、ニューラルネットワークが強力な近似器である理由を説明している。

普遍近似（非公式）。単一の隠れ層と適切な活性化関数を持つフィードフォワードニューラルネットワークは、十分な幅があれば、コンパクトな領域上の任意の連続関数を近似できる。

解釈。

- ニューラルネットワークは表現力が非常に高い
- 浅いネットワークでも複雑な関数を近似できる

制限。

- この定理では必要な単位数が明記されていない
- 実践的な学習は難しい場合がある

深さの役割。浅いネットワークでも理論的には十分だが、深いネットワークの方がより効率的な表現を提供することが多い。

洞察。普遍近似は存在を保証するが、効率性や学習可能性を保証するものではない。

実践との関連性。ディープアーキテクチャが好まれる理由は以下のとおりです。

- 必要なパラメータが少なく、
- 多くの場合、訓練が容易である。
- データの構成構造に合わせる。

15.4 表現学習

ニューラルネットワークの決定的な特徴の一つは、表現を自動的に学習できる能力である。

学習された特徴。各層は表現を生成します。

$$\ell^z = f_\ell(z(\ell-1)),$$

これは入力に関する情報を符号化する。

表象の階層構造。

- 初期層 : 局所的または低レベルの特徴
- 中間層 : パターンと構造

第15章 ニューラルネットワークを構成モデルとして捉える

- 最終層 :タスク固有の機能

古典的な方法とは対照的である。

- 古典的なモデルは固定フィーチャマップを使用する
- ニューラルネットワークはデータから特徴を学習する

幾何学的視点。各レイヤーはデータの形状を変換し、データの分離やモデリングを段階的に容易にします。

構成的学習。より単純な特徴を複数の層に組み合わせることで特徴が構築される。

解釈。学習には、以下の両方を発見することが含まれます。

- データをどのように表現するか、
- 表現を出力にマッピングする方法。

洞察。表現学習は、多様な分野における深層学習の成功の重要な理由の一つである。

15.5 統一的な視点

ニューラルネットワークは、以下の3つの相補的な視点から理解することができる。

- 機能的 :非線形関数の合成
- 幾何学的変換 :データ表現の変換
- 計算処理 :階層型処理アーキテクチャ

主要構成要素。

- パラメータ (w_l 、 b_l)
- 非線形活性化
- 構成構造

重要な洞察。ニューラルネットワークの強みは、その表現力だけでなく、構成を通して構造化された表現を学習する能力にもある。

15.6 展望

本章では、ニューラルネットワークを構成モデルとして紹介した。

- 階層型アーキテクチャ、
- 表現力における奥行き役割、
- 理論的基礎としての普遍近似、
- 表象学習を中心原理とする。

次の章では、ニューラルネットワークを効率的に学習させる方法について考察します。
バックプロパゲーションと自動微分法を用いる。

基本原則。複雑な関数は、より単純な関数の合成として理解できることが多く、ニューラルネットワークは、データからそのような合成を学習するための枠組みを提供する。

第15章 ニューラルネットワークを構成モデルとして捉える

第16章

逆伝播と 自動微分

16.1 計算グラフ

ニューラルネットワークは関数の合成である。勾配を効率的に計算するには、これらの計算を明示的に表現することが有効である。

計算グラフ。計算グラフとは、関数がより単純な操作からどのように構築されるかを表す有向非巡回グラフ（DAG）のことです。

ノードとエッジ。

- ノードは変数または中間値を表します
- エッジは関数的な依存関係を表す

例。単純な関数を考えてみましょう。

$$z = (x_1 + x_2) \cdot x_3。$$

これをグラフで表すと次のようになります。

- $a = x_1 + x_2$
- $z = a \cdot x_3$

順伝播。入力から出力までグラフを評価し、すべての中間値を計算します。

解説 :ニューラルネットワークは大規模な計算グラフであり、各層は一連の演算に対応している。

第16章 バックプロパゲーションと自動微分

16.2 連鎖律と逆モード微分 協会

ニューラルネットワークを訓練するには、すべてのパラメータに関して損失関数の勾配を計算する必要があります。

連鎖律。関数の合成の場合、

$$f(x) = f_L(f_{L-1}(\dots f_1(x)))$$

導関数は連鎖律を繰り返し適用することによって得られる。

局所微分。計算グラフの各ノードは局所微分に寄与する。

逆モード微分。出力からの感度をグラフを通して逆方向に伝播させることで勾配を計算します。

基本原理。変数 z が中間変数を介して x に依存する場合、

$$\frac{\partial L}{\partial x} = \text{パス} \quad \frac{\partial L}{\partial z} \cdot \frac{\partial z}{\partial x}.$$

逆伝播。ネットワークを通して勾配を逆方向に伝播させるこのプロセスは、逆伝播として知られています。

例。 $z = a \cdot x^3$ および $a = x_1 + x_2$ の場合、

$$\frac{\partial z}{\partial x_1} = \frac{\partial z}{\partial a} \cdot \frac{\partial a}{\partial x_1}.$$

洞察。バックプロパゲーションは、計算グラフ全体に連鎖律を体系的に適用します。

16.3 効率的な勾配計算

勾配を単純に計算すると、特にディープネットワークの場合、計算コストが高くなる。

重要なアイデア : 順伝播における中間計算結果を再利用する。

前方パス。

- すべての中間値を計算する
- 再利用のために保管する

バックパス。

- 勾配を逆順に計算する

- 保存済みの中間値を再利用する

複雑性。バックプロパゲーションは、関数自体を評価するのと同程度のコストで勾配を計算します。

勾配の流れ。勾配は層ごとに伝播します。

$$\frac{\partial L}{\partial W\ell} \quad \text{に依存する} \quad \frac{\partial L}{\partial z(\ell)}。$$

共有サブ計算。計算グラフにより、繰り返し行われる演算は一度だけ計算されることが保証されます。

洞察。バックプロパゲーションは、冗長な計算を回避し、ネットワークの構造を活用するため、効率的です。

16.4 実施に関する展望

現代の機械学習フレームワークは、自動微分を用いてバックプロパゲーションを実装している。

自動分化（AD）。

- 正確な導関数を計算します（数値精度まで）。
- 微分可能な演算の任意の組み合わせに対応

ADの2つのモード。

- 前進モード
- 逆方向モード（ディープラーニングで使用）

逆モードを使う理由 : 関数に多数のパラメータがあり、出力が1つしかない場合（学習問題でよく見られるケース）に効率的です。

実践的なワークフロー。

1. モデルを計算グラフとして定義する
2. フォワードパスを実行して損失を計算します。
3. 自動微分を用いて勾配を計算する
4. 最適化アルゴリズムを使用してパラメータを更新する

メモリに関する考慮事項。

- 中間値は後方パスのために保存する必要がある
- 大規模モデルでは、慎重なメモリ管理が必要です。

第16章 バックプロパゲーションと自動微分

数値的な問題。

- 消失勾配と爆発勾配
- 有限精度演算

洞察。自動微分は勾配計算の複雑さを抽象化し、実務者がモデル設計に集中できるようにします。

16.5 統一的な視点

バックプロパゲーションは、いくつかの中心的概念を結びつけています。

- 数学 : 導関数の連鎖律
- 計算 : 中間値の効率的な再利用
- アルゴリズム : 深層ネットワークのスケラブルなトレーニング

主要構成要素。

- 計算グラフ
- 前方パス
- バックパス

核心的な洞察。バックプロパゲーションは、連鎖律を体系的に適用することで、複雑なモデルの効率的な学習を可能にする。

16.6 展望

この章では、バックプロパゲーションと自動微分について紹介した。

- モデルの表現としての計算グラフ、
- 効率的な勾配のための逆モード微分、
- 自動微分による実用的な実装。

次の章では、深層ネットワークのトレーニングにおける課題について考察します。初期化や勾配関連の問題を含む。

基本原則。勾配の効率的な計算こそが、現代の深層学習を可能にする鍵である。

第17章

ディープネットワークのトレーニング

17.1 初期化戦略

深層ニューラルネットワークの学習では、高次元のパラメータ空間において、非常に非凸な目的関数を最適化する必要があります。初期化の選択は、最適化の成否を左右する上で極めて重要な役割を果たします。

ランダム初期化。パラメータは通常、ランダムに初期化されます。

$w_{\ell}^{(0)}$ 分布、 $b(0)_{\ell} = 0$ または小さい値。

なぜ初期値をゼロにしないのか？

- 対称性 :すべてのユニットは同じように動作する
- 有意義な学習は起こらないだろう

分散保存。重要な原則は、活性化が層を伝播する際に消滅したり爆発したりしないように初期化を選択することです。

例（ザビエル／グロロの初期化）。

$$\text{Var}(W_{ij}) \approx \frac{2}{\text{イン} + \text{アウト}}$$

例（He初期化）。

$$\text{Var}(W_{ij}) \approx \frac{2}{\text{イン}}$$

洞察 :適切な初期化により、層間における安定した信号伝搬が維持される。

トレーニングへの影響。

- 良好な初期化 → より速い収束
- 初期化不良 → トレーニングが遅い、または失敗する

17.2 消失勾配と爆発勾配

深層ネットワークの学習における大きな困難の一つは、勾配の挙動に起因する。

勾配伝播。逆伝播では、重み行列と導関数を繰り返し乗算します。

$$\frac{\partial L}{\partial z(\ell)} = \frac{\partial L}{\partial z(\ell+1)} \cdot \sigma'(z(\ell+1)) \cdot W_{\ell+1, \ell}^T$$

消失するグラデーション。

- 勾配は深さとともに指数関数的に縮小する
- 初期層は非常にゆっくりと学習する

勾配の爆発。

- 勾配は指数関数的に増加する
- 不安定性や数値的な問題を引き起こす

原因。

- 小さい値または大きい値を繰り返し乗算する
- 飽和活性化関数（例：シグモイド関数）

緩和策。

- 慎重な初期化
- 非飽和活性化関数（例：ReLU）の使用
- 正規化手法
- グラデーションクリッピング

考察：安定した勾配の流れは、深層ネットワークにおける効果的な学習に不可欠である。

17.3 最適化の課題

ディープネットワークは、従来のモデルで遭遇する課題を超えた最適化上の課題をもたらす。

非凸性。損失関数には多くの局所最小値と鞍点が存在する。

高次元性。パラメータ空間には数百万、あるいは数十億もの変数が含まれる可能性がある。

鞍点。

17.4. 経験的訓練行動

95

- 局所的最小値の低さよりも一般的

- 最適化を遅らせる可能性がある

平坦な領域と鋭利な領域。

- 平坦な地域 : 進展が遅い

- 鋭角領域 : 不安定性

条件が悪い。方向によって曲率が大きく異なる場合があります、最適化が困難になる。

実践的な戦略。

- 確率的最適化 (SGD)を使用する
- 勢いをつける方法または適応的な方法を適用する
- 入力と活性化を正規化する

考察。理論的には複雑であるにもかかわらず、現実世界の問題の構造上、単純な最適化手法が実際にはうまく機能することが多い。

17.4 経験的訓練行動

深層ネットワークの学習では、理論では完全には捉えきれない特徴的なパターンがしばしば現れる。

トレーニングのダイナミクス。

- 損失の初期段階での急速な減少
- 後期段階では収束が遅くなる

一般化行動。

- トレーニング損失はほぼゼロに近づく可能性がある
- テストの成績は依然として良好である可能性がある

二重降下（非公式）。モデルサイズを大きくすると、テスト誤差は最初は増加し、その後減少する可能性がある。

過剰パラメータ化の役割。

- 大規模モデルは最適化しやすい
- 多くのソリューションで低いトレーニングエラーが実現

暗黙的な正則化。最適化のダイナミクスは、特定の解、多くの場合、優れた汎化特性を持つ解を優先する。

学習曲線。

- トレーニング誤差と検証誤差を時間経過とともにプロットする
- アンダーフィッティングとオーバーフィッティングの診断に使用されます

実践的な観察結果。

- データセットが大きいほどパフォーマンスが向上する
- より深いモデルはより多くの構造を捉えることができる
- 多くの場合、慎重な調整が必要となる。

洞察。理論が不完全な場合、経験的な挙動は重要な指針となる。

17.5 統一的な視点

深層ネットワークのトレーニングには、相互に作用する複数の要素が含まれます。

- 初期化 : 開始点を設定します
- 勾配流 : 信号伝搬を決定する
- 最適化 : 損失状況を把握する
- データとモデルのサイズ : 一般化への影響

中核的な課題。高次元かつ非凸な環境において、安定かつ効率的なトレーニングを確保すること。

重要なポイント。トレーニングを成功させるには、アーキテクチャ、初期化、最適化を整合させる必要がある。

17.6 展望

本章では、深層ネットワークのトレーニングにおける実際的な課題について検討した。

- 初期化戦略、
- 消失および爆発するグラデーション、
- 最適化の難しさ、
- 経験的訓練行動。

次の章では、活性化関数とアーキテクチャ設計について学習します。
選択肢は、ディープネットワークの挙動にさらに影響を与える。

基本原則。深層ネットワークのトレーニングには、数学的原理と経験的知見のバランスが不可欠である。

第18章

活性化関数と アーキテクチャ

18.1 非線形活性化

非線形活性化関数は、ニューラルネットワークの基本的な構成要素である。

これらを用いることで、ネットワークは線形変換だけでは捉えきれない複雑な非線形関係を表現することが可能になる。

活性化関数の役割。ニューラルネットワークの各層は、次の形式の変換を適用します。

$$z \rightarrow \sigma(Wz + b)$$

ここで σ は要素ごとに適用される。

非線形性が必要な理由。 σ が線形であれば、層の構成は単一の線形変換に還元される。

$$W_L W_{L-1} \cdots W_1 x,$$

深さの利点を排除する。

一般的な起動関数。

- S状結腸：

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

- タン:

$$\sigma(z) = \tanh(z)$$

- ReLU（整流線形ユニット）：

$$\sigma(z) = \max(0, z)$$

98 第18章 活性化関数とアーキテクチャ

特性。

- シグモイド関数とtanh関数は滑らかですが、飽和する可能性があります
- ReLUはシンプルで、正の領域での飽和を回避します。

バリエーション。

- リークーReLU
- ELU
- ゲル

勾配挙動。

- 活性化の飽和 → 勾配の消失
- 区分的線形活性化関数 → 安定した勾配

考察 : 活性化関数の選択は、表現力と最適化のダイナミクスの両方に大きな影響を与える。

18.2 建築設計パターン

個々の層だけでなく、ニューラルネットワーク全体の構造もその性能に決定的な役割を果たす。

完全接続型ネットワーク。各層は前の層のすべてのユニットに接続されています。

畳み込みアーキテクチャ。

- 空間的局所性を活用する
- 複数の拠点間でパラメータを共有する

残存接続。

- レイヤー間に同一性マッピングを追加する：

$$z^{(\ell+1)} = z^{(\ell)} + F(z^{(\ell)})$$

- 勾配流量と安定性を向上させる

正規化レイヤー。

- バッチ正規化
- レイヤー正規化

モジュール設計。現代の建築は、多くの場合、繰り返し使用されるブロック（例えば、畳み込みブロック、トランスフォーマーブロック）で構成されています。

洞察。建築設計は、学習を導く帰納的バイアスを組み込んでいる。

18.3 奥行きと幅の関係

ニューラルネットワークの構造は、その深さと幅によって特徴づけられる。

幅。各層のユニット数。

深さ。層の数。

浅く広いネットワーク。

- 多くの関数を近似できる
- 多数のパラメータが必要になる場合があります

ディープネットワーク。

- 階層構造を捉える
- 多くの場合、よりパラメータ効率が良い

表現力の比較。特定の関数はディープネットワークで効率的に表現できるが、浅いネットワークでは指数関数的に大きな規模が必要となる。

最適化に関する考慮事項。

- ネットワークが深くなるほど、トレーニングが難しくなる。
- 残留接続などの技術はこれを軽減する

洞察。深みは、構成構造を符号化する自然な方法を提供する。

18.4 表現力に関する考察

ニューラルネットワークの表現力は、そのアーキテクチャと活性化関数に依存する。

表現力。モデルが幅広い関数を近似できる能力。

表現力に影響を与える要因。

- 奥行きと幅
- 起動機能の選択
- 接続構造

区分的線形ネットワーク。ReLUネットワークは、多数の線形領域から構成される関数を表します。

幾何学的観点。各層は入力空間を分割し、表現の複雑さを増していく。

トレードオフ。

100 第18章 活性化関数とアーキテクチャ

- 高い表現力 → より良い近似
- しかし、過学習のリスクと最適化の難しさが増大する。

暗黙の制約。アーキテクチャは表現可能な関数のクラスを制限し、帰納的な偏りをもたらす。

洞察。表現力だけでは十分ではない。効果的な学習には、表現力と学習可能性のバランスが必要である。

18.5 統一的な視点

活性化機能とアーキテクチャは共同で以下を決定する。

- 情報がネットワークをどのように流れるか、
- 複雑な関数をどのように表現できるか、
- モデルの学習の容易さ。

主要構成要素。

- 非線形活性化
- レイヤー接続
- 建築様式

重要な洞察。ニューラルアーキテクチャの設計は、数学的構造と経験的パフォーマンスを組み合わせた現代の機械学習の中心的側面です。
マンス。

18.6 展望

本章では、活性化関数とアーキテクチャの役割について考察した。

- 表現力豊かなモデルを可能にする非線形活性化、
- 学習を形作る建築パターン、
- 深さと幅のトレードオフ、
- 表現力に影響を与える要因。

次の章では、重要な役割を果たす正規化手法について学びます。
トレーニングの安定化と加速化において。

基本原則。深層学習システムの有効性は、その規模だけでなく、構造にも左右される。

第19章

正規化手法

19.1 バッチ正規化

深層ニューラルネットワークの学習は、活性化の規模と分布に影響を受けやすい。正規化手法は、中間表現を標準化することでこの問題を解決する。

バッチ正規化 (BatchNorm)。レイヤー内の活性化値 z が与えられた場合、Batch-Normはそれらを次のように変換します。

$$z_i = \frac{z_i - \mu_B}{\sqrt{\hat{\sigma}_B^2 + \epsilon}}$$

ここで、 μ_B と σ_B^2 は、これらは、ミニバッチ全体で計算された平均値と分散です。

アフィン変換。正規化後、学習可能な変換が適用されます。

$$y_i = \gamma z_i + \beta$$

ここで、 γ と β はパラメータである。

目的。

- 活性化分布を安定化させる
- 勾配流量を改善する
- トレーニングを加速する

解釈。バッチ正規化は、パラメータと入力のスケーリングに対する感度を低減します。

学習と推論。

- トレーニング中 : ミニバッチから計算された統計情報
- 推論中 : 移動平均が使用される

実効性。

- より大きな学習速度を可能にする
- 初期化への依存度を低減する

19.2 レイヤーとインスタンスの正規化

BatchNormはバッチ統計に依存しているが、他の正規化手法はバッチとは独立して動作する。

19.2.1 レイヤー正規化

定義。レイヤー正規化とは、単一のデータポイント内のフィーチャ間で正規化を行うことです。

$$z = \frac{z - \mu_{\text{層}}}{\sqrt{\sigma_{\text{層}}^2 + \epsilon}}$$

特性。

- バッチサイズに依存しない
- シーケンスモデル（例：変圧器）に適しています

19.2.2 インスタンスの正規化

定義。インスタンス正規化とは、視覚タスクにおいて、多くの場合空間次元にわたって、各サンプルを個別に正規化する手法である。

アプリケーション。

- 画像生成
- スタイル転送

方法の比較。

- BatchNorm: バッチ統計を使用します
- LayerNorm: サンプルごとの特徴統計を使用します
- InstanceNorm: サンプルごとに空間統計を使用します

考察：異なる正規化手法は、データの構造に関する異なる仮定を反映している。

19.3 トレーニングの安定化

正規化手法は、トレーニングの安定性と効率性を向上させる。

最適化への影響。

- 損失状況の平準化
- パラメータのスケーリングに対する感度を低減する
- コンディショニングを向上させる

勾配流。

- グラデーションの消失や爆発を防ぎます
- 一貫した信号伝搬を維持する

内部共変量シフト（非公式な説明）。トレーニング中にパラメータが変化すると、活性化の分布がシフトします。正規化はこの影響を軽減します。

正則化効果。

- BatchNormはバッチ統計を通じてノイズを導入します
- 一般化能力を向上させることができる

学習率の相互作用。

- より大きな学習率の使用を可能にする
- より速い収束につながる

洞察。正規化は最適化問題を再構成し、解決を容易にする。

19.4 理論的および実践的な洞察

正規化手法は広く用いられているものの、その理論的な理解は依然として発展途上にある。

スケール不変性。正規化により、ネットワークはパラメータのスケーリングに対する感度が低下します。

パラメータの再設定。正規化は、モデルのパラメータ設定を変更することと見なすことができ、これは最適化のダイナミクスに影響を与えます。

最適化の幾何学。正規化は損失関数の形状を効果的に変更し、多くの場合、より良好な条件数にします。

経験的観察。

- トレーニング速度を向上させる
- アーキテクチャ全体にわたる安定性を向上させる
- 多くの最新のディープネットワークにおいて不可欠

制限事項。

- BatchNormはバッチサイズに依存します
- 非常に少量のバッチでは動作が不安定になる可能性がある

設計上の考慮事項。

- 正規化の選択はアーキテクチャとデータに依存する
- 他の技術（例：残差接続）と組み合わせて使用されることが多い

洞察。正規化は、最適化を改善するための実用的なツールであると同時に、概念的なメカニズムでもある。

19.5 統一的な視点

正規化手法は、次のような変換として理解できます。

- 表現を標準化する、
- コンディショニングを改善する、
- 勾配流を安定させる、
- 暗黙的な正則化を導入する。

主要構成要素。

- 正規化ステップ
- 学習可能なスケールリングとシフト
- 最適化ダイナミクスとの相互作用

重要な洞察。正規化は、ディープネットワークを大規模に学習可能にする上で中心的な役割を果たす。

19.6 展望

本章では、深層学習における正規化手法について考察した。

- バッチ正規化とその派生形、
- 代替正規化戦略、
- 訓練の安定化における彼らの役割、
- 理論的および実践的な観点。

次の章では、ドロップアウトやデータ拡張など、深層学習に特有の正則化手法について学習します。

基本原則 : 中間表現の適切な変換は、最適化と汎化の両方を大幅に改善することができる。

第20章

深層学習における正則化 学ぶ

20.1 ドロップアウトとノイズ注入

深層ニューラルネットワークは表現力が非常に高い反面、訓練データに過学習しやすいという欠点がある。したがって、汎化性能を向上させるためには、正則化手法が不可欠である。

ドロップアウト。ドロップアウトは、学習中にユニットをランダムに非アクティブ化する確率的正則化手法です。

メカニズム。各ユニットについて、バイナリマスクがサンプリングされる。

$$m_i \sim \text{Bernoulli}(p)$$

アクティベーションは次のように変更されます

$$z_i = m_i z_i。$$

解釈。

- 各反復処理では、異なるサブネットワークがトレーニングされます。
- 機能の同時適応を防ぐ

推論。テスト時には、ドロップアウトを考慮してアクティベーションがスケールリングされます。

$$z_i \leftarrow p z_i。$$

効果。

- 堅牢性を向上させる
- 過学習を軽減する

ノイズ注入。より一般的には、ノイズは入力、活性化関数、またはパラメータに追加できます。

$$z \leftarrow z + \varepsilon,$$

ここで ε はランダムノイズである。

洞察。ノイズは、小さな摂動に影響を受けにくい安定した特徴をモデルが学習することを促します。

20.2 重量減少

重み減衰は、深層学習において最も広く用いられている正則化手法の一つである。

客観的。

$$\min_{\theta} R = n(\theta) + \lambda \|\theta\|_2^2.$$

解釈。

- 大きなパラメータ値にペナルティを課す
- よりシンプルなモデルを推奨する

最適化への影響。更新ルールは次のようになります。

$$\theta_{t+1} = (1 - \eta\lambda)\theta_t - \eta \nabla R(\theta_t).$$

考察 : パラメータはトレーニング中に徐々にゼロに向かって縮小されます。

安定性との関連性。重みが小さいほど、関数の動作が滑らかになり、汎化性能が向上することが多い。

ベイズ解釈。重みの減衰は、パラメータに対するガウス事前分布に対応する。

20.3 データ拡張

データ拡張は、訓練データの多様性を人為的に高めることで、汎化性能を向上させる。

基本的な考え方 : 変換を適用して新しいトレーニング例を生成する。

$$(x, y) \rightarrow (T(x), y),$$

ここで、 T はラベルを保持する。

例（視覚）。

- 回転、平行移動、拡大縮小

- 反転、トリミング

- 色の乱れ

例（他の分野）。

- 入力へのノイズ注入

- テキスト内の同義語置換

解釈。

- 不変性（例：回転不変性）を符号化する

- 有効なデータセットのサイズを拡大する

幾何学的表示。拡張機能は、各ラベルに関連付けられた入力空間の領域を拡大します。

洞察。データ拡張は、関数を変換に対して一貫した動作をするように制約することで、一種の正則化として機能する。

20.4 最適化における暗黙のバイアス

深層学習における正則化は、明示的な手法に限らない。最適化そのものが、ある種の暗黙的なバイアスを導入する。

過剰パラメータ化。ディープネットワークはデータポイントよりもパラメータ数が多いことが多く、その結果、学習誤差がゼロとなる解が多数存在する。

重要な質問。最適化アルゴリズムはどの解を選択するのか？

暗黙のバイアス。勾配ベースの手法は、次のような特定の特性を持つ解を好む傾向があります。

- 小さな規範、

- スムーズな機能、

- 特定の構造パターン。

例（線形モデル）。勾配降下法は、すべての補間解の中で最小ノルム解に収束する。

深層学習の観点から。

- SGDノイズは最適化の軌跡に影響を与える

- 異なる最適化手法を用いると、異なる解が得られる

洞察。トレーニングプロセス自体が正規化装置として機能する。

明示的な正則化との相互作用。暗黙的および明示的な正則化は、学習モデルを形成するためにしばしば連携して機能します。

20.5 統一的な視点

深層学習における正則化には、複数の形態がある。

- 明示的: 体重減少、脱落
- データ駆動型: 拡張
- 暗黙的: 最適化ダイナミクス

中核的な目的。

データを適合させ、一般化を促進する。

重要な洞察。汎化性能は、モデルそのものだけでなく、その学習方法や学習データによっても左右される。

20.6 展望

本章では、深層学習に特有の正則化手法について検討した。

- ドロップアウトとノイズ注入、
- 体重減少、
- データ拡張、
- 最適化における暗黙のバイアス。

次の章では、残余ネットワークとスキップ接続について学習します。
非常に深いアーキテクチャを実現する上で重要な役割を果たす。

基本原則: 効果的な正則化は、モデル構造、データ変換、および最適化ダイナミクスを組み合わせることによって実現される。

第21章

残余ネットワークと 接続をスキップ

21.1 劣化問題

ニューラルネットワークが深くなるにつれて、表現力が向上するため、性能も向上すると予想されるかもしれない。しかし実際には、ネットワークが深くなるほど、学習が難しくなる場合がある。

観察結果。より深いモデルはより浅いモデルと同じ機能を表現できるにもかかわらず、深さを増すとトレーニングエラーが増加する可能性がある。

劣化問題。

- より深いネットワークは、より浅いネットワークよりも性能が劣る。
- 過学習によるものではなく、最適化の難しさによる

直感的に言えば、追加の層によって恒等写像を学習させ、性能を維持できる可能性がある。しかし、標準的な学習手順では、そのような解決策を見出すのは困難である。

グラデーションとの関連性。

- 深みのある構図は、消えゆくグラデーションと爆発するグラデーションを増幅させる
- 情報は階層をまたいで劣化する可能性がある

洞察力。深みが増すと表現力は向上するが、同時に最適化の課題も生じるため、アーキテクチャ設計を通して対処する必要がある。

112 第21章 残余ネットワークとスキップ接続

21.2 残差学習

残差ネットワーク (ResNet)は、スキップ接続を導入することで劣化問題を解決します。

残余ブロック。

$$z^{(\ell+1)} = z^{(\ell)} + F(z^{(\ell)}),$$

ここで、 F は学習可能な変換である。

解釈。

- マッピング $H(z)$ を学習する代わりに、ネットワークは残差を学習します。

$$F(z) = H(z) - z$$

- 完全なマッピングは $H(z) = z + F(z)$ となります。

利点。

- アイデンティティの小さな摂動を学習しやすい
- レイヤー間のグラデーションの流れを改善
- 劣化を軽減する

勾配伝播。勾配は恒等接続を介して直接流れることができます。

$$\frac{\partial z^{(\ell+1)}}{\partial z^{(\ell)}} = I + \frac{\partial F}{\partial z^{(\ell)}}.$$

洞察。スキップ接続は、情報と勾配の代替経路を提供し、トレーニングを安定させます。

21.3 動的システム論的視点

残差ネットワークは、離散的な力学系として解釈することができる。

離散力学。

$$z^{(\ell+1)} = z^{(\ell)} + F(z^{(\ell)}).$$

連続時間アナロジー。これは常微分方程式の離散化に似ている。

$$\frac{dz(t)}{dt} = F(z(t))$$

オイラー離散化。ステップサイズ $\Delta t = 1$ 、

$$z(t + \Delta t) \approx z(t) + \Delta t F(z(t)).$$

解釈。

- 各層は時間ステップに対応します
- ネットワークの深さは時間の経過に伴う変化に対応する

安定性。残余接続は、表現空間における安定した軌跡を維持するのに役立ちます。

洞察。ニューラルネットワークを動的システムとして捉えることで、深さ、安定性、および学習ダイナミクスを理解するための枠組みが得られる。

21.4 非常に深いアーキテクチャ

残余接続を用いることで、極めて深いネットワークの学習が可能になる。

経験的観察。

- 数百層または数千層のネットワークを正常にトレーニングできる
- 残留接続を使用する場合、深度が増すにつれてパフォーマンスが向上します。

建築様式。

- 残りのブロックを積み重ねる
- 正規化レイヤーとの組み合わせ
- 効率化のためにボトルネック構造を利用する

スケーリング動作。

- より深いモデルは、より複雑なパターンを捉える。
- 接続をスキップすることでトレーニングは安定する

一般化。残差ネットワークは、容量が大きいにもかかわらず、多くの場合、優れた一般化性能を発揮する。

制限事項。

- 計算コストの増加
- 建築上の複雑さ

洞察力。綿密な建築設計により、奥行きが実用的に活用される。

114 第21章 残余ネットワークとスキップ接続

21.5 統一的な視点

残差ネットワークは、アーキテクチャ上の革新が深層学習における根本的な課題にどのように対処できるかを示す好例である。

主要構成要素。

- 接続をスキップ
- 残差マッピング
- 安定した勾配流

中核となる考え方。

- 完全な変換ではなく、摂動を学習する
- アイデンティティマッピングによる最適化を促進する
- ネットワークを動的システムとして解釈する

重要な洞察。アーキテクチャ設計は、学習アルゴリズムの動作を根本的に変える可能性がある。

21.6 展望

この章では、残余ネットワークとスキップ接続について紹介した。

- ディープネットワークにおける劣化問題、
- 残差学習を解決策として、
- 動的システムとの関連性、
- 非常に深いアーキテクチャを可能にする。

次の章では、畳み込みニューラルネットワークについて学びます。
データにおける空間構造。

基本原則。効果的なアーキテクチャは、数学的な構造と実用的な考慮事項を組み合わせることで、大規模な深層学習を可能にする。

第22章

畳み込みニューラルネットワーク ネットワーク

22.1 構造化線形演算としての畳み込み トー

畳み込みニューラルネットワーク (CNN)は、データ、特に画像や信号に含まれる構造を活用するように設計されています。その中心となる演算は畳み込みであり、これは構造化された線形変換として理解できます。

離散畳み込み。1次元入力 $x \in \mathbb{R}^n$ とカーネル $w \in \mathbb{R}^k$ に対して、畳み込みは次のように定義されます。

$$(y \otimes w)_i = \sum_{j=1}^k w_j x_{i-j}。$$

2次元畳み込み。画像の場合、畳み込みは空間次元に適用されます。

$$y(i, j) = \sum_{u, v} w(u, v) x(i - u, j - v)。$$

線形演算子の視点。畳み込みは行列とベクトルの乗算として表すことができます。

$$y = Kx、$$

ここで、 K は構造化行列（トープレッツ行列またはブロックトープレッツ行列）である。

重要な特性：パラメータ共有。

- すべての場所に同じカーネルが適用されます
- パラメータ数を削減する

ローカル接続。

- 各出力は入力 of 局所領域のみに依存する
- データにおける空間的局所性を反映する

考察 :畳み込みは線形変換に構造を与えることで、線形変換を効率的かつ構造化データに適したものにする。

22.2 並進不変性

畳み込みアーキテクチャの重要な動機の一つは、並進不変性である。

並進等変性。畳み込み層は以下を満たす。

$$x(\bullet - \tau) \rightarrow y(\bullet - \tau),$$

つまり、入力が増加すると、出力もそれに合わせて増加することである。

解釈。

- ある場所で検出された特徴は、他の場所でも検出される可能性がある
- このモデルは絶対位置に依存しない

等変性から不変性へ。

- 等変性は空間構造を保持する
- 不変性により位置に対する感度がなくなる

不変性を実現する。

- プール業務
- グローバル平均化

洞察。並進不変性は、視覚認知の重要な特性を反映している。つまり、物体は位置に関係なく認識できるということである。

22.3 プーリングと階層構造

CNN (畳み込みニューラルネットワーク)は通常、重要な特徴を保持しつつ空間解像度を低下させるプーリング演算を含んでいます。

プーリング。

- 最大プーリング :領域内の最大値を選択します
- 平均プーリング :平均値を計算します

効果。

- 次元を削減する
- 小さな変換に不変性を導入する

階層構造。

- 初期層は単純な特徴（エッジ、テクスチャ）を検出する
- 中間層はパターン（形状、部分）を検出する。 •より深い層は複雑な構造（物体）を検出する。

受容野。特定のニューロンに影響を与える入力領域の面積は、深さとともに拡大する。

解説 :CNNは階層的に表現を構築し、局所的な特徴を組み合わせることで全体的なパターンを作り出します。

22.4 視覚分野における応用

CNNは視覚タスクにおいて目覚ましい成功を収めている。

画像分類。

- 画像にラベルを割り当てる
- 例 :物体認識

物体検出。

- 画像内のオブジェクトを識別し、位置を特定する

セグメンテーション。

- 各ピクセルにラベルを割り当てる
- シーンの詳細な理解を可能にする

生成モデリング。

- 画像合成
- 超解像度

建築例。

- 畳み込み層+プーリング
- 残留接続
- エンコーダー•デコーダー構造

考察 :CNNが効果的なのは、ドメイン固有の構造をモデルに組み込んでいるからである。

22.5 統一的な視点

畳み込みニューラルネットワークは、いくつかの重要なアイデアを組み合わせています。

- 構造化線形演算子 : 畳み込み
- 帰納的バイアス : 局所性と並進不変性
- 階層構造 : マルチスケール表現学習

主要構成要素。

- 畳み込み層
- 非線形活性化
- プール業務

重要なポイント。CNNは、アーキテクチャに構造を組み込むことで、効率性と高い汎化性能の両方を実現している。

22.6 展望

本章では畳み込みニューラルネットワークについて紹介した。

- 構造化線形演算子としての畳み込み、
- 翻訳の等変性と不変性、
- 階層的特徴学習、
- 視覚分野への応用。

次の章では、ニューラルネットワークを拡張したシーケンスモデルについて学習します。シーケンスデータと時間データに対応。

基本原則。効果的なモデルは、処理対象とするデータの構造を最大限に活用する。

第23章

シーケンスモデル

23.1 再帰型ニューラルネットワーク

現実世界の多くのデータタイプは、時系列データ、テキスト、音声など、順序性のあるものです。シーケンスモデルは、時間軸に沿った依存関係を捉えることを目的としています。

リカレントニューラルネットワーク（RNN）。RNNは、時間とともに変化する隠れ状態 h_t を保持することで、シーケンス（ x_1 、 x_2 、...、 x_T ）を処理します。

$$h_t = (W_h h_{t-1} + W_x x_t + b)$$

$$y_t = \psi(W_y h_t + c)$$

ここで、 ψ は非線形関数である。

解釈。

- h_t は過去の情報を要約します
- 同じパラメータが複数のタイムステップで再利用される

パラメータ共有。フィードフォワードネットワークとは異なり、RNNは時間的に重みを共有するため、可変長のシーケンスに適しています。

時間軸に沿って展開していく。RNNは、共有パラメータを持つディープネットワークと見なすことができる。

$$h_1 \rightarrow h_2 \rightarrow \dots \rightarrow h_T。$$

考察：RNNは、隠れ状態を再帰的に更新することで、時間的な依存関係をモデル化する。

23.2 ゲート付きアーキテクチャ（LSTM、GRU）

標準的なRNNは長期的な依存関係を捉えるのが苦手である。ゲート付きアーキテクチャはこの限界に対処する。

23.2.1 長短期記憶（LSTM）

核心となるアイデア。長期間にわたって情報を保持できるメモリセルを導入する。

ゲイツ。

- 入力ゲート : 新しい情報を制御する
- 忘却ゲート : 何を捨てるかを制御する
- 出力ゲート : 何を公開するかを制御する

構造（概念）。

- 細胞の状態は制御された更新によって変化する
- ゲートは情報の流れを制御する

効果。

- 長期的な依存関係の学習を可能にする
- 勾配消失問題を軽減する

23.2.2 ゲート付き再帰ユニット（GRU）

簡素化されたアーキテクチャ。

- 入力メカニズムと忘却メカニズムを組み合わせる
- LSTMよりもパラメータ数が少ない

更新メカニズム。

- 更新ゲートがメモリ保持を制御する
- リセットゲートは過去の状態の影響を制御します

洞察。ゲーティングメカニズムにより、ネットワークは情報フローを動的に制御できます。

23.3 長期的な依存関係

シーケンスモデリングにおける中心的な課題は、長期間にわたる依存関係を捉えることである。

問題。

- 初期のタイムステップからの情報が失われる可能性がある
- 時間軸に沿った逆伝播の過程で勾配が消失する可能性がある

時間逆伝播（BPTT）。RNNの学習には、勾配を多数の時間ステップにわたって伝播させるプロセスが含まれます。

$$\frac{\partial L}{\partial h_t} = \frac{\partial L}{\partial h_T} \prod_{k=t}^{T-1} \frac{\partial h_{k+1}}{\partial h_k}.$$

勾配挙動。

- 繰り返し乗算を行うと、勾配が消失したり爆発したりする可能性があります。

ゲーティングの役割。

- グラデーションがよりスムーズに流れるための経路を提供する
- 選択的なメモリ保持を可能にする

実践的なテクニック。

- グラデーションクリッピング
- 切り捨てバックプロパゲーション

洞察。長期的な依存関係をモデル化するには、アーキテクチャと最適化の両方を考慮する必要があります。

23.4 再発の限界

再帰型アーキテクチャは長所を持つ一方で、重要な限界も抱えている。

逐次計算。

- 処理は段階的に行う必要がある
- 並列処理を制限する

長距離依存関係の処理が困難。

- ゲート付きアーキテクチャにも限界がある

- 情報は長いシーケンスでは劣化する可能性がある

最適化の課題。

- トレーニングは不安定になる可能性がある
- ハイパーパラメータに敏感

メモリのボトルネック。固定サイズの隠れ状態が過去のすべてを要約する必要がある。

考察 :再帰はシーケンスのための自然な枠組みを提供するが、複雑な長距離依存関係には効果的に対応できない可能性がある。

23.5 統一的な視点

シーケンスモデルは、ニューラルネットワークを時系列データに拡張したものです。

- 状態 :隠れ表現は時間とともに変化する
- ダイナミクス :再帰的な更新によって時間的な動作が定義される
- メモリ :情報は隠れた状態に保存される

建築の進化。

- RNN → LSTM/GRU → アテンションベースモデル

重要なポイント。シーケンスモデルの設計は、時間軸に沿った情報フローの管理を中心に展開される。

23.6 展望

本章では、シーケンスモデルについて紹介した。

- 再帰型ニューラルネットワーク、
- ゲート付き建築物、
- 長期依存の課題、
- 再発の制限。

次の章では、注意メカニズムについて研究します。
再帰モデルの限界。

基本原則。効果的なシーケンスモデリングには、関連情報を長期にわたって保存し、アクセスするためのメカニズムが必要である。

第24章

注目とトランスフォーマー

24.1 注意メカニズム

再帰に基づくシーケンスモデルは、過去の情報を固定サイズの隠れ状態に圧縮します。これは、長いシーケンスをモデル化する際にボトルネックとなります。

アテンションの基本概念。単一の隠れ状態に依存するのではなく、アテンションによってモデルは入力に関連するすべての部分に直接アクセスできるようになります。

クエリキーバリューフレームワーク。アテンションは、以下の3つの要素で定義されます。

- クエリ (q)
- キー (k)
- 価値観 (v)

注意重み。

$$\alpha_i = \frac{\exp(q, k_i)}{\sum_j \exp(q, k_j)}$$

出力。

$$\text{Attn}(q, K, V) = \sum_i \alpha_i v_i$$

解釈。

- クエリは、どの入力に関連しているかを決定します。
- 重み α_i は重要度を表す

洞察。注意は、固定された記憶を、柔軟でデータ依存的なメカニズムに置き換える。

24.2 自己注意

自己注意は、単一のシーケンス内で注意機構を適用する。

定義。シーケンスの各要素は、他のすべての要素に注意を向ける。

構築。入力 $x_1, \dots, x_T$ が与えられた場合、定義する：

$$q_i = WQx_i, \quad k_i = WKx_i, \quad v_i = WVx_i.$$

注意出力。

$$y_i = \sum_{j=1}^T a_{ij} v_j, \quad a_{ij} = \frac{\exp(q_i \cdot k_j)}{\sum_{l=1}^T \exp(q_i \cdot k_l)}.$$

特性。

- すべてのポジション間の依存関係を捉えます
- シーケンス要素全体で完全に並列化可能

位置符号化。自己注意機構は順列不変であるため、位置情報を明示的に追加する必要がある。

洞察。自己注意は、シーケンス内の関係性をモデル化するための柔軟なメカニズムを提供する。

24.3 トランスフォーマーアーキテクチャ

トランスフォーマーアーキテクチャは、すべてアテンションメカニズムから構築されている。

基本構成要素。

- マルチヘッド自己注意機構
- フィードフォワード層
- 残留接続
- 正規化レイヤー

マルチヘッドアテンション。複数のアテンションメカニズムが並列に適用されます。

$$\text{MultiHead}(Q, K, V) = \text{Concat}(H_1, \dots, H_h)W_O,$$

各ヘッド H_i は、異なる投影を用いて注意を計算する。

フィードフォワードネットワーク。

$$\text{FFN}(x) = \sigma(W_1x + b_1)W_2 + b_2.$$

残存構造。

$$x \leftarrow x + \text{Layer}(x),$$

続いて正規化が行われる。

建築レイアウト。

- 同じブロックの積み重ね
- 各ブロック : アテンション + フィードフォワード

エンコーダー・デコーダー構造。

- エンコーダは入力シーケンスを処理する
- デコーダはエンコーダの出力に注意を払いながら出力シーケンスを生成する。

洞察。トランスフォーマーは再帰をアテンションに置き換えることで、長距離依存関係の効率的なモデリングを可能にする。

24.4 スケーリングと応用

トランスフォーマーは、様々な分野において、驚異的な拡張性と性能を発揮してきた。

スケーリング動作。

- モデルのサイズ、データ量、計算量が増えるほどパフォーマンスが向上します
- 非常に大規模なモデルのトレーニングを可能にする

並列化。

- RNNとは異なり、トランスフォーマーはシーケンスを並列処理する
- 最新ハードウェアの効率的な活用

アプリケーション。

- 自然言語処理（翻訳、テキスト生成）
- ビジョン（ビジョン・トランスフォーマー）
- 音声処理
- マルチモーダル学習

事前学習と微調整。

- 大規模データセットで学習された大規模モデル

- 微調整によって特定のタスクに適応

制限事項。

- シーケンス長の2乗に比例する複雑さ
- 計算コストが高い

考察 : スケーリングとデータ可用性は、現代の深層学習のパフォーマンスを左右する重要な要素である。

24.5 統一的な視点

注意とトランスフォーマーは、いくつかの概念を統合する。

- 表現方法 : 入力 of 動的な重み付け
- 計算 : シーケンスの並列処理
- アーキテクチャ : モジュール式で拡張可能な設計

主要構成要素。

- クエリキーと値の関連付け
- マルチヘッド機構
- 残差層と正規化層

重要な洞察。アテンションは、固定された逐次構造に代わり、相互作用をモデル化するための柔軟なメカニズムを提供する。

24.6 展望

本章では、アテンションメカニズムとトランスフォーマーについて紹介した。

- 柔軟な記憶メカニズムとしての注意、
- シーケンスモデリングのための自己注意機構、
- トランスフォーマーアーキテクチャ、
- スケーリング動作とアプリケーション。

次の章では、確率モデルと潜在変数アプローチから始めて、生成モデルについて学習します。

基本原則。現代のアーキテクチャは、データ要素間の柔軟で拡張性の高い相互作用を可能にすることで成功する。

第25章

生成の基礎 モデリング

25.1 密度推定とサンプリング

生成モデリングは、データの根底にある分布を学習し、そこから新しいサンプルを生成することを目的としている。

目的 : 与えられたデータ $x = \text{pdata}$ に対して、真の分布を近似するモデル $p_\theta(x)$ を学習する。

密度推定。

- 明示的なモデルは確率密度 $p_\theta(x)$ を定義します
- 学習は通常、最尤推定に基づいて行われる。

$$\text{最大} \theta \quad \mathbb{E}_{x \sim \text{pdata}} [\log p_\theta(x)]。$$

サンプリング。モデルが学習されたら、新しいサンプルを生成します。

$$x \sim p_\theta(x)。$$

二つの視点。

- 尤度ベース : $p_\theta(x)$ を直接モデル化する
- 暗黙的 : 明示的な密度を用いずにサンプリング手順を定義する

課題。

- 高次元データ
- 複雑な分布

•効率的なサンプリング

洞察。生成モデリングとは、分布を表現することと、そこからサンプルを生成することの両方を含む。

25.2 潜在変数モデル

多くの生成モデルは、潜在的な構造を捉えるために潜在変数を導入する。

潜在変数定式化。

$$p_{\theta}(x) = \int p_{\theta}(x | z) p(z) dz,$$

ここで、 z は潜在変数である。

解釈。

- z は隠れた変動要因を表す
- $p(z)$ は単純な事前分布（例：ガウス分布）である。

生成プロセス。

1. サンプル $z \sim p(z)$
2. $x \sim p_{\theta}(x | z)$ を生成する

学習上の課題。周辺尤度には、扱いが困難な積分が含まれる。

推論。近似事後確率 $q(z | x)$ を導入します。

洞察。潜在変数は、複雑なデータ分布を構造的にモデル化する方法を提供する。

25.3 エネルギーに基づく視点

別の見方としては、エネルギー関数を用いて確率分布をモデル化するものがある。

エネルギーベースモデル（EBM）。

$$p_{\theta}(x) = \frac{\exp(-E_{\theta}(x))}{Z(\theta)}$$

ここで、 $E_{\theta}(x)$ はエネルギー関数、 $Z(\theta)$ は分配関数である。

$$Z(\theta) = \int \exp(-E_{\theta}(x)) dx.$$

解釈。

- 低エネルギー → 高確率
- 高エネルギー → 低確率

学ぶ。

- $Z(\theta)$ を含む勾配の推定が必要となる
- サンプルリングに基づく手法をよく用いる

物理学との関連性。エネルギーに基づくモデルは、統計力学における分布に類似している。

洞察。エネルギーベースの定式化は、正規化された密度を閉じた形式で必要とせずに分布を定義するための柔軟な方法を提供する。

25.4 生成モデルの評価

生成モデルの評価は、高次元分布の複雑さゆえに困難である。

可能性に基づく評価。

- 対数尤度
- パープレキシティ（シーケンスの場合）

サンプル品質。

- 目視検査（例：画像）
- 人間による評価（例：テキスト）

乖離度指標。

- カルバック・ライブラー情報量
- ジェンセン・シャノンダイバージェンス

分布指標。

- インセプションスコア
- フレッシュ開始距離（FID）

課題。

- サンプル品質と多様性のトレードオフ
- 高次元における尤度推定の難しさ

モード崩壊。一部のモデルは限られた多様性しか生成せず、可能な出力のごく一部に焦点を当てている。

洞察。生成モデルの品質を完全に捉える単一の指標は存在しない。

25.5 統一的な視点

生成モデリングは、複数の補完的なフレームワークを通して理解することができる。

- 確率論的 : $p(x)$ を直接モデル化する
- 潜在変数 : 隠れた構造の導入
- エネルギーベース : エネルギーによる分布の定義

中核的な課題。

- 高次元モデリング
- 効率的なサンプリング
- 信頼性の高い評価

重要な洞察。生成モデルは、データ分布の構造を捉え、理解と統合の両方を可能にすることを目指している。

25.6 展望

本章では、生成モデリングの基礎について概説した。

- 密度推定とサンプリング、
- 潜在変数モデル、
- エネルギーに基づく視点、
- 生成モデルの評価。

次の章では、変分オートエンコーダー、敵対的生成ネットワーク、拡散モデルなど、生成モデルの特定のクラスについて研究します。

基本原則。生成モデリングは、データを予測するだけでなく、その根底にある構造を理解し、再現することを目指す。

第26章

潜在変数を用いた尤度ベース学習

26.1 最尤推定

生成モデルにおける中心的な原理は、最尤推定（MLE）である。その目的は、観測データの確率を最大化するモデルパラメータを選択することである。

目的。与えられたデータ $\{x_i\}_{i=1}^n$

$$\text{最大化する: } \theta \rightarrow \max_{\theta} \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(x_i)$$

解釈。

- モデルが観測データに高い確率を割り当てるよう促す
- 負の対数尤度を最小化することと同等

ダイバージェンスとの関連性。MLEはカルバック・ライブラーダイバージェンスを最小化する。

$$KL(p_{\text{data}} \parallel p_{\theta}).$$

勾配。

$$\nabla_{\theta} \log p_{\theta}(x)$$

明示的なモデルであれば、多くの場合、効率的に計算できる。

洞察。MLEは、データから確率モデルを学習するための原理に基づいた方法を提供する。

132 第26章 潜在変数を用いた尤度ベース学習

26.2 隠れた変数と周辺化

潜在変数モデルは、隠れ変数 z を導入して、根底にある構造を捉えます。

周辺尤度。

$$p_{\theta}(x) = \int p_{\theta}(x, z) dz = \int p_{\theta}(x | z) p(z) dz。$$

対数尤度。

$$\log p_{\theta}(x) = \int \log p_{\theta}(x, z) dz。$$

解釈。

- z は x の変動性を説明する
- このモデルは、考えられるすべての潜在的な説明を統合する。

課題。 z に関する積分は、特に高次元の場合、しばしば扱いが困難です。

事後分布。

$$p_{\theta}(z | x) = \frac{p_{\theta}(x, z)}{p_{\theta}(x)}。$$

洞察。学習には、周辺尤度を評価することと、潜在変数について推論することの両方が必要である。

26.3 扱いの難しさと近似

周辺尤度を正確に計算することは、通常不可能である。

解決困難な原因。

- 高次元潜在空間
- 複雑な尤度関数

近似戦略。

- サンプルリングに基づく手法（例：モンテカルロ法）
- 決定論的近似
- 変分法

モンテカルロ近似法。

$$p_{\theta}(x) \approx \frac{1}{N} \sum_{i=1}^N p_{\theta}(x | z_i), z_i \sim p(z).$$

制限事項。

- 推定値のばらつきが大きい
- 計算コストが高い

別の視点。積分を直接近似するのではなく、事後確率 $p_{\theta}(z | x)$ を近似します。

洞察。潜在変数モデルでは近似は避けられず、理論と実践の両方を形作る。

26.4 変分原理

変分法は、扱いが難しい量を近似するための強力な枠組みを提供する。

変分分布。真の事後分布を近似する扱いやすい分布 $q(z | x)$ を導入します。

重要な識別情報。

$$\log p_{\theta}(x) = \mathbb{E}_{q(z|x)} \log \frac{p_{\theta}(x, z)}{q(z|x)} + \text{KL}(q(z|x) \parallel p_{\theta}(z|x)).$$

証拠下限値 (ELBO)。

$$L(\theta, x) = \mathbb{E}_{q(z|x)} [\log p_{\theta}(x, z) - \log q(z|x)].$$

下限の性質。

$$L(\theta, x) \leq \log p_{\theta}(x).$$

分解。

$$L(\theta, x) = \mathbb{E}_{q(z|x)} [\log p_{\theta}(x | z)] - \text{KL}(q(z|x) \parallel p(z)).$$

解釈。

- 第1項 : 再構成の質
- 第2項 : 事前情報への正則化

134 第26章 潜在変数を用いた尤度ベース学習

最適化。

- θ に関して ELBO を最大化する
- 生成モデルと推論モデルを同時に学習する

洞察。変分法は、扱いが困難な推論を最適化問題に変換する。

26.5 統一的な視点

潜在変数を用いた尤度ベース学習は、いくつかの相互に関連する概念から成り立っています。

- MLE: 観測データからの学習
- 潜在変数: 隠れた構造のモデリング
- 近似: 扱いにくい積分を扱う
- 変分推論: 最適化に基づく近似

根本的なトレードオフ。

近似精度と計算の容易性。

重要な洞察。潜在変数を導入することでモデリングの精度は向上するが、近似推論手法が必要となる。

26.6 展望

本章では、潜在変数を用いた尤度ベース学習について紹介した。

- 最尤推定、
- 隠れた変数に対する周辺化、
- 解決困難な課題、
- 変分原理と ELBO。

次の章では、これらのアイデアを変分オートエンコーダーに適用します。実用的で広く用いられている生成モデルの一種。

基本原則。複雑な確率モデルには近似推論が必要であり、変分法は原理に基づいた拡張可能な解決策を提供する。

第27章

変分オートエンコーダー

27.1 潜在表現

変分オートエンコーダー (VAE)は、潜在変数モデリングとニューラルネットワークを組み合わせた生成モデルである。

基本的な考え方 : データ x の根底にある構造を捉える低次元の潜在表現 z を学習する。

生成モデル。

$$z \sim p(z), x \sim p_{\theta}(x | z),$$

ここで、 $p(z)$ は通常、標準ガウス分布として選択される。

潜在空間。

- 連続的で低次元の表現
- データの意味構造をエンコードする

解釈。

- 潜在空間内の近接点は類似データに対応する
- 潜在空間における補間は意味のある変化を生み出す

目標 : 両方を学ぶ :

- 生成モデル $p_{\theta}(x | z)$ 、
- 推論モデル $q(z | x)$ 。

洞察。潜在表現は、複雑なデータ分布を構造的にモデル化する方法を提供する。

27.2 証拠下限値 (ELBO)

VAEは、前章で紹介したエビデンスの下限を最大化することによって学習される。

ELBOの目的。

$$L(\theta, \phi) = \mathbb{E}_{q(z|x)} [\log p_{\theta}(x|z)] - \text{KL}(q(z|x) \parallel p(z))。$$

解釈。

- 第1項 : 再構成精度
- 第2項 : 事前情報への正則化

トレード・オフ。

- 良好な再構成と構造化された潜在空間

パラメータ再設定のトリック。期待値を最適化するために、 z を次のように表現します。

$$z = \mu_{\phi}(x) + \sigma_{\phi}(x) \odot \epsilon, \epsilon \sim N(0, I)。$$

利点。

- 勾配ベースの最適化を可能にする
- 勾配推定値の分散を低減する

洞察。ELBOはデータ再構築と潜在構造のバランスを取り、VAEトレーニングの中核を形成します。

27.3 エンコーダー・デコーダーアーキテクチャ

VAEは、エンコーダー・デコーダーのフレームワークにおいてニューラルネットワークを用いて実装される。

エンコーダー。

$$q(z|x)$$

は入力データを潜在パラメータ($\mu_{\phi}(x)$, $\sigma_{\phi}(x)$) にマッピングします。

デコーダ。

$$p_{\theta}(x|z)$$

潜在変数をデータ空間にマッピングする。

建築。

- エンコーダーネットワーク : データを潜在表現に圧縮する
- デコーダーネットワーク : 潜在コードからデータを再構築する

トレーニングパイプライン。

1. x を (μ, σ) にエンコードする
2. 再パラメータ化を用いて z をサンプリングする
3. z をデコードして x を再構築する
4. ELBOを計算し、パラメータを更新する

サンプリング。新しいデータは次の方法で生成されます。

- $z \sim p(z)$ をサンプリングする
- $x \sim p_\theta(x | z)$ を計算する

洞察。エンコーダー・デコーダー構造は、推論と生成を統一されたフレームワークに統合します。

27.4 実務上の考慮事項

VAEを実装するには、いくつかの重要な設計上の選択が必要となる。

可能性の選択。

- 連続データに対するガウス尤度
- 二値データのベルヌーイ尤度

KL発散項。 $q(z | x)$ と $p(z)$ の両方がガウス分布に従う場合、多くの場合、閉じた形式をとります。

後方崩壊。

- このモデルは潜在変数を見捨てている
- $q(z | x)$ は $p(z)$ に近づく

緩和策。

- KLアンニリング
- より表現力豊かなデコーダー

潜在的な空間構造。

- 滑らかさにより補間が可能になる
- 正則化は意味のある表現を促進する

評価。

- トレーニング目標としてのELBO
- サンプルの品質と多様性

洞察。実際のパフォーマンスは、再構成、正則化、およびモデル容量のバランスに左右される。

27.5 統一的な視点

変分オートエンコーダーは、いくつかの重要なアイデアを組み合わせたものです。

- 潜在変数モデリング
- 変分推論
- ニューラルネットワークのパラメータ化

主要構成要素。

- エンコーダ $q(z|x)$
- デコーダ $p_\theta(x|z)$
- ELBOの目的

重要な知見。VAEは、潜在構造を持つ確率的生成モデルを学習するためのスケーラブルな手法を提供する。

27.6 展望

本章では、変分オートエンコーダーを紹介した。

- 潜在表現、
- ELBO最適化、
- エンコーダー・デコーダーアーキテクチャ、
- 実務上の考慮事項。

次の章では、生成モデルを異なる視点からアプローチする敵対的生成ネットワークについて考察します。

基本原則 : 確率モデルとニューラルネットワークを組み合わせることで、柔軟で拡張性の高い生成モデルを実現できる。

第28章

敵対的生成 ネットワーク

28.1 敵対的定式化

敵対的生成ネットワーク (GAN)は、2つのモデル間のゲームに基づいた、生成モデリングへの代替的なアプローチを提供する。

基本的な考え方 : 2つのネットワークを同時に学習させる。

- ジェネレーター G_θ : ノイズ $z \sim p(z)$ をデータ空間にマッピングする
- 識別器 D : 実データと生成データを区別する

ミニマックス目的関数。

$$\min_{\theta} \max_D \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z \sim p(z)} [\log(1 - D(G_\theta(z)))].$$

解釈。

- ジェネレーターはディスクリプタを騙そうとする
- 識別器は、本物のサンプルと偽のサンプルを区別しようとします。

平衡状態。最適状態においては、ジェネレーターは実際のデータと区別がつかないサンプルを生成する。

暗黙的なモデリング。GANは、 $p_\theta(x)$ を明示的にモデル化することなく、サンプリング手順を定義します。

洞察。学習は、二つの相反する目標間のゲームとして捉えられる。

28.2 発散最小化

GANは、分布間の乖離を最小化するものとして理解できる。

最適判別器。固定ジェネレータの場合、最適判別器は次のようになります。

$$D(x) = \frac{p_{data}(x)}{p_{data}(x) + p_{\theta}(x)}.$$

結果として得られる目的関数、 D を代入すると次のようになる。

$$JS(p_{data} \parallel p_{\theta}), \text{最小}$$

ここで、 JS はジェンセン・シャノンダイバージェンスを表す。

解釈。

- GANのトレーニングは、分布間の乖離を暗黙的に最小化する。
- 分布が近づくにつれて、ジェネレーターの性能が向上する

制限事項。

- サポートが重ならない場合、乖離はうまく機能しない可能性がある

洞察。GANはゲーム理論的学习と統計的発散最小化を結びつける。

28.3 トレーニングの不安定性

GANのトレーニングは、目的関数の敵対的な性質のため、しばしば困難を伴います。

非凸・非凹最適化。ミニマックス問題は一般に安定収束を許容しない。

モード崩壊。

- 発電機は限られた種類の出力を生成する
- データ分布を完全に把握できない

振動力学。

- ジェネレーターとディスクリプターが収束しない可能性がある
- パラメータは循環したり発散したりする可能性がある

グラデーションの問題。

- 識別器が強すぎると勾配が消失する
- 敵対的フィードバックによる不安定なアップデート

実践的なテクニック。

- ジェネレーターとディスクリミネータの更新を慎重にバランス調整する
- ラベルスムージング
- 勾配ペナルティ

洞察。敵対的学習は、標準的な最適化とは根本的に異なるダイナミクスをもたらします。

28.4 バリエーションと改良点

学習上の課題に対処し、性能を向上させるために、GANの多くの派生型が提案されてきた。

ワッサーシュタインGAN (WGAN)。

- JSダイバージェンスをワッサースタイン距離に置き換える
- 安定性と勾配挙動を改善

勾配ペナルティ付きWGAN。

- 勾配ペナルティによってリプシッツ制約を強制する

条件付きGAN。

- ラベルまたは入力に基づいて条件付きサンプルを生成する

CycleGANと画像変換。

- ペアデータなしでドメイン間のマッピングを学習する

スタイルベースのGAN。

- 構造化された潜在空間を導入する
- 生成された画像を細かく制御できるようにする

考察。GANの性能向上には、多くの場合、目的関数、アーキテクチャ、または学習手順の変更が伴います。

28.5 統一的な視点

GANは生成モデリングに独自のアプローチを提供する。

- 暗黙的モデル : 明示的な密度を用いずにサンプリングを定義する
- 敵対的学習 : 2つのネットワークが競合する
- 乖離最小化 : 分布の整合

主要構成要素。

- ジェネレーター G_θ
- 識別器 D
- ミニマックス目的関数

重要な洞察。敵対的学習は、生成モデルのための強力だが困難なフレームワークを提供する。

28.6 展望

本章では、敵対的生成ネットワークについて紹介した。

- 敵対的定式化、
- 相違に基づく解釈、
- トレーニングの課題、
- 主要なバリエーションと改良点。

次の章では、確率過程に基づいた生成モデリングへの根本的に異なるアプローチを提供する拡散モデルについて考察します。

基本原則 : 異なる生成フレームワークは、扱いやすさ、安定性、サンプル品質の間で異なるトレードオフを提供する。

第29章

フローの正規化

29.1 変数変換の公式

正規化フローは、確率分布の可逆変換に基づく生成モデルの一種を提供する。

基本的な考え方。単純な基本分布 $z \sim p(z)$ から始めて、それを複雑な分布 $x = f_\theta(z)$ に変換する。

変数変換の公式。 f が可逆かつ微分可能であれば、

$$p_\theta(x) = p(z) \det \frac{\partial z}{\partial x}, \quad \text{ここで } z = f^{-1}(x)$$

同等の形式。

$$\log p_\theta(x) = \log p(z) + \log \det \frac{\partial z}{\partial x}.$$

解釈。

- 局所的な体積歪みに応じて密度が変化する
- 決定要因は拡大または縮小を測定する

洞察。フローを正規化すると、単純な分布が複雑な分布に変換されると同時に、密度の変化も追跡されます。

29.2 可逆変換

正規化フローの設計は、表現力と計算効率の両方を兼ね備えた可逆変換を構築することに基づいている。

要件。

- f は可逆でなければならない
- ヤコビ行列式は扱いやすいものでなければならない

変換の合成。

$$x = f_L \circ f_{L-1} \circ \dots \circ f_1(z).$$

ヤコビアン分解。

$$\log \det \frac{\partial z}{\partial x} = \sum_{\ell=1}^L \log \det \frac{\partial h_{\ell-1}}{\partial h_{\ell}}.$$

変換の種類。

- アフィン結合層
- 自己回帰変換
- 体積保存流

トレード・オフ。

- 表現力と計算効率

洞察。可逆マッピングを慎重に設計することで、扱いやすく表現力豊かな生成モデルを実現できる。

29.3 正確な尤度計算

フローを正規化することの重要な利点は、正確な尤度を計算できることである。
可能性。

$$\log p_{\theta}(x) = \log p(f^{-1}(x)) + \log \det \frac{\partial f^{-1}}{\partial x}.$$

他のモデルとの比較。

- VAE: 近似尤度
- GANs: 暗黙の尤度
- フロー: 正確な尤度

サンプリング。

- サンプル $z \sim p(z)$

- $x = f_{\theta}(z)$ を計算する

推論。

- $z = f$ を計算する θ^{-1} (×)
- 変数変換を用いて密度を評価する

効率性に関する考慮事項。

- ヤコビ行列式は効率的に計算可能でなければならない。
- 多くの場合、三角形行列または構造化行列によって実現される

洞察。フローを正規化することで、正確な尤度と効率的なサンプリングという稀有な組み合わせが実現します。

29.4 モデル設計

効果的な正規化フローを設計するには、表現力と扱いやすさのバランスを取る必要がある。

結合層。

- 変数を2つの部分に分割する
- 一方の部分を他方の部分に依存するように変換する

自己回帰フロー。

- 依存関係を順次モデル化する
- 三角形ヤコビ行列は行列式の計算を簡略化する

変換の重ね合わせ。

- 複数のレイヤーが表現力を高める
- 各層が変換の複雑さに寄与する

可逆ニューラルネットワーク。

- 可逆性を確保するように設計されたアーキテクチャ

制限事項。

- 可逆性に関するアーキテクチャ上の制約
- 高次元データの計算コスト

考察：フローにおけるモデル設計には、柔軟性と計算上の制約とのバランスを取る必要がある。

29.5 統一的な視点

フローの正規化は、いくつかの重要な概念を組み合わせたものです。

- 変換 : 単純な分布を複雑な分布にマッピングする
- 可逆性 : 正確な密度計算を可能にする
- 構成 : レイヤーを通して表現力豊かなモデルを構築する

主要構成要素。

- 基本分布 $p(z)$
- 可逆写像 f_θ
- ヤコビ行列式

重要な洞察。可逆変換を慎重に設計することで、正確な尤度を持つ表現力豊かな生成モデルを構築できる。

29.6 展望

この章では、フローの正規化について紹介しました。

- 密度変換のための変数変換、
- 可逆変換、
- 正確な尤度計算、
- 実用的なモデル設計。

次の章では、生成モデルに近づく拡散モデルを研究します。
確率過程と反復的な改良によるモデリング。

基本原則 : 確率分布の構造化変換は、生成モデル構築のための強力な枠組みを提供する。

第30章

拡散モデル :直感

30.1 ノイズ注入プロセス

拡散モデルは、データを徐々にノイズに変換し、その後このプロセスを逆転させることに基づく生成モデルである。

順方向プロセス。次の条件を満たす確率変数のシーケンス($x_0, x_1, \dots, x_T$) を定義します。

- $x_0 \sim p_{\text{data}}$
- x_T は単純な分布 (例えばガウスノイズ)に近づく

ノイズ注入。各ステップで、小さなガウスノイズを加えます。

$$x_t = \sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \epsilon_t, \quad \epsilon_t \sim N(0, I)。$$

マルコフ構造。

- 各ステップは前の状態のみに依存する
- このプロセスはマルコフ連鎖である

効果。

- データ内の構造を徐々に破壊する
- データ分布をノイズに変換する

洞察。順方向処理は、複雑なデータ分布を単純なデータ分布にマッピングするための制御された方法を定義する。

30.2 ノイズ除去の観点から

生成プロセスは、ノイズ注入を逆転させる方法を学習する。

逆のプロセス。我々は以下のモデル化を目指します。

$$p_{\theta}(x_{t-1} | x_t),$$

ノイズを段階的に除去します。

ノイズ除去の解釈。

- 各ステップでは、ノイズの少ないバージョンのデータが予測されます。
- モデルはノイズから構造を復元することを学習する

学習目標 : このモデルは、各ステップで追加されるノイズを予測するように学習されます。

$$\epsilon_{\theta}(x_t, t) \approx \epsilon_t.$$

簡略化された損失。

$$\mathbb{E}_{t, x_0, \epsilon} \|\epsilon - \epsilon_{\theta}(x_t, t)\|^2.$$

サンプリング。

- ノイズ $x_T \sim N(0, I)$ から開始
- 繰り返しノイズ除去を行い、 x_0 を取得する

洞察。生成は、ランダムノイズを繰り返し除去して構造化データに変換することによって実現されます。

30.3 スコアベースのビュー

拡散モデルは、スコア関数を通して解釈することもできる。

スコア関数。

$$s(x) = \nabla_x \log p(x).$$

重要な考え方。 $p(x)$ を直接モデル化するのではなく、そのスコアを学習する。

拡散との関連性。

- ノイズ除去関数は、ノイズのある分布のスコアを近似する。
- 各ステップは、 $\nabla_x \log p_t(x)$ の推定に対応します。

ランジュバン動力学。

$$x_{t+1} = x_t + \eta \nabla_x \log p(x_t) + 2\eta \xi_t,$$

ここで ξ_t はガウスノイズである。

解釈。

- サンプルは対数密度勾配に従って生成される
- ノイズは分布の探索を保証する

考察。拡散モデルは、ノイズ除去と確率分布からの勾配ベースのサンプリングを結びつける。

30.4 概念的なつながり

拡散モデルは、確率論、最適化、物理学におけるいくつかの概念を統合したものである。

他のモデルとの接続。

- 潜在変数モデル : 中間的なノイズ状態を導入する
- エネルギーベースのモデル : スコア関数に関連する
- マルコフ過程 : 逐次変換

連続時間制限。

- 離散的なステップは確率微分方程式を近似する
- 連続拡散プロセスにつながる

データの幾何学。

- ノイズはデータ分布を平滑化する
- ノイズ除去により構造が回復する

他の生成モデルとの比較。

- VAE : 確率的潜在モデリング
- GANs : 敵対的学習
- フロー : 可逆変換
- 拡散 : 反復的な改良

洞察。拡散モデルは、確率的モデリングと反復的なノイズ除去、および勾配ベースのサンプリングを組み合わせたものです。

30.5 統一的な視点

拡散モデルは、複数の視点から理解することができる。

- 確率論的 : ノイズ過程による分布のモデリング
- アルゴリズム的 : 反復的なノイズ除去手順
- 幾何学的 : データ空間における勾配に従う

主要構成要素。

- 前方ノイズ処理
- 逆ノイズ除去処理
- 学習済みスコアまたはノイズ予測器

重要な洞察。単純な確率過程を逆算することで、複雑なデータ分布を生成できる。

30.6 展望

本章では、拡散モデルを直感的な観点から紹介した。

- ノイズ注入プロセス、
- 生成としてのノイズ除去、
- スコアに基づく解釈、
- 他のモデルとの概念的な関連性。

次の章では、拡散モデルについて、その確率的定式化や学習目標を含め、より厳密に研究します。

基本原則 : 単純なノイズを学習による変換を通して段階的に洗練させることで、複雑な構造を学習することができる。

第31章

拡散モデル： 数学的基礎

31.1 順方向プロセスと逆方向プロセス

拡散モデルは、順方向（ノイズを加える）プロセスと逆方向（ノイズを除去する）プロセスという2つの確率プロセスに基づいて構築されています。

順方向プロセス。マルコフ連鎖($x_0, x_1, \dots, x_T$) を次のように定義します。

$$q(x_t | x_{t-1}) = N(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I),$$

ここで $\{\beta_t\}_{t=1}^T$ は差分表です。

閉形式の表現。ガウス遷移を合成することにより、以下が得られる。

$$q(x_t | x_0) = N(x_t; \sqrt{\alpha_t} x_0, (1 - \alpha_t) I),$$

ここで $\alpha_t = 1 - \beta_t$ および $\alpha_t = \prod_{s=1}^t \alpha_s$ 。

- t が増加するにつれて、 x_t はますますノイズが多くなる。

- T が大きい場合、 $x_T \approx N(0, I)$

逆のプロセス。我々は以下のモデル化を目指します。

$$p_\theta(x_{t-1} | x_t),$$

適切な仮定の下では、これもガウス分布に従う。

$$p_\theta(x_{t-1} | x_t) = N(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)).$$

学習目標 : パラメータ θ は、真の逆遷移を近似するように学習されます。

洞察。順方向の処理は固定されていて単純だが、逆方向の処理は学習によって習得される。

152 第31章 拡散モデル :数学的基礎

31.2 スコアマッチング

拡散モデルの別の定式化は、スコアマッチングに基づいている。

スコア関数。

$$s_t(x) = \nabla_x \log p_t(x),$$

ここで、 $p_t(x)$ は x_t の分布である。

目的。 $p_t(x)$ を直接モデル化する代わりに、 $s_t(x)$ を学習します。

ノイズ除去スコアマッチング。ガウス摂動の場合、スコアは以下を満たす。

$$s_t(x_t) = -\frac{1}{\alpha^{-t}} (x_t - \sqrt{\alpha^{-t}} x_0).$$

学習定式化。ニューラルネットワーク $s_\theta(x_t, t)$ を訓練してスコアを近似します。

$$\mathbb{E}_{t, x_0, \varepsilon} \|s_\theta(x_t, t) - \nabla_x \log q(x_t | x_0)\|^2.$$

等価性。この目的は、ノイズ ε を予測することと同等です。

洞察。スコアマッチングは、対数密度の勾配を学習するための原理に基づいた方法を提供する。

31.3 ランジュバン動力学

分布からのサンプリングは、ランジュバン動力学を用いることで実現できる。

ランジュバンに関する最新情報。

$$x_{k+1} = x_k + \eta \nabla_x \log p(x_k) + 2\eta \xi_k, \quad \xi_k \sim \mathcal{N}(0, I).$$

解釈。

- 勾配項はサンプルを高密度領域へと導く
- ノイズ項は探索を保证する

拡散モデルとの関連性。

- 学習されたスコアは $\nabla_x \log p(x)$ を近似する
- サンプリングではスコアベースの更新を使用する

連続時間極限。ランジュバン動力学は確率微分方程式に対応する。

$$dx_t = \nabla_x \log p(x_t) dt + \sqrt{2} dW_t,$$

ここで、 W_t はブラウン運動を表す。

考察。拡散サンプリングは、学習されたスコアを用いた近似ランジュバン動力学として捉えることができる。

31.4 サンプリングアルゴリズム

拡散モデルの数学的定式化から、いくつかのサンプリング手順が導き出される。

祖先サンプリング。

- $x_T \sim N(0, I)$ から開始
- 反復的にサンプリングする：

$$x_{t-1} \sim p_{\theta}(x_{t-1} | x_t)$$

決定論的な変種。

- サンプリングではなく、決定論的な更新を使用する
- ばらつきを減らし、生成速度を向上させる

スコアに基づくサンプリング。

- 離散化されたランジュバン動力学を使用する
- 学習したスコア関数を使用して更新する

トレードオフ。

- より多くのステップ → より高品質なサンプル
- 手順が少ない → 生成が速い

数值的な考察。

- ステップサイズを選択
- アップデートの安定性

洞察。サンプリングは、学習された勾配によって導かれる反復的な改良プロセスです。

31.5 統一的な視点

拡散モデルは、複数の数学的枠組みを通して理解することができる。

- マルコフ過程 : 順方向連鎖と逆方向連鎖
- スコアマッチング : 対数密度勾配の学習
- 確率力学 : ランジュバン方程式

主要構成要素。

154 第31章 拡散モデル : 数学的基礎

- 前方ノイズ過程 $q(x_t | x_{t-1})$
- 逆プロセス $p_\theta(x_{t-1} | x_t)$
- スコア関数 $s_\theta(x_t, t)$

重要な洞察。拡散モデルは、確率モデリング、確率過程、および勾配ベースのサンプリングを統合する。

31.6 展望

本章では、拡散モデルの数学的基礎について解説した。

- 順方向および逆方向の確率過程、
- スコアマッチング式、
- ランジュバン力学、
- サンプリングアルゴリズム。

次の章では、現代の改良と実践的な実装について学びます。
拡散モデルの分類。

基本原理 : 複雑な分布は、確率的動的システム内で学習された勾配を追うことでサンプリングできる。

第32章

大規模生成 モデル

32.1 拡散の実際（例 :安定拡散）

拡散モデルは、特に画像合成において、大規模な生成モデリングにおける主要なアプローチの一つとなっている。

理論から実践へ。実用的な拡散システムは、基本的なフレームワークを拡張し、アーキテクチャとアルゴリズムの改良を加えています。

- ノイズ除去のためのU-Netアーキテクチャ
- 条件付けメカニズム（例 :テキスト埋め込み）
- 効率的なサンプリング戦略

潜在拡散。モデルはピクセル空間で直接動作するのではなく、より低次元の潜在空間で動作します。

- 画像を潜在表現に符号化する
- 潜在空間で拡散を実行する
- ピクセル空間にデコードする

利点。

- 計算コストの削減
- 拡張性の向上

条件付け。生成モデルは、追加の入力によって制御できます。

- テキストプロンプト
- クラスラベル
- その他の方法

洞察。現代の拡散システムは、確率的モデリングと強力な神経アーキテクチャおよび条件付けメカニズムを組み合わせている。

32.2 大規模言語モデル

大規模言語モデル（LLM）は、シーケンスを生成するモデルであり、通常はトランスフォーマーアーキテクチャに基づいています。

自己回帰モデル。LLMは、シーケンスの同時分布をモデル化します。

$$p(x_1, \dots, x_T) = \prod_{t=1}^T p(x_t | x_1, \dots, x_{t-1})$$

研修目標。

$$\max_{\theta} E \sum_{t=1}^T \log p_{\theta}(x_t | x_{<t})。$$

トランスフォーマーのバックボーン。

- 自己注意層
- フィードフォワードネットワーク
- 残余接続と正規化

機能。

- テキスト生成
- 質問への回答
- コード生成
- 推論課題

事前学習と微調整。

- 大規模コーパスで事前学習済み
- 下流のタスクに適応

洞察。LLMは、規模とアーキテクチャを活用して、複雑な逐次的な依存関係をモデル化します。

32.3 スケーリング法則

実証研究は、モデルの性能と規模の間に体系的な関係があることを明らかにしている。

スケーリング係数。

- モデルサイズ（パラメータ数）
- データセットのサイズ
- コンピューティングリソース

経験法則。

$$\text{誤差} \propto N^{-\alpha}$$

ここで、 N はスケールを表し、 $\alpha > 0$ である。

影響。

- 大型モデルの方が性能が良い傾向がある
- 規模が大きくなるにつれて利益は減少する

計算上の最適なトレードオフ。

- モデルサイズとデータセットサイズのバランスを取る
- 計算リソースの効率的な割り当て

創発的行動。

- 新たな機能が大規模に登場
- 小規模モデルからは容易に予測できない

洞察。スケーリングは、現代の機械学習システムにおけるパフォーマンスの根本的な推進要因である。

32.4 エンジニアリング上の考慮事項

大規模な生成モデルは、学習と展開において綿密なエンジニアリングを必要とする。

分散型トレーニング。

- データ並列処理
- モデルの並列処理
- パイプラインの並列処理

ハードウェアアクセラレーション。

- GPUおよび専用アクセラレータ
- メモリと帯域幅の制約

最適化の課題。

- 大量生産
- 学習率スケジューリング
- 大規模環境における安定性

推論に関する考察。

- レイテンシとスループット
- モデルの圧縮と量子化

データに関する考慮事項。

- データ品質と多様性
- 前処理とフィルタリング

安全性とアライメント。

- モデル出力の制御
- 有害または偏った行動を軽減する

洞察。工学は、理論モデルを実用的なシステムへと変換する上で極めて重要な役割を果たす。

32.5 統一的な視点

大規模生成モデルは複数の次元を統合する：

- モデリング : 確率的アーキテクチャとニューラルアーキテクチャ
- 計算 : 大規模最適化
- データ : 膨大かつ多様なデータセット
- システム : 分散型で効率的な実装

核心となる考え方。パフォーマンスは、モデル、データ、計算の相互作用から生まれる。

重要な洞察。現代の生成モデルは、数学的な定式化のみによって定義されるのではなく、その規模とシステムレベルの設計によって定義される。

32.6 展望

本章では、大規模な生成モデルについて検討した。

- 実践における拡散モデル、
- 大規模言語モデル、
- スケーリング法則、
- 工学的考慮事項。

これで、現代の生成モデリング技術に関する研究は終了です。

基本原則 :機械学習の進歩は、理論、アーキテクチャ、データ、そして大規模な計算の組み合わせから生まれる。

第33章

深層における汎化 学ぶ

33.1 過剰パラメータ化

古典的な学習理論では、パラメータが多すぎるモデルは過学習を起こすとされています。しかし、現代の深層学習は、パラメータ数が訓練サンプル数を上回る、極めてパラメータ過多な状態で動作することがよくあります。

観察。

- ディープネットワークはトレーニングデータに正確に適合できる
- しかし、それらは未知のデータにもうまく一般化できることが多い。

補間方式。過剰パラメータモデルでは、多くの場合、訓練誤差をゼロにすることが可能です。

$$R_n(\theta) = 0。$$

複数の解決策が存在する。データを補間するためのパラメータ設定は多数存在する。

重要な疑問。なぜこれらの解決策の中には、汎用性が高いものと低いものがあるのだろうか？

効果的な複雑性。

- パラメータ数だけでは汎化性能は決まらない
- 構造とトレーニングのダイナミクスが役割を果たす

洞察。過剰パラメータ化は学習の性質を変える。モデルの中から選択するのではなく、解の中から選択するようになる。

33.2 勾配法の暗黙のバイアス

最適化アルゴリズムは、考えられるすべての解を均等に探索するわけではありません。むしろ、特定の解に対して暗黙の偏りを示す傾向があります。

暗黙のバイアス。最適化手法が、訓練誤差の少ない多数の解の中から特定の解を優先する傾向のこと。

例（線形回帰）。劣決定系では、勾配降下法は最小ノルム解に収束する。

$$\min \|w\|_2 \text{ 制約条件 } Xw = y。$$

ディープネットワーク。

- 潜在的偏見はより複雑である
- アーキテクチャ、初期化、オプティマイザに依存します

SGDの役割。

- 確率的勾配におけるノイズは軌跡に影響を与える
- より平坦な極小値を好む可能性がある

平坦な極値と鋭い極値。

- 平坦な極小値 : 摂動に対してより頑健
- 鋭い最小値 : 感度が高いが、一般化の精度は低下する可能性がある

洞察。汎化性能は、モデルそのものだけでなく、その最適化方法によっても左右される。

33.3 二重降下現象

古典的なバイアス・バリエーションのトレードオフ理論では、モデルの複雑さが増すと過学習につながると予測されている。しかし、近年の観測結果は、より複雑な挙動を示している。

二段階降下。

- モデルサイズが大きくなるにつれて、テスト誤差はまず減少し、次に増加し、その後再び減少する。

段階。

- パラメータ不足領域 : 古典的な挙動
- 補間閾値 : ピークテスト誤差

- 過剰パラメータ化レジーム : 改善された一般化

解釈。

- より大規模なモデルは、より優れた補間解を見つけることができる
- 最適化が重要な役割を果たす

実証的証拠。

- ニューラルネットワーク、カーネル法、その他のモデルで観察される

洞察。モデルの複雑さと一般化の間には、古典的な理論が示唆するよりも複雑な関係が存在する。

33.4 未解決の疑問

著しい進歩が見られるものの、深層学習における汎化理論は依然として不完全なままである。

主な課題。

- 過剰パラメータ化モデルが一般化される理由を理解する
- 深層ネットワークにおける潜在的バイアスの特性評価
- 最適化ダイナミクスの役割を説明する

理論的な方向性。

- パラメータ数以外の複雑性指標
- 安定性に基づく一般化限界
- 情報理論的アプローチ

他分野との関連性。

- 統計物理学（エネルギーランドスケープ）
- 動的システム（トレーニングダイナミクス）
- 情報理論（圧縮と表現）

実務上の意味合い。

- 建築設計
- 最適化アルゴリズムの選択
- 正則化戦略

洞察。深層学習における汎化能力の理解は、理論と実践を結びつける活発な研究分野である。

33.5 統一的な視点

深層学習における汎化は、複数の要因の相互作用から生じる。

- モデル容量 : ニューラルネットワークの表現力
- 最適化 : トレーニングアルゴリズムの暗黙のバイアス
- データ : 入力データの構造と分布

核心となる考え方。一般化は単一の要因によって決定されるのではなく、学習プロセス全体のダイナミクスによって決定される。

重要な洞察。現代の深層学習は従来の直感に挑戦し、新たな理論的枠組みを必要としている。

33.6 展望

本章では、深層学習における汎化について考察した。

- 過剰パラメータ化と補間、
- 最適化手法の暗黙のバイアス、
- 二重降下現象、
- 未解決の理論的問題。

これで、現代の機械学習と深層学習の理論的および実践的な基礎に関する考察を終わります。

指導原則。汎化を理解するには、最適化、確率、表現学習の概念を統合する必要がある。

第34章

幾何学と力学 学ぶ

34.1 損失の景観

ニューラルネットワークの学習は、高次元の損失関数のランドスケープをナビゲートすることと見なすことができる。

損失関数。パラメータ $\theta \in \mathbb{R}^d$ が与えられている。 $\mathbb{R}^d$ 、損失関数は以下を定義します。

$$L(\theta) : \mathbb{R}^d \rightarrow \mathbb{R}.$$

景観解釈。

- ポイントはパラメータ設定に対応します
- 高さは損失値に対応します

重要なポイント。

- 局所的最小値 : $\nabla L(\theta) = 0$ 、正の曲率
- 鞍点 : 曲率方向が混在

高次元幾何学。

- 鞍点の方が劣悪な局所的最小値よりも多く見られる
- 多くの方向はほぼ平坦です

平坦な極値と鋭い極値。

- 平坦な極小値 : 摂動に対して頑健

- 鋭い最小値 : パラメータの変化に敏感

視覚化（概念図）。低次元投影により、谷、尾根、高原が明らかになる。

洞察。損失関数の形状は、最適化と汎化性能に大きな影響を与える。

34.2 ニューラルタンジェントカーネル（直感）

ニューラルタンジェントカーネル（NTK）は、ニューラルネットワークのトレーニングを線形化した形で表現する。

線形化。初期値 θ_0 付近では、ネットワークは次のように近似できる。

$$f_{\theta}(x) \approx f_{\theta_0}(x) + \nabla_{\theta} f_{\theta_0}(x) (\theta - \theta_0)。$$

ニューラルタンジェントカーネル。

$$K(x, x') = \nabla_{\theta} f_{\theta_0}(x) \cdot \nabla_{\theta} f_{\theta_0}(x')$$

解釈。

- 初期化時にネットワークによって誘導されるカーネルを定義します
- トレーニングはカーネル K を用いたカーネル回帰に似ている

無限幅の限界。

- NTK が決定論的になる
- トレーニングのダイナミクスが線形になる

洞察。NTK は、深層学習と古典的なカーネル法を結びつけます。

34.3 トレーニングの連続時間ビュー

勾配ベースの最適化は、連続時間動的システムとして捉えることができる。

勾配降下法のアップデート。

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t)。$$

連続時間極限。 $\eta \rightarrow 0$ のとき、次の微分方程式が得られる。

$$\frac{d\theta(t)}{dt} = -\nabla L(\theta(t)) \cdot dt$$

勾配流。

- パラメータは最も急な降下方向に沿って変化する
- 軌跡はパラメータ空間内の曲線に沿って進む

エネルギー解釈。損失は軌道に沿って減少する。

$$\frac{d}{dt}L(\theta(t)) = -\|\nabla L(\theta(t))\|^2 \leq 0。$$

確率力学への拡張。確率的勾配降下法はノイズを導入する。

$$d\theta(t) = -\nabla L(\theta(t))dt + \Sigma^{1/2} dW_t, \text{ここで}$$

W_t はブラウン運動である。

洞察。トレーニングは、勾配とノイズの両方によって形作られる連続的な流れとして理解できる。

34.4 動的システム論的視点

ニューラルネットワークのトレーニングと表現学習は、動的システムの観点から捉えることができる。

パラメータの動態。

- 最適化における $\theta(t)$ の変化

表象のダイナミクス。

- トレーニング中の特徴量 $f_{\theta(t)}(x)$ の変化

安定性。

- 安定固定点は最小値に対応する
- 安定性は曲率とノイズに依存する

アトラクター。

- 最適化はパラメータ空間の特定の領域に収束する可能性がある

残差ネットワークとの関連性。ディープネットワークは、離散化された動的システムに似ている。

機能の進化。

- 初期トレーニング :急速な特徴変化
- 後期段階 :微調整

洞察。学習は、時間の経過とともにパラメーターと表現の両方が進化する動的なプロセスである。

34.5 統一的な視点

学習の幾何学と力学は、統一的な枠組みを提供する。

- 幾何学 : 損失ランドスケープの構造
- ダイナミクス : 最適化の軌跡
- 線形化 : NTK近似
- 確率性 : トレーニングにおけるノイズの役割

核心となる考え方。学習を理解するには、目的の構造と最適化のダイナミクスの両方を分析する必要がある。

重要な洞察。現代の深層学習は、幾何学、確率論、および力学系の交点に位置する。

34.6 展望

本章では、学習の幾何学と力学について考察した。

- 損失の景観とその構造、
- ニューラルタンジェントカーネルの観点、
- 最適化の連続時間ビュー、
- 力学系の解釈。

これらの視点は、学習がどのように行われるかについてのより深い理論的理解を提供する。
現代の機械学習システムでは、このようなことが起こる。

指導原則。学習は、モデル構造と最適化の相互作用によって形成される、幾何学的な問題であると同時に動的なプロセスでもある。

第35章

実践的なシステム設計

35.1 データパイプライン

現代の機械学習システムにおいて、データはモデルと同様に重要です。効果的なシステム設計は、信頼性が高く拡張性の高いデータパイプラインから始まります。

データパイプライン。データパイプラインは、生データをトレーニングや評価に適した形式に変換します。

段階。

- データ収集
- 洗浄および前処理
- 特徴抽出またはエンコーディング
- 保管とアクセス

前処理。

- 正規化とスケーリング
- 欠損値の処理
- データ拡張

ストリーミング処理とバッチ処理の比較。

- バッチパイプラインはデータを大きな塊で処理します
- ストリーミングパイプラインはデータを継続的に処理します

データ品質。

- 一貫性と正確性

- ノイズとバイアスに関する考慮事項

洞察。機械学習システムの品質は、根本的にデータの質によって制限される。

35.2 トレーニングワークフロー

最新のモデルを訓練するには、データ、計算、実験を管理する協調的なワークフローが必要です。

トレーニングループ。

1. データのバッチを読み込む
2. 予測値を計算する
3. 損失を評価する
4. 勾配を計算する
5. パラメータを更新する

実験管理。

- ハイパーパラメータを追跡する
- メトリクスとログを記録する
- 異なるモデル構成を比較する

ハイパーパラメータチューニング。

- グリッドサーチ、ランダムサーチ
- 適応型手法（例：ベイズ最適化）

分散型トレーニング。

- 複数のデバイス間でのデータ並列処理
- 大規模モデルにおけるモデル並列処理

チェックポイント。

- 中間モデル状態を保存する
- 復旧と実験を可能にする

洞察。適切に設計されたワークフローは、効率的な実験と信頼性の高いモデル開発を可能にします。

35.3 デバッグと診断

機械学習モデルのトレーニングには、最適化の過程で発生する問題の診断がしばしば含まれる。

よくある問題。

- トレーニングは収束しない
- 過学習または過小学習
- 数値的不安定性

診断ツール。

- トレーニング曲線と検証曲線
- 勾配ノルム
- アクティベーション統計

正気確認。

- 小規模データセットにおける損失減少を検証する
- グラデーションの正確性を確認する
- ラベルとデータの一貫性を確保する

視覚化。

- 時間の経過に伴う指標の監視
- 中間出力を検査する

体系的なデバッグ。

- 構成要素を分離する
- モデルを簡略化する
- 段階的に複雑さを増す

洞察。デバッグは機械学習において不可欠なスキルであり、理論的な理解と実践的な経験の両方が求められる。

35.4 再現性

再現性は、科学のおよび工学的信頼性にとって極めて重要である。

定義 : 結果が再現可能であるとは、同じ条件下で一貫して得られる場合をいう。

変動要因。

- ランダム初期化
- データシャッフル
- ハードウェアと数値の違い

ベストプラクティス。

- 乱数シードを修正する
- 設定とハイパーパラメータを記録する
- バージョンデータセットとコード

実験の追跡。

- 結果を体系的に保存する
- 実験記録を保持する

決定論対パフォーマンス。

- 完全決定論的な実行はパフォーマンスを低下させる可能性がある
- 再現性と効率性のトレードオフ

洞察。再現性によって、結果の信頼性が確保され、それを基盤として研究を進めることができる。

35.5 統一的な視点

実用的なシステム設計では、複数のコンポーネントが統合されます。

- データ : パイプラインと前処理
- 計算 : トレーニングワークフロー
- 診断 : デバッグツール
- 信頼性 : 再現性に関する実践

基本的な考え方 : 機械学習システムを成功させるには、データ、モデル、インフラストラクチャの綿密な連携が不可欠である。

重要な洞察。実用性はアルゴリズムだけでなく、それを支えるシステムにも左右される。

35.6 見通し

本章では、機械学習システムの実際的な側面について考察した。

- データパイプライン、
- トレーニングワークフロー、
- デバッグと診断、
- 再現性。

これで本書は終了です。

最終的な指針。機械学習は数学的な学問分野であると同時に工学的な実践でもあり、理論、データ、システムに関する深い理解が求められる。

第36章

限界と未来 方向

36.1 堅牢性と不確実性

現代の機械学習システムは目覚ましい性能を発揮する一方で、外乱や不確実性に対しては依然として敏感である。

堅牢性。モデルは、入力値のわずかな変化に対して予測が安定している場合に堅牢であると言えます。

$$\|x - x'\| \text{ 小さい} \Rightarrow f(x) \approx f(x')$$

敵対的サンプル。

- 綿密に設計された摂動は、予測を大きく変える可能性がある。
- 人間にはしばしば感知できない

分布の変化。

- トレーニングデータとテストデータの分布は異なる場合があります
- 新たな条件下では性能が低下する可能性がある

不確実性の推定。

- 偶然的な不確実性 : データに内在するノイズ
- 認識的な不確実性 : 限られた知識に起因する不確実性

アプローチ。

- ベイズ法

- アンサンブルモデル

- 校正技術

洞察。信頼性の高いAIシステムは、正確な予測を行うだけでなく、不確実性を定量化し、管理する必要がある。

36.2 現代AIの障害モード

優れた実証性能を示すにもかかわらず、現代のモデルは体系的な故障モードを示す。

よくある問題。

- 誤った予測に対する過信
- 偽相関に対する感度
- 稀な入力値や分布外の入力値に対する堅牢性の欠如

データ依存性。

- モデルはトレーニングデータに存在するバイアスを継承する
- パフォーマンスは真の理解ではなく、データの分布を反映している

一般化の限界。

- トレーニング体制を超えた外挿の難しさ
- 構成的推論における課題

スケーリングの制限。

- サイズを大きくしても全ての問題が解決するわけではない
- 大規模な場合でも、一部の不具合は依然として存在する。

洞察。故障モードを理解することは、信頼性の向上と今後の研究の指針となる上で不可欠である。

36.3 解釈可能性

解釈可能性とは、モデルがどのように、そしてなぜ予測を行うのかを理解しようとするものである。

モチベーション。

- 信頼と透明性
- デバッグとモデルの改善

36.4. 今後の研究の方向性

177

- 科学的理解

解釈可能性の種類。

- 特徴量の帰属 : 入力的重要性
- 表現分析 : 学習された特徴の構造
- モデルの単純化 : 複雑なモデルをより単純なモデルで近似する

課題。

- 高次元表現
- 非線形相互作用
- 独自の解釈の欠如

トレードオフ。

- 正確性 vs 解釈可能性
- シンプルさ vs 忠実さ

洞察。解釈可能性とは単一の特性ではなく、複雑なモデルを理解するための様々なアプローチの集合体である。

36.4 今後の研究の方向性

機械学習の未来は、理論、データ、システムの交差点にある。

理論的な方向性。

- 深層学習における汎化の理解
- 最適化ダイナミクスの特性評価
- 離散モデルと連続モデルの橋渡し

モデリングの手順。

- 視覚、言語、行動を組み合わせたマルチモーダルモデル
- より効率的で拡張性の高いアーキテクチャ
- 推論能力が向上したモデル

データと学習パラダイム。

- 自己指導型学習と非指導型学習

- 限られたデータやノイズの多いデータから学習する
- 継続的かつ生涯にわたる学習

システムと効率性。

- 計算コストとエネルギーコストの削減
- 効率的なトレーニングと推論

安全性とアライメント。

- 信頼性が高く制御可能な動作を確保する
- 意図しない結果を軽減する

学際的なつながり。

- 神経科学および認知科学
- 物理学および力学系
- 数学と統計学

洞察。今後の進歩には、様々な分野にわたる知見を統合し、理論と実証的進歩のバランスを取ることが必要となるだろう。

36.5 最終的な展望

本書は、機械学習と深層学習を数学的観点と実践的観点の両方から探求している。

主要テーマ。

- 関数近似と最適化としての学習
- 深層アーキテクチャによる表現学習
- 確率的モデリングと生成プロセス
- スケーリングとシステムレベルの考慮事項

共通の考え方。学習システムは、データ、モデル、アルゴリズムの相互作用によって形成される。

最後に、人工知能は進化し続ける分野であり、理論と実践は互いに影響を与え合い、刺激し合いながら発展していく。

36.6 結びの言葉

機械学習は、厳密な数学と実用的な工学を融合させた、他に類を見ない学問分野の交差点に位置している。

見通し。

- 新たな理論的枠組みは、私たちの理解を深めるだろう
- 新しいアーキテクチャとシステムにより機能が拡張されます
- 責任ある開発が現実世界への影響を形作る

最終的な指針。AIの未来は、性能向上だけでなく、理解、信頼性、そして責任ある利用にもかかっている。