

Искусственный интеллект: математический и Инженерная точка зрения

Март 2026 г.

Глава 1

Обучение как функция Приближение

1.1 Проблемы обучения и данные

Современный искусственный интеллект в значительной степени занимается проблемой обучения на основе данных. В общих чертах, нам предоставляются наблюдения за миром, и нас просят построить систему, которая может делать прогнозы, принимать решения или генерировать новые данные.

Мы формализуем это следующим образом. Пусть

$$X \subseteq \mathbb{R}^d$$

обозначим входное пространство и

$$Y$$

Выходное пространство. Набор данных — это совокупность образцов.

$$D = \{(x_i, y_i)\}_{i=1}^n, x_i \in X, y_i \in Y.$$

Цель обучения — построить функцию.

$$f: X \rightarrow Y$$

которая отражает взаимосвязь между входными и выходными данными.

Примеры.

- В регрессионном анализе $Y \subseteq \mathbb{R}$.
- В классификации $Y = \{1, \dots, K\}$.
- В генеративном моделировании $Y = X$, Цель состоит в том, чтобы смоделировать распределение данных.

Хотя эта формулировка кажется простой, она скрывает главную проблему машинного обучения: мы наблюдаем лишь конечное число выборок, но при этом ищем функцию, которая хорошо работает с неизвестными данными.

1.2 Функции, модели и представления

Алгоритм машинного обучения не перебирает все возможные функции. Вместо этого он выбирает функцию из класса моделей (или пространства гипотез).

$$H = \{f_\theta : \theta \in \Theta\}.$$

Здесь:

- θ обозначает параметры,
- Θ — пространство параметров,
- f_θ — это функция, определяемая параметром θ .

Пример (линейная модель).

$$f_\theta(x) = w \cdot x + b, \theta = (w, b).$$

Пример (нейронная сеть).

$$f_\theta(x) = W_L \sigma(W_{L-1} \sigma(\dots \sigma(W_1 x))),$$

где σ — нелинейная функция активации.

Выбор H отражает предположения о структуре проблемы.

Это явление известно как индуктивная предвзятость, к которой мы вернемся в последующих главах.

Способ представления имеет значение. Две модели могут представлять один и тот же класс функций, но вести себя совершенно по-разному на практике из-за:

- свойства оптимизации,
- численная устойчивость,
- Обобщающее поведение.

Таким образом, модель — это не просто класс функций, это также вычислительный и статистический объект.

1.3 Приближение как основная парадигма

По своей сути, машинное обучение — это задача аппроксимации.

Мы предполагаем, что существует неизвестная функция.

$$\phi : X \rightarrow Y$$

который управляет данными:

$$y = \phi(x) + \text{шум}.$$

1.4. ПРИМЕРЫ ИЗ РЕГРЕССИИ И КЛАССИФИКАЦИИ

5

Поскольку f неизвестно, мы ищем приближение f_θ такое, что

$$f_\theta \approx f.$$

Для количественной оценки этого приближения мы вводим функцию потерь.

$$\ell : Y \times Y \rightarrow \mathbb{R}.$$

Качество f оценивается по риску.

$$R(f) = E_{(x,y)} \ell(f(x), y).$$

Поскольку распределение данных неизвестно, мы вместо этого минимизируем эмпирический риск.

$$\hat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i).$$

Проблема обучения.

$$\min_{\theta \in \Theta} \hat{R}_n(f_\theta).$$

Эта простая задача оптимизации лежит в основе практически всех современных алгоритмов машинного обучения.

1.4 Примеры из регрессии и классификации

1.4.1 Регрессия

В регрессионном анализе выходное пространство — это $Y = \mathbb{R}$.

В качестве функции потерь часто используется квадратичная ошибка:

$$\ell(f(x), y) = (f(x) - y)^2.$$

Эмпирический риск становится

$$\hat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n (f(x_i) - y_i)^2.$$

Интерпретация.

- Строго наказывает за большие отклонения
- Приводит к аналитически разрешимым решениям для линейных моделей

1.4.2 Классификация

В классификации $Y = \{1, \dots, K\}$.

Вместо прямого предсказания меток, модели часто выдают оценки или вероятности:

$$f(x) \in \mathbb{R}^K.$$

Распространенной функцией потерь является кросс-энтропийная функция потерь:

$$\ell(f(x), y) = -\log p_\theta(y | x).$$

Интерпретация.

- Способствует правильному определению вероятностей принадлежности к классу.
- Тесная связь с методом максимального правдоподобия

1.5 От приближения к обобщению

Возникает ключевой вопрос: минимизация эмпирического риска не гарантирует хороших результатов при работе с новыми данными.

Ключевой вопрос. Почему функция, хорошо подходящая для обучающих данных, должна также хорошо работать на неизвестных данных?

Этот вопрос приводит к изучению:

- обобщение,
- сложность модели,
- регуляризация,
- индуктивное смещение.

Эти идеи составляют теоретическую основу машинного обучения и будут использоваться в дальнейшем. разработано на протяжении всей этой книги.

1.6 Объединяющая перспектива

Подведем итоги процесса обучения:

1. Выберите модель класса H .
2. Определите функцию потерь ℓ .
3. Решите задачу оптимизации.
4. Проведите оценку на основе ранее не встречавшихся данных.

Три взаимодействующих компонента:

- Аппроксимация (выразительность модели)
- Оптимизация (способность находить оптимальные параметры)
- Обобщение (эффективность на новых данных)

Современный искусственный интеллект, в частности глубокое обучение, добивается успеха, потому что он обеспечивает баланс этих трех аспектов в масштабе.

1.7 Прогноз

В этой главе представлена центральная точка зрения данной книги: обучение как аппроксимация функций в условиях неопределенности.

В следующей главе мы разработаем вероятностную структуру, лежащую в основе обучения, связывая эмпирическую минимизацию риска со статистическим выводом.

Основной принцип. На протяжении всего текста мы будем подчеркивать следующее:

- Интуиция, основанная на математике,
- модели как структурированные приближения,
- и алгоритмы как вычислительные реализации этих идей.

Глава 2

Вероятностный взгляд на Обучение

2.1 Случайность и генерация данных

В главе 1 мы представили обучение как задачу аппроксимации неизвестной функции на основе данных. Теперь мы уточняем этот подход, учитывая неопределенность.

Данные не являются детерминированными. Даже когда существует истинная взаимосвязь, наблюдения подвержены шуму, изменчивости и неполной информации. Естественный способ моделирования этого — использование вероятности.

Мы предполагаем, что данные генерируются в соответствии с неизвестным распределением вероятностей.

$$P \text{ на } X \times Y.$$

Набор данных

$$D = \{(x_i, y_i)\}_{i=1}^n$$

моделируется как независимые выборки, взятые из P :

$$(x_i, y_i) \sim P.$$

Интерпретация.

- Распределение P отражает все свойства процесса генерации данных.
- Представленный набор данных содержит лишь конечное, зашумленное наблюдение этого процесса.

Этот подход меняет цель обучения: вместо подгонки набора данных мы стремимся изучить свойства базового распределения.

2.2 Условная структура и прогнозирование

Полезное разложение P дается следующим образом:

$$P(x, y) = P(y | x)P(x).$$

Ключевой объект: условное распределение $P(y | x)$.

Прогнозирование можно понимать как оценку этой условной зависимости.

Пример (регрессия).

$$y = f(x) + \epsilon, E[\epsilon | x] = 0.$$

Затем

$$\phi(x) = E[y | x].$$

Пример (классификация).

$$P(y = k | x), k = 1, \dots, K.$$

Прогнозирование соответствует выбору наиболее вероятного класса:

$$\arg \max_k P(y = k | x). \hat{y} =$$

Таким образом, многие задачи обучения сводятся к оценке условных ожиданий или вероятностей.

2.3 Теорема Байеса и вывод

Теорема Байеса устанавливает фундаментальную связь между условными вероятностями:

$$P(y | x) = \frac{P(x | y)P(y)}{P(x)}.$$

Интерпретация.

- $P(y)$ — это априорное убеждение относительно y ,
- $P(x | y)$ — вероятность наблюдения x при условии y ,
- $P(y | x)$ — апостериорное доверие после наблюдения x .

На практике теорема Байеса предполагает два взаимодополняющих подхода:

- Дискриминативное моделирование: прямое моделирование $P(y | x)$
- Генеративное моделирование: модель $P(x | y)$ и $P(y)$

Инженерная точка зрения.

- Дискриминативные модели часто демонстрируют лучшие прогностические результаты.
- Генеративные модели обеспечивают более богатую структуру и могут генерировать данные.

2.4 Функции потерь как статистические целевые функции

В главе 1 мы ввели функции потерь как меры ошибок. С вероятностной точки зрения, функции потерь естественным образом вытекают из статистических принципов.

Рассмотрим модель f_θ , которая определяет условное распределение $p_\theta(y | x)$.

Отрицательная логарифмическая функция правдоподобия.

$$\ell(f_\theta(x), y) = -\log p_\theta(y | x).$$

Минимизация эмпирического риска

$$\frac{1}{n} \sum_{i=1}^n \ell(f_\theta(x_i), y_i)$$

Это эквивалентно максимизации вероятности:

$$\max_{\theta} \prod_{i=1}^n p_\theta(y_i | x_i).$$

Примеры.

- Гауссовский шум квадратичная функция потерь
- Категориальное распределение кросс-энтропийная потеря

Таким образом, многие широко используемые функции потерь не являются произвольными — они коррелируют реагировать на вероятностные предположения относительно данных.

2.5 Риск и ожидаемые потери

Истинная цель обучения — минимизировать ожидаемые потери (или риск).

$$R(f) = E_{(x,y)} \ell(f(x), y).$$

Идеальная задача.

$$\min_f R(f).$$

Однако P неизвестно, поэтому $R(f)$ нельзя вычислить точно.

Вместо этого мы аппроксимируем его, используя эмпирический риск:

$$\hat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i).$$

Минимизация эмпирического риска (МЭР).

$$\min_f \hat{R}_n(f).$$

ERM — это центральный принцип, лежащий в основе большинства алгоритмов машинного обучения.

2.6 Приближение, оценка и оптимизация

ИОН

Вероятностная формулировка выявляет три различных источника ошибок:

1. Ошибка аппроксимации. Класс моделей H может не содержать истинную функцию.
2. Ошибка оценки. Мы наблюдаем лишь конечную выборку из P .
3. Ошибка оптимизации. Мы можем не найти точный минимизатор эмпирического риска.

Вывод: современные системы машинного обучения эффективны, потому что они уравнивают эти три ошибки.

2.7 Условное ожидание как оптимальное предварительное условие

диктор

Ключевой теоретический результат позволяет понять структуру оптимальных предикторов.

Утверждение. Для квадрата убытка функция, минимизирующая риск, имеет вид:

$$\phi^*(x) = E[y \mid x].$$

Интерпретация.

- Оптимальным прогнозом является условное среднее.
- Цель обучения — приблизиться к этому условному ожиданию.

Этот результат объясняет, почему регрессионные модели фокусируются на оценке средних значений, даже когда данные зашумлены.

2.8 От вероятностей к алгоритмам

Хотя вероятностный подход обеспечивает ясность, практические алгоритмы должны работать в условиях ограничений:

- ограниченные данные,
- многомерные входные данные,
- вычислительные ограничения.

Таким образом, модели разрабатываются не только с учетом статистической достоверности, но и с учетом следующих факторов:

- вычислительно эффективный,

- численно устойчивый,
- Масштабируемость для больших наборов данных.

Это взаимодействие между вероятностью и вычислениями является определяющей чертой современного машинного обучения.

2.9 Объединяющая перспектива

Теперь мы можем усовершенствовать процесс обучения:

1. Предположим, что данные получены из неизвестного распределения P .
2. Выберите модель $p_\theta(y | x)$ или функцию f_θ .
3. Дайте определение убытка, выведенного из вероятностных принципов.
4. Минимизация эмпирического риска

Главный вывод. Обучение — это процесс аппроксимации условных распределений на основе конечных выборок.

2.10 Прогноз

В этой главе были представлены вероятностные основы обучения:

- данные в виде выборок из распределения,
- прогнозирование как оценка условной структуры,
- функции потерь как статистические цели.

В следующей главе мы изучим пространства гипотез и индуктивную предвзятость, которые определяют, какие типы функций могут быть изучены и как становится возможной генерализация.

Основной принцип. Вероятность предоставляет язык неопределенности, но для успешного обучения необходимо сочетать ее со структурой, вычислениями и приближенными методами.

Глава 3

Гипотетические пространства и Индуктивное смещение

3.1 Классы функций и семейства моделей

В предыдущих главах мы сформулировали процесс обучения как проблему выбора функции, минимизирующей эмпирический риск. Однако мы еще не рассмотрели один важный вопрос:

Какие функции нам разрешено выбирать?

Ответ на этот вопрос определяется путем задания пространства гипотез (или класса моделей).

$$H = \{f_\theta : \theta \in \Theta\}.$$

Пространство гипотез определяет набор функций-кандидатов, которые может обучить процесс. алгоритм может представлять.

Примеры функциональных классов.

- Линейные модели:

$$f(x) = w \cdot x + b.$$

- Полиномиальные модели:

$$f(x) = \sum_{|a| \leq d} c_a x^a.$$

- Нейронные сети:

$$f_\theta(x) = W_L \sigma(W_{L-1} \sigma(\dots \sigma(W_1 x)) \dots).$$

Каждый выбор параметра H накладывает структурные предположения о взаимосвязи между входными и выходными данными.

Выразительность. Пространство гипотез называется выразительным, если оно может аппроксимировать широкий диапазон функций.

Пример. Нейронные сети достаточной ширины могут аппроксимировать любую непрерывную функцию на компактных областях (универсальное свойство аппроксимации).

Однако одной лишь выразительности недостаточно для определения производительности. Модель с высокой выразительностью может идеально соответствовать обучающим данным, но не обладать способностью к обобщению.

Таким образом, выбор H — это не просто вопрос аппроксимации, а вопрос баланса между выразительностью, стабильностью и обучаемостью.

3.2 Индуктивная предвзятость и априорная структура

Пространство гипотез вводит неявное предпочтение одних функций перед другими. Это предпочтение известно как индуктивная предвзятость.

Определение (неформальное). Индуктивная предвзятость — это набор допущений, позволяющих алгоритму обучения обобщать результаты за пределы наблюдаемых данных.

Без индуктивного подхода обучение невозможно: бесконечное множество функций могут интерполировать обучающие данные, но лишь некоторые из них будут хорошо обобщать данные.

Источники индуктивной предвзятости.

- Класс моделей: Линейные модели отдают предпочтение линейным зависимостям.
- Архитектура: Сверточные сети отдают предпочтение локальности и трансляции. дисперсия.
- Регуляризация: Наложение штрафа на большие параметры способствует использованию более простых функций.
- Оптимизация: Градиентные методы могут отдавать предпочтение определенным решениям. среди многих.

Связь с имеющимися знаниями. Индуктивную предвзятость можно рассматривать как кодирование имеющихся знаний о проблеме:

- гладкость,
- разреженность,
- композиционная структура,
- инвариантности.

Инженерная точка зрения. Успешные модели не являются нейтральными — они тщательно разрабатываются, чтобы отражать структуру данных.

Например:

- Сверточные нейронные сети используют пространственную локальность в изображениях.

- Трансформаторы используют взаимосвязи между элементами в последовательностях.

Таким образом, индуктивная предвзятость является не ограничением, а необходимым элементом обучения.

3.3 Компромисс между смещением и дисперсией (интуиция)

Теперь рассмотрим, как выбор пространства гипотез влияет на обобщение.

Рассмотрим ожидаемую ошибку прогнозирования в точке x :

$$E(f(x) - y)^2.$$

Эту ошибку можно концептуально разложить на три компонента:

- Смещение: ошибка, обусловленная систематической аппроксимацией.
- Дисперсия: ошибка, обусловленная чувствительностью к данным.
- Шум: присущая данным случайность.

Модели с высоким смещением.

- Простые пространства гипотез (например, линейные модели)
- Может не соответствовать данным
- Низкая дисперсия, но большая систематическая ошибка

Модели с высокой дисперсией.

- Высокоэффективные модели (например, глубокие нейронные сети)
- Может точно соответствовать обучающим данным
- Чувствителен к шуму и колебаниям

Компромисс. Увеличение сложности модели обычно приводит к следующим результатам:

- уменьшает предвзятость,
- увеличивает дисперсию.

Проницательность. Для качественного обобщения необходимо сбалансировать эти два эффекта.

Примечание. В современном глубоком обучении эта классическая картина уточняется: модели с высокой степенью избыточной параметризации по-прежнему могут хорошо обобщать данные благодаря неявным эффектам регуляризации и оптимизации.

3.4 Выбор способов представления информации

Эффективность обучающей системы зависит не только от класса функций, но и от способа представления входных данных.

Определение. Представление — это преобразование.

$$\phi : X \rightarrow Z$$

который отображает исходные данные в пространство признаков.

В этом случае модель работает с $\phi(x)$ вместо x :

$$f(x) = g(\phi(x)).$$

Пример.

- Полиномиальные характеристики: $\phi(x) = (x, x^2, \dots)$
- Изученные признаки в нейронных сетях

Основная идея. Простая модель, примененная к сложной системе представления данных, может быть более эффективной, чем сложная модель, примененная к исходным данным.

Разработка признаков против обучения представлению информации.

- Классические подходы основаны на элементах, разработанных вручную.
- Глубокое обучение автоматически изучает представления

Композиционные представления. Глубокие нейронные сети строят представления иерархически:

- Нижние слои улавливают локальные закономерности,
- Более высокие слои отражают абстрактную структуру.

Геометрическая точка зрения. Представления преобразуют геометрию данных таким образом, что:

- Классы становятся разделимыми,
- структура становится проще,
- Обучение становится проще.

Таким образом, выбор способа представления эквивалентен выбору системы координат. в результате чего проблема обучения становится разрешимой.

3.5 Объединяющая перспектива

Теперь мы можем уточнить задачу обучения:

1. Выберите представление ϕ
2. Выберите пространство гипотез H .
3. Внедрение индуктивного смещения посредством структуры и регуляризации.
4. Оптимизация эмпирического риска

Ключевые компоненты обучения:

- Представление (способ кодирования данных)
- Класс функций (что можно выразить)
- Индуктивная предвзятость (что предпочтительнее)

Современные системы глубокого обучения объединяют эти элементы: они обучаются репрезентативным моделям. Одновременное выполнение функций и задач, руководствуясь неявными и явными предубеждениями.

3.6 Прогноз

В этой главе подчеркивалось, что обучение — это не только подгонка данных, но и выбор правильного пространства функций и представлений.

В следующей главе мы рассмотрим обучение как задачу оптимизации, сосредоточив внимание на том, как модели обучаются на практике.

Основной принцип. Обобщение возникает не только на основе данных, но и в результате взаимодействия данных, структуры модели и индуктивной предвзятости.

Глава 4

Обучение как оптимизация

4.1 Оптимизационные формулировки процесса обучения

В предыдущих главах мы сформулировали задачу обучения как задачу минимизации эмпирического риска. Теперь мы рассмотрим эту задачу с точки зрения оптимизации.

Напомним, что модель параметризуется параметром $\theta \in \Theta$, а обучение заключается в решении задач.

$$\min_{\theta \in \Theta} \hat{R}_n(\theta), \text{ где } \hat{R}_n(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\theta}(x_i), y_i).$$

Ключевое наблюдение. Обучение сводится к минимизации функции в многомерном пространстве параметров.

Данная формулировка объединяет широкий спектр моделей:

- Линейная регрессия — выпуклая квадратичная оптимизация
- Логистическая регрессия — выпуклая оптимизация
- Нейронные сети — сильно невыпуклая оптимизация

Структура цели.

- Сумма потерь по точкам данных
- Часто гладкий (дифференцируемый)
- Многомерный и, возможно, невыпуклый

Инженерное ограничение. Точная минимизация редко возможна. Вместо этого мы стремимся найти параметры, которые будут достаточно хороши при ограниченном вычислительном времени.

Таким образом, оптимизация — это не просто математический инструмент, она определяет, какие модели применимы на практике.

4.2 Методы, основанные на градиенте

Большинство современных алгоритмов машинного обучения основаны на оптимизации с использованием градиента.

Градиентный спуск. Для заданной дифференцируемой целевой функции $L(\theta)$ правило обновления выглядит следующим образом:

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t),$$

где $\eta > 0$ — скорость обучения.

Интерпретация.

- Градиент $\nabla L(\theta)$ указывает в направлении наибольшего возрастания.
- Движение в направлении отрицательного градиента уменьшает потери.

Геометрический вид. Градиентный спуск следует локальной геометрии поверхности потерь, двигаясь к областям с меньшими значениями.

Выбор темпа обучения.

- Слишком малый размер η — медленная сходимость
- Слишком большой размер η — нестабильность или дивергенция

Пример (квадратичная функция потерь). Для выпуклой квадратичной функции градиентный спуск сходится к глобальному минимуму при подходящих условиях.

Ограничение. Для вычисления полного градиента необходимо просуммировать все точки данных:

$$L(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f\theta(x_i), y_i).$$

Для больших наборов данных это становится вычислительно затратным процессом.

4.3 Стохастическая оптимизация

Для решения проблемы вычислительных затрат, связанных с полными градиентами, мы используем стохастические приближения.

Стохастический градиентный спуск (SGD). На каждом шаге выбирается точка данных (или мини-пакет) и вычисляется приближенный градиент:

$$\theta_{t+1} = \theta_t - \eta \nabla \ell(f\theta(x_{it}), y_{it}).$$

Мини-партия SGD.

$$\theta_{t+1} = \theta_t - \eta \frac{1}{|B_t|} \sum_{i \in B_t} \nabla \ell(f\theta(x_i), y_i).$$

Основные характеристики.

- Более низкая вычислительная стоимость за итерацию
- Вносит шум в процесс оптимизации

Вывод: шум в алгоритме стохастического градиентного спуска не является исключительно вредным — он может помочь избежать плохих локальных минимумов и улучшить обобщающую способность.

Компромисс.

- Небольшой размер пакета — шумные, но дешевые обновления
- Большой размер пакета — стабильные, но дорогостоящие обновления

Практические методы.

- Momentum: ускоряет сходимость за счет сглаживания обновлений.
- Адаптивные методы (например, Adam): регулируют скорость обучения для каждого параметра.

Стохастическая оптимизация — это основа современного глубокого обучения.

4.4 Геометрия ландшафтов потерь

Для понимания поведения оптимизации полезно рассмотреть геометрию функции потерь.

Ландшафт потерь. Функция

$$L(\theta)$$

Определяет поверхность в пространстве параметров.

Ключевые моменты.

- Локальные минимумы: $L(\theta) = 0$, L локально минимален
- Седловые точки: $L(\theta) = 0$, но не минимумы

Выпуклые и невыпуклые.

- Выпуклые задачи: все локальные минимумы являются глобальными.
- Невыпуклые задачи: множественные локальные минимумы и седловые точки

Нейронные сети приводят к появлению сильно невыпуклых ландшафтов функции потерь, однако методы, основанные на градиенте, часто оказываются успешными на практике.

Плоские и острые минимумы.

- Плоские минимумы: потери медленно изменяются вокруг решения.
- Резкие минимумы: потери быстро меняются

Наблюдение. Решения, найденные методом стохастического градиентного спуска (SGD), как правило, лежат в более пологих областях, которые... часто ассоциируются с лучшей обобщаемостью.

Эффекты в многомерном пространстве. В многомерном пространстве:

- Седловые точки встречаются чаще, чем плохие локальные минимумы.
- Многие направления могут иметь кривизну, близкую к нулю.

Геометрическая интуиция. Оптимизацию можно рассматривать как управление сложным процессом.

Ландшафт сформирован следующим образом:

- модель архитектуры,
- распространение данных,
- параметризация.

4.5 Оптимизация и обобщение

Оптимизация делает больше, чем просто минимизирует потери при обучении — она влияет на обобщающую способность.

Основная идея. Различные алгоритмы оптимизации могут сходиться к разным решениям, даже если они достигают схожей ошибки обучения.

Скрытая предвзятость. Градиентные методы демонстрируют предпочтение определенным решениям среди множества возможных минимизаторов.

Пример.

- В перепараметризованных линейных моделях градиентный спуск часто находит минимум нормальные решения

Вывод. Оптимизация является частью процесса моделирования — она неявно регуляризует изученную функцию.

4.6 Объединяющая перспектива

Теперь мы можем усовершенствовать процесс обучения:

1. Определите функцию потерь на основе данных и модели.
2. Сформулируйте задачу оптимизации.
3. Примените градиентные методы (часто стохастические).
4. Получите решение, сформированное как целевой функцией, так и динамикой оптимизации.

Три взаимодействующих аспекта:

- Цель (что минимизируется)
- Алгоритм (как он минимизируется)
- Геометрия (структура ландшафта потерь)

Современное машинное обучение добивается успеха не только потому, что четко определены целевые функции, но и потому, что эффективные методы оптимизации могут использовать их структуру.

4.7 Прогноз

В этой главе оптимизация была представлена как центральный компонент обучения:

- обучение как минимизация эмпирического риска,
- градиентные методы как основной инструмент,
- Стохастичность как необходимость и как преимущество.

В следующей главе мы более подробно изучим обобщение, рассмотрев фундаментальный вопрос о том, почему модели, хорошо соответствующие данным, могут по-прежнему хорошо работать на примерах, которые ранее не встречались.

Основной принцип. Обучение заключается не только в том, что мы оптимизируем, но и в том, как мы это оптимизируем.

Глава 5

Обобщение и Переобучение

5.1 Результаты обучения и тестирования

В предыдущих главах мы сформулировали процесс обучения как минимизацию эмпирического риска и изучили, как алгоритмы оптимизации находят решения. Однако остается центральный вопрос:

Почему модель, хорошо подходящая для обучающих данных, должна показывать хорошие результаты на неизвестных данных?

Для решения этой проблемы мы различаем два типа исполнения.

Ошибка обучения.

$$\hat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(e(x_i), y_i).$$

Ошибка тестирования (ошибка обобщения).

$$R(f) = \mathbb{E}_{(x,y)} \ell(f(x), y).$$

Ключевое отличие.

- Показатели ошибки обучения соответствуют наблюдаемым данным
- Показатель ошибки тестирования измеряет производительность на новых данных.

Модель хорошо обобщает данные, если ошибка обучения близка к ошибке тестирования.

Разрыв в обобщении.

$$R(f) - \hat{R}_n(f).$$

Вывод: одной лишь минимизации ошибок обучения недостаточно. Цель обучения — минимизировать ошибки тестирования, которые не поддаются непосредственному наблюдению.

Практический подход. Мы аппроксимируем результаты тестирования, используя проверочный набор данных, отдельный от обучающих данных.

5.2 Переобучение и недообучение

Взаимосвязь между ошибками обучения и тестирования приводит к двум основным режимам сбоев.

Недостаточная подгонка.

- Модель слишком проста, чтобы отразить структуру данных.
- Высокая ошибка обучения
- Высокая погрешность тестирования

Переобучение.

- Модель слишком точно соответствует обучающим данным, включая шум.
- Очень низкая ошибка обучения
- Высокая погрешность тестирования

Иллюстрация. Высокогибкая модель может интерполировать все обучающие точки, но при этом вести себя непредсказуемо между ними.

Компромисс. По мере усложнения модели:

- Ошибка обучения обычно уменьшается.
- Ошибка тестирования может сначала уменьшаться, а затем увеличиваться.

Классическая картина. Существует оптимальный уровень сложности, который уравнивает недообучение и переобучение.

Замечание (с современной точки зрения). В глубоком обучении модели часто работают далеко за пределами этого классического режима, достигая низкой ошибки обучения без обязательного ухудшения обобщающей способности. К этому явлению мы вернемся позже.

5.3 Модельная емкость и сложность

Для понимания переобучения необходимо количественно оценить выразительную способность модели.

Модельная емкость. Способность пространства гипотез H аппроксимировать широкий диапазон функций.

Примеры.

5.4. ПРИНЦИПЫ НЕФОРМАЛЬНОГО ОБОБЩЕНИЯ

29

- Линейные модели: низкая пропускная способность
- Полиномы высокой степени: высокая пропускная способность
- Глубокие нейронные сети: очень высокая пропускная способность

Качественные эффекты потенциала.

- Низкая пропускная способность высокое смещение, низкая дисперсия
- Высокая пропускная способность низкое смещение, высокая дисперсия

Меры сложности (неформальные).

- Количество параметров
- Глубина и ширина сетей
- Нормы параметров

Важное замечание. Производительность определяется не только количеством параметров. Структура модели и алгоритм обучения также играют решающую роль.

Пример. Две нейронные сети с одинаковым числом параметров могут вести себя совершенно по-разному в зависимости от:

- архитектура,
- инициализация,
- Динамика оптимизации.

Таким образом, потенциал следует рассматривать как сочетание представления, параметризации и процедуры обучения.

5.4 Принципы неформального обобщения

Хотя полная теория обобщения в современном машинном обучении все еще находится в стадии разработки, на практике широко соблюдаются несколько руководящих принципов.

1. Более простые модели, как правило, лучше обобщают данные.

Этот принцип часто называют бритвой Оккама: среди моделей, соответствующих данным, предпочтение отдается более простым.

Простота может принимать разные формы:

- меньше параметров,
- меньшие нормы,

- Более плавная работа функций.

2. Регуляризация улучшает обобщающую способность.

Регуляризация вводит дополнительные ограничения или штрафы, которые благоприятствуют более простым решениям.

Примеры включают:

- снижение веса,
- выбывать,
- преждевременная остановка.

3. Больше количество данных улучшает обобщаемость.

По мере увеличения размера выборки:

- Эмпирический риск лучше аппроксимирует истинный риск.
- Ошибка оценки уменьшается.

4. Индуктивная предвзятость имеет важное значение.

Обобщение зависит от допущений, заложенных в модель:

- гладкость,
- инвариантность,
- композиционная структура.

5. Оптимизация влияет на обобщающую способность.

Выбор алгоритма оптимизации может повлиять на то, какое решение будет найдено, даже если несколько решений обеспечивают низкую ошибку обучения.

Это явление известно как неявная регуляризация.

6. Шум может быть полезен.

Стохастичность в процессе обучения (например, в алгоритме стохастического градиентного спуска) может помочь избежать переобучения, предотвращая сходимость к чрезмерно сложным решениям.

Краткое изложение основных выводов. Обобщение определяется не одним фактором, а взаимодействием следующих факторов:

- модельная мощность,
- данные,
- индуктивное смещение,
- оптимизация.

5.5 Объединяющая перспектива

Теперь мы можем переосмыслить процесс обучения как проблему балансирования двух целей:

- подгонка обучающих данных,
- сохранение способности к обобщению.

Основное напряжение.

Подгонка данных под параметры обучения против избегания переобучения.

Практическая стратегия.

1. Выберите подходящий класс моделей.
2. Контроль пропускной способности посредством регулирования.
3. Используйте валидацию для выбора модели.
4. Мониторинг результатов обучения и тестирования.

Современная точка зрения. Системы глубокого обучения работают в режимах, где классические интуитивные представления верны лишь частично, однако основополагающие принципы индуктивной предвзятости и структуры остаются крайне важными.

5.6 Прогноз

В этой главе обобщение было представлено как центральная задача в обучении:

- различие результатов обучения и тестирования,
- понимание переобучения и недообучения,
- установление связи между возможностями модели и ее способностью к обобщению.

В следующей главе мы более подробно изучим методы регуляризации, сосредоточившись на том, как на практике контролировать сложность модели.

Основной принцип. Хорошая модель — это не та, которая идеально соответствует данным, а та, которая отражает лежащую в основе структуру таким образом, что это выходит за рамки наблюдаемых примеров.

Глава 6

Регуляризация и Структура

6.1 Регуляризация на основе норм

В предыдущих главах мы видели, что высокопроизводительные модели могут очень хорошо соответствовать обучающим данным, но при этом существует риск переобучения. Регуляризация предоставляет систематический способ контроля сложности модели и улучшения обобщающей способности.

Основная идея. Дополнить эмпирический риск штрафом за параметры:

$$\min_{\theta} \hat{R}(\theta) + \lambda \Omega(\theta),$$

где:

- $\Omega(\theta)$ измеряет сложность модели.
- $\lambda > 0$ определяет силу регуляризации.

Типичные варианты наказаний.

- Регуляризация ℓ_2 (снижение веса):

$$\Omega(\theta) = \|\theta\|_2^2.$$

- Регуляризация ℓ_1 :

$$\Omega(\theta) = \|\theta\|_1.$$

Интерпретация.

- Регуляризация ℓ_2 способствует получению малых распределенных параметров.
- Регуляризация ℓ_1 способствует разреженности

Геометрическая точка зрения. Регуляризация ограничивает область решения пространством параметров с контролируемой нормой.

Статистический подход. Штрафные санкции за несоответствие норм можно интерпретировать как наложение априорных распределений на параметры:

- ℓ_2 Гауссово априорное распределение

- ℓ_1 Априорное значение Лапласа

Практический эффект. Регуляризация уменьшает дисперсию и повышает стабильность, часто ценой небольшого увеличения смещения.

6.2 Ограничения и штрафные санкции

Регуляризацию можно сформулировать двумя эквивалентными способами:

- Форма наказания:

$$\min_{\theta} \hat{R}^n(\theta) + \lambda \Omega(\theta),$$

- Ограниченная форма:

$$\min_{\theta} \hat{R}^n(\theta) \text{ при условии } \Omega(\theta) \leq C.$$

Вывод. Эти формулировки тесно связаны: при правильном выборе λ и C они дают схожие решения.

Примеры.

- Гребневая регрессия: штраф ℓ_2

- Лассо: штраф ℓ_1

Интерпретация. Это ограничение сужает эффективное пространство поиска, предотвращая создание чрезмерно сложных решений.

Двойная перспектива. Штрафные санкции обеспечивают компромисс между соответствием данных и простотой модели, в то время как ограничения устанавливают строгий предел сложности.

С инженерной точки зрения. Формулировки с учетом штрафных санкций часто проще оптимизировать, в то время как формулировки с ограничениями обеспечивают более ясную геометрическую интуицию.

6.3 Неявная регуляризация

Не все методы регуляризации являются явными. Во многих современных системах обучения сам алгоритм оптимизации определяет предпочтение определенных решений.

Определение (неформальное). Неявная регуляризация относится к тенденции алгоритма отдавать предпочтение определенным решениям даже при отсутствии явных штрафов.

Пример (линейные модели). В перепараметризованной линейной регрессии градиентный спуск сходится к решению с минимальной нормой среди всех интерполирующих решений.

Пример (глубокое обучение).

- Методы стохастического градиентного спуска (SGD) обычно находят решения с определенной структурой.
- Различные оптимизаторы могут приводить к различному поведению при обобщении.

Источники неявной регуляризации.

- Инициализация
- Динамика оптимизации
- Стохастичность (например, мини-пакетирование)

Ключевой вывод. Даже если модель обладает достаточной мощностью, чтобы идеально соответствовать данным, процедура обучения определяет, какое решение будет найдено.

Вывод. Понимание обобщения требует анализа не только модели и функции потерь, но и процесса оптимизации.

6.4 Ранняя остановка и практические методы

Упорядочение также может быть достигнуто с помощью практических стратегий обучения.

Ранняя остановка. Вместо того чтобы полностью минимизировать потери при обучении, мы останавливаем обучение, когда производительность валидации начинает ухудшаться.

Интерпретация.

- Ранние итерации позволяют зафиксировать крупномасштабную структуру.
- В последующих итерациях может потребоваться подгонка шума.

Связь с регуляризацией. Ранняя остановка во многих случаях ведет себя аналогично регуляризации [2].

Другие практические методы.

- Dropout: случайным образом деактивирует юниты во время обучения.

- Расширение данных: увеличение объема набора данных посредством преобразований.
- Введение шума: добавление шума к входным сигналам или параметрам.

Интерпретация.

- Dropout способствует избыточности и устойчивости.
- Расширение данных кодирует инвариантность
- Шум сглаживает изученную функцию

С инженерной точки зрения. Эти методы часто просты в реализации, но при этом весьма эффективны, особенно в системах глубокого обучения.

6.5 Структура как регуляризация

Помимо явных штрафов и уловок при обучении, сама структура модели выступает в качестве мощной формы регуляризации.

Примеры.

- Сверточные слои обеспечивают локальность
- Остаточные связи стабилизируют глубокие сети
- Механизмы внимания улавливают реляционную структуру

Ключевая идея. Структура ограничивает класс функций, которые могут быть представлены, тем самым направляя обучение к осмысленным решениям.

Вывод: в современном машинном обучении проектирование архитектуры зачастую важнее, чем явная регуляризация.

6.6 Объединяющая перспектива

Регуляризацию можно понимать как управление эффективной сложностью изучаемой функции.

Формы регуляризации.

- Явные (штрафы, ограничения)
- Неявный (динамика оптимизации)
- Структурный (модель архитектуры)

Единая цель.

Соответствие данных и контрольной сложности.

Ключевые компоненты.

- Класс модели
- Механизм регуляризации
- Алгоритм оптимизации

Эти элементы взаимодействуют, определяя как эффективность тренировки, так и способность к обобщению.

6.7 Прогноз

В этой главе регуляризация была представлена как центральный инструмент для контроля сложности модели:

- штрафы, основанные на нормах,
- ограничения и штрафные санкции,
- неявные эффекты оптимизации,
- Практические методы, такие как ранняя остановка и прекращение участия.

В следующей части книги мы перейдем к конкретным моделям обучения с учителем, начиная с линейной регрессии и метода наименьших квадратов.

Основной принцип. Успешное обучение требует не только подгонки данных, но и формирования пространства решений таким образом, чтобы выявлялись значимые закономерности.

Глава 7

Линейная регрессия и

Метод наименьших квадратов

7.1 Линейные модели и проекции

Линейная регрессия — одна из самых простых и фундаментальных моделей в машинном обучении. Несмотря на свою простоту, она иллюстрирует множество ключевых идей, применимых и к более сложным моделям.

Модель. Мы рассматриваем функции вида

$$f(x) = w \cdot x + b,$$

где $w \in \mathbb{R}^d$ и $b \in \mathbb{R}$.

Дан набор данных $\{(x_i, y_i)\}_{i=1}^n$. Наша цель — найти параметры (w, b) , которые наилучшим образом соответствуют...

Матричная формулировка. Пусть

$$X = \begin{pmatrix} x_1 & & \\ x_2 & & \\ \vdots & & \\ x_n & & \end{pmatrix} \in \mathbb{R}^{n \times d}, \quad y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^n.$$

Для простоты мы включаем смещение в вектор параметров путем добавления упомянув x с постоянной составляющей. Тогда модель принимает следующий вид:

$$f(x) = w \cdot x,$$

а вектор прогноза — это

$$\hat{y} = Xw.$$

Геометрическая интерпретация. Столбцы матрицы X образуют подпространство $\mathbb{R}^n$. Линейная регрессия ищет в этом подпространстве вектор $\hat{y}$, наиболее близкий к y .

Таким образом, линейную регрессию можно рассматривать как задачу ортогональной проекции.

7.2 Метод наименьших квадратов как метод оптимизации

Естественным выбором функции потерь является квадратичная ошибка:

$$\ell(f(x_i), y_i) = (f(x_i) - y_i)^2.$$

Цель.

$$\min_w \sum_{i=1}^n (Xw - y_i)^2.$$

Это задача выпуклой квадратичной оптимизации.

Условие оптимальности. Приравнивание градиента к нулю приводит к нормальным уравнениям:

$$X^T X w = X^T y.$$

Решение (когда $X^T X$ обратимо).

$$w = (X^T X)^{-1} X^T y.$$

Проекционная интерпретация. Полученные значения $\hat{y} = Xw$ удовлетворяют условию

$$y - \hat{y} \perp \text{span}(X),$$

это означает, что остаток ортогонален столбцовому пространству матрицы X .

Вывод. Решение, полученное методом наименьших квадратов, является наилучшим приближением значения y в рамках класса моделей с точки зрения евклидова расстояния.

Перепараметризованный случай. Если $X^T X$ не обратимо (например, $d > n$), существует бесконечно много решений. В этом случае часто выбирают решение с минимальной нормой:

$$w = X (X^T X + \lambda I)^{-1} X^T y.$$

Это решение тесно связано с неявной регуляризацией, как обсуждалось в предыдущих главах.

7.3 Условные нагрузки и численная стабильность

Хотя аналитическое решение дает некоторое представление о ситуации, практические вычисления зависят от численных свойств матрицы $X^T X$.

Условные условия. Число обусловленности $X^T X$ измеряет чувствительность к возмущениям:

$$\kappa(X^T X) = \frac{\lambda_{\max}}{\lambda_{\min}},$$

где $\lambda_{\max}$ и $\lambda_{\min}$ — наибольшее и наименьшее собственные значения.

Неправильная обусловленность.

7.4. Регрессия гребня

41

- Происходит, когда $\lambda_{\min}$ очень мало
- Приводит к неустойчивым решениям
- Небольшие изменения в данных могут привести к значительным изменениям в w

Причины.

- Высоко коррелированные признаки
- Избыточные или почти избыточные входные данные

Практические последствия.

- Численная неустойчивость при инверсии
- Плохая обобщающая способность

Лекарственные средства.

- Масштабирование и нормализация признаков
- Удаление избыточных функций
- Регуляризация (обсуждается далее)

Примечание по алгоритму. На практике часто избегают прямой инверсии, отдавая предпочтение более стабильным методам, таким как QR-разложение или сингулярное разложение (SVD).

7.4 Гребневая регрессия

Гребневая регрессия вводит регуляризацию ℓ_2 в задачу наименьших квадратов.

Цель.

$$\min_w \|Xw - y\|_2^2 + \lambda \|w\|_2^2, \quad \lambda > 0.$$

Решение.

$$w = (X^T X + \lambda I)^{-1} X^T y.$$

Интерпретация.

- Повышает стабильность за счет смещения собственных значений $X^T X$
- Снижает чувствительность к шуму
- Контролирует величину параметров

Геометрический подход. Гребневая регрессия сжимает решение по направлению к началу координат, обеспечивая баланс между соответствием данных и нормой параметров.

Компромисс между смещением и дисперсией.

- Немного усиливает предвзятость
- Значительно снижает вариативность

Связь с обусловливанием. Матрица $X^T X + \lambda I$ всегда обратима при $\lambda > 0$, что повышает численную устойчивость.

Байесовская интерпретация. Гребневая регрессия соответствует предположению о гауссовском априорном распределении для w .

7.5 Объединяющая перспектива

Линейная регрессия иллюстрирует несколько центральных тем машинного обучения:

- Обучение как проекция на функциональное пространство
- Оптимизация как решение структурированных задач
- Регуляризация как способ контроля сложности и стабильности

Три точки зрения.

- Геометрический: проекция на подпространство
- Алгебраический метод: решение нормальных уравнений
- Статистический метод: оценка условного математического ожидания

Эти подходы естественным образом распространяются и на более сложные модели, включая нейронные сети.

7.6 Прогноз

В этой главе линейная регрессия была представлена как основополагающая модель:

- формулировка метода наименьших квадратов,
- геометрическая интерпретация,
- числовые соображения,
- Регуляризация с помощью гребневой регрессии.

В следующей главе мы распространим эти идеи на классификацию с помощью логистической регрессии, где центральную роль играет вероятностное моделирование.

Основной принцип. Простые модели часто выявляют глубинную структуру. Понимание этих моделей позволяет получить представление о более сложных системах обучения.

Глава 8

Логистическая регрессия и Классификация

8.1 Вероятностная интерпретация

В отличие от регрессии, где выходные данные являются вещественными, задачи классификации предполагают прогнозирование дискретных меток. Естественный подход заключается в моделировании вероятности каждого класса при заданных входных данных.

Бинарная классификация. Пусть $Y = \{0, 1\}$. Вместо прямого предсказания меток мы моделируем

$$P(y = 1 \mid x).$$

Логистическая модель. Мы предполагаем

$$P(y = 1 \mid x) = \sigma(\mathbf{w} \cdot \mathbf{x}),$$

где σ — сигмоидная функция

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Свойства сигмоиды.

- Отображает $\mathbb{R}$ в $(0, 1)$
- Плавный и монотонный
- Интерпретируется как вероятность

Интерпретация логарифма отношения шансов. Модель подразумевает

$$= \frac{P(y = 1 \mid x) \log}{\mathbf{w} \cdot \mathbf{x} \quad P(y = 0 \mid x)}$$

Таким образом, логистическая регрессия моделирует логарифм отношения шансов как линейную функцию входных данных.

Расширение для многоклассовой классификации. Для K классов мы используем функцию softmax:

$$P(y = k \mid x) = \frac{\exp(w_k \cdot x)}{\sum_{j=1}^K \exp(w_j \cdot x)}.$$

Данная формулировка гарантирует, что вероятности будут положительными и в сумме будут равны единице.

8.2 Кросс-энтропийные потери

Для обучения модели нам необходима функция потерь, отражающая вероятностную точность.

Бинарная кросс-энтропийная функция потерь.

$$\ell(f(x), y) = -y \log p(x) + (1 - y) \log(1 - p(x)),$$

где $p(x) = P(y = 1 \mid x)$.

Многоклассовая кросс-энтропия.

$$\ell(f(x), y) = -\log P(y \mid x).$$

Интерпретация.

- Жестко наказывает за уверенные, но неверные прогнозы.
- Способствует использованию калиброванных вероятностей

Геометрический анализ. Перекрестная энтропия измеряет расхождение между предсказанным распределением и истинным распределением меток.

Практическое преимущество. В отличие от квадратичной функции потерь, кросс-энтропия приводит к получению хорошо управляемых градиентов для задач классификации.

8.3 Перспектива максимального правдоподобия

Логистическая регрессия может быть выведена из принципа максимального правдоподобия.

Функция правдоподобия.

$$L(w) = \prod_{i=1}^N P(y_i \mid x_i; w).$$

Логарифмическая функция правдоподобия.

$$\ell(w) = \sum_{i=1}^N \log P(y_i \mid x_i; w).$$

8.4. ГРАНИЦЫ ПРИНЯТИЯ РЕШЕНИЙ

45

Максимизация логарифмической функции правдоподобия эквивалентна минимизации эмпирической кросс-энтропийной функции потерь:

$$\min_w \sum_{i=1}^N \log P(y_i | x_i; w).$$

Бинарная задача. Замена сигмоидной модели приводит к задаче выпуклой оптимизации.

Градиент. Для бинарной классификации,

$$w \ell(w) = \sum_{i=1}^N (\sigma(w \cdot x_i) - y_i) x_i.$$

Понимание.

- Градиент отражает ошибку прогнозирования, взвешенную по входным признакам.
- В процессе обучения параметры корректируются для уменьшения расхождений между прогнозируемыми вероятностями и метками.

Регуляризация. Как и в линейной регрессии, часто добавляют штраф ℓ_2 :

$$\min_w \sum_{i=1}^N \log P(y_i | x_i; w) + \lambda \|w\|_2^2.$$

Интерпретация. Это соответствует оценке максимальной апостериорной вероятности (MAP) при гауссовском априорном распределении.

8.4 Границы принятия решений

Хотя логистическая регрессия моделирует вероятности, в конечном итоге она принимает решения.

Правило бинарного принятия решений.

$$\hat{y} = \begin{cases} 1, & \text{если } P(y = 1 | x) \geq 0.5, \\ 0, & \text{в противном случае.} \end{cases}$$

Эквивалентное условие.

$$w \cdot x \geq 0.$$

Граница принятия решения. Множество точек, удовлетворяющих условию.

$$w \cdot x = 0$$

определяет гиперплоскость в $\mathbb{R}^D$.

Геометрическая интерпретация.

- Входное пространство разделено на два полупространства.
- Вектор нормали w определяет ориентацию

Многоклассовый случай. Границы принятия решений определяются путем сравнения линейных баллы:

$$w_k \cdot x = w_j \cdot x.$$

Ограничение. Логистическая регрессия создает линейные границы принятия решений. Она не может уловить нелинейную структуру без преобразования признаков.

Расширение. Нелинейные границы принятия решений можно получить следующим образом:

- сопоставление признаков,
- методы ядра,
- нейронные сети.

8.5 Объединяющая перспектива

Логистическая регрессия связывает несколько ключевых идей:

- Вероятностное моделирование: прогнозирование условных вероятностей
- Оптимизация: минимизация потерь перекрестной энтропии.
- Геометрия: линейные границы принятия решений

Сравнение с линейной регрессией.

- Линейная регрессия прогнозирует значения
- Логистическая регрессия предсказывает вероятности

Ключевая идея. Классификацию можно рассматривать как моделирование неопределенности в отношении дискретных результатов.

8.6 Прогноз

В этой главе была представлена логистическая регрессия как фундаментальная модель классификации:

- вероятностная интерпретация,
- кросс-энтропийные потери,
- оценка методом максимального правдоподобия,
- Геометрическая структура границ принятия решений.

В следующей главе мы расширим линейные модели, используя карты признаков и ядра, что позволяет им выявлять нелинейные зависимости.

Основной принцип. Эффективная классификация требует как выразительных моделей, так и соответствующих вероятностных формулировок.

Глава 9

Карты объектов и Нелинейные модели

9.1 Расширение базиса

Линейные модели просты и вычислительно эффективны, но их выразительность ограничена: они могут представлять только линейные зависимости в пространстве входных данных. Естественный способ преодоления этого ограничения — преобразование входных данных перед применением линейной модели.

Карта признаков. Карта признаков — это функция.

$$\phi: X \rightarrow \mathbb{R}^m,$$

который отображает исходные данные в новое пространство признаков.

Затем мы определяем модель следующего вида:

$$f(x) = w \cdot \phi(x).$$

Пример (полиномиальные характеристики). Для $x \in \mathbb{R}, x \in \mathbb{R}^d$.

$$\phi(x) = (1, x, x^2, \dots,$$

Пример (характеристики взаимодействия). Для $x \in \mathbb{R}^d$, включать такие термины, как $x_i x_j$, чтобы осуществляется захват взаимодействий.

Основная идея. Линейная модель в пространстве признаков соответствует нелинейной модели в исходном пространстве входных данных.

Интерпретация. Разложения по базисам позволяют аппроксимировать комплексные функции путем комбинирования более простых элементов.

Связь с теорией аппроксимации. Полиномы, базисы Фурье и другие системы функций могут аппроксимировать широкий спектр функций при линейном комбинировании.

9.2 Линейные модели в пространстве признаков

После определения карты признаков процесс обучения продолжается как и прежде:

$$\min_w \frac{1}{N} \sum_{i=1}^N \ell(w, \phi(x_i), y_i).$$

Матричная формулировка. Пусть $\Phi \in \mathbb{R}^{N \times M}$. Пусть это будет матрица признаков:

$$\Phi = \begin{pmatrix} \phi(x_1) \\ \phi(x_2) \\ \vdots \\ \phi(x_N) \end{pmatrix}.$$

Затем даются прогнозы, представленные следующим образом:

$$\hat{y} = \Phi w.$$

Проницаемость. Все методы линейной регрессии и классификации напрямую распространяются на пространство признаков путем замены X на Φ .

Выразительность против сложности.

- Увеличение размерности признаков m повышает выразительность.
- Но это также увеличивает риск переобучения и вычислительные затраты.

Геометрическая точка зрения. Данные встраиваются в многомерное пространство, где они могут стать линейно разделимыми.

Пример. Точки, которые не разделяются прямой в $\mathbb{R}^2$ могут стать разделимыми гиперплоскостью после отображения в $\mathbb{R}^3$.

9.3 Основная идея (интуиция)

Сложность возникает, когда пространство признаков имеет очень высокую размерность или даже бесконечную размерность.

Наблюдение. Многие алгоритмы зависят от скалярных произведений между векторами признаков:

$$\phi(x), \phi(x').$$

Ядерная функция. Ядро — это функция.

$$k(x, x') = \phi(x), \phi(x').$$

который вычисляет это скалярное произведение без явного вычисления $\phi(x)$.

Ключевая идея (ключевой приём). Мы можем работать неявно в многомерном пространстве признаков, используя $k(x, x')$ напрямую.

Примеры ядер.

- Полиномиальное ядро:

$$k(x, x') = (x \cdot x' + c)^D$$

- Гауссово (RBF) ядро:

$$k(x, x') = \exp \left(-\frac{\|x - x'\|^2}{2\sigma^2} \right)$$

Интерпретация.

- Ядра измеряют сходство между входными данными.
- Они определяют неявное пространство признаков

Практическое преимущество.

- Избегайте явных многомерных вычислений.
- Обеспечение возможности создания гибких нелинейных моделей

Ограничение.

- Вычислительная стоимость масштабируется в зависимости от количества точек данных.
- Менее масштабируем, чем современные подходы к глубокому обучению.

9.4 Выразительность за счет функций

Карты признаков определяют, какие функции может представлять модель.

Ключевой вопрос. Как выбор ϕ влияет на выразительную способность модели?

Вывод. Линейная модель в достаточно богатом пространстве признаков может аппроксимировать функции очень высокой сложности.

Компромисс.

- Богатый функционал → высокая выразительность
- Но повышен риск переобучения

Принципы проектирования функций.

- Кодирование знаний предметной области (например, инвариантности)
- Захват соответствующей структуры
- Обеспечить вычислительную разрешимость

От проектирования признаков до обучения представлению информации.

- Классические методы основаны на элементах, разработанных вручную.
- Глубокое обучение автоматически извлекает признаки из данных.

Композиционность. Сложные элементы можно создавать путем компоновки более простых преобразований:

$$\phi(x) = \phi_L(\phi_{L-1}(\dots \phi_1(x))).$$

Эта идея лежит в основе глубоких нейронных сетей.

Геометрическая перспектива. Карты объектов изменяют геометрию данных:

- кластеры становятся разделимыми,
- нелинейные структуры становятся линейными,
- Расстояния и сходства переопределены.

9.5 Объединяющая перспектива

Карты признаков обеспечивают связь между линейными моделями и нелинейным поведением.

Ключевые компоненты.

- Карта объектов ϕ
- Линейная модель в пространстве признаков
- Оптимизация параметров

Две парадигмы.

- Исправленные функции: разработаны вручную (например, ядра)
- Изученные признаки: оптимизированы совместно с моделью (глубокое обучение)

Ключевая идея. Нелинейность в машинном обучении часто возникает не из-за самой модели, а из-за способа представления данных.

9.6 Прогноз

В этой главе были представлены карты признаков как способ расширения линейных моделей:

- базисные разложения для нелинейного моделирования,
- линейное обучение в трансформированных пространствах,
- ядерные методы для неявных многомерных признаков,

- роль репрезентации в выразительности.

В следующей главе мы изучим машины опорных векторов, которые объединяют географические и Анализ метрик с использованием ядерных методов для создания мощных классификаторов.

Основной принцип. Выбор способа представления информации часто определяет успех. Это касается как системы обучения, так и выбора модели.

Глава 10

Метод опорных векторов

10.1 Максимизация прибыли

В предыдущих главах мы изучали линейные классификаторы и их расширения с помощью карт признаков. Методы опорных векторов (SVM) уточняют эти идеи, вводя геометрический принцип: максимизацию поля.

Задача бинарной классификации. Пусть $y_i \in \{-1, +1\}$, и рассмотрим линейный классификатор.

$$f(x) = w \cdot x + b.$$

Точка классифицируется правильно, если

$$y_i(w \cdot x_i + b) > 0.$$

Поле. Функциональное поле точки данных определяется как

$$y_i(w \cdot x_i + b).$$

Геометрическая граница. Расстояние от точки до границы принятия решения — это

$$\frac{y_i(w \cdot x_i + b)}{w}.$$

Цель. Найти классификатор, который максимизирует минимальный отступ по всем обучающим точкам.

Задача оптимизации.

$$\max_{w, b} \min_i \frac{y_i(w \cdot x_i + b)}{w}.$$

Эквивалентная формула. Зафиксировав масштаб, получаем

$$\min_{w, b} \frac{1}{2} \|w\|^2 \quad \text{при условии } y_i(w \cdot x_i + b) \geq 1 \quad i.$$

Интерпретация.

- Максимизация запаса — минимизация $\|w\|$
- Способствует четкому разделению классов

Опорные векторы. На решение влияют только точки, расположенные ближе всего к границе принятия решения (т.е. точки, в которых выполняется равенство в ограничении).

Анализ. Метод опорных векторов (SVM) фокусируется на наиболее информативных моментах, а не на всех обучающих данных.

10.2 Жесткие и мягкие границы

Приведенная выше формулировка предполагает, что данные линейно разделимы. На практике это редко бывает так.

Метод опорных векторов с жесткими

границами. • Предполагает идеальную разделимость.

- Обеспечивает соблюдение ограничений:

$$y_i(w \cdot x_i + b) \geq 1$$

Ограничение. Чувствителен к шуму и выбросам; может не иметь приемлемого решения.

Метод опорных векторов с мягким отступом. Введение дополнительных переменных $\xi_i \geq 0$:

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i.$$

Цель.

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i,$$

где $C > 0$ регулирует компромисс между размером поля и ошибкой классификации.

Интерпретация.

- ξ_i измеряет нарушение ограничения по пределу прочности
- Чем больше значение C , тем сильнее штрафуются ошибки.
- Меньший размер C обеспечивает большую гибкость

Связь с функциями потерь. Формулировка с мягким пределом соответствует минимизации потерь в шарнире:

$$\ell(x_i, y_i) = \max(0, 1 - y_i f(x_i)).$$

Анализ. Методы опорных векторов (SVM) сочетают максимизацию запаса прочности с устойчивостью к неразделимым данным.

10.3 Двойная формула (концептуальная)

Задача оптимизации SVM допускает альтернативное представление, известное как двойственная формулировка.

Основная идея. Вместо оптимизации по w , мы вводим переменные α_i , связанные с каждой точкой данных.

Двойственная проблема (неформально).

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j \in \text{ДЖ}} \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle,$$

с учетом ограничений на α_i .

Важные замечания.

- Решение зависит только от скалярных произведений $\langle x_i, x_j \rangle$
- Только опорные векторы имеют ненулевое значение α_i

Реконструкция w .

$$w = \sum_{i=1}^n \alpha_i y_i x_i.$$

Анализ. Классификатор представлен в виде взвешенной комбинации обучающих точек.

Практическое значение.

- Позволяет использовать методы ядра
- Выявляет разреженность в решении

10.4. Методы ядра: повторное рассмотрение

Двойственная формулировка позволяет нам расширить применение SVM для нелинейной классификации.

Подстановка ядра. Замените скалярные произведения функцией ядра:

$$\langle x_i, x_j \rangle \rightarrow k(x_i, x_j).$$

Полученный классификатор.

$$f(x) = \sum_{i=1}^n \alpha_i y_i k(x_i, x) + b.$$

Интерпретация.

- Неявно отображает данные в пространство признаков

- Создает нелинейные границы принятия решений в исходном пространстве.

Примеры.

- Полиномиальное ядро
- Гауссово (RBF) ядро

Геометрическое представление. Данные преобразуются в пространство, где они становятся линейно разделимыми, и там находится разделитель с максимальным отступом.

Преимущества.

- Гибкое нелинейное моделирование
- Надежные теоретические гарантии

Ограничения.

- Вычислительные затраты растут с увеличением размера набора данных.
- Менее масштабируем, чем современные подходы к глубокому обучению.

10.5 Объединяющая перспектива

Метод опорных векторов объединяет несколько ключевых идей:

- Геометрия: максимизация запаса прочности
- Оптимизация: выпуклое квадратичное программирование
- Представление: карты признаков и ядра

Ключевые выводы.

- Хорошие классификаторы обеспечивают максимальное разделение между классами.
- Решение определяется лишь подмножеством точек данных.
- Нелинейность может быть введена с помощью ядер

Метод опорных векторов (SVM) демонстрирует, как сочетание геометрии и оптимизации приводит к созданию мощных алгоритмов машинного обучения.

10.6 Прогноз

В этой главе были представлены машины опорных векторов как принципиальный подход к классификации:

- обучение на основе полей
- Мягкие ограничения для реальных данных,
- двойная формула и разреженность,
- Ядерные методы для нелинейных моделей.

В следующей главе мы вернемся к оценке и выбору моделей, сосредоточившись на следующем: о том, как сравнивать модели и выбирать гиперпараметры на практике.

Основной принцип. Эффективное обучение сочетает в себе выразительность и надежность, зачастую за счет геометрических принципов и принципов оптимизации.

Глава 11

Оценка модели и Выбор

11.1 Обучение, проверка и тестирование

В предыдущих главах мы разработали модели и методы оптимизации для обучения на основе данных. Однако остается важный практический вопрос: как надежно оценивать и сравнивать модели?

Главная проблема заключается в том, что истинный риск

$$R(f) = E(x, y) \quad P [\ell(f(x), y)] \text{ неизвестно,}$$

поскольку распределение P , генерирующее данные, недоступно.

Разделение данных. Для приблизительной оценки обобщающей способности мы делим имеющийся набор данных на три части:

- Тренировочный набор: используется для подгонки параметров модели.
- Набор данных для валидации: используется для настройки гиперпараметров.
- Тестовый набор: используется для оценки конечной производительности

Рабочий процесс.

1. Обучите модель на обучающем наборе данных.
2. Выберите гиперпараметры, используя набор данных для проверки.
3. Оцените итоговую модель на тестовом наборе данных.

Ключевой принцип. Тестовый набор данных не следует использовать при выборе модели, поскольку это приведет к чрезмерно оптимистичным оценкам.

Переобучение на данных валидации. Многократная настройка может косвенно привести к переобучению на наборе данных валидации. Это мотивирует разработку более надежных стратегий оценки, таких как перекрестная валидация.

11.2 Перекрестная проверка

Перекрестная проверка предоставляет систематический способ оценки производительности модели с использованием ограниченных данных.

k-кратная перекрестная проверка.

- Разделить набор данных на k подмножеств (фолдов).
- Для каждой складки:
 - Обучение на k - 1 складках
 - Оцените оставшуюся часть текста.
- Усреднить результаты по всем группам итераций

Оценка, полученная методом перекрестной проверки.

$$R^{CV} = \frac{1}{k} \sum_{j=1}^K R_j \text{ Дж.}$$

где R_j — ошибка валидации в j-й фолде.

Преимущества.

- Эффективное использование данных
- Более стабильные оценки производительности

Выбор k.

- Малое значение k (например, 5): быстрее, большее смещение
- Большое значение k (например, метод «исключения одного элемента»): меньшее смещение, большая дисперсия и стоимость.

Практическое применение. Перекрестная проверка широко используется для настройки гиперпараметров, особенно когда наборы данных имеют небольшой или средний размер.

11.3 Показатели эффективности

Выбор метрики оценки зависит от задачи обучения.

11.3. Показатели эффективности

63

11.3.1 Метрики регрессии

- Среднеквадратичная ошибка (MSE):

$$\frac{1}{N} \sum_{i=1}^N (f(x_i) - y_i)^2$$

- Средняя абсолютная ошибка (MAE):

$$\frac{1}{N} \sum_{i=1}^N |f(x_i) - y_i|$$

Интерпретация.

- MSE более строго наказывает за большие ошибки
- MAE более устойчив к выбросам

11.3.2 Метрики классификации

Точность.

$$\frac{\text{количество правильных прогнозов}}{\text{общее количество прогнозов}}$$

Точность и полнота.

- Точность: доля правильных прогнозируемых положительных результатов.
- Напоминание: доля фактически обнаруженных положительных результатов.

Показатель F1.

$$F1 = 2 \cdot \frac{\text{точность} \cdot \text{полнота}}{\text{точность} + \text{полнота}}$$

ROC и AUC.

- ROC-кривая отображает соотношение истинно положительных результатов и ложноположительных результатов.
- Показатель AUC суммирует общую эффективность классификации.

Несбалансированные данные. Точность может вводить в заблуждение, когда классы несбалансированы; более информативными показателями оценки являются точность, полнота и AUC.

Вероятностные метрики. Для моделей, выдающих вероятности, в качестве метрики оценки часто используется кросс-энтропийная функция потерь.

11.4 Сравнение моделей

Выбор модели предполагает сравнение нескольких кандидатов на основе результатов валидации.

Гиперпараметры.

- Сила регуляризации
- Архитектура модели
- Параметры оптимизации

Процедура отбора.

1. Определите набор моделей-кандидатов.
2. Оцените каждую модель с помощью валидации или перекрестной валидации.
3. Выберите модель с наилучшими характеристиками.

Выбор модели против оценки.

- Выбор модели осуществляется с использованием данных валидации.
- Для окончательной оценки используются тестовые данные.

Переобучение при выборе модели. Тестирование множества моделей увеличивает риск случайного выбора той, которая показывает хорошие результаты.

Практические стратегии.

- Используйте перекрестную проверку
- Ограничить пространство поиска гиперпараметров
- При схожей производительности следует отдавать предпочтение более простым моделям.

Компромиссы.

- Точность против сложности
- Производительность против вычислительных затрат

Воспроизводимость. Для надежного сравнения моделей необходимы согласованные разделения данных и контролируемые экспериментальные условия.

11.5 Объединяющая перспектива

Оценка и выбор моделей являются неотъемлемой частью процесса обучения.

Конвейер.

- Обучение моделей на данных
- Оценка эффективности обобщения
- Выберите лучшую модель
- Оценить итоговые результаты

Основные проблемы.

- Ограниченные данные
- Разброс оценок
- Риск переобучения в процессе отбора

Ключевая идея. Для надежной оценки необходимо разделить роли обучения, проверки и тестирования.

11.6 Прогноз

В этой главе были представлены принципы оценки и выбора моделей:

- Разделение данных для беспристрастной оценки,
- Использование перекрестной проверки для получения надежных оценок.
- выбор соответствующих показателей эффективности,
- систематическое сравнение моделей.

В следующей главе мы более подробно изучим методы оптимизации, уделяя особое внимание...
опираясь на практические методы, используемые в крупномасштабном машинном обучении.

Основной принцип. Качество модели напрямую зависит от способа её оценки. Надежная оценка необходима для осмысленного обучения.

Глава 12

Оптимизация на практике

12.1 Стохастический градиентный спуск

В главе 4 мы представили оптимизацию на основе градиента как основной метод обучения моделей машинного обучения. Однако на практике вычисление полных градиентов на больших наборах данных часто оказывается вычислительно нецелесообразным.

Стохастический градиентный спуск (SGD). Вместо вычисления полного градиента,

$$L(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f\theta(x_i), y_i),$$

Мы аппроксимируем это, используя одну случайно выбранную точку данных:

$$\theta_{t+1} = \theta_t - \eta \ell'(f\theta(x_{it}), y_{it}).$$

Интерпретация.

- Каждое обновление представляет собой зашумленную оценку истинного градиента.
- Шум возникает из-за дискретизации.

Основные характеристики.

- Низкая вычислительная стоимость за итерацию
- Позволяет проводить обучение на больших наборах данных
- Вводит элемент стохастичности в оптимизацию

Конвергентное поведение (неформальное).

- Метод стохастического градиентного спуска не сходится точно к минимуму.
- Вместо этого, он колеблется вокруг областей с низкими потерями.

Вывод: стохастичность SGD может помочь избежать резких минимумов и более эффективно исследовать ландшафт потерь.

12.2 Мини-пакетирование и эффективность

На практике метод стохастического градиентного спуска (SGD) редко реализуется с использованием отдельных точек данных. Вместо этого мы используем мини-пакеты.

Мини-партия SGD.

$$\theta_{t+1} = \theta_t - \eta \frac{1}{|B_t|} \sum_{i \in B_t} \nabla \ell(f\theta(x_i), y_i),$$

где B_t — это подмножество (пакет) точек данных.

Преимущества.

- Уменьшает дисперсию оценок градиента
- Использует возможности параллельных вычислений (например, графические процессоры)
- Более стабильные обновления, чем при использовании чистого SGD

Компромисс между размером партии.

- Небольшая партия:
 - Шумные обновления
 - В некоторых случаях – лучшее обобщение.
- Большая партия:
 - Более точные градиенты
 - Более высокие вычислительные затраты на шаг

Соображения эффективности.

- Ограничения памяти ограничивают размер пакета.
- Для обработки больших партий данных полезно аппаратное ускорение.

Эпохи и итерации.

- Одна эпоха: один проход по набору данных
- Итерация: обновление одного параметра

12.3 Методы импульса и адаптивные методы

Базовый метод стохастического градиентного спуска (SGD) может быть медленным или нестабильным, особенно в задачах с высокой размерностью.

Ряд усовершенствований повышает его производительность.

12.3. ИМПУЛЬСНЫЕ И АДАПТИВНЫЕ МЕТОДЫ

69

12.3.1 Импульс

Обновить правило.

$$v_{t+1} = \beta v_t + \sqrt{1 - \beta} \nabla L(\theta_t), \theta_{t+1} = \theta_t - \eta v_{t+1}.$$

Интерпретация.

- Накапливает предыдущие градиенты
- Обеспечивает плавное обновление и ускоряет сходимость.

Геометрическая интуиция. Импульс помогает быстро преодолевать плоские участки и уменьшает колебания в направлениях с высокой кривизной.

12.3.2 Адаптивные методы

Адаптивные методы корректируют скорость обучения в зависимости от индивидуальных параметров.

Примеры.

- AdaGrad
- RMSProp
- Адам

Главная идея.

- Обновление масштаба на основе прошлых значений градиента
- Используйте более крупные шаги для редко встречающихся функций.
- Используйте меньшие шаги для часто обновляемых параметров.

Адам (концептуальная форма).

- Поддерживает скользящие средние градиентов и квадратов градиентов.
- Сочетает в себе импульс и адаптивное масштабирование

Практическое наблюдение.

- Адаптивные методы часто сходятся быстрее.
- Метод стохастического градиентного спуска с учетом момента импульса может лучше обобщаться в некоторых условиях.

12.4 Практическое поведение конвергенции

В реальных условиях оптимизация редко соответствует идеализированному теоретическому поведению.

Планирование темпа обучения.

- Снижение темпа обучения с течением времени
- Распространенные стратегии:
 - ступенчатое
 - затухание, – экспоненциальное
 - затухание, – косинусное отжиг

Разогревать.

- Начинайте с небольших темпов обучения
- Постепенно увеличивать нагрузку для стабилизации начальных этапов тренировки.

Плато и крутые обрывы.

- Потеря веса во время тренировок может постепенно уменьшаться, а затем внезапно увеличиться.
- Отражает изменения в сфере потерь

Шум и обобщение.

- Шум от SGD может выступать в качестве неявной регуляризации.
- Помогает избежать резких минимумов

Критерии остановки.

- Фиксированное количество эпох
- Сближение потерь в процессе обучения
- Ранняя остановка на основе валидации

Практические проблемы.

- Выбор темпа обучения
- Настройка гиперпараметров
- Баланс между скоростью и устойчивостью

Проницательность. Оптимизация на практике — это в равной степени искусство и наука, руководствующиеся как теоретическими принципами, так и эмпирическим опытом.

12.5 Объединяющая перспектива

В современном машинном обучении оптимизация включает в себя множество взаимодействующих компонентов:

- Алгоритм: SGD и его варианты
- Гиперпараметры: скорость обучения, размер пакета
- Динамика: шум, кривизна, структура ландшафта

Основные компромиссы.

- Скорость против устойчивости
- Точность против вычислительных затрат
- Оптимизация против обобщения

Ключевая мысль. Поведение алгоритмов оптимизации определяет не только скорость обучения моделей, но и то, какие решения они находят.

12.6 Прогноз

В этой главе оптимизация рассматривалась с практической точки зрения:

- методы стохастического градиента,
- Мини-пакетирование и эффективность,
- алгоритмы импульса и адаптивные алгоритмы,
- Поведение, демонстрирующее сходимость в реальных условиях.

В следующей главе мы изучим численную и статистическую устойчивость, сосредоточив внимание на том, как предварительная обработка и обусловливание данных влияют на обучение.

Основной принцип. Эффективная оптимизация требует понимания как алгоритма, так и структуры задачи, к которой он применяется.

Глава 13

Численные и статистические методы

Стабильность

13.1 Неправильная обусловленность

В предыдущих главах мы изучали методы оптимизации и их практическое применение. Однако эффективность этих методов критически зависит от численных характеристик задачи.

Определение (неформальное). Задача считается плохо обусловленной, если небольшие изменения входных данных приводят к большим изменениям в выходных данных.

Пример (линейная регрессия). Решение.

$$\mathbf{b} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

чувствителен к возмущениям, когда $\mathbf{X}^T \mathbf{X}$ является почти сингулярным.

Число обусловленности. Для положительно определённой матрицы A число обусловленности равно

$$\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}.$$

Интерпретация.

- Большое значение $\kappa(A)$ — плохо обусловленная задача
- Малое $\kappa(A)$ — хорошо обусловленная задача

Геометрическая интуиция. Плохая обусловленность соответствует вытянутым множествам уровня функции потерь, что затрудняет оптимизацию.

Последствия.

- Медленная сходимость градиентных методов

- Численная неустойчивость при обращении матрицы
- Чувствительность к шуму

Источники неправильной обусловленности.

- Высоко коррелированные признаки
- Избыточные входы
- Неправильное масштабирование переменных

13.2 Масштабирование и нормализация

Простой, но эффективный способ улучшить обусловливание — это предварительная обработка данных.

Масштабирование признаков. Преобразуйте каждый признак так, чтобы его величина была сопоставима.

Стандартизация.

$$x_j = \frac{x_j - \mu_j}{\sigma_j},$$

где μ_j и σ_j — среднее значение и стандартное отклонение признака j .

Нормализация. Масштабирование входных данных для получения ограниченных норм, например,

$$x = \frac{x - \min}{\max - \min}.$$

Влияние на оптимизацию.

- Обеспечивает более сбалансированный градиент по измерениям.
- Повышает скорость сходимости
- Снижает численную нестабильность

Связь с обусловливанием. Правильное масштабирование уменьшает число обусловленных состояний проблемы.

Нормализация в глубоком обучении.

- Пакетная нормализация
- Нормализация слоев

Вывод: нормализацию можно рассматривать как динамическую корректировку геометрии задачи оптимизации.

13.3 Чувствительность к шуму

Данные из реального мира часто содержат шумы. Стабильный алгоритм обучения не должен быть чрезмерно чувствительным к малым возмущениям.

Источники шума.

- Ошибки измерений
- Неполные наблюдения
- Внутренняя случайность

Влияние на обучение.

- Может привести к переобучению
- Может дестабилизировать оценки параметров

Пример (метод наименьших квадратов). В плохо обусловленных задачах небольшой шум в u может вызывать большие изменения в w .

Перспектива смещения-дисперсии.

- Модели с высокой дисперсией более чувствительны к шуму
- Регуляризация снижает чувствительность

Стабильность как устойчивость. Стабильный алгоритм выдает схожие результаты при незначительных возмущениях входных данных.

Алгоритмическая устойчивость (неформальное определение). Если удаление или изменение одной точки данных не приводит к существенным изменениям в обученной модели, алгоритм считается устойчивым.

Вывод. Стабильность тесно связана с обобщающей способностью: стабильные алгоритмы, как правило, лучше обобщают данные.

13.4 Вопросы надежности

Помимо численной устойчивости, нас часто интересует устойчивость к более широким формам возмущений.

Виды устойчивости.

- Устойчивость к шуму в данных
- Устойчивость к изменениям распределения
- Устойчивость к враждебным возмущениям

Надежные функции потерь.

- Среднеквадратичная ошибка: чувствительна к выбросам
- Абсолютная погрешность: более надежный метод

Регуляризация и устойчивость. Ограничение сложности модели часто повышает ее устойчивость.

Расширение данных. Введение вариаций в обучающие данные может повысить устойчивость к преобразованиям.

Неформальная точка зрения, основанная на противостоянии. Небольшие, тщательно подобранные возмущения могут существенно повлиять на прогнозы модели, особенно в многомерных условиях.

Проницательность. Для обеспечения надежности необходимы как стабильные модели, так и соответствующие предположения относительно данных.

13.5 Объединяющая перспектива

Численная и статистическая устойчивость тесно взаимосвязаны:

- Численная устойчивость: чувствительность к ошибкам вычислений
- Статистическая стабильность: чувствительность к изменениям данных.

Ключевые факторы.

- Постановка проблемы
- Предварительная обработка данных
- Сложность модели
- Регуляризация

Ключевая идея. Стабильные обучающиеся системы — это те, которые ведут себя предсказуемо при небольших возмущениях, как численных, так и статистических.

13.6 Прогноз

В этой главе устойчивость рассматривалась как с численной, так и со статистической точки зрения:

- Плохая физическая подготовка и её последствия,
- роль масштабирования и нормализации,

- чувствительность к шуму,
- соображения надежности.

В следующей главе мы перейдем от классических моделей к нейронным сетям.

Обоснование необходимости глубокого обучения как естественного продолжения этих идей.

Основной принцип. Стабильность необходима для надежного обучения: модели должны не только соответствовать данным, но и делать это таким образом, чтобы это было устойчиво к возмущениям и неопределенности.

Глава 14

От классических моделей к Нейронные сети

14.1 Ограничения моделей с неглубокой структурой

В предыдущих главах мы изучили ряд классических моделей, включая линейную регрессию, логистическую регрессию и ядерные методы. Эти модели являются мощными и хорошо изученными, однако они имеют фундаментальные ограничения.

Поверхностные модели. Мы имеем в виду модели вида

$$f(x) = w, \phi(x),$$

где ϕ либо фиксировано, либо включает только один слой преобразования.

Ключевое ограничение: представление. Успех этих моделей критически зависит от выбора признаков $\phi(x)$.

Проблемы.

- Разработка эффективных функций требует экспертных знаний в данной области.
- Карты с фиксированными характеристиками могут не отображать сложную структуру.
- Многомерные пространства признаков могут быть вычислительно затратными

Ограничения выразительности.

- Линейные модели создают линейные границы принятия решений.
- Ядерные методы обеспечивают гибкость, но плохо масштабируются с увеличением размера данных.

Проклятие размерности. Явное расширение признаков часто требует экспоненциального количества признаков для выявления сложных закономерностей.

Проницательность. Классические модели разделяют представление и обучение: сначала разрабатываются признаки, а затем подгоняется модель. Такое разделение может ограничивать их эффективность.

14.2 Композиционная структура функций

Многие функции, встречающиеся в реальном мире, обладают композиционной структурой.

Определение (неформальное). Функция является композиционной, если её можно представить в виде композиции более простых функций:

$$f(x) = f_L(f_{L-1}(\dots f_1(x))).$$

Примеры.

- Изображения: края, формы, объекты
- Язык: символы, слова, предложения

Иерархическая структура. Каждый слой отражает закономерности на разном уровне абстракции.

Эффективность композиции. Композиционные представления позволяют описывать сложные функции, используя относительно небольшое количество параметров.

В отличие от неглубоких моделей. Неглубокая модель может потребовать экспоненциально большего количества элементов для представления функции, которую можно компактно выразить с помощью нескольких слоев.

Проницательность. Глубина позволяет повторно использовать промежуточные вычисления, что приводит к более эффективным представлениям.

14.3 Мотивация для глубокого обучения

Глубокое обучение основано на идее изучения как представлений, так и функций посредством композиции.

Нейронные сети. Нейронная сеть с L слоями имеет вид

$$f(x) = f_L(f_{L-1}(\dots f_1(x))),$$

где каждый слой, как правило, представляет собой аффинное преобразование, за которым следует нелинейное преобразование.

Основные преимущества.

- Автоматическое обучение признакам: признаки изучаются на основе данных, а не создаются вручную.
- Выразительность: Глубокие нейронные сети способны представлять очень сложные функции.
- Масштабируемость: Эффективное обучение с использованием больших наборов данных и современного оборудования.

Универсальная аппроксимация (неформально). Нейронные сети могут аппроксимировать широкий класс функций при наличии достаточной пропускной способности.

Практический успех. Глубокое обучение показало высокие результаты в следующих областях:

- компьютерное зрение,
- обработка естественного языка,
- распознавание речи,
- генеративное моделирование.

Ключевое изменение. Вместо проектирования функций мы проектируем архитектуры, способные автоматически изучать эти функции.

14.4 Переход к усвоенным представлениям

Переход от классических моделей к глубокому обучению предполагает изменение способа построения представлений.

Классический подход.

- Карта признаков ϕ фиксирована
- Модель изучает параметры w

Подход на основе глубокого обучения.

- Карта признаков ϕ_θ параметризована
- Представление и модель изучаются совместно.

Структура модели.

$$f(x) = g_\theta(\phi_\theta(x)),$$

где ϕ_θ и g_θ зависят от параметров.

Иерархические представления.

- Ранние слои: локальные или низкоуровневые признаки
- Промежуточные слои: узоры и структуры
- Финальные слои: представления, специфичные для конкретной задачи

Геометрический подход. Глубокие нейронные сети преобразуют данные посредством последовательных нелинейных отображений, изменяя их геометрию для облегчения обучения.

Перспектива оптимизации. Обучение включает в себя одновременную оптимизацию сильно невыпуклой целевой функции на всех уровнях.

Регуляризация посредством структуры. Архитектурные решения накладывают индуктивные предубеждения, которые направляют обучение:

- Сверточные слои кодируют локальность,

82 ГЛАВА 14. ОТ КЛАССИЧЕСКИХ МОДЕЛЕЙ К НЕЙРОННЫМ СЕТЯМ

- Механизмы внимания кодируют взаимосвязи,
- Остаточные связи стабилизируют обучение.

Insight. Глубокое обучение объединяет представление, моделирование и оптимизацию в единую структуру.

14.5 Объединяющая перспектива

Теперь мы можем переосмыслить эволюцию моделей:

- Классические модели: фиксированные представления + простые модели
- Методы ядра: неявные многомерные представления
- Глубокое обучение: обучение иерархическим представлениям

Основная идея. Сила современного машинного обучения заключается в обучении представлениям, которые упрощают решение задачи.

Ключевые компоненты.

- Представление (характеристики)
- Функция (отображение)
- Оптимизация (обучение)

Глубокое обучение объединяет эти компоненты единым и масштабируемым способом.

14.6 Прогноз

В этой главе были изложены мотивы перехода от классических моделей к нейронным сетям:

- ограничения неглубоких моделей,
- важность композиционной структуры,
- преимущества глубоких архитектур,
- переход к усвоенным представлениям.

В следующей главе мы начнем наше изучение глубокого обучения с рассмотрения нейронных сетей. сети как аппроксиматоры композиционных функций.

Основной принцип. Сложные проблемы часто требуют структурированных представлений, а глубина представляет собой естественный способ их построения.

Глава 15

Нейронные сети как Композиционные модели

15.1 Многоуровневые архитектуры

Нейронные сети представляют собой композиции простых преобразований, организованных в слои. Эта многослойная архитектура является определяющей особенностью, позволяющей им моделировать сложные взаимосвязи.

Базовая структура. Нейронная сеть с L слоями определяет функцию.

$$f(x) = f_L \circ f_{L-1} \circ \dots \circ f_1(x),$$

где каждый слой имеет форму

$$f_\ell(z) = \sigma(W_\ell z + b_\ell).$$

Компоненты.

- W_ℓ : весовая матрица
- b_ℓ : вектор смещения
- σ : нелинейная функция активации

Прямое распространение. Получив входной сигнал x , сеть вычисляет промежуточные представления:

$$z^{(1)} = f_1(x), z^{(2)} = f_2(z^{(1)}), \dots, z^{(L)} = f_L(x).$$

Интерпретация.

- Каждый слой преобразует представление данных.

84 ГЛАВА 15. НЕЙРОННЫЕ СЕТИ КАК КОМПОЗИЦИОННЫЕ МОДЕЛИ

- Конечный результат зависит от последовательных уточнений.

Общие функции активации.

- Функция активации ReLU: $\sigma(z) = \max(0, z)$
- Сигмоидная функция: $\sigma(z) = \frac{1}{1 + e^{-z}}$
- Tanh: $\sigma(z) = \tanh(z)$

Роль нелинейности. Без нелинейных функций активации композиция линейных слоев сводится к одному линейному преобразованию.

Проницательность. Нелинейность позволяет нейронным сетям представлять сложные нелинейные зависимости.

15.2 Выразительность и глубина

Ключевой вопрос заключается в том, как архитектура нейронной сети влияет на ее выразительные возможности.

Ширина против глубины.

- Ширина: количество элементов на слой
- Глубина: количество слоев

Поверхностные и глубокие нейронные сети.

- Неглубокие сети: мало слоев, возможно, очень широкие.
- Глубокие нейронные сети: много слоев, часто более узкие.

Ключевое наблюдение. Глубина позволяет более эффективно представлять функции.

Пример (композиционные функции). Функции с иерархической структурой могут быть компактно представлены глубокими сетями, но в неглубоких сетях могут потребовать экспоненциально большего количества параметров.

Геометрическая интуиция. Каждый слой изменяет входное пространство, постепенно преобразуя сложные структуры в более простые.

Кусочно-линейная зависимость. Сети с активацией ReLU представляют собой кусочно-линейные функции с потенциально большим количеством областей.

Проницательность. Глубина экспоненциально увеличивает количество линейных областей, повышая выразительность.

Компромисс.

- Большая глубина — более высокая выразительность
- Но также и более сложная задача оптимизации.

15.3 Универсальное приближение (проницательность)

Фундаментальный теоретический результат объясняет, почему нейронные сети являются мощными аппроксиматорами.

Универсальная аппроксимация (неформально). Прямая нейронная сеть с одним скрытым слоем и подходящей функцией активации может аппроксимировать любую непрерывную функцию на компактной области при достаточной ширине.

Интерпретация.

- Нейронные сети обладают высокой выразительностью.
- Даже неглубокие сети могут аппроксимировать сложные функции

Ограничение.

- В теореме не указано, сколько единиц требуется.
- Практическое обучение может быть затруднительным.

Роль глубины. Хотя теоретически достаточны неглубокие сети, глубокие сети часто обеспечивают более эффективное представление данных.

Прозрение. Универсальное приближение гарантирует существование, но не эффективность или обучаемость.

Связь с практикой. Глубокие архитектуры предпочтительнее, потому что они:

- требуют меньшего количества параметров,
- Во многих случаях их проще тренировать.
- соответствовать композиционной структуре данных.

15.4 Обучение представлению

Одной из определяющих особенностей нейронных сетей является их способность автоматически обучаться представлениям.

Обученные признаки. Каждый слой создает представление.

$$z^{(\ell)} = f_{\ell}(z^{(\ell-1)}),$$

который кодирует информацию о входных данных.

Иерархия представлений.

- Ранние слои: локальные или низкоуровневые признаки
- Промежуточные слои: узоры и структуры

86 ГЛАВА 15. НЕЙРОННЫЕ СЕТИ КАК КОМПОЗИЦИОННЫЕ МОДЕЛИ

- Финальные слои: функции, специфичные для конкретной задачи

Сравните с классическими методами.

- Классические модели используют фиксированные карты признаков
- Нейронные сети обучаются распознавать признаки на основе данных

Геометрический подход. Каждый слой преобразует геометрию данных, постепенно упрощая их разделение или моделирование.

Композиционное обучение. Характеристики формируются путем объединения более простых характеристик из разных слоев.

Интерпретация. Обучение включает в себя открытие как:

- как представить данные,
- Как сопоставить представления с выходными данными.

Вывод: обучение представлениям является ключевой причиной успеха глубокого обучения в самых разных областях.

15.5 Объединяющая перспектива

Нейронные сети можно понять с трех взаимодополняющих точек зрения:

- Функциональный: композиции нелинейных функций
- Геометрические преобразования: преобразования способов представления данных
- Вычислительные: многоуровневые архитектуры обработки данных

Основные компоненты.

- Параметры (W_ℓ , b_ℓ)
- Нелинейные активации
- Композиционная структура

Ключевая идея. Сила нейронных сетей заключается не только в их выразительности, но и в их способности обучаться структурированным представлениям посредством композиции.

15.6 Прогноз

В этой главе нейронные сети были представлены как композиционные модели:

- многоуровневые архитектуры,
- роль глубины в выразительности,
- универсальное приближение как теоретическое основание,
- обучение представлению информации как центральный принцип.

В следующей главе мы изучим, как эффективно обучать нейронные сети.

с использованием обратного распространения ошибки и автоматического дифференцирования.

Основной принцип. Сложные функции часто можно рассматривать как композиции более простых, а нейронные сети предоставляют основу для обучения таким композициям на основе данных.

Глава 16

Обратное распространение и Автоматическое дифференцирование

16.1 Вычислительные графы

Нейронные сети представляют собой композиции функций. Для эффективного вычисления градиентов полезно представлять эти вычисления в явном виде.

Вычислительный граф. Вычислительный граф — это ориентированный ациклический граф (DAG), который показывает, как функция строится из более простых операций.

Узлы и рёбра.

- Узлы представляют переменные или промежуточные значения
- Рёбра представляют функциональные зависимости

Пример. Рассмотрим простую функцию.

$$z = (x_1 + x_2) \cdot x_3.$$

Это можно представить в виде графика:

- $a = x_1 + x_2$
- $z = a \cdot x_3$

Прямой проход. Мы оцениваем граф от входных данных к выходным, вычисляя все промежуточные значения.

Введение. Нейронная сеть — это большой вычислительный граф, где каждый слой соответствует набору операций.

16.2 Правило цепочки и дифференцирование в обратном режиме ация

Для обучения нейронной сети необходимо вычислить градиенты функции потерь по всем параметрам.

Правило цепочки. Для композиции функций,

$$f(x) = f_L(f_{L-1}(\dots f_1(x))),$$

Производная получается путем многократного применения правила цепочки.

Локальные производные. Каждый узел в вычислительном графе вносит свой вклад в виде локальной производной.

Дифференцирование в обратном режиме. Градиенты вычисляются путем распространения чувствительности от выхода в обратном направлении по графу.

Основной принцип. Если переменная z зависит от x через промежуточные переменные, то

$$\frac{\partial L}{\partial x} = \sum_{\text{пути}} \frac{\partial L}{\partial z} \cdot \frac{\partial z}{\partial x}.$$

Обратное распространение ошибки. Этот процесс распространения градиентов в обратном направлении по сети называется обратным распространением ошибки.

Пример. Для $z = a \cdot x_3$ и $a = x_1 + x_2$,

$$\frac{\partial z}{\partial x_1} = \frac{\partial z}{\partial a} \cdot \frac{\partial a}{\partial x_1}.$$

Проницаемость. Метод обратного распространения ошибки систематически применяет правило цепочки ко всему вычислительному графу.

16.3 Эффективное вычисление градиента

Простой расчет градиентов был бы вычислительно затратным, особенно для глубоких нейронных сетей.

Основная идея. Повторное использование промежуточных вычислений из прямого прохода.

Пас вперёд.

- Вычислите все промежуточные значения

- Сохраните их для повторного использования

Обратный пас.

- Вычисляйте градиенты в обратном порядке.

- Повторное использование сохраненных промежуточных значений

Сложность. Обратное распространение ошибки вычисляет градиенты со стоимостью, сопоставимой со стоимостью вычисления самой функции.

Градиентный поток. Градиенты распространяются слой за слоем:

$$\frac{L}{W\ell} \quad \text{зависит от} \quad \frac{L}{z(\ell)}.$$

Совместное выполнение подзадач. Вычислительный граф гарантирует, что повторяющиеся операции вычисляются только один раз.

Вывод: метод обратного распространения ошибки эффективен, поскольку позволяет избежать избыточных вычислений и использует структуру сети.

16.4 Перспективы реализации

Современные фреймворки машинного обучения реализуют обратное распространение ошибки с использованием автоматического дифференцирования.

Автоматическое дифференцирование (АД).

- Вычисляет точные производные (с точностью до численной точности)
- Работает для произвольных композиций дифференцируемых операций

Два режима АЦП.

- Режим прямой передачи
- Обратный режим (используется в глубоком обучении)

Почему обратный режим? Он эффективен, когда функция имеет много параметров и один выходной результат (что типично для задач обучения).

Практичный рабочий процесс.

1. Определите модель как вычислительный граф.
2. Выполните прямой проход для вычисления потерь.
3. Используйте автоматическое дифференцирование для вычисления градиентов.
4. Обновление параметров с использованием алгоритма оптимизации.

Вопросы памяти.

- Для обратного прохода необходимо сохранить промежуточные значения.
- Для больших моделей требуется тщательное управление памятью.

92 ГЛАВА 16. ОБРАТНОЕ РАСПРОСТРАНЕНИЕ И АВТОМАТИЧЕСКОЕ ДИФФЕРЕНЦИРОВАНИЕ

Численные проблемы.

- Исчезающие и взрывающиеся градиенты
- Арифметика конечной точности

Insight. Автоматическое дифференцирование упрощает вычисление градиента, позволяя специалистам сосредоточиться на проектировании модели.

16.5 Объединяющая перспектива

Обратное распространение ошибки связывает в себе несколько ключевых идей:

- Математика: правило цепочки для производных
- Вычисления: эффективное повторное использование промежуточных значений
- Алгоритмы: масштабируемое обучение глубоких нейронных сетей

Ключевые компоненты.

- Вычислительный граф
- Пас вперед
- Обратный пас

Ключевая идея. Обратное распространение ошибки позволяет эффективно обучать сложные модели за счет систематического применения правила цепочки.

16.6 Прогноз

В этой главе были представлены методы обратного распространения ошибки и автоматического дифференцирования:

- вычислительные графы как представление моделей,
- Дифференцирование в обратном режиме для эффективного получения градиентов,
- Практическая реализация посредством автоматического дифференцирования.

В следующей главе мы рассмотрим проблемы обучения глубоких нейронных сетей, включая вопросы инициализации и работы с градиентами.

Основной принцип. Эффективное вычисление градиентов — это ключ к возможности современного глубокого обучения.

Глава 17

Обучение глубоких нейронных сетей

17.1 Стратегии инициализации

Обучение глубоких нейронных сетей включает в себя оптимизацию сильно невыпуклых целевых функций в многомерном пространстве параметров. Выбор начальных условий играет решающую роль в определении успешности оптимизации.

Случайная инициализация. Параметры обычно инициализируются случайным образом:

$W^{(0)}$ — распределение, $b^{(0)} = 0$ или малые значения.

Почему бы не инициализировать значение нулем?

- Симметрия: все элементы будут вести себя одинаково.
- Никакого значимого обучения не произойдет.

Сохранение дисперсии. Ключевой принцип заключается в выборе инициализации таким образом, чтобы активации не исчезали и не взрывались по мере распространения через слои.

Пример (инициализация Ксавье/Глорота).

$$\text{Var}(W_{ij}) = \frac{2}{n_{\text{ин}} + n_{\text{оут}}}.$$

Пример (инициализация Хе).

$$\text{Var}(W_{ij}) = \frac{2}{n_{\text{ин}}}.$$

Проницаемость. Правильная инициализация обеспечивает стабильное распространение сигнала между слоями.

Влияние на тренировку.

- Хорошая инициализация — более быстрая сходимость
- Некачественная инициализация — медленное или неудачное обучение

17.2 Исчезающие и взрывающиеся градиенты

Основная трудность при обучении глубоких нейронных сетей возникает из-за поведения градиентов.

Распространение градиента. Обратное распространение включает многократное умножение на матрицы весов и производных:

$$\frac{\partial L}{\partial z^{(\ell)}} = \frac{\partial L}{\partial z^{(\ell+1)}} W^{(\ell+1)} \cdot \sigma'(z^{(\ell)}).$$

Исчезающие градиенты.

- Градиенты экспоненциально уменьшаются с глубиной
- Ранние слои обучаются очень медленно.

Взрывающиеся градиенты.

- Градиенты растут экспоненциально
- Приводит к нестабильности и численным проблемам.

Причины.

- Многократное умножение малых или больших значений
- Насыщающие функции активации (например, сигмоидная)

Стратегии смягчения последствий.

- Тщательная инициализация
- Использование ненасыщающих активаций (например, ReLU)
- Методы нормализации
- Отсечение градиента

Вывод: стабильный градиентный поток необходим для эффективного обучения в глубоких нейронных сетях.

17.3 Проблемы оптимизации

Глубокие нейронные сети создают задачи оптимизации, выходящие за рамки тех, с которыми сталкиваются классические модели.

Невыпуклость. Функция потерь имеет множество локальных минимумов и седловых точек.

Высокая размерность. Пространство параметров может содержать миллионы или миллиарды переменных.

Седловые точки.

- Встречается чаще, чем плохие локальные минимумы
- Может замедлить оптимизацию

Плоские и острые области.

- Равнинные регионы: медленный прогресс
- Острые области: нестабильность

Плохая обусловленность. Разные направления могут иметь очень разную кривизну, что затрудняет оптимизацию.

Практические стратегии.

- Используйте стохастическую оптимизацию (SGD)
- Примените методы, основанные на инерции или адаптации.
- Нормализация входных данных и активаций

Вывод. Несмотря на теоретическую сложность, простые методы оптимизации часто хорошо работают на практике благодаря своей структуре, присущей реальным задачам.

17.4 Эмпирическое поведение в процессе обучения

В процессе обучения глубокие нейронные сети часто демонстрируют характерные закономерности, которые не в полной мере описываются теорией.

Динамика тренировок.

- Быстрое первоначальное снижение потерь
- Более медленная сходимости на поздних этапах

Обобщающее поведение.

- Потери от тренировок могут приблизиться к нулю
- Результаты тестирования могут оставаться хорошими.

Двойной спуск (неформальный). Увеличение размера модели может сначала увеличить, а затем уменьшить ошибку тестирования.

Роль избыточной параметризации.

- Большие модели легче оптимизировать.
- Многие решения обеспечивают низкую ошибку обучения

Неявная регуляризация. Динамика оптимизации отдает предпочтение определенным решениям, часто обладающим хорошими обобщающими свойствами.

Кривые обучения.

- Постройте графики ошибок обучения и валидации во времени.
- Используется для диагностики недостаточной и избыточной подгонки модели.

Практические наблюдения.

- Большие наборы данных повышают производительность
- Более глубокие модели способны улавливать больше структурных элементов.
- Часто требуется тщательная настройка

Проницательность. Эмпирическое поведение дает важные ориентиры, когда теория неполна.

17.5 Объединяющая перспектива

Обучение глубоких нейронных сетей включает в себя несколько взаимодействующих компонентов:

- Инициализация: задает начальную точку
- Градиентный поток: определяет распространение сигнала
- Оптимизация: помогает ориентироваться в условиях потерь
- Размер данных и модели: влияют на обобщаемость.

Основная задача. Обеспечение стабильного и эффективного обучения в многомерных, невыпуклых условиях.

Ключевой вывод. Успешное обучение зависит от согласованности архитектуры, инициализации и оптимизации.

17.6 Прогноз

В этой главе были рассмотрены практические проблемы обучения глубоких нейронных сетей:

- стратегии инициализации,
- исчезающие и взрывающиеся градиенты,
- трудности оптимизации,
- эмпирическое тренировочное поведение.

В следующей главе мы изучим функции активации и архитектурное проектирование. выбор, который, в свою очередь, влияет на поведение глубоких нейронных сетей.

Основной принцип. Обучение глубоких нейронных сетей требует баланса между математическими принципами и эмпирическим опытом.

Глава 18

Функции активации и Архитектуры

18.1 Нелинейные активации

Нелинейные функции активации являются фундаментальным компонентом нейронных сетей. Они позволяют сетям представлять сложные нелинейные взаимосвязи, которые невозможно описать одними лишь линейными преобразованиями.

Роль функций активации. Каждый слой в нейронной сети применяет преобразование вида

$$z = \sigma(Wz + b),$$

где σ применяется поэлементно.

Почему необходима нелинейность. Если σ является линейной функцией, то композиция слоев сводится к одному линейному преобразованию:

$$W_L W_{L-1} \cdots W_1 x,$$

Устранение преимуществ глубины.

Общие функции активации.

- Сигмоидная функция:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

- Танх:

$$\sigma(z) = \tanh(z)$$

- ReLU (выпрямленный линейный блок):

$$\sigma(z) = \max(0, z)$$

98 ГЛАВА 18. ФУНКЦИИ И АРХИТЕКТУРЫ АКТИВАЦИИ

Характеристики.

- Сигмоида и $\tanh$ являются гладкими функциями, но могут вызывать насыщение.
- Функция активации ReLU проста и позволяет избежать насыщения в положительной области спектра.

Варианты.

• Протекающая функция активации ReLU

• ELU

• ГЕЛУ

Градиентное поведение.

- Насыщение активаций — исчезновение градиентов
- Кусочно-линейная активация — стабильные градиенты

Вывод. Выбор функции активации оказывает сильное влияние как на выразительность, так и на динамику оптимизации.

18.2 Архитектурные проектные шаблоны

Помимо отдельных слоев, общая структура нейронной сети играет решающую роль в ее производительности.

Полностью взаимосвязанные сети. Каждый слой соединен со всеми устройствами предыдущего слоя.

Сверточные архитектуры.

- Использование пространственной локальности
- Обмен параметрами между местоположениями

Остаточные соединения.

- Добавить сопоставление идентификаторов между слоями:

$$z^{(\ell+1)} = z^{(\ell)} + F(z^{(\ell)})$$

- Улучшение градиентного потока и стабильности

Слои нормализации.

- Пакетная нормализация
- Нормализация слоев

Модульная конструкция. Современные архитектуры часто состоят из повторяющихся блоков (например, сверточных блоков, блоков-трансформаторов).

Проницательность. Архитектурный дизайн содержит индуктивные предубеждения, которые направляют процесс обучения.

18.3 Глубина против ширины

Структура нейронной сети характеризуется её глубиной и шириной.

Ширина. Количество элементов в каждом слое.

Глубина. Количество слоев.

Поверхностные широкие сети.

- Может аппроксимировать многие функции
- Может потребоваться большое количество параметров

Глубокие сети.

- Захват иерархической структуры
- Зачастую более эффективно используют параметры

Сравнение выразительности. Некоторые функции могут быть эффективно представлены глубокими нейронными сетями, но требуют экспоненциально больших неглубоких сетей.

Вопросы оптимизации.

- Более глубокие нейронные сети сложнее обучать.
- Такие методы, как остаточные соединения, позволяют смягчить эту проблему.

Проницательность. Глубина обеспечивает естественный способ кодирования композиционной структуры.

18.4 Вопросы выразительности

Выразительная способность нейронной сети зависит от её архитектуры и функций активации.

Выразительность. Способность модели аппроксимировать широкий спектр функций.

Факторы, влияющие на экспрессивность.

- Глубина и ширина
- Выбор функции активации
- Структура связей

Пошаговые линейные сети. Сети ReLU представляют собой функции, состоящие из множества линейных областей.

Геометрический подход. Каждый слой разделяет входное пространство, увеличивая сложность представления.

Компромиссы.

100 ГЛАВА 18. ФУНКЦИИ И АРХИТЕКТУРЫ АКТИВАЦИИ

- Высокая выразительность — лучшее приближение
- Но при этом возрастает риск переобучения и возникают трудности с оптимизацией.

Неявные ограничения. Архитектуры ограничивают класс функций, которые могут быть представлены, обеспечивая индуктивную предвзятость.

Проницательность. Одной лишь выразительности недостаточно; для эффективного обучения необходим баланс между способностью к представлению информации и возможностью её обучения.

18.5 Объединяющая перспектива

Функции активации и архитектуры совместно определяют:

- как информация распространяется по сети,
- как можно представить сложные функции,
- Насколько легко можно обучить модель.

Основные компоненты.

- Нелинейные активации
- Взаимосвязь уровней
- Архитектурные модели

Ключевая идея. Разработка нейронных архитектур является центральным аспектом современного машинного обучения, сочетающим математическую структуру с эмпирическими показателями. манс.

18.6 Прогноз

В этой главе рассматривалась роль функций активации и архитектур:

- нелинейные активации, позволяющие создавать выразительные модели,
- архитектурные модели, влияющие на процесс обучения,
- компромисс между глубиной и шириной,
- факторы, влияющие на экспрессивность.

В следующей главе мы изучим методы нормализации, которые играют ключевую роль в целях стабилизации и ускорения тренировок.

Основной принцип. Эффективность систем глубокого обучения зависит не только от их размера, но и от того, как они структурированы.

Глава 19

Методы нормализации

19.1 Пакетная нормализация

Обучение глубоких нейронных сетей может быть чувствительно к масштабу и распределению активаций. Методы нормализации решают эту проблему путем стандартизации промежуточных представлений.

Пакетная нормализация (BatchNorm). При наличии активаций z в слое, BatchNorm преобразует их следующим образом:

$$\hat{z}_i = \frac{z_i - \mu_B}{\sqrt{\frac{2}{B} + \epsilon \sigma}},$$

где μ_B и σ^2 — среднее значение и дисперсия вычисляются по мини-пакету данных.

Аффинное преобразование. После нормализации применяется обучаемое преобразование:

$$y_i = \gamma \hat{z}_i + \beta,$$

где γ и β — параметры.

Цель.

- Стабилизировать распределение активаций
- Улучшение градиентного потока
- Ускорить обучение

Интерпретация. Пакетная нормализация снижает чувствительность к масштабу параметров и входных данных.

Обучение против вывода.

- В процессе обучения: статистические данные, вычисленные на основе мини-пакетов.
- В процессе вывода результатов используются скользящие средние.

Практический эффект.

- Позволяет достигать более высоких темпов обучения
- Снижает зависимость от инициализации

19.2 Нормализация слоев и экземпляров

В то время как BatchNorm основан на статистике пакетов данных, альтернативные методы нормализации работают независимо от пакета.

19.2.1 Нормализация слоев

Определение. Нормализация слоев выполняет нормализацию признаков в пределах одной точки данных:

$$\hat{z} = \frac{z_{\text{МКЛ}}}{\sqrt{2 \sigma_{\text{Слой}}^2 + \epsilon}}.$$

Характеристики.

- Не зависит от размера партии
- Подходит для моделей последовательностей (например, трансформаторов)

19.2.2 Нормализация экземпляров

Определение. Нормализация экземпляров нормализует каждый образец независимо, часто по пространственным измерениям в задачах компьютерного зрения.

Приложения.

- Генерация изображений
- Перенос стиля

Сравнение методов.

- BatchNorm: использует статистику пакетной обработки
- LayerNorm: использует статистику признаков для каждого образца
- InstanceNorm: использует пространственную статистику для каждого образца

Вывод: Различные методы нормализации отражают разные предположения о структуре данных.

19.3 Стабилизация тренировок

Методы нормализации повышают стабильность и эффективность обучения.

Влияние на оптимизацию.

- Сглаживает картину потерь
- Снижает чувствительность к масштабированию параметров
- Улучшает физическую подготовку

Градиентный поток.

- Предотвращает исчезновение и взрыв градиентов
- Обеспечивает стабильное распространение сигнала

Внутренний сдвиг ковариат (неформально). Поскольку параметры изменяются в процессе обучения, распределение активаций смещается. Нормализация уменьшает этот эффект.

Эффект регуляризации.

- BatchNorm вносит шум за счет пакетной статистики.
- Может улучшить обобщающую способность

Взаимодействие скорости обучения.

- Позволяет использовать более высокие темпы обучения
- Приводит к более быстрой сходимости

Проницаемость. Нормализация преобразует задачу оптимизации, упрощая ее решение.

19.4 Теоретические и практические аспекты

Несмотря на широкое применение методов нормализации, их теоретическое понимание все еще находится в стадии развития.

Масштабная инвариантность. Нормализация делает сеть менее чувствительной к масштабированию параметров.

Перепараметризация. Нормализацию можно рассматривать как изменение параметризации модели, что влияет на динамику оптимизации.

Геометрия оптимизации. Нормализация эффективно изменяет геометрию ландшафта функции потерь, часто делая его более обусловленным.

Эмпирические наблюдения.

- Повышает скорость тренировки
- Повышает стабильность работы различных архитектур
- Незаменим во многих современных глубоких нейронных сетях

Ограничения.

- Параметр BatchNorm зависит от размера партии.
- Может плохо себя вести при работе с очень малыми партиями.

Вопросы проектирования.

- Выбор метода нормализации зависит от архитектуры и типа данных.
- Часто сочетается с другими методами (например, с остаточными соединениями)

Проницательность. Нормализация — это одновременно практический инструмент и концептуальный механизм для улучшения оптимизации.

19.5 Объединяющая перспектива

Методы нормализации можно понимать как преобразования, которые:

- стандартизировать представления,
- улучшить физическую подготовку,
- стабилизация градиентного потока,
- ввести неявную регуляризацию.

Основные компоненты.

- Этап нормализации
- Возможность обучения масштабированию и сдвигу
- Взаимодействие с динамикой оптимизации

Ключевой вывод. Нормализация играет центральную роль в обеспечении возможности масштабируемого обучения глубоких нейронных сетей.

19.6 Прогноз

В этой главе были рассмотрены методы нормализации в глубоком обучении:

- пакетная нормализация и её варианты,
- альтернативные стратегии нормализации,
- их роль в стабилизации тренировок,
- теоретические и практические перспективы.

В следующей главе мы рассмотрим методы регуляризации, специфичные для глубокого обучения, включая дропаут и аугментацию данных.

Основной принцип. Грамотно разработанные преобразования промежуточных представлений могут значительно улучшить как оптимизацию, так и обобщение.

Глава 20

Регуляризация в глубоком Обучении

20.1 Выпадение сигнала и добавление шума

Глубокие нейронные сети обладают высокой выразительностью и легко могут переобучиться на обучающих данных. Таким образом, методы регуляризации необходимы для повышения обобщающей способности.

Dropout. Dropout — это стохастический метод регуляризации, при котором нейроны случайным образом деактивируются во время обучения.

Механизм. Для каждого блока производится выборка бинарной маски:

$$m_i \sim \text{Bernoulli}(p),$$

и активации модифицируются следующим образом

$$\tilde{z}_i = m_i z_i.$$

Интерпретация.

- На каждой итерации обучается отдельная подсеть.
- Предотвращает совместную адаптацию функций

Вывод. Во время тестирования активации масштабируются с учетом эффекта отсеивания (dropout):

$$z_i \leftarrow p z_i.$$

Эффект.

- Повышает надежность
- Снижает риск переобучения

Введение шума. В более общем смысле, шум может добавляться к входным данным, активациям или параметрам:

$$z = \hat{z} + \epsilon,$$

где ϵ — случайный шум.

Проницательность. Шум побуждает модель к изучению стабильных характеристик, нечувствительных к малым возмущениям.

20.2 Снижение веса

Регулирование с помощью затухания весов — один из наиболее широко используемых методов регуляризации в глубоком обучении.

Цель.

$$\min_{\theta} \hat{R}^n(\theta) + \lambda \|\theta\|_2^2.$$

Интерпретация.

- Наказывает за большие значения параметров
- Способствует созданию более простых моделей

Влияние на оптимизацию. Правило обновления становится следующим:

$$\theta_{t+1} = (1 - \eta\lambda)\theta_t - \eta \nabla \hat{R}^n(\theta_t).$$

Анализ. В процессе обучения параметры постепенно сужаются до нуля.

Связь со стабильностью. Меньший вес часто приводит к более плавным функциям и улучшенной обобщающей способности.

Байесовская интерпретация. Затухание веса соответствует гауссовому априорному распределению параметров.

20.3 Расширение данных

Расширение данных улучшает обобщающую способность за счет искусственного увеличения разнообразия обучающих данных.

Основная идея. Генерация новых обучающих примеров путем применения преобразований:

$$(x, y) \rightarrow (T(x), y),$$

где T сохраняет метку.

Примеры (зрение).

- Вращение, перемещение, масштабирование

- Переворачивание, обрезка
- Цветовые искажения

Примеры (другие области).

- Введение шума во входные сигналы
- Замена синонимов в тексте

Интерпретация.

- Кодирование инвариантности (например, инвариантность относительно вращения)
- Расширяет эффективный размер набора данных

Геометрическое представление. Расширение увеличивает область входного пространства, связанную с каждой меткой.

Анализ. Расширение данных действует как форма регуляризации, ограничивая функцию таким образом, чтобы она вела себя согласованно при преобразованиях.

20.4 Неявная предвзятость оптимизации

Регуляризация в глубоком обучении не ограничивается явными методами. Сама оптимизация вносит определенную форму неявного смещения.

Избыточная параметризация. Глубокие нейронные сети часто имеют больше параметров, чем точек данных, что приводит к множеству решений с нулевой ошибкой обучения.

Ключевой вопрос. Какое решение выберет алгоритм оптимизации?

Скрытая предвзятость. Методы, основанные на градиенте, как правило, отдают предпочтение решениям с определенными свойствами, такими как:

- небольшие нормы,
- плавная работа функций,
- определенные структурные закономерности.

Пример (линейные модели). Градиентный спуск сходится к решению с минимальной нормой среди всех интерполирующих решений.

Перспектива глубокого обучения.

- Шум SGD влияет на траекторию оптимизации
- Различные оптимизаторы приводят к различным решениям

Проницаемость. Сам процесс обучения выступает в качестве механизма упорядочивания.

Взаимодействие с явной регуляризацией. Неявная и явная регуляризация часто работают вместе, формируя обучаемую модель.

20.5 Объединяющая перспектива

Регуляризация в глубоком обучении принимает различные формы:

- Явно: снижение веса, отсев
- На основе данных: расширение возможностей
- Неявно: динамика оптимизации

Основная цель.

Подгонка данных под нужды пользователя + содействие обобщению.

Ключевой вывод. Обобщающая способность формируется не только самой моделью, но и тем, как она обучается и какие данные она использует.

20.6 Прогноз

В этой главе были рассмотрены методы регуляризации, специфичные для глубокого обучения:

- выпадение сигнала и внедрение шума,
- снижение веса,
- расширение данных,
- Скрытая предвзятость оптимизации.

В следующей главе мы изучим остаточные сети и пропускные соединения, которые играют ключевую роль в обеспечении возможности создания очень глубоких архитектур.

Основной принцип. Эффективная регуляризация возникает в результате сочетания структуры модели, преобразований данных и динамики оптимизации.

Глава 21

Остаточные сети и Пропустить соединения

21.1 Проблема деградации

По мере углубления нейронных сетей можно было бы ожидать улучшения их производительности за счет повышения выразительности. Однако на практике обучение более глубоких сетей может оказаться сложнее.

Наблюдение. Увеличение глубины может привести к большей ошибке обучения, даже несмотря на то, что более глубокая модель может представлять те же функции, что и более мелкая.

Проблема деградации.

- Более глубокие нейронные сети показывают худшие результаты, чем их более мелкие аналоги.
- Не из-за переобучения, а из-за сложности оптимизации.

Интуиция. В принципе, дополнительные слои могли бы изучить отображение идентичности и сохранить производительность. Однако стандартные процедуры обучения с трудом находят такие решения.

Связь с градиентами.

- Глубокие композиции усиливают исчезающие и взрывающиеся градиенты.
- Информация может ухудшаться на разных уровнях.

Проницательность. Глубина повышает выразительность, но также создает проблемы оптимизации, которые необходимо решать посредством архитектурного проектирования.

21.2 Остаточное обучение

Остаточные сети (ResNets) решают проблему деградации за счет введения пропускных соединений.

Остаточный блок.

$$z^{(\ell+1)} = z^{(\ell)} + F(z^{(\ell)}),$$

где F — обучаемое преобразование.

Интерпретация.

- Вместо обучения отображению $H(z)$ сеть обучается остатку:

$$F(z) = H(z) - z$$

- Полное отображение принимает вид $H(z) = z + F(z)$

Преимущества.

- Легче усваивать небольшие нарушения идентичности
- Улучшает поток градиента между слоями
- Снижает степень деградации

Распространение градиентов. Градиенты могут передаваться напрямую через тождественное соединение:

$$\frac{dz^{(\ell+1)}}{dz^{(\ell)}} = I + \frac{F}{dz^{(\ell)}}.$$

Анализ. Пропуски вложений обеспечивают альтернативные пути для получения информации и градиентов, стабилизируя процесс обучения.

21.3 Перспектива динамических систем

Остаточные сети допускают интерпретацию как дискретные динамические системы.

Дискретная динамика.

$$z^{(\ell+1)} = z^{(\ell)} + F(z^{(\ell)}).$$

Аналогия с непрерывным временем. Это напоминает дискретизацию обыкновенного дифференциального уравнения:

$$\frac{dz(t)}{dt} = F(z(t)).$$

Дискретизация Эйлера. С шагом $\Delta t = 1$,

$$z(t + \Delta t) \approx z(t) + \Delta t F(z(t)).$$

Интерпретация.

- Слои соответствуют временным шагам
- Глубина сети соответствует эволюции во времени.

Стабильность. Остаточные связи помогают поддерживать стабильные траектории в пространстве представлений.

Проницательный вывод. Рассмотрение нейронных сетей как динамических систем обеспечивает основу для понимания глубины, стабильности и динамики обучения.

21.4 Очень глубокие архитектуры

Остаточные связи позволяют обучать чрезвычайно глубокие нейронные сети.

Эмпирическое наблюдение.

- Можно успешно обучать нейронные сети, состоящие из сотен или тысяч слоев.
- Производительность повышается с увеличением глубины при использовании остаточных соединений.

Архитектурные модели.

- Складывание остаточных блоков
- Сочетание со слоями нормализации
- Использование структур, являющихся узкими местами, для повышения эффективности

Масштабируемое поведение.

- Более глубокие модели позволяют выявлять более сложные закономерности
- Обучение остается стабильным благодаря пропускам подключений.

Обобщение. Остаточные сети часто хорошо обобщаются, несмотря на большую пропускную способность.

Ограничения.

- Увеличение вычислительных затрат
- Архитектурная сложность

Проницательность. Тщательно продуманный архитектурный дизайн позволяет сделать глубину практически применимой.

21.5 Объединяющая перспектива

Остаточные сети демонстрируют, как архитектурные инновации могут решать фундаментальные проблемы глубокого обучения.

Ключевые компоненты.

- Пропустить соединения
- Остаточные отображения
- Стабильный градиентный поток

Основные идеи.

- Изучайте возмущения, а не полные преобразования.
- Содействие оптимизации посредством сопоставления идентификаторов.
- Интерпретировать сети как динамические системы

Ключевая идея. Архитектурный дизайн может коренным образом изменить поведение алгоритмов машинного обучения.

21.6 Прогноз

В этой главе были представлены остаточные сети и соединения с пропуском:

- проблема деградации в глубоких нейронных сетях,
- остаточное обучение как решение,
- связи с динамическими системами,
- обеспечение возможности создания очень сложных архитектур.

В следующей главе мы изучим сверточные нейронные сети, которые используют пространственную структуру в данных.

Основной принцип. Эффективные архитектуры сочетают математическую структуру с практическими соображениями, что делает глубокое обучение осуществимым в масштабах.

Глава 22

Сверточная нейронная сеть Сети

22.1 Свертка как структурированная линейная операция тор

Сверточные нейронные сети (CNN) предназначены для использования структуры данных, особенно изображений и сигналов. Центральной операцией является свертка, которую можно понимать как структурированное линейное преобразование.

Дискретная свертка. Для одномерного входного сигнала $x \in \mathbb{R}^n$ и ядра $w \in \mathbb{R}^k$, свертка определяется как

$$(y \otimes w)_i = \sum_{j=1}^k w_j x_{i-j}.$$

Двумерная свертка. Для изображений свертка применяется к пространственным измерениям:

$$y(i, j) = \sum_{u, v} w(u, v) x(i-u, j-v).$$

Представление в виде линейного оператора. Свертку можно записать как умножение матрицы на вектор:

$$y = Kx,$$

где K — структурированная (тепличова или блочно-тепличова) матрица.

Ключевое свойство: совместное использование параметров.

- Во всех местах применяется одно и то же ядро.
- Сокращает количество параметров

Локальная связь.

- Каждый выходной сигнал зависит только от локальной области входного сигнала.
- Отражает пространственную локальность данных

Полезный вывод. Свертка накладывает структуру на линейные преобразования, делая их эффективными и подходящими для структурированных данных.

22.2 Инвариантность трансляции

Ключевым мотивом для создания сверточных архитектур является инвариантность к сдвигу.

Эквивариантность сдвига. Сверточный слой удовлетворяет следующему условию:

$$x(\cdot - \tau) \rightarrow y(\cdot - \tau),$$

Это означает, что сдвиг входного сигнала приводит к соответствующему сдвигу выходного сигнала.

Интерпретация.

- Обнаруженные в одном месте признаки могут быть обнаружены и в другом месте.
- Модель не зависит от абсолютного положения

От эквивариантности к инвариантности.

- Эквивариантность сохраняет пространственную структуру
- Инвариантность устраняет чувствительность к положению

Достижение инвариантности.

- Операции по объединению ресурсов
- Глобальное усреднение

Прозрение. Инвариантность к сдвигу отражает ключевое свойство визуального восприятия: объекты можно распознать независимо от их местоположения.

22.3 Объединение и иерархии

В сверточных нейронных сетях обычно используются операции пулинга, которые снижают пространственное разрешение, сохраняя при этом важные характеристики.

Объединение.

- Максимальное объединение: выбирает максимальное значение в заданной области.
- Усреднение: вычисляет среднее значение

Эффект.

- Уменьшает размерность
- Вводит инвариантность для малых преобразований

Иерархическая структура.

- Ранние слои обнаруживают простые элементы (края, текстуры).
- Промежуточные слои обнаруживают закономерности (формы, части)
- Более глубокие слои обнаруживают сложные структуры (объекты)

Рецептивное поле. Область входного сигнала, влияющая на данную единицу, увеличивается с глубиной.

Проницательный вывод. Сверточные нейронные сети строят представления иерархически, объединяя локальные признаки в глобальные закономерности.

22.4 Применение в компьютерном зрении

Сверточные нейронные сети достигли замечательных успехов в задачах, требующих обработки визуальной информации.

Классификация изображений.

- Присвоить метку изображению
- Пример: распознавание объектов

Обнаружение объектов.

- Идентификация и локализация объектов на изображении

Сегментация.

- Присвойте метку каждому пикселю.
- Обеспечивает детальное понимание сцен

Генеративное моделирование.

- Синтез изображений
- Сверхвысокое разрешение

Архитектурные примеры.

- Сверточные слои + пулинг
- Остаточные соединения
- Структуры кодировщик-декодер

Вывод: сверточные нейронные сети эффективны, потому что они включают в модель специфическую для предметной области структуру.

22.5 Объединяющая перспектива

Сверточные нейронные сети объединяют в себе несколько ключевых идей:

- Структурированные линейные операторы: свертка
- Индуктивная предвзятость: локальность и инвариантность к сдвигу
- Иерархия: многомасштабное обучение представлению

Основные компоненты.

- Сверточные слои
- Нелинейные активации
- Операции по объединению ресурсов

Ключевая идея. Благодаря включению структуры в архитектуру, сверточные нейронные сети достигают как эффективности, так и высокой обобщающей способности.

22.6 Прогноз

В этой главе были представлены сверточные нейронные сети:

- свертка как структурированный линейный оператор,
- Эквивариантность и инвариантность трансляции,
- иерархическое обучение признакам,
- Применение в системах машинного зрения.

В следующей главе мы изучим модели последовательностей, которые расширяют возможности нейронных сетей к последовательным и временным данным.

Основной принцип. Эффективные модели используют структуру данных, для обработки которых они предназначены.

Глава 23

Модели последовательностей

23.1 Рекуррентные нейронные сети

Многие типы данных в реальном мире являются последовательными, включая временные ряды, текст и речь. Модели последовательности призваны учитывать зависимости во времени.

Рекуррентные нейронные сети (РНН). РНН обрабатывает последовательность $(x_1, x_2, \dots, x_T)$, поддерживая скрытое состояние h_t , которое изменяется со временем:

$$h_t = \phi(W_h h_{t-1} + W_x x_t + b),$$

$$y_t = \psi(W_y h_t + c),$$

где ϕ и ψ — нелинейные функции.

Интерпретация.

- h_t обобщает информацию за прошлые периоды
- Одни и те же параметры используются на разных временных шагах.

Совместное использование параметров. В отличие от прямых нейронных сетей, рекуррентные нейронные сети совместно используют веса во времени, что делает их подходящими для последовательностей переменной длины.

Разворачиваясь во времени. Рекуррентную нейронную сеть можно рассматривать как глубокую сеть с общими параметрами:

$$h_1 \quad h_2 \quad \dots \quad h_T.$$

Insight. Рекуррентные нейронные сети моделируют временные зависимости путем рекурсивного обновления скрытого состояния.

23.2 Архитектуры с вентилями (LSTM, GRU)

Стандартные рекуррентные нейронные сети с трудом улавливают долгосрочные зависимости. Архитектуры с вентилями решают эту проблему.

23.2.1 Долговременная кратковременная память (ДКП)

Основная идея. Ввести ячейку памяти, способную сохранять информацию в течение длительных периодов времени.

Ворота.

- Входной клапан: управляет новой информацией
- Заглушка «Забыть»: контролирует, что следует отбросить.
- Выходной затвор: управляет тем, что должно быть показано.

Структура (концептуальная).

- Состояние клетки изменяется под воздействием контролируемых обновлений.
- Шлюзы регулируют поток информации

Эффект.

- Позволяет изучать долгосрочные зависимости
- Смягчает проблему затухания градиента

23.2.2 Вентилируемый рекуррентный блок (GRU)

Упрощенная архитектура.

- Объединяет механизмы ввода и забывания
- Меньше параметров, чем у LSTM

Механизм обновления.

- Управление сохранением данных в памяти посредством шлюза обновления
- Регулировка состояния с помощью механизма сброса контролирует влияние предыдущего состояния.

Анализ. Механизмы управления позволяют сети динамически контролировать поток информации.

23.3 Долгосрочные зависимости

Одной из главных задач моделирования последовательностей является выявление зависимостей на протяжении длительных временных интервалов.

Проблема.

- Информация, полученная на ранних этапах, может быть утеряна.
- Градиенты могут исчезать во время обратного распространения ошибки во времени.

Обратное распространение ошибки во времени (BPTT). Обучение рекуррентных нейронных сетей включает в себя распространение градиентов через множество временных шагов:

$$\frac{\partial L}{\partial h_t} = \frac{\partial L}{\partial h_T} \prod_{k=t}^{T-1} \frac{\partial h_{k+1}}{\partial h_k}.$$

Градиентное поведение.

- Повторное умножение может привести к исчезновению или взрыву градиентов.

Роль механизма управления доступом.

- Обеспечивает более лёгкий поток градиентов
- Позволяет избирательно сохранять информацию в памяти

Практические методы.

- Отсечение градиента
- Усеченное обратное распространение

Анализ. Моделирование долгосрочных зависимостей требует учета как архитектурных, так и оптимизационных аспектов.

23.4 Ограничения рецидива

Несмотря на свои преимущества, рекуррентные архитектуры имеют существенные ограничения.

Последовательные вычисления.

- Обработка должна происходить поэтапно.
- Ограничения на распараллеливание

Трудности с зависимостями на больших расстояниях.

- Даже у архитектур с управляемыми воротами есть свои ограничения.

- Информация может ухудшаться на протяжении длительных последовательностей.

Проблемы оптимизации.

- Обучение может быть нестабильным
- Чувствителен к гиперпараметрам

Проблема нехватки памяти. Скрытое состояние фиксированного размера должно содержать полную информацию о прошлом.

Вывод: Рекуррентность обеспечивает естественную основу для последовательностей, но может быть неэффективно масштабируема для сложных зависимостей на больших расстояниях.

23.5 Объединяющая перспектива

Модели последовательностей расширяют возможности нейронных сетей для работы с временными данными:

- Состояние: скрытое представление эволюционирует с течением времени
- Динамика: рекурсивные обновления определяют временное поведение.
- Память: информация хранится в скрытых состояниях

Эволюция архитектуры.

- RNN LSTM/GRU модели на основе механизма внимания

Ключевая идея. Разработка моделей последовательности основана на управлении потоком информации во времени.

23.6 Прогноз

В этой главе были представлены модели последовательностей:

- рекуррентные нейронные сети,
- архитектуры с управляемыми воротами,
- проблемы, связанные с долгосрочной зависимостью,
- Ограничения, связанные с рецидивом.

В следующей главе мы изучим механизмы внимания, которые затрагивают многие аспекты... ограничения рекуррентных моделей.

Основной принцип. Эффективное моделирование последовательностей требует механизмов для сохранения и доступа к соответствующей информации во времени.

Глава 24

Внимание и трансформаторы

24.1 Механизмы внимания

Модели последовательностей, основанные на рекуррентности, сжимают прошлую информацию в скрытое состояние фиксированного размера. Это создает узкое место при моделировании длинных последовательностей.

Основная идея механизма внимания. Вместо того чтобы полагаться на одно скрытое состояние, механизм внимания позволяет модели напрямую получать доступ ко всем релевантным частям входных данных.

Структура «запрос-ключ-значение». Внимание определяется с помощью трех компонентов:

- Запрос (q)
- Ключи (k_i)
- Значения (v_i)

Весовые коэффициенты внимания.

$$\alpha_i = \frac{\exp(q, k_i)}{\sum_j \exp(q, k_j)}$$

Выход.

$$\text{Attn}(q, K, V) = \sum_i \alpha_i v_i$$

Интерпретация.

- Запрос определяет, какие входные данные являются релевантными.
- Весовые коэффициенты α_i обозначают важность

Прозрение. Внимание заменяет фиксированную память гибким, зависящим от данных механизмом.

24.2 Самовнимание

Самовнимание задействует механизм внимания в рамках одной последовательности.

Определение. Каждый элемент последовательности уделяет внимание всем остальным элементам.

Построение. Даны входные данные $x_1, \dots, x_T$, определять:

$$q_i = WQx_i, \quad k_i = WKx_i, \quad v_i = WVx_i.$$

Вывод внимания.

$$y_i = \sum_{j=1}^T a_{ij} v_j, \quad a_{ij} = \frac{\exp(q_i \cdot k_j)}{\sum_{k=1}^T \exp(q_i \cdot k_k)}.$$

Характеристики.

- Улавливает зависимости между всеми позициями
- Полная возможность распараллеливания по всем элементам последовательности

Позиционное кодирование. Поскольку самовнимание инвариантно относительно перестановок, позиционная информация должна добавляться явно.

Проницательность. Самовнимание обеспечивает гибкий механизм для моделирования взаимосвязей внутри последовательностей.

24.3 Архитектура трансформатора

Архитектура трансформера полностью построена на механизмах внимания.

Основные компоненты.

- Многоголовочное самовнимание
- Слои прямого распространения
- Остаточные соединения
- Слои нормализации

Многоголовочный механизм внимания. Параллельно применяются несколько механизмов внимания:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(H_1, \dots, H_h)W_O,$$

где каждая головка H_i вычисляет внимание с помощью различных проекций.

Нейронная сеть прямого распространения.

$$\text{FFN}(x) = \sigma(W_1 x + b_1)W_2 + b_2.$$

Остаточная структура.

$$x = x + \text{Layer}(x),$$

затем следует нормализация.

Архитектурная планировка.

- Стопка одинаковых блоков
- Каждый блок: внимание + прямая связь

Структура кодировщик-декодер.

- Кодировщик обрабатывает входную последовательность
- Декoder генерирует выходную последовательность, учитывая выходные сигналы кодировщика.

Проницательность. Трансформеры заменяют рекуррентность механизмом внимания, что позволяет эффективно моделировать зависимости на больших расстояниях.

24.4 Масштабирование и приложения

Трансформаторы продемонстрировали замечательную масштабируемость и производительность в различных областях применения.

Масштабируемое поведение.

- Производительность повышается с увеличением размера модели, объема данных и вычислительных мощностей.
- Позволяет обучать очень большие модели

Параллелизация.

- В отличие от рекуррентных нейронных сетей, трансформеры обрабатывают последовательности параллельно.
- Эффективное использование современного оборудования

Приложения.

- Обработка естественного языка (перевод, генерация текста)
- Зрение (трансформаторы зрения)
- Обработка речи
- Мультимодальное обучение

Предварительное обучение и тонкая настройка.

- Крупные модели, обученные на огромных массивах данных

- Адаптировано к конкретным задачам посредством тонкой настройки

Ограничения.

- Квадратичная сложность по длине последовательности
- Высокая вычислительная стоимость

Анализ. Масштабируемость и доступность данных являются ключевыми факторами, определяющими производительность современных методов глубокого обучения.

24.5 Объединяющая перспектива

Внимание и трансформаторы объединяют несколько идей:

- Представление: динамическое взвешивание входных данных
- Вычисления: параллельная обработка последовательностей
- Архитектура: модульная и масштабируемая конструкция

Основные компоненты.

- Внимание к ключу-значению запроса
- Многоголовочные механизмы
- Остаточные и нормализационные слои

Ключевая идея. Механизм внимания обеспечивает гибкий подход к моделированию взаимодействий, заменяя фиксированные последовательные структуры.

24.6 Прогноз

В этой главе были представлены механизмы внимания и трансформеры:

- Внимание как гибкий механизм памяти,
- механизм самовнимания для моделирования последовательностей,
- Архитектуры трансформаторов,
- Масштабирование и особенности применения.

В следующей главе мы изучим генеративные модели, начиная с вероятностного моделирования и подходов, основанных на скрытых переменных.

Основной принцип. Успех современных архитектур достигается за счет обеспечения гибкого и масштабируемого взаимодействия между элементами данных.

Глава 25

Основы генеративного подхода

Моделирование

25.1 Оценка плотности и отбор проб

Цель генеративного моделирования — изучить базовое распределение данных и на его основе сгенерировать новые образцы.

Цель. Имея данные x p_{data} , построить модель $p_{\theta}(x)$, которая аппроксимирует истинное распределение.

Оценка плотности.

- Явные модели определяют плотность вероятности $p_{\theta}(x)$
- Обучение, как правило, основано на принципе максимального правдоподобия:

$$\max_{\theta} \mathbb{E}_{x \sim p_{data}} [\log p_{\theta}(x)].$$

Выборка. После обучения модели мы генерируем новые образцы:

$$x \sim p_{\theta}(x).$$

Две точки зрения.

- Метод, основанный на правдоподобии: прямое моделирование $p_{\theta}(x)$
- Неявное определение: процедура выборки определяется без явного указания плотности.

Проблемы.

- Многомерные данные
- Комплексные распределения

- Эффективный отбор проб

Введение. Генеративное моделирование включает в себя как представление распределений, так и генерацию выборок на их основе.

25.2 Модели скрытых переменных

Многие генеративные модели вводят скрытые переменные для отражения лежащей в основе структуры.

Формулировка скрытых переменных.

$$p_{\theta}(x) = \int p_{\theta}(x | z) p(z) dz,$$

где z — скрытая переменная.

Интерпретация.

- z обозначает скрытые факторы изменчивости
- $p(z)$ — это простая априорная вероятность (например, гауссова).

Генеративный процесс.

1. Образец $z \sim p(z)$
2. Сгенерировать $x \sim p_{\theta}(x | z)$

Задача обучения. Расчет предельной вероятности включает в себя неразрешимый интеграл.

Вывод. Мы вводим приближительное апостериорное распределение $q_{\phi}(z | x)$.

Полезный вывод. Скрытые переменные предоставляют структурированный способ моделирования сложных распределений данных.

25.3 Энергетические перспективы

Альтернативный подход моделирует распределения вероятностей с помощью энергетических функций.

Энергетическая модель (EBM).

$$p_{\theta}(x) = \frac{1}{Z(\theta)} \exp(-E_{\theta}(x)),$$

где $E_{\theta}(x)$ — функция энергии, а $Z(\theta)$ — функция распределения:

$$Z(\theta) = \int \exp(-E_{\theta}(x)) dx.$$

Интерпретация.

- Низкая энергия высокая вероятность
- Высокая энергия низкая вероятность

Обучение.

- Требуется оценка градиентов, включающих $Z(\theta)$
- Часто используются методы, основанные на выборочном отборе проб.

Связь с физикой. Модели, основанные на энергии, напоминают распределения в статистической механике.

Понимание. Формулировки, основанные на энергии, обеспечивают гибкий способ определения распределений без необходимости использования нормированных плотностей в замкнутой форме.

25.4 Оценка генеративных моделей

Оценка генеративных моделей представляет собой сложную задачу из-за многомерности распределений.

Оценка на основе вероятности.

- Логарифмическая функция правдоподобия
- Перплексия (для последовательностей)

Качество образцов.

- Визуальный осмотр (например, изображения)
- Оценка человеком (например, текста)

Меры дивергенции.

- Дивергенция Кульбака-Лейблера
- Дивергенция Дженсена-Шеннона

Показатели распределения.

- Оценка за начало обучения
- Расстояние начала Фреше (FID)

Проблемы.

- Компромисс между качеством выборки и ее разнообразием
- Сложность оценки вероятности в многомерном пространстве

Схлопывание режимов. Некоторые модели генерируют ограниченное разнообразие, фокусируясь на подмножестве возможных результатов.

Вывод: ни один отдельный показатель не может в полной мере отразить качество генеративной модели.

25.5 Объединяющая перспектива

Генеративное моделирование можно рассматривать с помощью нескольких взаимодополняющих подходов:

- Вероятностный подход: прямое моделирование $p(x)$.
- Скрытая переменная: введение скрытой структуры
- Энергетический подход: определение распределений посредством энергии

Основные проблемы.

- Многомерное моделирование
- Эффективный отбор проб
- Надежная оценка

Ключевая идея. Генеративные модели направлены на то, чтобы зафиксировать структуру распределения данных таким образом, чтобы обеспечить как понимание, так и синтез этих данных.

25.6 Прогноз

В этой главе были представлены основы генеративного моделирования:

- Оценка плотности и отбор проб,
- модели скрытых переменных,
- энергетические перспективы,
- Оценка генеративных моделей.

В следующих главах мы изучим конкретные классы генеративных моделей, включая вариационные автокодировщики, генеративные состязательные сети и диффузионные модели.

Основной принцип. Генеративное моделирование стремится не только к прогнозированию данных, но и к пониманию и воспроизведению их лежащей в основе структуры.

Глава 26

Обучение на основе вероятности с использованием скрытых переменных

26.1 Оценка максимального правдоподобия

Центральным принципом генеративного моделирования является оценка максимального правдоподобия (MLE). Цель состоит в выборе параметров модели, которые максимизируют вероятность наблюдаемых данных.

Цель. Даны данные $\{x_i\}_n$

мы максимизируем: $i=1, \dots, n$

$$\max_{\theta} \frac{1}{n} \sum_{i=1}^n \log p_{\theta}(x_i).$$

Интерпретация.

- Способствует тому, чтобы модель присваивала наблюдаемым данным высокую вероятность.
- Эквивалентно минимизации отрицательного логарифма правдоподобия

Связь с дивергенцией. Метод максимального правдоподобия минимизирует дивергенцию Кульбака-Лейблера:

$$KL(p_{\text{data}} \parallel p_{\theta}).$$

Градиент.

$$\theta \log p_{\theta}(x)$$

Для явных моделей это часто можно эффективно вычислить.

Insight. Метод максимального правдоподобия (MLE) предлагает принципиальный способ построения вероятностных моделей на основе данных.

26.2 Скрытые переменные и маргинализация

Модели со скрытыми переменными вводят скрытые переменные z для отражения лежащей в основе структуры.

Предельная вероятность.

$$p_{\theta}(x) = \int p_{\theta}(x, z) dz = \int p_{\theta}(x | z)p(z) dz.$$

Логарифмическая функция правдоподобия.

$$\log p_{\theta}(x) = \int \log p_{\theta}(x, z) dz.$$

Интерпретация.

- z объясняет изменчивость в x
- Модель интегрирует все возможные скрытые объяснения.

Сложность. Интеграл по z часто оказывается трудноразрешимой задачей, особенно в многомерном пространстве.

Апостериорное распределение.

$$p_{\theta}(z | x) = p_{\theta}(x) \frac{p_{\theta}(x, z)}{\int p_{\theta}(x, z) dz}.$$

Проницательность. Обучение требует как оценки предельной вероятности, так и рассуждений о скрытых переменных.

26.3 Неразрешимость и приближение

Точное вычисление предельной вероятности, как правило, не представляется возможным.

Источники трудностей.

- Многомерное латентное пространство
- Комплексные функции правдоподобия

Стратегии приближенного анализа.

- Методы, основанные на выборочном анализе (например, метод Монте-Карло)
- Детерминированные приближения
- Вариационные методы

Приближение методом Монте-Карло.

$$p_{\theta}(x) \approx \frac{1}{N} \sum_{i=1}^N p_{\theta}(x | z_i), z_i \sim p(z).$$

Ограничения.

- Оценки с высокой дисперсией
- Вычислительно затратно

Альтернативная точка зрения. Вместо прямого приближения интеграла мы аппроксимируем апостериорное распределение $p_{\theta}(z | x)$.

Проницательность. Приближение неизбежно в моделях со скрытыми переменными и формирует как теорию, так и практику.

26.4 Вариационные принципы

Вариационные методы предоставляют мощную основу для аппроксимации трудноразрешимых величин.

Вариационное распределение. Введем удобное для обработки распределение $q_{\phi}(z | x)$ для аппроксимации истинного апостериорного распределения.

Ключевая идентификация.

$$\log p_{\theta}(x) = \mathbb{E}_{q_{\phi}(z | x)} \log q_{\phi}(z | x) + \frac{\mathbb{E}_{q_{\phi}(z | x)} p_{\theta}(x, z)}{q_{\phi}(z | x)} + \text{KL}(q_{\phi}(z | x) \| p_{\theta}(z | x)).$$

Нижняя граница доказательств (ELBO).

$$L(\theta, \phi) = \mathbb{E}_{q_{\phi}(z | x)} [\log p_{\theta}(x, z) - \log q_{\phi}(z | x)].$$

Нижняя граница собственности.

$$L(\theta, \phi) \leq \log p_{\theta}(x).$$

Разложение.

$$L(\theta, \phi) = \mathbb{E}_{q_{\phi}(z | x)} [\log p_{\theta}(x | z)] - \text{KL}(q_{\phi}(z | x) \| p(z)).$$

Интерпретация.

- Первый термин: качество реконструкции
- Второй член: регуляризация по отношению к предыдущему члену

134 ГЛАВА 26. ОБУЧЕНИЕ НА ОСНОВЕ ВЕРОЯТНОСТИ С ИСПОЛЬЗОВАНИЕМ СКРЫТЫХ ПЕРЕМЕННЫХ

Оптимизация.

- Максимизировать ELBO относительно θ и ϕ
- Совместное обучение генеративных и выводных моделей

Проницательность. Вариационные методы превращают трудноразрешимые задачи вывода в задачу оптимизации.

26.5 Объединяющая перспектива

Обучение на основе вероятностей с использованием скрытых переменных включает в себя несколько взаимосвязанных идей:

- Метод максимального правдоподобия: обучение на основе наблюдаемых данных
- Скрытые переменные: моделирование скрытой структуры
- Аппроксимация: обработка трудноразрешимых интегралов
- Вариационный вывод: аппроксимация на основе оптимизации

Ключевой компромисс.

Точность аппроксимации против вычислительной разрешимости.

Ключевой вывод. Введение скрытых переменных повышает возможности моделирования, но требует применения методов приближительного вывода.

26.6 Прогноз

В этой главе было представлено обучение на основе функции правдоподобия с использованием скрытых переменных:

- оценка методом максимального правдоподобия,
- маргинализация скрытых переменных,
- проблемы, связанные с неразрешимостью
- Вариационные принципы и ELBO.

В следующей главе мы применим эти идеи к вариационным автокодировщикам, Практичный и широко используемый класс генеративных моделей.

Основной принцип. Сложные вероятностные модели требуют приближенного вывода, а вариационные методы предоставляют принципиальное и масштабируемое решение.

Глава 27

Вариационные автокодировщики

27.1 Скрытые представления

Вариационные автокодировщики (ВАЭ) — это генеративные модели, которые сочетают моделирование скрытых переменных с нейронными сетями.

Основная идея. Изучение низкоразмерного латентного представления z , которое отражает базовую структуру данных x .

Генеративная модель.

$$z \sim p(z), \quad x \sim p_\theta(x | z),$$

где $p(z)$ обычно выбирается как стандартная гауссова функция.

Скрытое пространство.

- Непрерывное низкоразмерное представление
- Кодировать семантическую структуру данных

Интерпретация.

- Близлежащие точки в латентном пространстве соответствуют аналогичным данным.
- Интерполяция в латентном пространстве приводит к значимым изменениям.

Цель. Изучить оба варианта:

- генеративная модель $p_\theta(x | z)$,
- модель вывода $q_\phi(z | x)$.

Проницаемость. Скрытые представления предоставляют структурированный способ моделирования сложных распределений данных.

27.2 Нижняя граница доказательств (ELBO)

VAE-модели обучаются путем максимизации нижней границы доказательств, введенной в предыдущей главе.

Цель ELBO.

$$\mathcal{L}(\theta, \phi) = \mathbb{E}_{q\phi(z|x)} [\log p\theta(x|z)] - \text{KL}(q\phi(z|x) \parallel p(z)).$$

Интерпретация.

- Первый термин: точность реконструкции
- Второй член: регуляризация по отношению к предыдущему члену

Компромисс.

- Качественная реконструкция по сравнению со структурированным латентным пространством

Приём перепараметризации. Для оптимизации математического ожидания мы выражаем z следующим образом:

$$z = \mu\phi(x) + \sigma\phi(x) \epsilon, \epsilon \sim \mathcal{N}(0, \mathbf{I}).$$

Выгода.

- Обеспечивает оптимизацию на основе градиента
- Уменьшает дисперсию оценок градиента

Анализ. Метод ELBO обеспечивает баланс между реконструкцией данных и скрытой структурой, составляя основу обучения VAE.

27.3 Архитектуры кодировщика-декодера

VAE-ы реализуются с использованием нейронных сетей в рамках архитектуры кодировщик-декодер.

Кодировщик.

$$q\phi(z|x)$$

сопоставляет входные данные с латентными параметрами ($\mu\phi(x)$, $\sigma\phi(x)$).

Декодер.

$$p\theta(x|z)$$

отображает скрытые переменные обратно в пространство данных.

Архитектура.

- Сеть кодировщика: сжимает данные в скрытое представление
- Сеть декодера: восстанавливает данные из скрытого кода

Конвейер обучения.

1. Закодировать x в (μ, σ)
2. Выборка z с использованием репараметризации
3. Расшифруйте z , чтобы восстановить x .
4. Вычислите ELBO и обновите параметры.

Выборка. Новые данные генерируются путем:

- Выборки $z \sim p(z)$
- Вычисления $x \sim p_\theta(x | z)$

Проницательность. Структура кодировщик-декодировщик объединяет вывод и генерацию в единую систему.

27.4 Практические соображения

Внедрение VAE предполагает принятие нескольких важных проектных решений.

Выбор вероятности.

- Гауссова функция правдоподобия для непрерывных данных
- Вероятность Бернулли для бинарных данных

Член дивергенции Кульбака-Лейблера. Часто имеет замкнутую форму, когда $q_\phi(z | x)$ и $p(z)$ являются гауссовыми.

Задний коллапс.

- Модель игнорирует скрытые переменные
- $q_\phi(z | x)$ приближается к $p(z)$

Стратегии смягчения последствий.

- Отжиг KL
- Более выразительные декодеры

Структура латентного пространства.

- Плавность обеспечивает возможность интерполяции
- Регуляризация способствует созданию осмысленных представлений.

Оценка.

- ELBO как цель обучения
- Качество и разнообразие выборки

Вывод: практическая эффективность зависит от баланса между реконструкцией, регуляризацией и возможностями модели.

27.5 Объединяющая перспектива

Вариационные автокодировщики объединяют несколько ключевых идей:

- Моделирование скрытых переменных
- Вариационный вывод
- Параметризация нейронных сетей

Основные компоненты.

- Кодировщик $q\phi(z | x)$
- Декодер $p\theta(x | z)$
- Цель ELBO

Ключевая идея. VAE-модели предоставляют масштабируемый метод для обучения вероятностных генеративных моделей со скрытой структурой.

27.6 Прогноз

В этой главе были представлены вариационные автокодировщики:

- скрытые представления,
- Оптимизация ELBO,
- Архитектуры кодировщика-декодера,
- Практические соображения.

В следующей главе мы изучим генеративные состязательные сети, которые рассматривают генеративное моделирование с другой точки зрения.

Основной принцип. Сочетание вероятностного моделирования с нейронными сетями позволяет создавать гибкие и масштабируемые генеративные модели.

Глава 28

Генеративный состязательный Сети

28.1 Состязательная формулировка

Генеративные состязательные сети (GAN) предлагают альтернативный подход к генеративному моделированию, основанный на игре между двумя моделями.

Основная идея. Две нейронные сети обучаются одновременно:

- Генератор G_θ : отображает шум $z \sim p(z)$ в пространство данных.
- Дискриминатор D_ϕ : отличает реальные данные от сгенерированных данных

Цель минимакса.

$$\min_{\theta} \max_{\phi} V_{\theta, \phi} = \mathbb{E}_{x \sim p_{\text{data}}} [\log D_{\phi}(x)] + \mathbb{E}_{z \sim p(z)} [\log(1 - D_{\phi}(G_{\theta}(z)))].$$

Интерпретация.

- Генератор пытается обмануть дискриминатор.
- Дискриминатор пытается отличить реальные образцы от поддельных.

Равновесие. В оптимальном состоянии генератор выдает образцы, неотличимые от реальных данных.

Неявное моделирование. GAN-сети определяют процедуру выборки без явного моделирования $p_{\theta}(x)$.

Проницательность. Обучение рассматривается как игра между двумя конкурирующими целями.

28.2 Минимизация дивергенции

GAN-сети можно рассматривать как сети, минимизирующие расхождение между распределениями.

Оптимальный дискриминатор. Для фиксированного генератора оптимальным дискриминатором является:

$$D^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_{\theta}(x)}.$$

Полученная целевая функция. Подставляя D^* , получаем:

$$J_S(p_{data}, p_{\theta}) = \min_{\theta} J_S(p_{data}, p_{\theta})$$

где J_S обозначает дивергенцию Йенсена–Шеннона.

Интерпретация.

- Обучение GAN неявно минимизирует расхождение между распределениями.
- Генератор улучшается по мере сближения распределений.

Ограничения.

- Расхождения могут вести себя некорректно, если области поддержки не перекрываются.

Insight. GANs связывают теоретико-игровое обучение со статистической минимизацией дивергенции.

28.3 Нестабильность тренировок

Обучение генеративно-сопоставительных сетей (GAN) часто представляет собой сложную задачу из-за состязательного характера целевой функции.

Невыпуклая-невогнутая оптимизация. Задача минимакса, как правило, не допускает устойчивой сходимости.

Сворачивание режима.

- Генератор выдает ограниченное количество различных выходных сигналов.
- Не удается зафиксировать полное распределение данных

Колебательная динамика.

- Генератор и дискриминатор могут не сойтись.
- Параметры могут циклически изменяться или расходиться.

Проблемы с градиентом.

- Исчезающие градиенты при слишком сильном дискриминаторе
- Нестабильные обновления из-за негативной обратной связи

Практические методы.

- Тщательная балансировка обновлений генератора и дискриминатора
- Сглаживание меток
- Штрафы за градиент

Проницательность. Обучение с использованием состязательных методов вводит динамику, принципиально отличающуюся от стандартной оптимизации.

28.4 Варианты и улучшения

Для решения проблем обучения и повышения производительности было предложено множество вариантов генеративно-состязательных сетей (GAN).

Wasserstein GAN (WGAN).

- Заменяет дивергенцию JS расстоянием Вассерштейна
- Улучшает стабильность и градиентное поведение

WGAN с градиентным штрафом.

- Обеспечивает соблюдение ограничения Липшица с помощью штрафных санкций за градиент.

Условные GAN-сети.

- Генерировать образцы, сформированные на основе меток или входных данных.

CycleGAN и перевод изображений.

- Изучение сопоставлений между доменами без парных данных

GAN-сети, основанные на стиле.

- Введение структурированных латентных пространств
- Обеспечивает точный контроль над создаваемыми изображениями

Анализ. Улучшение GAN-сетей часто включает в себя изменение целевой функции, архитектуры или процедуры обучения.

28.5 Объединяющая перспектива

GAN-сети предлагают принципиально иной подход к генеративному моделированию:

- Неявные модели: определяют выборку без явного указания плотности
- Соперническое обучение: конкурирующие две нейронные сети
- Минимизация дивергенции: выравнивание распределений

Основные компоненты.

- Генератор G_θ
- Дискриминатор D_ϕ
- Цель минимакса

Ключевая идея. Состязательное обучение предоставляет мощную, но сложную основу для генеративного моделирования.

28.6 Прогноз

В этой главе были представлены генеративно-состязательные сети:

- враждебная формулировка,
- интерпретация на основе расхождений,
- проблемы обучения,
- Ключевые варианты и улучшения.

В следующей главе мы изучим диффузионные модели, которые предлагают принципиально иной подход к генеративному моделированию, основанному на стохастических процессах.

Основной принцип. Различные генеративные платформы предлагают разные компромиссы между управляемостью, стабильностью и качеством образцов.

Глава 29

Нормализация потоков

29.1 Формула замены переменных

Нормализующие потоки представляют собой класс генеративных моделей, основанных на обратимых преобразованиях распределений вероятностей.

Основная идея. Начнем с простого базового распределения $z \sim p(z)$ и преобразуем его в комплексное распределение $x = f\theta(z)$.

Формула замены переменных. Если функция f обратима и дифференцируема, то

$$p\theta(x) = p(z) \det \frac{dz}{dx}, \quad \text{где } z = f^{-1}(x).$$

Эквивалентная форма.

$$\log p\theta(x) = \log p(z) + \log \det \frac{dz}{dx}.$$

Интерпретация.

- Плотность изменяется в зависимости от локального искажения объема.
- Определяющий фактор измеряет расширение или сжатие

Анализ. Нормализующие потоки преобразуют простые распределения в сложные, отслеживая при этом изменения плотности.

29.2 Обратимые преобразования

Разработка нормализующих потоков основана на построении обратимых преобразований, которые являются одновременно выразительными и вычислительно эффективными.

Требования.

- Функция f должна быть обратимой
- Определитель Якоби должен быть поддающимся вычислению.

Композиция преобразований.

$$x = f_L \circ f_{L-1} \circ \dots \circ f_1(z).$$

Факторизация Якоби.

$$\log \det \frac{dz}{dx} = \sum_{\ell=1}^L \log \det \frac{dh_{\ell}}{dh_{\ell-1}}.$$

Типы преобразований.

- Слои аффинной связи
- Авторегрессивные преобразования
- Потоки, сохраняющие объем

Компромисс.

- Выразительность против вычислительной эффективности

Проницательность. Тщательная разработка обратимых отображений позволяет создавать удобные и выразительные генеративные модели.

29.3 Точное вычисление вероятности

Ключевым преимуществом нормализации потоков является возможность вычисления точных вероятностей.

Вероятность.

$$\log p_{\theta}(x) = \log p(f^{-1}(x)) + \log \det \frac{df^{-1}}{dx}.$$

Сравнение с другими моделями.

- VAE: приближительная вероятность
- GAN: неявная вероятность
- Потоки: точная вероятность

Отбор проб.

- Образец $z \sim p(z)$

- Вычислите $x = f\theta(z)$

Умозаключение.

- Вычислите $z = f_{\theta}^{-1}(x)$
- Оцените плотность, используя изменение переменных.

Соображения эффективности.

- Определитель Якоби должен быть легко вычисляемым.
- Часто достигается с помощью треугольных или структурированных матриц.

Проницательность. Нормализующие потоки обеспечивают редкое сочетание точной функции правдоподобия и эффективной выборки.

29.4 Проектирование моделей

Разработка эффективных нормализующих потоков предполагает баланс между выразительностью и управляемостью.

Соединительные слои.

- Разделите переменные на две части
- Преобразовать одну часть, обусловленную другой.

Авторегрессивные потоки.

- Последовательное моделирование зависимостей
- Треугольный якобиан упрощает вычисление определителя

Преобразования методом наложения.

- Многослойность повышает выразительность
- Каждый слой вносит свой вклад в сложность преобразования

Обратимые нейронные сети.

- Архитектуры, разработанные для обеспечения обратимости

Ограничения.

- Архитектурные ограничения для обратимости
- Вычислительная стоимость обработки многомерных данных

Вывод: при проектировании моделей потоков необходимо найти баланс между гибкостью и вычислительными ограничениями.

29.5 Объединяющая перспектива

Нормализующие потоки объединяют несколько ключевых идей:

- Преобразования: отображение простых распределений на сложные.
- Обратимость: позволяет точно вычислить плотность.
- Композиция: построение выразительных моделей посредством слоев.

Основные компоненты.

- Базовое распределение $p(z)$
- Обратимое отображение f_θ
- Определитель Якоби

Ключевая идея. Тщательно разрабатывая обратимые преобразования, мы можем создавать выразительные генеративные модели с точными вероятностями.

29.6 Прогноз

В этой главе были представлены нормализующие потоки:

- замена переменных для преобразования плотности,
- обратимые преобразования,
- точное вычисление вероятности,
- Практическое проектирование моделей.

В следующей главе мы изучим диффузионные модели, которые приближаются к генеративным. моделирование с помощью стохастических процессов и итеративного уточнения.

Основной принцип. Структурированные преобразования распределений вероятностей обеспечивают мощную основу для генеративного моделирования.

Глава 30

Диффузионные модели: Интуиция

30.1 Процессы введения шума

Диффузионные модели — это генеративные модели, основанные на постепенном преобразовании данных в шум, а затем на обращении этого процесса вспять.

Прямой процесс. Мы определяем последовательность случайных величин $(x_0, x_1, \dots, x_T)$, где:

- $x_0 \sim p_{\text{data}}$
- x_T приближается к простому распределению (например, гауссовскому шуму)

Введение шума. На каждом шаге мы добавляем небольшой гауссовский шум:

$$x_t = \sqrt{\beta_t} x_{t-1} + \sqrt{1 - \beta_t} \epsilon_t, \epsilon_t \sim N(0, I).$$

Марковская структура.

- Каждый шаг зависит только от предыдущего состояния.
- Процесс представляет собой цепь Маркова.

Эффект.

- Постепенно разрушает структуру данных
- Преобразует распределение данных в шум

Проницаемость. Прямой процесс определяет контролируемый способ сопоставления сложных распределений данных с простыми.

30.2 Перспектива шумоподавления

В процессе генерации обучаются обращению процесса введения шума.

Обратный процесс. Наша цель — смоделировать:

$$p_{\theta}(x_{t-1} | x_t),$$

который устраняет шум шаг за шагом.

Интерпретация шумоподавления.

- На каждом этапе прогнозируется менее зашумленная версия данных.
- Модель учится восстанавливать структуру из шума

Цель обучения. Модель обучается прогнозировать шум, добавляемый на каждом шаге:

$$\epsilon_{\theta}(x_t, t) \approx \epsilon_t.$$

Упрощенный убыток.

$$\mathbb{E}_{t, x_0, \epsilon} \|\epsilon - \epsilon_{\theta}(x_t, t)\|^2.$$

Отбор проб.

- Начинаем с шума $x_T \sim N(0, I)$
- Итеративно выполняйте шумоподавление для получения x_0

Проницательность. Генерация достигается путем многократного подавления случайного шума в структурированных данных.

30.3 Оценка на основе баллов

Диффузионные модели также можно интерпретировать с помощью функций оценки.

Функция оценки.

$$s(x) = -x \log p(x).$$

Основная идея. Вместо того чтобы моделировать $p(x)$ напрямую, нужно узнать его оценку.

Связь с распространением.

- Функция шумоподавления аппроксимирует оценку зашумленных распределений.
- Каждый шаг соответствует оценке $-x \log p_t(x)$

Динамика Ланжевена.

$$x_{t+1} = x_t + \eta \left(-x_t \log p(x_t) + 2\eta \xi_t \right),$$

где ξ_t — гауссовский шум.

Интерпретация.

- Образцы формируются путем следования градиентам логарифма плотности.
- Шум обеспечивает исследование распределения

Анализ. Диффузионные модели связывают шумоподавление с градиентным сэмплингом из вероятностных распределений.

30.4 Концептуальные связи

Диффузионные модели объединяют несколько идей из теории вероятностей, оптимизации и физики.

Связи с другими моделями.

- Модели скрытых переменных: вводят промежуточные зашумленные состояния.
- Модели, основанные на энергии: связаны с функциями оценки
- Марковские процессы: последовательные преобразования

Ограничение непрерывного времени.

- Дискретные шаги аппроксимируют стохастические дифференциальные уравнения
- Приводит к непрерывному процессу диффузии

Геометрия данных.

- Шум сглаживает распределение данных
- Шумоподавление восстанавливает структуру

Сравнение с другими генеративными моделями.

- VAE: вероятностное моделирование скрытых переменных
- GAN: состязательное обучение
- Потоки: обратимые преобразования
- Диффузия: итеративное уточнение

Анализ. Диффузионные модели сочетают вероятностное моделирование с итеративным шумоподавлением и выборкой на основе градиента.

30.5 Объединяющая перспектива

Диффузионные модели можно рассматривать с разных точек зрения:

- Вероятностный подход: моделирование распределений посредством шумовых процессов
- Алгоритмический: итеративные процедуры шумоподавления
- Геометрический: следование градиентам в пространстве данных

Основные компоненты.

- Процесс прямого шума
- Процесс обратного шумоподавления
- Обученный предсказатель оценок или шума

Ключевая идея. Сложные распределения данных можно получить, обратив простой стохастический процесс.

30.6 Прогноз

В этой главе были представлены модели диффузии с интуитивной точки зрения:

- процессы введения шума,
- шумоподавление как процесс генерации,
- интерпретации на основе баллов,
- концептуальные связи с другими моделями.

В следующей главе мы более подробно изучим модели диффузии, включая их вероятностную формулировку и цели обучения.

Основной принцип. Сложную структуру можно изучить, постепенно уточняя простой шум посредством изученных преобразований.

Глава 31

Диффузионные модели: Математические основы

31.1 Прямые и обратные процессы

Диффузионные модели строятся на основе пары стохастических процессов: прямого (шумящего) процесса и обратного (шумящего) процесса.

Прямой процесс. Мы определяем цепь Маркова $(x_0, x_1, \dots, x_T)$ такую, что:

$$q(x_t | x_{t-1}) = N(x_t; \mu_t, \sigma_t^2),$$

где $\{\sigma_t\}_{t=1}^T$ — это график отклонений.

Выражение в замкнутой форме. Путем компоновки гауссовых переходов получаем:

$$q(x_t | x_0) = N(x_t; \mu_t, \sigma_t^2),$$

где $\mu_t = \mu_0 + \sum_{s=1}^t \sigma_s$ и $\sigma_t^2 = \sigma_0^2 + \sum_{s=1}^t \sigma_s^2$.

Интерпретация.

- По мере увеличения t , шум в x_t становится все более сильным.
- При больших значениях T , $x_T \sim N(0, I)$

Обратный процесс. Мы стремимся смоделировать:

$$p_\theta(x_{t-1} | x_t),$$

которое также является гауссовым при соответствующих предположениях:

$$p_\theta(x_{t-1} | x_t) = N(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)).$$

Цель обучения. Параметры θ подбираются таким образом, чтобы аппроксимировать истинные обратные переходы.

Проницаемость. Прямой процесс является фиксированным и простым, тогда как обратный процесс является обучаемым.

31.2 Сопоставление результатов

Альтернативная формулировка моделей диффузии основана на сопоставлении оценок.

Функция оценки.

$$s_t(x) = -x \log p_t(x),$$

где $p_t(x)$ — распределение x_t .

Цель. Вместо непосредственного моделирования $p_t(x)$ мы обучаемся $s_t(x)$.

Сопоставление оценок шумоподавления. Для гауссовых возмущений оценка удовлетворяет следующему условию:

$$s_t(x_t) = -\frac{1}{\alpha^{-1} t} (x_t - \bar{x}_t | x_0).$$

Формулировка задачи обучения. Мы обучаем нейронную сеть $s_\theta(x_t, t)$ для аппроксимации оценки:

$$\mathbb{E}_{t, x_0, \epsilon} [s_\theta(x_t, t) - x_t \log q(x_t | x_0)]^2.$$

Эквивалентность. Данная задача эквивалентна прогнозированию шума ϵ .

Анализ. Метод сопоставления оценок предоставляет принципиальный способ изучения градиентов логарифмических плотностей.

31.3 Динамика Ланжевена

Выборка из распределения может быть осуществлена с помощью динамики Ланжевена.

Обновление информации о Ланжевене.

$$x_{k+1} = x_k + \eta [-x_k \log p(x_k) + 2\eta \xi_k], \quad \xi_k \sim \mathcal{N}(0, I).$$

Интерпретация.

- Градиентный член направляет образцы в области с высокой плотностью.
- Шумовой термин обеспечивает исследование

Связь с диффузионными моделями.

- Полученный результат аппроксимирует $-x \log p(x)$
- Выборка использует обновления на основе оценок.

Предел непрерывного времени. Динамика Ланжевена соответствует стохастическому дифференциальному уравнению:

$$dx_t = -x_t \log p(x_t) dt + \sqrt{2} dW_t,$$

где W_t — броуновское движение.

Вывод. Диффузионную выборку можно рассматривать как приближительную динамику Ланжевена с использованием обученных оценок.

31.4 Алгоритмы выборки

Из математической формулировки моделей диффузии вытекает несколько процедур отбора проб.

Выборочное исследование предков.

- Начните с $x_T \sim N(0, I)$

- Итеративная выборка:

$$x_{t-1} \sim p_\theta(x_{t-1} | x_t)$$

Детерминированные варианты.

- Используйте детерминированные обновления вместо выборки.
- Снижение вариативности и ускорение генерации

Выборка на основе баллов.

- Использовать дискретизированную динамику Ланжевена
- Обновление с использованием функции обученной оценки

Компромиссы.

- Больше шагов — образцы более высокого качества
- Меньше шагов — быстрее генерация

Численные соображения.

- Выбор размера шага
- Стабильность обновлений

Анализ. Выборка — это итеративный процесс уточнения, основанный на изученных градиентах.

31.5 Объединяющая перспектива

Диффузионные модели можно понять с помощью различных математических подходов:

- Марковские процессы: прямые и обратные цепи
- Сопоставление оценок: обучение градиентов логарифмической плотности
- Стохастическая динамика: уравнения Ланжевена

Основные компоненты.

154 ГЛАВА 31. МОДЕЛИ ДИФфуЗИИ: МАТЕМАТИЧЕСКИЕ ОСНОВЫ

- Прямой шумовой процесс $q(x_t | x_{t-1})$
- Обратный процесс $p\theta(x_{t-1} | x_t)$
- Функция оценки $s\theta(x_t, t)$

Ключевая идея. Диффузионные модели объединяют вероятностное моделирование, стохастические процессы и выборку на основе градиента.

31.6 Прогноз

В этой главе были изложены математические основы диффузионных моделей:

- прямые и обратные стохастические процессы,
- формулы сопоставления оценок,
- Динамика Ланжевена,
- алгоритмы выборки.

В следующей главе мы рассмотрим современные усовершенствования и практическое применение. позиционирования моделей диффузии.

Основной принцип. Сложные распределения можно отбирать путем следования обученным градиентам в рамках стохастической динамической системы.

Глава 32

Крупномасштабный генеративный Модели

32.1 Диффузия на практике (например, стабильная диффузия)

Диффузионные модели стали одним из доминирующих подходов к крупномасштабному генеративному моделированию, особенно в синтезе изображений.

От теории к практике. Практические системы распространения расширяют базовую структуру за счет архитектурных и алгоритмических улучшений:

- Архитектуры U-Net для шумоподавления
- Механизмы обусловливания (например, векторные представления текста)
- Эффективные стратегии отбора проб

Латентная диффузия. Вместо работы непосредственно в пиксельном пространстве, модели работают в латентном пространстве меньшей размерности:

- Кодирование изображений в скрытые представления
- Провести диффузию в латентном пространстве
- Декодировать обратно в пиксельное пространство

Преимущества.

- Снижение вычислительных затрат
- Улучшенная масштабируемость

Условные условия. Генеративные модели могут управляться дополнительными входными данными:

- Текстовые подсказки
- Метки классов
- Другие методы

Анализ. Современные диффузионные системы сочетают вероятностное моделирование с мощными нейронными архитектурами и механизмами обусловливания.

32.2 Большие языковые модели

Большие языковые модели (LLM) — это генеративные модели для последовательностей, как правило, основанные на архитектурах трансформеров.

Авторегрессионное моделирование. Модели с линейной регрессией моделируют совместное распределение последовательности:

$$p(x_1, \dots, x_T) = \prod_{t=1}^T p(x_t | x_1, \dots, x_{t-1}).$$

Цель обучения.

$$\max_{\theta} \mathbb{E} \sum_{t=1}^T \log p_{\theta}(x_t | x_{<t}).$$

Трансформаторная магистраль.

- Слои самовнимания
- Прямые нейронные сети
- Остаточные соединения и нормализация

Возможности.

- Генерация текста
- Ответы на вопросы
- Генерация кода
- Задания на логическое мышление

Предварительное обучение и тонкая настройка.

- Предварительно обучено на больших корпусах данных
- Адаптировано для выполнения последующих задач

Анализ. Модели LLM используют масштаб и архитектуру для моделирования сложных последовательных зависимостей.

32.3 Законы масштабирования

Эмпирические исследования выявляют систематические взаимосвязи между эффективностью модели и ее масштабом.

Масштабные коэффициенты.

- Размер модели (количество параметров)
- Размер набора данных
- Вычислительные ресурсы

Эмпирический закон.

$$\text{Ошибка} \propto N^{-\alpha},$$

где N обозначает масштаб, а $\alpha > 0$.

Подразумеваемое.

- Более крупные модели, как правило, демонстрируют лучшие результаты.
- Прирост прибыли уменьшается с увеличением масштаба.

Компромиссы, оптимальные с точки зрения вычислений.

- Сбалансируйте размер модели и размер набора данных.
- Эффективное распределение вычислительных ресурсов

Возникающее поведение.

- Новые возможности появляются в больших масштабах
- Нелегко предсказать на основе небольших моделей

Анализ. Масштабирование является фундаментальным фактором, определяющим производительность современных систем машинного обучения.

32.4 Технические аспекты

Для обучения и развертывания крупномасштабных генеративных моделей требуется тщательная разработка.

Дистанционное обучение.

- Параллелизм данных
- Параллелизм моделей
- Параллелизм конвейера

Аппаратное ускорение.

- Графические процессоры и специализированные ускорители
- Ограничения по памяти и пропускной способности

Проблемы оптимизации.

- Большие объемы партий
- Планирование скорости обучения
- Стабильность в масштабе

Соображения относительно выводов.

- Задержка против пропускной способности
- Сжатие и квантование модели

Вопросы, касающиеся данных.

- Качество и разнообразие данных
- Предварительная обработка и фильтрация

Безопасность и соосность.

- Управление выходными данными модели
- Смягчение вредного или предвзятого поведения

Проницательность. Инженерное дело играет решающую роль в преобразовании теоретических моделей в практические системы.

32.5 Объединяющая перспектива

Крупномасштабные генеративные модели объединяют множество измерений:

- Моделирование: вероятностные и нейронные архитектуры
- Вычисления: крупномасштабная оптимизация
- Данные: огромные и разнообразные наборы данных
- Системы: распределенные и эффективные реализации

Основная идея. Производительность возникает в результате взаимодействия моделей, данных и вычислений.

Ключевая мысль. Современные генеративные модели определяются не только своей математико-математической формулировкой, но и масштабом и системным проектированием.

32.6 Прогноз

В этой главе рассматривались крупномасштабные генеративные модели:

- Модели диффузии на практике,
- большие языковые модели,
- законы масштабирования,
- инженерные соображения.

На этом завершается наше исследование современных методов генеративного моделирования.

Основной принцип. Достижения в области машинного обучения являются результатом сочетания теории, архитектуры, данных и вычислительных мощностей в масштабе предприятия.

Глава 33

Обобщение в глубоком Обучении

33.1 Перепараметризация

Классическая теория обучения предполагает, что модели со слишком большим количеством параметров должны переобучаться. Однако современное глубокое обучение часто работает в режимах с чрезмерно большим количеством параметров, когда число параметров превышает число обучающих выборок.

Наблюдение.

- Глубокие нейронные сети могут точно соответствовать обучающим данным.
- Однако они часто хорошо распространяются на ранее неизвестные данные.

Режим интерполяции. В моделях с избыточным количеством параметров часто удается достичь нулевой ошибки обучения:

$$R^{\text{н}}(\theta) = 0.$$

Существует множество решений. Есть много конфигураций параметров, позволяющих интерполировать данные.

Ключевой вопрос: почему одни из этих решений хорошо подходят для обобщения, а другие — нет?

Эффективная сложность.

- Количество параметров само по себе не определяет обобщающую способность.
- Структура и динамика тренировок играют важную роль.

Прозрение. Избыточная параметризация меняет природу обучения: вместо выбора между моделями мы выбираем между решениями.

33.2 Скрытая предвзятость градиентных методов

Алгоритмы оптимизации не рассматривают все возможные решения в равной степени. Вместо этого они проявляют скрытую предвзятость в отношении определенных решений.

Скрытая предвзятость. Тенденция метода оптимизации отдавать предпочтение определенным решениям среди множества тех, которые обеспечивают низкую ошибку обучения.

Пример (линейная регрессия). В недоопределенных системах градиентный спуск сходится к решению с минимальной нормой:

$$\min \|w\|^2 \text{ при условии } Xw = y.$$

Глубокие сети.

- Скрытая предвзятость — более сложная проблема.
- Зависит от архитектуры, инициализации и оптимизатора.

Роль SGD.

- Шум в стохастических градиентах влияет на траектории
- Может способствовать более пологим минимумам

Плоские и острые минимумы.

- Плоские минимумы: более устойчивы к возмущениям
- Острые минимумы: более высокая чувствительность, но потенциально худшая обобщающая способность.

Проницательность. Обобщающая способность формируется не только самой моделью, но и способом её оптимизации.

33.3 Феномен двойного спуска

Классическая модель компромисса между смещением и дисперсией предсказывает, что увеличение сложности модели приводит к переобучению. Однако современные наблюдения показывают более тонкий характер этого явления.

Двойной спуск.

- Ошибка тестирования сначала уменьшается, затем увеличивается, а затем снова уменьшается по мере роста размера модели.

Фазы.

- Недостаточно параметризованный режим: классическое поведение
- Порог интерполяции: пиковая ошибка тестирования

- Режим избыточной параметризации: улучшенная обобщающая способность

Интерпретация.

- Более крупные модели могут находить лучшие решения для интерполяции.
- Оптимизация играет ключевую роль

Эмпирические данные.

- Наблюдается в нейронных сетях, методах ядра и других моделях.

Вывод: взаимосвязь между сложностью модели и ее обобщаемостью гораздо глубже, чем предполагает классическая теория.

33.4 Открытые вопросы

Несмотря на значительный прогресс, теория обобщения в глубоком обучении остается неполной.

Основные проблемы.

- Понимание того, почему модели с избыточным количеством параметров обеспечивают обобщение.
- Характеристика скрытых предубеждений в глубоких нейронных сетях
- Объяснение роли динамики оптимизации

Теоретические направления.

- Меры сложности, выходящие за рамки подсчета параметров
- Границы обобщения, основанные на устойчивости
- Информационно-теоретические подходы

Связи с другими областями.

- Статистическая физика (энергетические ландшафты)
- Динамические системы (динамика обучения)
- Теория информации (сжатие и представление)

Практические последствия.

- Проектирование архитектурных сооружений
- Выбор алгоритмов оптимизации
- Стратегии регуляризации

Проницательность. Понимание процесса обобщения в глубоком обучении — это активно развивающаяся область исследований, объединяющая теорию и практику.

33.5 Объединяющая перспектива

Обобщение в глубоком обучении возникает в результате взаимодействия множества факторов:

- Модельная емкость: выразительность нейронных сетей
- Оптимизация: неявная предвзятость алгоритмов обучения
- Данные: структура и распределение входных данных

Основная идея. Обобщение определяется не одним фактором, а динамикой всего процесса обучения.

Ключевая идея. Современное глубокое обучение бросает вызов классическим представлениям, требуя новых теоретических основ.

33.6 Прогноз

В этой главе рассматривалась способность к обобщению в глубоком обучении:

- избыточная параметризация и интерполяция,
- неявная предвзятость методов оптимизации,
- феномен двойного спуска,
- Открытые теоретические вопросы.

На этом завершается наше исследование теоретических и практических основ современного машинного обучения и глубокого обучения.

Основной принцип. Понимание обобщения требует интеграции идей из области оптимизации, теории вероятностей и обучения представлениям.

Глава 34

Геометрия и динамика Обучение

34.1 Ландшафты потерь

Обучение нейронной сети можно рассматривать как перемещение по многомерному ландшафту функции потерь.

Функция потерь. Заданные параметры $\theta \in \mathbb{R}^D$, функция потерь определяет следующее:

$$L(\theta) : \mathbb{R}^D \rightarrow \mathbb{R}.$$

Интерпретация ландшафта.

- Точки соответствуют конфигурациям параметров.
- Высота соответствует значению убытка

Ключевые моменты.

- Локальные минимумы: $L(\theta) = 0$, положительная кривизна
- Седловые точки: смешанные направления кривизны

Многомерная геометрия.

- Седловые точки встречаются чаще, чем плохие локальные минимумы.
- Многие направления практически плоские

Плоские и острые минимумы.

- Плоские минимумы: устойчивы к возмущениям

- Четкие минимумы: чувствительны к изменениям параметров

Визуализация (концептуальная). Низкоразмерные проекции позволяют увидеть долины, хребты и плато.

Вывод: геометрия ландшафта функции потерь оказывает сильное влияние на оптимизацию и обобщение.

34.2 Нейронное касательное ядро (интуиция)

Нейронное касательное ядро (НТК) обеспечивает линейаризованное представление процесса обучения нейронной сети.

Линеаризация. Вблизи начального значения θ_0 сеть можно аппроксимировать следующим образом:

$$f_{\theta}(x) \approx f_{\theta_0}(x) + \nabla f_{\theta_0}(x) (\theta - \theta_0).$$

Нейронное касательное ядро.

$$K(x, x') = \nabla f_{\theta_0}(x) \nabla f_{\theta_0}(x')^T.$$

Интерпретация.

- Определяет ядро, создаваемое сетью при инициализации.
- Обучение аналогично ядерной регрессии с ядром K .

Предел бесконечной ширины.

- НТК становится детерминированным
- Динамика тренировок становится линейной

Анализ. НТК объединяет глубокое обучение с классическими методами ядра.

34.3 Непрерывный временной анализ процесса обучения

Оптимизацию на основе градиента можно рассматривать как динамическую систему непрерывного времени.

Обновление градиентного спуска.

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t).$$

Предел непрерывного времени. При $\eta \rightarrow 0$ получаем дифференциальное уравнение:

$$\frac{d\theta(t)}{dt} = -\nabla L(\theta(t)).$$

Градиентный поток.

- Параметры изменяются в направлении наибольшего спуска
- Траектории следуют по кривым в пространстве параметров.

Интерпретация энергии. Потери уменьшаются вдоль траекторий:

$$\frac{d}{dt}L(\theta(t)) = -\|\nabla L(\theta(t))\|^2 \leq 0.$$

Расширение на стохастическую динамику. Стохастический градиентный спуск вносит шум:

$$d\theta(t) = -\nabla L(\theta(t))dt + \Sigma^{1/2} dW_t, \text{ где } W_t \text{ —}$$

броуновское движение.

Проницательность. Обучение можно рассматривать как непрерывный поток, формируемый как градиентами, так и шумом.

34.4 Перспектива динамических систем

Обучение нейронных сетей и освоение представлений можно рассматривать с точки зрения динамических систем.

Динамика параметров.

- Эволюция $\theta(t)$ в процессе оптимизации

Динамика представления.

- Эволюция характеристик $f_{\theta(t)}(x)$ в процессе обучения

Стабильность.

- Устойчивые неподвижные точки соответствуют минимумам
- Устойчивость зависит от кривизны и шума.

Аттракторы.

- Оптимизация может сходиться к определенным областям пространства параметров.

Связь с остаточными сетями. Глубокие сети напоминают дискретизированные динамические системы.

Эволюция функций.

- Начальный этап обучения: быстрые изменения характеристик
- Более поздние этапы: тонкая настройка

Проницательность. Обучение — это динамический процесс, в котором со временем изменяются как параметры, так и способы представления информации.

34.5 Объединяющая перспектива

Геометрия и динамика обучения обеспечивают единую структуру:

- Геометрия: структура ландшафта потерь
- Динамика: траектории оптимизации
- Линеаризация: аппроксимация NTK
- Стохастичность: роль шума в обучении

Основная идея. Понимание процесса обучения требует анализа как структуры цели, так и динамики оптимизации.

Ключевая идея. Современное глубокое обучение находится на стыке геометрии, теории вероятностей и динамических систем.

34.6 Прогноз

В этой главе рассматривались геометрия и динамика обучения:

- утрата ландшафтов и их структуры,
- перспектива нейронного касательного ядра,
- Непрерывный временной подход к оптимизации,
- Интерпретация динамических систем.

Эти точки зрения обеспечивают более глубокое теоретическое понимание того, как происходит обучение. Это явление наблюдается в современных системах машинного обучения.

Основной принцип. Обучение — это одновременно геометрическая задача и динамический процесс, формируемый взаимодействием между структурой модели и оптимизацией.

Глава 35

Практическое проектирование систем

35.1 Конвейеры данных

В современных системах машинного обучения данные так же важны, как и модели. Эффективное проектирование системы начинается с надежных и масштабируемых конвейеров обработки данных.

Конвейер обработки данных. Конвейер обработки данных преобразует необработанные данные в форму, подходящую для обучения и оценки.

Этапы.

- Сбор данных
- Очистка и предварительная обработка
- Извлечение или кодирование признаков
- Хранение и доступ

Предварительная обработка.

- Нормализация и масштабирование
- Обработка пропущенных значений
- Расширение данных

Потоковая обработка против пакетной обработки.

- Пакетные конвейеры обрабатывают данные большими блоками.
- Потоковые конвейеры обрабатывают данные непрерывно.

Качество данных.

- Последовательность и правильность

- Учет шума и смещения

Вывод: качество системы машинного обучения в корне зависит от качества используемых данных.

35.2 Рабочие процессы обучения

Для обучения современных моделей необходимы скоординированные рабочие процессы, которые управляют данными, вычислениями и экспериментами.

Цикл обучения.

1. Загрузка пакета данных
2. Вычисление прогнозов
3. Оцените ущерб.
4. Вычислите градиенты
5. Обновление параметров

Управление экспериментами.

- Отслеживание гиперпараметров
- Записывать метрики и журналы.
- Сравните различные конфигурации моделей

Настройка гиперпараметров.

- Поиск по сетке, случайный поиск
- Адаптивные методы (например, байесовская оптимизация)

Дистанционное обучение.

- Параллельная обработка данных на нескольких устройствах
- Параллельный режим работы с моделями больших размеров

Создание контрольных точек.

- Сохранение промежуточных состояний модели
- Обеспечивает возможность восстановления и экспериментирования

Проницательность. Грамотно разработанные рабочие процессы обеспечивают эффективное проведение экспериментов и надежную разработку моделей.

35.3 Отладка и диагностика

Обучение моделей машинного обучения часто включает в себя диагностику проблем, возникающих в процессе оптимизации.

Распространенные проблемы.

- Обучение не приводит к сходимости
- Переобучение или недообучение
- Численная неустойчивость

Диагностические инструменты.

- Кривые обучения и валидации
- Градиентные нормы
- Статистика активации

Проверка на адекватность.

- Проверить снижение потерь на небольших наборах данных
- Проверьте правильность градиента
- Обеспечьте согласованность меток и данных.

Визуализация.

- Отслеживание показателей во времени
- Проверка промежуточных результатов

Систематическая отладка.

- Изолировать компоненты
- Упростите модель
- Постепенно увеличивайте сложность

Важный момент. Отладка — важнейший навык в машинном обучении, требующий как теоретического понимания, так и практического опыта.

35.4 Воспроизводимость

Воспроизводимость имеет решающее значение для надежности научных и инженерных результатов.

Определение. Результат считается воспроизводимым, если его можно последовательно получить в одинаковых условиях.

Источники изменчивости.

- Случайная инициализация
- Перетасовка данных
- Различия в аппаратном обеспечении и численных параметрах

Передовые методы.

- Исправлена ошибка с генератором случайных чисел
- Запись конфигураций и гиперпараметров
- Версии наборов данных и кода

Отслеживание эксперимента.

- Систематически сохраняйте результаты
- Вести журналы экспериментов

Детерминизм против результативности.

- Полностью детерминированное выполнение может снизить производительность
- Компромисс между воспроизводимостью и эффективностью

Проницательность. Воспроизводимость гарантирует надежность результатов и возможность их дальнейшего развития.

35.5 Объединяющая перспектива

Практическое проектирование систем объединяет множество компонентов:

- Данные: конвейеры обработки и предварительная обработка
- Вычисления: рабочие процессы обучения
- Диагностика: инструменты отладки
- Надежность: методы обеспечения воспроизводимости

Основная идея. Для успешной работы систем машинного обучения необходима тщательная координация данных, моделей и инфраструктуры.

Ключевой вывод. Практическая эффективность зависит не только от алгоритмов, но и от систем, которые их поддерживают.

35.6 Прогноз

В этой главе рассматривались практические аспекты систем машинного обучения:

- конвейеры обработки данных,
- рабочие процессы обучения,
- отладка и диагностика,
- Воспроизводимость.

На этом книга завершается.

Последний руководящий принцип. Машинное обучение — это одновременно математическая дисциплина и инженерная практика, требующая понимания теории, данных и систем.

Глава 36

Ограничения и будущее Направления

36.1 Устойчивость и неопределенность

Современные системы машинного обучения демонстрируют впечатляющие результаты, однако они по-прежнему чувствительны к возмущениям и неопределенности.

Устойчивость. Модель считается устойчивой, если её прогнозы остаются стабильными при небольших изменениях входных данных:

$$x \rightarrow x' \text{ мало } \Rightarrow f(x) \approx f(x').$$

Примеры, противоречащие друг другу.

- Тщательно продуманные возмущения могут существенно изменить прогнозы.
- Часто незаметны для человека

Смещение распределения.

- Распределения обучающей и тестовой выборки могут отличаться.
- Производительность может снижаться в новых условиях.

Оценка неопределенности.

- Алеаторная неопределенность: присущий данным шум.
- Эпистемическая неопределенность: неопределенность, обусловленная ограниченными знаниями.

Подходы.

- Байесовские методы

- Ансамблевые модели
- Методы калибровки

Вывод: надежные системы искусственного интеллекта должны не только делать точные прогнозы, но и количественно оценивать и управлять неопределенностью.

36.2 Виды сбоев современного ИИ

Несмотря на убедительные эмпирические результаты, современные модели демонстрируют систематические сбои.

Распространенные проблемы.

- Чрезмерная самоуверенность в неверных прогнозах
- Чувствительность к ложным корреляциям
- Недостаточная устойчивость к редким или выходящим за рамки распределения входным данным.

Зависимость от данных.

- Модели наследуют смещения, присутствующие в обучающих данных.
- Производительность отражает распределение данных, а не истинное понимание.

Пределы обобщения.

- Сложности с экстраполяцией результатов за пределы тренировочного режима.
- Трудности с композиционным рассуждением

Ограничения масштабируемости.

- Увеличение размера не решает всех проблем
- Некоторые сбои сохраняются даже в больших масштабах.

Важный вывод. Понимание причин отказов имеет решающее значение для повышения надежности и определения направлений будущих исследований.

36.3 Интерпретируемость

Интерпретируемость направлена на понимание того, как и почему модели делают прогнозы.

Мотивация.

- Доверие и прозрачность
- Отладка и улучшение модели

- Научное понимание

Типы интерпретируемости.

- Присвоение признаков: важность входных данных
- Анализ представления: структура изученных признаков
- Упрощение модели: аппроксимация сложных моделей более простыми.

Проблемы.

- Многомерные представления
- Нелинейные взаимодействия
- Отсутствие однозначных объяснений

Компромиссы.

- Точность против интерпретируемости
- Простота против точности

Проницательность. Интерпретируемость — это не одно свойство, а совокупность подходов к пониманию сложных моделей.

36.4 Направления будущих исследований

Будущее машинного обучения лежит на стыке теории, данных и систем.

Теоретические направления.

- Понимание обобщения в глубоком обучении
- Характеристика динамики оптимизации
- Соединение дискретных и непрерывных моделей

Направления моделирования.

- Мультимодальные модели, объединяющие зрение, язык и действие
- Более эффективные и масштабируемые архитектуры
- Модели с улучшенными возможностями рассуждения

Данные и парадигмы обучения.

- Самостоятельное и неконтролируемое обучение

- Обучение на основе ограниченных или зашумленных данных

- Непрерывное обучение на протяжении всей жизни

Системы и эффективность.

- Снижение вычислительных и энергетических затрат

- Эффективное обучение и вывод результатов

Безопасность и соосность.

- Обеспечение надежного и контролируемого поведения

- Смягчение непредвиденных последствий

Междисциплинарные связи.

- Нейробиология и когнитивная наука

- Физика и динамические системы

- Математика и статистика

Проницательность. Дальнейший прогресс потребует интеграции результатов исследований из разных дисциплин и баланса между теорией и эмпирическими достижениями.

36.5 Заключительная точка зрения

В этой книге машинное обучение и глубокое обучение рассмотрены как с математической, так и с практической точек зрения.

Основные темы.

- Обучение как аппроксимация и оптимизация функций
- Обучение представлений с помощью глубоких архитектур
- Вероятностное моделирование и генеративные процессы
- Вопросы масштабируемости и системного уровня

Объединяющая идея. Системы обучения формируются в результате взаимодействия данных, моделей и алгоритмов.

В заключение отметим: искусственный интеллект — это развивающаяся область, где теория и практика постоянно взаимно обогащают и бросают вызов друг другу.

36.6 Заключительные замечания

Машинное обучение находится на уникальном пересечении дисциплин, сочетая строгую математику с практической инженерией.

Перспектива.

- Новые теоретические концепции углубят наше понимание
- Новые архитектуры и системы расширят возможности.
- Ответственное развитие окажет реальное влияние на окружающий мир.

Главный руководящий принцип. Будущее ИИ зависит не только от повышения производительности, но и от понимания, надежности и ответственного использования.